SKRIPSI

OPTIMISASI PORTOFOLIO SAHAM MENGGUNAKAN *KOMODO MLIPIR ALGORITHM* BERDASARKAN KLASTER *K-MEANS*

(*STOCK PORTFOLIO OPTIMIZATION USING KOMODO MLIPIR ALGORITHM BASED ON K-MEANS CLUSTERING*)



BRYAN FLORENTINO LEO
21/473767/PA/20429

PROGRAM SARJANA PROGRAM STUDI STATISTIKA
DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA
2025

SKRIPSI

OPTIMISASI PORTOFOLIO SAHAM MENGGUNAKAN *KOMODO MLIPIR ALGORITHM* BERDASARKAN KLASTER *K-MEANS*

(*STOCK PORTFOLIO OPTIMIZATION USING KOMODO MLIPIR ALGORITHM BASED ON K-MEANS CLUSTERING*)

Diajukan untuk memenuhi salah satu syarat memperoleh derajat
Sarjana Statistika Program Sarjana Program Studi Statistika



BRYAN FLORENTINO LEO
21/473767/PA/20429

PROGRAM SARJANA PROGRAM STUDI STATISTIKA
DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA
2025

HALAMAN PENGESAHAN

SKRIPSI

OPTIMISASI PORTOFOLIO SAHAM MENGGUNAKAN *KOMODO MLIPIR ALGORITHM* BERDASARKAN KLASTER *K-MEANS*

Telah dipersiapkan dan disusun oleh

BRYAN FLORENTINO LEO
21/473767/PA/20429

Telah dipertahankan di depan Tim Penguji
pada tanggal 16 Juli 2025

Susunan Tim Penguji

Dr. Dwi Ertiningsih, M.Si.
Pembimbing Utama

Prof. Dr. Abdurakhman, S.Si., M.Si.
Ketua Tim Penguji

Dr. Adhitya Ronnie Effendie, M.Sc
Penguji

Dr. Solikhatun, S.Si., M.Si.
Penguji

Mengetahui,
a.n. Dekan FMIPA UGM
Wakil Dekan Bidang Pendidikan, Pengajaran
dan Kemahasiswaan

Prof. Drs. Roto, M.Eng., Ph.D.
NIP. 196711171993031020

PERNYATAAN BEBAS PLAGIASI

Saya yang bertanda tangan di bawah ini:

nama	:	BRYAN FLORENTINO LEO
NIM	:	21/473767/PA/20429
tahun terdaftar	:	2021
program studi	:	Program Sarjana Program Studi Statistika
fakultas	:	Fakultas Matematika dan Ilmu Pengetahuan Alam

menyatakan bahwa dalam dokumen ilmiah skripsi ini tidak terdapat bagian dari karya ilmiah lain yang telah diajukan untuk memperoleh gelar akademik di suatu lembaga Pendidikan Tinggi, dan juga tidak terdapat karya atau pendapat yang pernah ditulis atau diterbitkan oleh orang/lembaga lain, kecuali yang secara tertulis disitasi dalam dokumen ini dan disebutkan sumbernya secara lengkap dalam daftar pustaka.

Dengan demikian saya menyatakan bahwa dokumen ilmiah ini bebas dari unsur-unsur plagiasi dan apabila dokumen ilmiah skripsi ini di kemudian hari terbukti merupakan plagiasi dari hasil karya penulis lain dan/atau dengan sengaja mengajukan karya atau pendapat yang merupakan hasil karya penulis lain, maka Penulis bersedia menerima sanksi akademik dan/atau sanksi hukum yang berlaku.

Yogyakarta, 16 Juli 2025



BRYAN FLORENTINO LEO

21/473767/PA/20429

Untuk Bapa dan Papa di surga.

”Aku mengucap syukur kepada Allahku setiap kali aku mengingat kamu.”

Filipi 1:3 (TB)

PRAKATA

Segala puji dan syukur Penulis naikkan kepada Tuhan Yesus, yang oleh karena kasih dan perkenanan-Nya, Penulis dapat menyelesaikan skripsi berjudul ”Optimisasi Portofolio Saham Menggunakan *Komodo Mlipir Algorithm* Berdasarkan Klaster *K-Means*”. Keberadaan tugas akhir ini menandakan tersisanya beberapa langkah lagi sebelum perjalanan Penulis dalam menuntut ilmu di Program Studi Sarjana Statistika Fakultas Matematika dan Ilmu Pengetahuan Alam (MIPA) Universitas Gadjah Mada (UGM) mencapai penghujungnya dan Penulis dapat meraih gelar Sarjana Statistika.

Adapun dalam menyusun skripsi ini, Penulis mengucapkan terima kasih kepada:

1. Tuhan Yesus, Bapa yang setia dan kawan yang sejati;
2. Alm. Papa, Mama, serta adik-adik, Agnes dan Albert, yang membawa Penulis dalam doa dan kasih tanpa mengenal jarak dan waktu;
3. Prof. Dr. Eng. Kuwat Triyana, M.Si., selaku Dekan Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Gadjah Mada;
4. Dr. Nanang Susyanto, S.Si., M.Sc., selaku Ketua Departemen Matematika Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Gadjah Mada;
5. Dr. Dwi Ertiningsih, M.Si., selaku Dosen Pembimbing Tugas Akhir atas pengarahan yang telah dikerahkan bagi Penulis dalam menyusun tugas akhir ini;
6. Prof. Dr. Abdurakhman, M.Si., selaku Dosen Pembimbing Akademik atas pengarahan dan dukungan akademik selama perjalanan studi Penulis;
7. Drs. Zulaela, Dipl.Med.Stats., M.Si., selaku Dosen Pembimbing Akademik purnatugas;
8. Seluruh dosen Program Studi Sarjana Statistika Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Gadjah Mada atas bekal pengetahuan yang sungguh bermakna dan bermanfaat;
9. Rekan-rekan seperjuangan dari Statistika 2021 ”SIRIUS” atas kebersamaan dan

uluran tangan selama Penulis menjalankan proses studi;

10. Dafi, Jordan, Amelia, Chandra, Melodia, Pramana, Saprina, dan Syafiqa selaku rekan-rekan seperbimbingan Tugas Akhir;
11. Dhea, Chia, dan Priska selaku saudari-saudari seiman yang saling membersamai dalam perjalanan iman di GPdI Hagios Family Sosrowijayan, Yogyakarta serta menghadapi gunung dan lembah dalam perjalanan studi masing-masing;
12. Syachnaz, Putri, Angela, Iren, Tessa, Dhea, Chia, dan Icil selaku sesama Pengurus Harian dan Pengurus Inti Persekutuan Mahasiswa Kristen (PMK) Fakultas MIPA UGM periode 2023;
13. Ace, Indah, Owen, Angel, Nanta, dan Syela selaku rekan-rekan sekerja Allah dalam Badan Pengurus Harian Unit Kegiatan Mahasiswa Kerohanian Kristen (UKK) UGM periode 2024;
14. Seluruh anggota KKN-PPM ”Buru Basudara” Periode 2 Tahun 2024, terkhusus Subunit Waemangit beserta keluarga piara dan warga Desa Waemangit, Kabupaten Buru yang tiada hentinya saling merangkul dalam doa;
15. Keluarga besar yang telah memberi dukungan materiil maupun non-materiil; serta
16. Seluruh pihak yang telah memberikan berbagai bentuk dukungan yang tidak bisa Penulis sebutkan satu per satu.

Penulis menyadari bahwa skripsi ini tidak luput dari kekurangan dan kesalahan. Oleh karena itu, Penulis sangat terbuka terhadap masukan, kritik, dan saran sebagai bekal bagi Penulis untuk menyempurnakan skripsi ini maupun karya-karya yang akan datang. Besar harapan Penulis agar skripsi ini bermanfaat bagi para pembacanya. Tuhan memberkati.

Yogyakarta, 16 Juli 2025

Penulis

DAFTAR ISI

HALAMAN JUDUL ..... **i**
HALAMAN PENGESAHAN ..... **ii**
HALAMAN PERNYATAAN ..... **iii**
HALAMAN PERSEMBAHAN ..... **iv**
HALAMAN MOTTO ..... **v**
PRAKATA ..... **vi**
DAFTAR ISI ..... **viii**
DAFTAR TABEL ..... **xiii**
DAFTAR LAMBANG ..... **xiv**
INTISARI ..... **xv**
ABSTRACT ..... **xvi**
BAB I PENDAHULUAN **1**
1.1. Latar Belakang 1
1.2. Pembatasan Masalah 3
1.3. Tujuan dan Manfaat Penelitian 4
1.4. Tinjauan Pustaka 5
1.5. Metodologi Penelitian 6
1.6. Sistematika Penulisan 7
BAB II LANDASAN TEORI **9**
2.1. Aljabar Vektor dan Matriks 9
2.1.1. Vektor 9
2.1.2. Matriks 10
2.1.3. Eigenvektor dan Eigennilai 13
2.1.4. Bentuk Kuadrat 14
2.1.5. Matriks Definit Positif dan Matriks Semidefinit Positif 14
2.2. Derivatif Parsial 15
2.3. Ruang Sampel dan Kejadian 17
2.4. Probabilitas 17

2.5. Variabel Random 18
2.5.1. Variabel Random Diskret 18
2.5.2. Variabel Random Kontinu 19
2.5.3. Penyokong Variabel Random 20
2.5.4. Distribusi Probabilitas Gabungan 20
2.5.5. Distribusi Probabilitas Marginal 23
2.6. Sifat-Sifat Variabel Random 23
2.6.1. Ekspektasi 23
2.6.2. Variansi 24
2.6.3. Deviasi Standar 25
2.6.4. Kovariansi 25
2.6.5. Korelasi 26
2.7. Analisis Multivariat 26
2.7.1. Vektor Mean 27
2.7.2. Matriks Kovariansi 28
2.7.3. Jarak Euclid 30
2.7.4. Analisis Klaster 30
2.8. Distribusi Probabilitas 31
2.8.1. Distribusi Bernoulli 31
2.8.2. Distribusi Binomial 32
2.8.3. Distribusi Poisson 32
2.8.4. Distribusi Uniform 33
2.8.5. Distribusi Normal 33
2.9. Bilangan *Pseudo-Random* 34
2.10. Sampel Random 35
2.11. Pengujian Hipotesis 35
2.12. Uji Kolmogorov-Smirnov 37
2.13. Proses Stokastik 38
2.13.1. Rantai Markov 38
2.13.2. Proses *Random Walk* 39
2.14. Perusahaan 40
2.15. Investasi 41
2.16. Saham 42
2.16.1. *Return* dan Risiko Saham 43

2.16.2. *Short Sale* 44
2.17. Pasar Saham. 44
2.18. Portofolio Saham 45
2.18.1. *Return* dan Risiko Portofolio Saham 45
2.18.2. Beta Portofolio 48
2.18.3. Ukuran Performa Portofolio 49
2.18.4. *Sharpe Ratio* 50
2.18.5. Portofolio Tangen 50
2.18.6. Portofolio Efisien 51
2.18.7. *Capital Asset Pricing Model* 52
2.18.8. *Jensen's Alpha* 53
2.18.9. *Treynor Ratio* 54
2.19. Indeks Saham LQ45 54
2.20. Metode Pengali Lagrange. 56
2.21. Syarat-Syarat Kuhn-Tucker untuk Permasalahan Minimisasi 57
2.22. Pemrograman Kuadratik. 59
2.23. Algoritma Optimisasi Metaheuristik. 60
BAB III ANALISIS KLASTER *K-MEANS* DAN ALGORITMA-ALGORITMA OPTIMISASI PORTOFOLIO. 62
3.1. Analisis Klaster *K-Means* 62
3.2. Metode Portofolio *Minimum Variance* 65
3.3. *Genetic Algorithm*. 69
3.3.1. Terminologi Genetika. 69
3.3.2. Konsep Matematis *Genetic Algorithm* 70
3.3.3. Struktur *Genetic Algorithm* dan Variasinya 71
3.4. *Komodo Mlipir Algorithm* 74
3.4.1. Komodo 75
3.4.2. Perilaku Komodo 76
3.4.3. Konsep Matematis *Komodo Mlipir Algorithm*. 78
3.4.4. Struktur Umum *Komodo Mlipir Algorithm* 81
3.4.5. Percobaan *Komodo Mlipir Algorithm*. 82

BAB IV STUDI KASUS 84
4.1. Deskripsi Data 84
4.2. *Return* Terealisasi Harian Saham 84
4.3. Uji Normalitas *Return* Harian Saham 84
4.4. Analisis Klaster *K-Means* 85
4.5. Pembobotan Portofolio *Minimum Variance* 87
4.6. Pembobotan Portofolio Menggunakan *Genetic Algorithm* 91
4.7. Penyesuaian Konsep Matematis *Komodo Mlipir Algorithm* 95
4.8. Pembahasan Percobaan *Komodo Mlipir Algorithm* 96
4.9. Pembobotan Portofolio Menggunakan *Komodo Mlipir Algorithm* 97
4.10. Pembobotan Portofolio Menggunakan *Particle Swarm Optimization* 101
4.11. Perhitungan Beta Portofolio 102
4.12. Perbandingan Performa Portofolio 103
BAB V PENUTUP 105
5.1. Kesimpulan 105
5.2. Saran 105
DAFTAR PUSTAKA 107
LAMPIRAN 114
Lampiran 1. Daftar Saham dalam Indeks LQ45 114
Lampiran 2. *Pseudocode Genetic Algorithm* (GA) 116
Lampiran 3. *Pseudocode Komodo Mlipir Algorithm* (KMA) 117
Lampiran 4. Data Riwayat Harga Saham 118
Lampiran 5. Komputasi *Return* Saham 120
Lampiran 6. Uji Kolmogorov-Smirnov terhadap Normalitas *Return* Harian Saham 121
Lampiran 7. Vektor Mean *Return*, Deviasi Standar, dan *Sharpe Ratio* dari Saham dengan *Return* Harian Berdistribusi Normal 124
Lampiran 8. Diagram Pencar Mean *Return* dan Risiko dari Saham dengan *Return* Harian Berdistribusi Normal 126
Lampiran 9. Visualisasi *Silhouette Score* 127
Lampiran 10. Analisis Klaster *K-Means* 128

Lampiran 11. Pembobotan Portofolio *Minimum Variance* 129
Lampiran 12. Aplikasi *Genetic Algorithm* untuk Menyelesaikan Fungsi Sphere 132
Lampiran 13. Pembobotan Portofolio Menggunakan *Genetic Algorithm* . . . 134
Lampiran 14. Fungsi *Komodo Mlipir Algorithm* 136
Lampiran 15. Aplikasi *Komodo Mlipir Algorithm* untuk Menyelesaikan Fungsi Sphere 146
Lampiran 16. Pembobotan Portofolio Menggunakan *Komodo Mlipir Algorithm* 148
Lampiran 17. Pembobotan Portofolio Menggunakan *Particle Swarm Optimization* 149
Lampiran 18. Data Riwayat Harga IHSG 151
Lampiran 19. Komputasi *Return* IHSG 152
Lampiran 20. Komputasi Portofolio Saham Relatif Terhadap Portofolio Pasar 153
Lampiran 21. Komputasi Beta Portofolio 154
Lampiran 22. Komputasi *Sharpe Ratio* 156
Lampiran 23. Komputasi *Treynor Ratio* 157
Lampiran 24. Komputasi *Jensen's Alpha* 158

DAFTAR TABEL

2.1 Tabel Keputusan 2 $\times$ 2 Pengujian Hipotesis 36

4.1 Pembagian klaster untuk saham-saham dengan *return* berdistribusi normal. 86

4.2 Perbandingan penelitian Suyanto dkk. (2022) dengan penelitian ini. 97

4.3 Perbandingan ukuran performa portofolio *minimum variance*, GA, KMA, dan PSO. 103

DAFTAR LAMBANG

e	: Bilangan Euler
$x!$	: x faktorial, $x! = x(x-1)\cdots(1)$
$\mathbf{x}$	: Vektor $\mathbf{x}$ (dinotasikan dengan huruf kecil yang dicetak tebal)
$\mathbf{x}'$	: *Transpose* vektor $\mathbf{x}$
$\mathbf{X}$	: Matriks $\mathbf{X}$ (dinotasikan dengan huruf kapital yang dicetak tebal)
$\|\mathbf{X}\|$	: Determinan matriks
$\mathbf{X}'$	: *Transpose* matriks $\mathbf{X}$
x_i	: Elemen ke-i (pada himpunan atau vektor)
x_{ij}	: Elemen pada baris ke-i dan kolom ke-j (pada matriks)
$\mathbb{Z}$	: Himpunan semua bilangan bulat
$\mathbb{R}$	: Himpunan semua bilangan real
A^c	: Komplemen dari himpunan A
$\|A\|$	: Kardinalitas atau jumlah elemen dalam himpunan A
$\subseteq$	: Subhimpunan atau himpunan bagian (dari himpunan)
$P(\cdot)$	: Probabilitas
$\sim$	: Mengikuti distribusi probabilitas

INTISARI

OPTIMISASI PORTOFOLIO SAHAM MENGGUNAKAN *KOMODO MLIPIR ALGORITHM* BERDASARKAN KLASTER *K-MEANS*

oleh

BRYAN FLORENTINO LEO

21/473767/PA/20429

Sejak pandemi COVID-19 melanda Indonesia pada tahun 2020, jumlah investor individu di Indonesia telah bertumbuh pesat, khususnya dari kalangan Generasi Z. Saham merupakan salah satu instrumen investasi berisiko yang paling digemari oleh generasi tersebut. Portofolio yang optimal merupakan sarana untuk mendiversifikasi risiko investasi, seperti yang termuat pada saham. Pada masa kini, banyak permasalahan optimisasi diselesaikan menggunakan algoritma-algoritma metaheuristik.

Penelitian ini ditujukan untuk menguji performa *Komodo Mlipir Algorithm* (KMA), salah satu algoritma metaheuristik terbaru, dalam mengoptimisasi portofolio saham. Pemilihan saham dilakukan berdasarkan analisis klaster *K-Means* atas saham-saham dari indeks LQ45 dengan *return* yang berdistribusi normal. Performa portofolio yang dihasilkan melalui KMA dibandingkan dengan metode portofolio *minimum variance* dan *Genetic Algorithm* (GA) menggunakan *Sharpe ratio*, *Treynor ratio*, dan *Jensen's alpha*. Melalui komputasi dari ketiga ukuran ini, diperoleh bahwa KMA menghasilkan portofolio dengan performa terbaik dari antara ketiga portofolio yang dibentuk.

ABSTRACT

STOCK PORTFOLIO OPTIMIZATION USING KOMODO MLIPIR ALGORITHM BASED ON *K*-MEANS CLUSTERING

by

BRYAN FLORENTINO LEO

21/473767/PA/20429

Since the COVID-19 pandemic occurred in Indonesia in 2020, the number of individual investors in Indonesia has grown swiftly, especially from the Generation Z. Stocks are one of the risky investing instruments which were the most preferred by the generation. An optimal portfolio acts to diversify investing risks, as obtained in a stock. These days, a lot of optimization problems are solved using metaheuristic algorithms.

This research aims to test the performance of Komodo Mlipir Algorithm (KMA), one of the novel metaheuristic algorithms, on optimizing stock portfolio. Stocks are selected based on *K*-Means clustering on stocks from the LQ45 index which returns are normally distributed. The performance of the portfolio produced through KMA is then compared with the portfolios produced from the minimum variance method and Genetic Algorithm (GA) based on Sharpe ratio, Treynor ratio, and Jensen's alpha. The result of these three measures from computation shows that the KMA portfolio has the best performance out of the three portfolios.

BAB I

PENDAHULUAN

1.1. Latar Belakang

Pada tahun 2021 yang lalu, Presiden Joko Widodo menetapkan pembentukan sebuah kementerian baru bernama Kementerian Investasi dan Hilirisasi Republik Indonesia. Kementerian ini menggantikan Badan Koordinasi Penanaman Modal (BKPM) dengan tujuan untuk meningkatkan investasi negara, menciptakan lapangan pekerjaan, serta merespons peresmian Undang-Undang Cipta Kerja dan kenaikan pagu anggaran untuk BKPM yang mencapai 147,9 persen (Finaka, 2021; Putri, 2021). Hadirnya Kementerian Investasi dan Hilirisasi telah menunjukkan dampak yang signifikan terhadap kegiatan investasi pemerintahan Indonesia. Pada akhir tahun 2023, Badan Pusat Statistik (BPS) mencatat bahwa realisasi investasi penanaman modal dalam negeri nasional mencapai nominal 674,9234 triliun rupiah pada 266.722 unit proyek. Angka ini berturut-turut meningkat sebanyak 50,96 persen dan 151,62 persen dari tahun 2021, menandakan peran positif kementerian tersebut dalam mengoptimalisasi anggaran negara untuk proyek-proyek investasi yang semakin beragam. Lebih lanjut, statistik ini tidak melibatkan investasi pada sektor minyak bumi dan gas, keuangan, asuransi, pasar modal, dan rumah tangga. Maka, andaikan investasi di kalangan masyarakat turut dipertimbangkan, aktivitas investasi di Indonesia sejatinya jauh lebih luas daripada ukuran statistik-statistik tersebut. Dengan kata lain, kontribusi investor-investor individu sejatinya memegang peran yang tidak kalah penting.

Sejak beberapa tahun silam, banyak masyarakat Indonesia telah memilih investasi sebagai upaya menunjang situasi keuangan pribadi. Sejak masa pandemi COVID-19 melanda pada tahun 2020 hingga awal tahun 2024, PT Kustodian Sentral Efek Indonesia (KSEI) mencatat pertumbuhan jumlah angka investor individu hingga lebih dari tiga kali lipat. Tujuan investasi masyarakat didominasi untuk dana

darurat, penghasilan tambahan, atau dana pensiun (Wiranto, 2022). Terkini, investasi tidak hanya dilakukan oleh mereka yang telah berkeluarga, tetapi juga di tengah kalangan anak muda. Berdasarkan data KSEI pula, jumlah investor Generasi Z pada akhir tahun 2023 telah mencapai lebih dari dua belas juta orang, memenuhi 56,4 persen demografi investor individu di Indonesia. Peristiwa ini tidak hanya terjadi di Indonesia, tetapi juga di beberapa negara maju. Hal ini diyakini karena informasi tentang investasi digital dan edukasi literasi keuangan mulai menjamur di media sosial. Bertambahnya aplikasi investasi digital dan naiknya tren mata uang kripto juga diduga mendorong fenomena ini. Lebih lanjut, investasi juga merupakan alternatif yang sejalan dengan karakter Generasi Z yang tidak menggemari pekerjaan kantoran dan hendak mencapai kebebasan finansial dalam waktu yang cepat (Pramuji, 2024). Didukung dengan tingkat keamanan yang tinggi dan kebutuhan modal yang minimum, hasil survei Populix menyatakan bahwa 67 persen masyarakat Indonesia berencana untuk melanjutkan kegiatan investasi pada tahun 2025 mendatang (Fitri, 2024).

Reksa dana, emas, dan saham merupakan tiga instrumen investasi yang paling banyak diincar oleh investor individu. Investor emas didominasi oleh Generasi X dan Generasi Y (alias Milenial), sedangkan reksa dana dan saham lebih digemari oleh Generasi Z. Pertimbangan masyarakat dalam berinvestasi pada emas didasari oleh profil risiko emas yang rendah. Sementara, reksa dana dan saham dinilai aman karena telah terdaftar di Otoritas Jasa Keuangan (OJK) dan telah tersedia di berbagai aplikasi digital maupun perdagangan elektronik (*e-commerce*) (Wiranto, 2022). Meski dirasa lebih praktis dan dekat dengan genggaman kalangan dewasa muda, tidak dapat dipungkiri bahwa reksa dana dan saham merupakan dua instrumen investasi yang berisiko.

Penanganan risiko dalam berinvestasi, khususnya pada sekuritas keuangan seperti reksa dana dan saham, dapat diperantarai oleh portofolio. Portofolio membobotkan dua sekuritas atau lebih dengan mempertimbangkan potensi *return* dan risiko yang terasosiasi dengan tiap sekuritas tersebut. Perkembangan popularitas portofolio diawali dengan penemuan Teori Portofolio Modern oleh Harry

Markowitz pada tahun 1952. Seiring berjalannya waktu, berbagai metode optimisasi portofolio konvensional hadir, lalu tergantikan oleh algoritma-algoritma heuristik. Selanjutnya, algoritma-algoritma heuristik semakin dikembangkan menjadi algoritma-algoritma metaheuristik yang becermin terhadap fenomena alam dan perilaku makhluk hidup pada alam.

Salah satu algoritma metaheuristik terbaru ialah *Komodo Mlipir Algorithm* (KMA). KMA ditemukan oleh ilmuwan asal Indonesia, Prof. Suyanto, dalam pengukuhannya sebagai guru besar di Telkom University pada tahun 2022. Penemuan KMA terinspirasi dari perilaku komodo jantan dewasa, komodo betina, dan komodo jantan muda di habitatnya. Literatur perdana tentang KMA oleh Suyanto dkk. (2022) membandingkan performa KMA dengan enam algoritma metaheuristik terdahulu dalam optimisasi fungsi-fungsi matematis berdimensi besar. Penelitian ini menyimpulkan bahwa KMA merupakan algoritma optimisasi baru yang unggul. KMA selanjutnya digunakan dalam berbagai eksperimen untuk menyelesaikan berbagai permasalahan optimisasi praktis. Akan tetapi, hingga saat ini, belum terdapat penelitian ilmiah yang mengulas pemanfaatan KMA pada bidang keuangan, khususnya permasalahan optimisasi portofolio yang cukup populer dalam bidang ini. Oleh karena itu, Penulis termotivasi untuk mengimplementasikan KMA serta membandingkannya dengan model portofolio *minimum variance* dan *Genetic Algorithm* (GA) pada permasalahan optimisasi portofolio saham yang didasarkan pada klaster *K-Means*.

1.2. Pembatasan Masalah

Pada penelitian ini, Penulis membatasi metode optimisasi pada model portofolio *minimum variance*, *Genetic Algorithm* (GA), dan *Komodo Mlipir Algorithm* (KMA). Menimbang aplikasi KMA yang masih terbatas pada permasalahan-permasalahan optimisasi di dunia nyata, KMA menjadi metode utama yang difokuskan dalam laporan ini. Penulis menggunakan data riwayat harga dari 45 saham yang termuat dalam indeks LQ45 menurut pembaruan terkini pada bulan Agustus 2024. Rincian nama-nama saham tersebut dapat diamati pada Lampiran 1. Data ri-

wayat harga saham diperoleh dari situs web *investing.com* dan dibatasi pada periode Desember 2023 hingga November 2024 agar data bersifat terkini dan utuh. Model permasalahan optimisasi yang dilibatkan dibatasi pada permasalahan minimalisasi risiko dan tidak terdapat *shortselling*. Dengan kata lain, tiap saham yang terlibat dalam portofolio harus berbobot nonnegatif.

Performa portofolio yang terbentuk dari tiga metode yang digunakan akan diukur dan dibandingkan melalui ukuran *Sharpe ratio*, *Treynor ratio*, dan *Jensen's alpha*. Agar ketiga ukuran ini berlaku, diberlakukan asumsi bahwa risiko bernilai konstan selama periode data yang digunakan.

1.3. Tujuan dan Manfaat Penelitian

Tujuan penelitian ini adalah:

1. Mempelajari teori-teori penyusunan portofolio saham yang optimal.
2. Mempelajari *Komodo Mlipir Algorithm* sebagai salah satu algoritma optimisasi metaheuristik terbaru.
3. Mengaplikasikan *Komodo Mlipir Algorithm* pada pembentukan portofolio saham yang optimal berdasarkan klaster *K-Means*.
4. Menganalisis keoptimalan portofolio saham yang didasarkan pada kemampuan meminimasi risiko menggunakan *Komodo Mlipir Algorithm* berdasarkan klaster *K-Means* terhadap metode-metode optimisasi portofolio klasik, yaitu model portofolio *minimum variance* dan *Genetic Algorithm*.

Adapun manfaat penelitian ini adalah:

1. Mengembangkan aplikasi *Komodo Mlipir Algorithm* pada bidang statistika keuangan, khususnya optimisasi portofolio saham.
2. Mendukung perluasan aplikasi *Komodo Mlipir Algorithm* dalam berbagai bidang ilmu.
3. Mempromosikan *Komodo Mlipir Algorithm* sebagai karya ilmuwan nasional.

1.4. Tinjauan Pustaka

Ide optimisasi portofolio pertama kali dicetuskan oleh Markowitz pada tahun 1952. Penemuan Markowitz, yang dikenal sebagai model portofolio *mean-variance* atau *minimum variance*, didasarkan pada kesetimbangan *return* dan risiko yang diperoleh dalam melakukan investasi terhadap aset-aset yang terlibat. *Return* dan risiko berturut-turut diukur melalui vektor ekspektasi *return* dan matriks kovariansi. Sensitivitas terhadap mean dan kovariansi menjadikan model portofolio *mean-variance* tidak optimal (Dai, 2019). Permasalahan ini ditangani dengan menggunakan estimasi matriks kovariansi yang tak bias, seperti matriks kovariansi terboboti eksponensial, kovariansi tersusutkan Ledoit-Wolf, kovariansi Gerber, matriks kovariansi sampel, estimator kovariansi *Ordinary Least Square* (OLS), dan estimator *eigenvalue clipping* (Zhou, 2020; Bitar dkk., 2023). Selain itu, model *mean-variance* juga dapat dikembangkan dan diperbaiki pada skala yang lebih besar, seperti menuju model *global minimum variance* (GMV) dan model faktor (Sun dkk., 2019). Kelemahan lain dari model portofolio *mean-variance* ialah komponen bobot portofolio dapat bernilai negatif. Jagannathan dan Ma (2003) mengatasi permasalahan ini dengan melibatkan suatu kendala pertidaksamaan dalam model.

Algoritma optimisasi metaheuristik merupakan salah satu kebaruan dalam cabang ilmu matematika optimisasi yang masih terus dikembangkan oleh para ilmuwan hingga hari ini. Salah satu pionir perkembangan algoritma metaheuristik ialah *Genetic Algorithm* (GA). Ditemukan oleh John Holland pada tahun 1975, GA terinspirasi dari fenomena mutasi dan rekombinasi genetika. Reeves (2010) memaparkan bahwa GA dapat dimanfaatkan untuk menyelesaikan permasalahan optimisasi biner, diskret, permutasi, maupun nonbiner. Seiring berjalannya waktu, GA telah diaplikasikan secara luas pada berbagai bidang ilmu. Bahkan, GA merupakan algoritma metaheuristik terpopuler kedua yang dirujuk atau dimuat dalam lebih dari tujuh puluh ribu publikasi ilmiah pada tahun 2022 (Rajwar dkk., 2023). Dalam mengatasi permasalahan optimisasi portofolio, beberapa penelitian menggunakan GA secara murni, seperti Zhu (2016), Dubinskas dan Urbšienė (2017), Cheong dkk. (2017), dan Li dan Shi (2022). Sementara, beberapa penelitian lainnya meng-

gabungkan GA dengan pendekatan, ukuran numerik, atau algoritma pemelajaran mesin (*machine learning*), seperti pendekatan jumlah terbobot (Faia dkk., 2018), valuasi aset (Lim dkk., 2020), indeks prioritas (Vasiani dkk., 2020), pemrograman linear (Sukono dkk., 2018), dan jaringan saraf tiruan *Long-Short Term Memory* (LSTM) (Flores-Fernandez dkk., 2024).

GA dan algoritma-algoritma turunannya tidak dapat diskalakan dan tidak stabil. *Komodo Mlipir Algorithm* (KMA) ditemukan dan telah teruji sebagai algoritma metaheuristik baru yang mampu mengatasi kelemahan-kelemahan ini. Dalam perbandingan antara KMA dengan enam algoritma terdahulu oleh Suyanto dkk. (2022), KMA menempati urutan terbaik dalam aspek kestabilan dan skalabilitas, sedangkan GA berada pada urutan terakhir. Studi-studi lanjutan mengaplikasi-kan KMA pada permasalahan deteksi partikel udara PM2.5 (Li dan Zhao, 2022), penjadwalan generator listrik (Aditya dkk., 2022), penentuan mekanisme rute optimal (Soundarayaa dan Balasubramanian, 2024), dan efisiensi energi pada jaringan-jaringan radio kognitif (Dharmapuri dan Reddy, 2024). Lebih lanjut, beberapa studi bahkan telah mengembangkan KMA atau meleburkan KMA dengan algoritma lain untuk membentuk algoritma metaheuristik baru, yakni antara lain *Stochastic Komodo Algorithm* (SKA) (Kusuma dan Kallista, 2022), *Improved Adaptive Komodo Mlipir Algorithm* (IKMA) (Liu dan Zhang, 2022), *Discrete Komodo Algorithm* (DKA) (Jati dkk., 2023), dan *Hybrid Pelican Komodo Algorithm* (HPKA) (Kusuma dan Dinimaharawati, 2022).

1.5. Metodologi Penelitian

Penelitian dalam skripsi ini berupa studi literatur dan studi kasus. Studi literatur dilakukan dengan mengumpulkan informasi dan merangkum pengetahuan yang terkait dengan topik penelitian penulis dari berbagai buku, jurnal, dan artikel secara daring. Informasi dan pengetahuan yang diperoleh menjadi acuan dalam menyusun skripsi ini dan melaksanakan studi kasus. Adapun studi kasus yang dilakukan ialah berupa pembandingan metode portofolio *minimum variance*, *Genetic Algorithm* (GA), dan *Komodo Mlipir Algorithm* (KMA) dalam memperoleh

portofolio saham yang optimal, yaitu portofolio yang meminimisasi risiko investasi. Sebagai tambahan, untuk tujuan yang serupa, KMA juga akan dibandingkan dengan *Particle Swarm Optimization* (PSO) sebagai algoritma metaheuristik yang sama-sama berbasis kecerdasan kawanan. Data yang digunakan merupakan data sekunder berupa data riwayat harga saham-saham yang termuat dalam indeks saham LQ45 yang diperoleh dari situs web *investing.com*. Riwayat dibatasi pada bingkai waktu Desember 2023 hingga November 2024. Studi kasus didukung secara komputasional menggunakan bahasa pemrograman R yang diperantarai oleh aplikasi RStudio. Padanan-padanan istilah mengacu pada padanan yang telah ditentukan oleh Badan Pengembangan dan Pembinaan Bahasa Kementerian Pendidikan Dasar dan Menengah dan diluncurkan pada aplikasi PASTI (Padanan Istilah).

1.6. Sistematika Penulisan

Dalam menyusun skripsi ini, Penulis mengacu pada sistematika penulisan sebagai berikut:

BAB I PENDAHULUAN

Bab I (Pendahuluan) memuat latar belakang, pembatasan masalah, tujuan dan manfaat penelitian, tinjauan pustaka, metodologi penelitian, dan sistematika penulisan. Secara umum, bab ini ditujukan untuk menjelaskan alasan diusungnya topik penelitian, cakupan permasalahan, perbandingan dengan penelitian-penelitian terdahulu, dan susunan laporan.

BAB II LANDASAN TEORI

Bab II (Landasan Teori) berisi dasar-dasar teori yang digunakan untuk membahas topik penelitian dan permasalahan di dalamnya. Pada penelitian ini, termuat dasar-dasar teori yang berasal dari tiga rumpun keilmuan, yaitu matematika (aljabar vektor dan matriks, derivatif parsial, dan topik-topik seputar teori optimisasi), statistika (topik-topik seputar probabilitas, pengujian hipotesis, dan proses stokastik), dan ekonomika (perusahaan, investasi, serta topik-topik seputar saham dan portofolio).

BAB III ANALISIS KLASTER *K-MEANS* DAN ALGORITMA-ALGORITMA OPTIMISASI PORTOFOLIO

Bab III (Analisis Klaster *K-Means* dan Algoritma-Algoritma Optimisasi Portofolio) berisi penjabaran metodologi-metodologi yang digunakan dalam penelitian, yaitu analisis klaster *K-Means*, metode portofolio *minimum variance*, *Genetic Algorithm* (GA), dan *Komodo Mlipir Algorithm* (KMA).

BAB IV STUDI KASUS

Bab IV (Studi Kasus) memuat studi kasus, yaitu aplikasi analisis klaster *K-Means*, algoritma-algoritma optimisasi portofolio, dan ukuran-ukuran performa portofolio dalam suatu kerangka yang terstruktur untuk membentuk portofolio-portofolio atas beberapa saham yang bersumber dari indeks saham LQ45.

BAB V PENUTUP

Bab V (Penutup) memuat kesimpulan dari penelitian yang dilakukan serta saran yang ditujukan untuk perkembangan pada penelitian-penelitian di masa yang akan datang.

DAFTAR PUSTAKA

Daftar Pustaka memuat sumber-sumber pustaka ilmiah yang dijadikan referensi dalam laporan ini. Sumber-sumber tersebut disusun menggunakan gaya penulisan American Psychological Association (APA) Style edisi ketujuh.

LAMPIRAN

Lampiran memuat konten-konten tambahan yang turut dilibatkan dalam penelitian, meliputi data, *pseudocode*, sintaksis, dan luaran komputasi.

BAB II

LANDASAN TEORI

2.1. Aljabar Vektor dan Matriks

Dalam ilmu matematika, nilai-nilai dari sekumpulan variabel dapat dimuat dalam sebuah vektor atau matriks. Berikut merupakan definisi serta sifat-sifat vektor dan matriks dalam matematika.

2.1.1. Vektor

Vektor didefinisikan sebagai berikut.

Definisi 2.1.1 *(Johnson dan Winchern, 2007) Vektor adalah suatu larik,* $\mathbf{x}$*, yang beranggotakan* n *bilangan real,* $x_1, x_2, \ldots, x_n$*, dan dinotasikan sebagai:*

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}.$$

Beberapa operasi vektor, sifat vektor, dan vektor khusus diberikan sebagai berikut.

1. Penjumlahan vektor

   Hasil penjumlahan dua buah vektor dengan panjang yang sama, $\mathbf{x}$ dan $\mathbf{y}$, adalah:

$$\mathbf{x} + \mathbf{y} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} + \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_n + y_n \end{bmatrix}.$$

2. Perkalian vektor dengan skalar

Hasil perkalian sembarang konstanta, c, dengan sembarang vektor, $\mathbf{x}$, adalah:

$$c\mathbf{x} = \begin{bmatrix} cx_1 \\ cx_2 \\ \vdots \\ cx_n \end{bmatrix}.$$

3. *Transpose* vektor

   Transpose suatu vektor mengubah kolom-kolom vektor menjadi baris-baris vektor. *Transpose* sembarang vektor, $\mathbf{x}$, diberikan sebagai:

$$\mathbf{x}' = \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix}.$$

4. Vektor nol

   Vektor nol dengan panjang n adalah sebuah vektor yang seluruh n elemennya bernilai nol. Vektor nol didefinisikan:

$$\mathbf{0}_n = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

5. Vektor satu

   Vektor satu (disebut juga *vector of ones* atau *all-ones vector*) dengan panjang n adalah sebuah vektor yang seluruh n elemennya bernilai satu. Vektor satu didefinisikan:

$$\mathbf{1}_n = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}.$$

2.1.2. Matriks

Perluasan dari sebuah vektor dikenal sebagai sebuah matriks. Definisi matriks diberikan sebagai berikut.

Definisi 2.1.2 *(Johnson dan Winchern, 2007) Matriks adalah suatu larik persegi panjang sembarang yang beranggotakan bilangan real. Suatu matriks,* $\mathbf{A}$*, yang berukuran* n *baris dan* p *kolom, dirumuskan sebagai berikut:*

$$\underset{(n\times p)}{\mathbf{A}} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{np} \end{bmatrix}. \tag{2.1}$$

Beberapa operasi matriks, sifat matriks, dan matriks khusus diberikan sebagai berikut.

1. Penjumlahan matriks

   Hasil penjumlahan dua buah matriks dengan dimensi yang sama, $\mathbf{A}$ dan $\mathbf{B}$, adalah:

$$\begin{aligned} \mathbf{A}+\mathbf{B} &= \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{np} \end{bmatrix} + \begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1p} \\ b_{21} & b_{22} & \cdots & b_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ b_{n1} & b_{n2} & \cdots & b_{np} \end{bmatrix} \\ &= \begin{bmatrix} a_{11}+b_{11} & a_{12}+b_{12} & \cdots & a_{1p}+b_{1p} \\ a_{21}+b_{21} & a_{22}+b_{22} & \cdots & a_{2p}+b_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1}+b_{n1} & a_{n2}+b_{n2} & \cdots & a_{np}+b_{np} \end{bmatrix}. \end{aligned}$$

2. Perkalian matriks dengan skalar

   Hasil perkalian sembarang konstanta, c, dengan sembarang matriks, $\mathbf{A}$, adalah:

$$c\mathbf{A} = \begin{bmatrix} ca_{11} & ca_{12} & \cdots & ca_{1p} \\ ca_{21} & ca_{22} & \cdots & ca_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ ca_{n1} & ca_{n2} & \cdots & ca_{np} \end{bmatrix}.$$

3. *Transpose* matriks

   Transpose suatu matriks menukar kolom-kolom matriks menjadi baris-baris matriks. *Transpose* sembarang matriks dengan dimensi $(n \times p)$, $\mathbf{A}$, sebagaimana

didefinisikan sebelumnya pada Persamaan (2.1), diberikan sebagai:

$$\underset{(p\times n)}{\mathbf{A}'} = \begin{bmatrix} a_{11} & a_{21} & \cdots & a_{n1} \\ a_{12} & a_{22} & \cdots & a_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1p} & a_{2p} & \cdots & a_{np} \end{bmatrix}.$$

4. Perkalian dua buah matriks

   Hasil perkalian dua buah matriks, $\underset{(n\times k)}{\mathbf{A}}$ dan $\underset{(k\times p)}{\mathbf{B}}$, ialah matriks berdimensi $(n \times p)$ dengan elemen pada baris ke-i dan kolom ke-j adalah *inner product* dari baris ke-i dari $\mathbf{A}$ dan kolom ke-j dari $\mathbf{B}$, yaitu:

$$\begin{aligned} \text{elemen ke-}(i,j)\text{ dari }\mathbf{AB} &= a_{i1}b_{1j} + a_{i2}b_{2j} + \cdots + a_{1k}b_{kj} \\ &= \sum_{l=1}^{k} a_{il}b_{lj}. \end{aligned}$$

5. Matriks persegi

   Suatu matriks disebut matriks persegi jika ia memiliki banyak baris yang sama dengan banyak kolom.

6. Matriks simetris

   Sembarang matriks persegi, $\underset{(n\times n)}{\mathbf{A}}$, disebut simetris jika $\mathbf{A} = \mathbf{A}'$ atau $a_{ij} = a_{ji}$ untuk tiap i dan j.

7. Matriks identitas

   Matriks identitas adalah matriks persegi dengan nilai satu pada diagonal utamanya dan nol untuk elemen lainnya. Matriks identitas didefinisikan:

$$\mathbf{I} = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix}.$$

   Untuk sembarang matriks persegi, $\mathbf{A}$, dengan dimensi yang sama dengan $\mathbf{I}$, dipenuhi sifat:

$$\mathbf{IA} = \mathbf{AI} = \mathbf{A}.$$

8. Determinan matriks

   Determinan dari suatu matriks persegi, $\mathbf{A}$, berukuran $n \times n$ didefinisikan sebagai:

$$\begin{aligned} |\mathbf{A}| &= \sum_{i=1}^{n} (-1)^{f(i_1,\ldots,i_n)} a_{1i_1} a_{2i_2} \cdots a_{ni_n} \\ &= \sum_{i=1}^{n} (-1)^{f(i_1,\ldots,i_n)} a_{i_1 1} a_{i_2 2} \cdots a_{i_n n}, \end{aligned}$$

   dengan a_{ij} melambangkan elemen matriks $\mathbf{A}$ pada baris ke-i dan kolom ke-j serta $f(i_1, \ldots, i_n)$ melambangkan banyak transposisi yang diperlukan untuk mengubah $(i_1, \ldots, i_n)$ menuju $(1, \ldots, m)$. Transposisi dimaknai sebagai pertukaran dua buah bilangan.

   Determinan matriks juga dapat diperoleh melalui ekspansi baris atau kolom, yaitu untuk suatu matriks persegi, $\mathbf{A}$:

$$|\mathbf{A}| = \sum_{j=1}^{m} a_{ij} \mathbf{A}_{ij}$$

   atau

$$|\mathbf{A}| = \sum_{i=1}^{m} a_{ij} \mathbf{A}_{ij}.$$

   Untuk sembarang matriks dengan determinan nol, matriks tersebut disebut matriks singular.

9. Matriks invers

   Jika untuk sembarang matriks persegi nonsingular, $\mathbf{A}$, terdapat matriks persegi nonsingular $\mathbf{B}$ sedemikian sehingga:

$$\mathbf{BA} = \mathbf{AB} = \mathbf{I},$$

   maka $\mathbf{B}$ disebut matriks invers dari $\mathbf{A}$ dan dinotasikan $\mathbf{A}^{-1}$.

2.1.3. Eigenvektor dan Eigennilai

Definisi eigenvektor dan eigennilai diberikan sebagai berikut.

Definisi 2.1.3 *(Schott, 2017) Jika* $\mathbf{A}$ *merupakan sebuah matriks berukuran* $n \times n$*, maka sembarang skalar,* λ*, yang memenuhi persamaan berikut:*

$$\mathbf{Ax} = \lambda \mathbf{x}$$

untuk beberapa vektor berukuran $n \times 1$*,* $\mathbf{x} \neq \mathbf{0}$*, disebut eigennnilai dari* $\mathbf{A}$*. Vektor* $\mathbf{x}$ *disebut eigenvektor dari* $\mathbf{A}$ *yang berkorespondensi dengan eigennilai* λ*.*

Eigennilai dari suatu matriks, $\mathbf{A}$, dapat diperoleh sebagai akar-akar dari persamaan karakteristik $\mathbf{A}$, yaitu:

$$|\mathbf{A} - \lambda \mathbf{I}_n| = 0,$$

dengan $|\cdot|$ melambangkan determinan matriks dan $\mathbf{I}_n$ merupakan matriks identitas berukuran $n \times n$. Hal ini dikarenakan melalui definisi determinan, persamaan karakteristik dapat dipandang sebagai polinomial derajat n atas λ:

$$(-\lambda)^n + \alpha_{n-1}(-\lambda)^{n-1} + \cdots + \alpha_1 \lambda + \alpha_0 = 0,$$

dengan $\alpha_0, \alpha_1, \ldots, \alpha_{n-1}$ adalah skalar-skalar.

2.1.4. Bentuk Kuadrat

Bentuk kuadrat dari suatu vektor didefinisikan sebagai berikut.

Definisi 2.1.4 *(Schott, 2017) Diberikan vektor* $\mathbf{x}$ *berukuran* $n \times 1$ *dan matriks persegi simetris* $\mathbf{A}$ *berukuran* $n \times n$*. Bentuk kuadrat dari* $\mathbf{x}$ *dirumuskan sebagai:*

$$\mathbf{x}'\mathbf{A}\mathbf{x} = \sum_{i=1}^{n} \sum_{j=1}^{n} x_i x_j a_{ij}. \tag{2.2}$$

$\mathbf{A}$ *disebut matriks bentuk kuadrat.*

2.1.5. Matriks Definit Positif dan Matriks Semidefinit Positif

Suatu matriks persegi dapat disebut matriks definit positif atau matriks semidefinit positif berdasarkan bentuk kuadratnya atau eigennilai-eigennilainya. Untuk sifat bentuk kuadrat tertentu, dipenuhi sifat sebagai berikut:

1. Jika $\mathbf{x}'\mathbf{A}\mathbf{x} > 0$ untuk semua $\mathbf{x} \neq \mathbf{0}_n$, maka $\mathbf{A}$ bersifat definit positif.
2. Jika $\mathbf{x}'\mathbf{A}\mathbf{x} \geq 0$ untuk semua $\mathbf{x}$ dan $\mathbf{x}'\mathbf{A}\mathbf{x} = 0$ untuk sebagian $\mathbf{x} \neq \mathbf{0}_n$, maka $\mathbf{A}$ bersifat semidefinit positif.

Di sisi lain, berdasarkan eigennilai-eigennilainya, sifat definit positif dan semidefinit positif dari suatu matriks diberikan oleh teorema berikut.

Teorema 2.1.5 *(Schott, 2017) Diberikan $\lambda_1, \ldots, \lambda_n$, eigennilai-eigennilai dari suatu matriks persegi, $\mathbf{A}$, berukuran $n \times n$. Maka, berlaku:*

1. $\mathbf{A}$ *bersifat definit positif jika dan hanya jika $\lambda_i > 0$ untuk seluruh i; dan*
2. $\mathbf{A}$ *bersifat semidefinit positif jika dan hanya jika $\lambda_i \geq 0$ untuk seluruh i dan $\lambda_i = 0$ untuk setidaknya satu i.*

2.2. Derivatif Parsial

Definisi derivatif parsial perlu diawali dengan memahami fungsi multivariabel yang didefinisikan sebagai berikut.

Definisi 2.2.1 *(Stewart, 2015) Fungsi n variabel adalah fungsi bernilai real yang memetakan suatu bilangan, $z = f(x_1, x_2, \ldots, x_n)$, menuju rangkap n (n-tuple), $(x_1, x_2, \ldots, x_n)$. Domain fungsi f adalah subhimpunan dari $\mathbb{R}^n$.*

Suatu fungsi multivariabel dapat dipandang sebagai fungsi atas n variabel real, $x_1, x_2, \ldots, x_n$; suatu variabel titik, $(x_1, x_2, \ldots, x_n)$; atau suatu variabel vektor, $\mathbf{x}' = [x_1, x_2, \ldots, x_n]$.

Derivatif parsial dari suatu fungsi multivariabel didefinisikan sebagai berikut.

Definisi 2.2.2 *(Stewart, 2015) Diberikan suatu fungsi n variabel, $f(x_1, x_2, \ldots, x_n)$. Derivatif parsial f terhadap variabel ke-i, x_i, didefinisikan:*

$$\frac{\partial f}{\partial x_i} = \lim_{h \to 0} \frac{f(x_1, \ldots, x_{i-1}, x_i + h, x_{i+1}, \ldots, x_n) - f(x_1, \ldots, x_i, \ldots, x_n)}{h}$$

dan dapat dinotasikan pula sebagai:

$$\frac{\partial f}{\partial x_i} = f_{x_i} = f_i = D_i f.$$

Konsep derivatif parsial dapat diperluas untuk fungsi atas vektor atau matriks. Menurut Schott (2017), jika f adalah suatu fungsi bernilai real atas suatu vektor berukuran $n \times 1$, $\mathbf{x} = [x_1, x_2, \ldots, x_n]'$, maka derivatif f terhadap $\mathbf{x}$ diberikan sebagai vektor baris:

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}'} = \left[\frac{\partial}{\partial x_1} f(\mathbf{x}) \quad \cdots \quad \frac{\partial}{\partial x_n} f(\mathbf{x}) \right],$$

yaitu derivatif f terhadap tiap elemen vektor $\mathbf{x}$, jika derivatif tersebut ada.

Jika f mempunyai bentuk khusus:

$$f(\mathbf{x}) = \mathbf{a}'\mathbf{x}$$

dengan $\mathbf{a}$ adalah suatu vektor $n \times 1$ berelemen konstanta, elemen (kolom) ke-h dari derivatif f terhadap $\mathbf{x}$ dirumuskan:

$$\begin{aligned} \frac{\partial f}{\partial x_h} &= \frac{\partial}{\partial x_h} \sum_{i=1}^{n} a_i x_i \\ &= \sum_{i=1}^{n} a_i \left(\frac{\partial}{\partial x_h} x_i \right). \end{aligned} \tag{2.3}$$

Karena

$$\frac{\partial}{\partial x_h} x_i = \begin{cases} 1, & \text{jika } i = h, \\ 0, & \text{jika } i \neq h. \end{cases},$$

Persamaan (2.3) menjadi:

$$\frac{\partial f}{\partial x_h} = a_h$$

sehingga diperoleh:

$$\frac{\partial f}{\partial \mathbf{x}'} = \mathbf{a}'.$$

Di sisi lain, jika f mempunyai bentuk khusus:

$$f(\mathbf{x}) = \mathbf{x}'\mathbf{A}\mathbf{x}$$

dengan $\mathbf{A}$ adalah suatu matriks simetris $n \times n$ berelemen konstanta, elemen ke-h dari derivatif f terhadap $\mathbf{x}$ dirumuskan:

$$\begin{aligned} \frac{\partial f}{\partial x_h} &= \frac{\partial}{\partial x_h} \sum_{i=1}^{n} \sum_{j=1}^{n} a_{ij} x_i x_j \\ &= \sum_{i=1}^{n} \sum_{j=1}^{n} a_{ij} \left(\frac{\partial}{\partial x_h} x_i x_j \right) \\ &= \sum_{i=1}^{n} \sum_{j=1}^{n} a_{ij} \left[\left(\frac{\partial}{\partial x_h} x_i \right) x_j + x_i \left(\frac{\partial}{\partial x_h} x_j \right) \right] \\ &= \sum_{j=1}^{n} a_{hj} x_j + \sum_{i=1}^{n} a_{ih} x_i \end{aligned}$$

$$= \sum_{j=1}^{n} a_{jh}x_j + \sum_{i=1}^{n} a_{ih}x_i$$
$$= 2\sum_{i=1}^{n} a_{ih}x_i$$

karena $a_{jh} = a_{hj}$. Derivatif ini dapat dinotasikan:

$$\frac{\partial f}{\partial \mathbf{x}} = 2\mathbf{x}'\mathbf{A}.$$

2.3. Ruang Sampel dan Kejadian

Menurut Bain dan Engelhardt (1992), eksperimen adalah proses mengamati atau memperoleh hasil dari suatu fenomena. Penyelenggaraan sebuah eksperimen disebut percobaan dan hasil yang diamati disebut luaran (*outcome*). Ruang sampel diartikan sebagai himpunan semua luaran yang memungkinkan dari suatu eksperimen dan umumnya dinotasikan S.

Kejadian adalah subhimpunan (*subset*) dari ruang sampel. Jika A melambangkan suatu kejadian, maka A disebut sudah terjadi jika A beranggotakan luaran-luaran yang sudah terjadi. Kejadian-kejadian $A_1, A_2, A_3, \ldots$ dikatakan saling lepas (*mutually exclusive*) jika tiap pasangan yang memungkinkan saling lepas, yaitu jika $A_i \cap A_j = \varnothing$ untuk tiap $i \neq j$.

2.4. Probabilitas

Secara sederhana, probabilitas dapat dipandang sebagai suatu fungsi atas himpunan, yaitu fungsi yang memetakan sekumpulan kejadian menuju suatu subhimpunan bilangan real. Secara formal, probabilitas didefinisikan sebagai berikut.

Definisi 2.4.1 *(Bain dan Engelhardt, 1992) Jika diberikan S, suatu ruang sampel, dan $A, A_1, A_2, \ldots$, sekumpulan kejadian yang memungkinkan, $P(A)$ disebut probabilitas atas A jika memenuhi sifat-sifat berikut:*

$0 \leq P(A)$ *untuk tiap* A;

$P(S) = 1$; *dan*

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

2.5. Variabel Random

Teori statistika matematik mengenai pengujian hipotesis, proses stokastik, dan algoritma optimisasi melibatkan variabel random dan distribusinya. Variabel random didefinisikan sebagai berikut.

Definisi 2.5.1 *(Bain dan Engelhardt, 1992) Variabel random, X, adalah sebuah fungsi yang terdefinisi pada suatu ruang sampel, S, yang memasangkan tiap kemungkinan, $s \in S$, dengan suatu bilangan real, x. Secara matematik, definisi variabel random sebagai fungsi dapat dinotasikan sebagai:*

$$X(s) = x.$$

Variabel random umumnya dinotasikan menggunakan huruf kapital, sedangkan nilai-nilai yang dipasangkan oleh variabel random dilambangkan dengan huruf kecil.

Berdasarkan sifat distribusi probabilitas suatu variabel random, terdapat dua jenis variabel random, yaitu variabel random diskret dan kontinu.

2.5.1. Variabel Random Diskret

Secara sederhana, variabel random diskret diartikan sebagai variabel random yang memetakan bilangan-bilangan bulat. Secara matematis, variabel random diskret dimaknai sebagai berikut.

Definisi 2.5.2 *(Bain dan Engelhardt, 1992) Suatu variabel random, X, disebut sebagai variabel random diskret jika himpunan semua kemungkinannya (possible values), $\{x_1, x_2, \ldots x_n\}$ atau $\{x_1, x_2, \ldots\}$, adalah suatu himpunan tercacah yang berhingga atau tak berhingga dan beranggotakan bilangan-bilangan bulat.*

Fungsi yang memetakan tiap nilai massa dari X, yaitu x_i, dengan probabilitas disebut sebagai fungsi massa peluang (*probability mass function* atau PMF) atau fungsi kepadatan peluang diskret (*discrete probability density function* atau PDF diskret) dan dinotasikan:

$$f_X(x) = P[X = x], \quad x = x_1, x_2, \ldots \in \mathbb{Z}.$$

Suatu fungsi, $f_X(x)$, disebut PMF jika dan hanya jika ia memenuhi sifat-sifat:

$$f_X(x_i) \geq 0$$

dan

$$\sum_{\forall x_i} f_X(x_i) = 1$$

untuk sembarang himpunan bilangan real tercacah, $\{x_i\}, i = 1, 2, \ldots$.

Di sisi lain, fungsi distribusi kumulatif (*cumulative distribution function* atau CDF) atas suatu variabel random, X, ialah fungsi yang memetakan interval-interval $(-\infty, x]$ menuju probabilitasnya. Menurut Ross (2010), CDF diskret dinotasikan:

$$F_X(x) = P[X \leq x] = \sum_{\forall x_i \leq x} f_X(x_i)$$

dan terdefinisi untuk tiap $x \in \mathbb{R}$. Suatu fungsi $F_X(x)$ disebut CDF atas variabel random X jika dan hanya jika ia memenuhi sifat-sifat:

$$\lim_{x \to -\infty} F_X(x) = 0, \tag{2.4}$$

$$\lim_{x \to \infty} F_X(x) = 1, \tag{2.5}$$

$$\lim_{h \to 0^+} F_X(x + h) = F_X(x), \text{ dan} \tag{2.6}$$

$$\text{jika } a < b, \text{ maka } F_X(a) \leq F_X(b). \tag{2.7}$$

2.5.2. Variabel Random Kontinu

Definisi variabel random kontinu diberikan sebagai berikut.

Definisi 2.5.3 *(Bain dan Engelhardt, 1992) Suatu variabel random, X, disebut variabel random kontinu jika terdapat suatu fungsi, $f_X(x)$, yang disebut fungsi kepadatan peluang kontinu (continuous probability density function atau PDF kontinu) dari X sedemikian sehingga CDF (kontinu) atas X dapat dirumuskan:*

$$F_X(x) = P[X \leq x] = \int_{-\infty}^{x} f_X(t)\, dt$$

dan memenuhi sifat-sifat yang tertuang pada Persamaan (2.4) hingga (2.7).

Dengan demikian, PDF kontinu dapat diperoleh sebagai derivatif dari CDF kontinu, yaitu:

$$f_X(x) = \frac{d}{dx} F_X(x) = F'_X(x)$$

jika derivatifnya ada. Suatu fungsi $f_X(x)$ disebut PDF kontinu jika dan hanya jika ia memenuhi sifat-sifat:

$$f_X(x) \geq 0$$

dan

$$\int_{-\infty}^{\infty} f_X(x)\, dx = 1$$

untuk semua $x \in \mathbb{R}$.

2.5.3. Penyokong Variabel Random

Penyokong (*support*) suatu variabel random didefinisikan sebagai berikut.

Definisi 2.5.4 *(Hogg dkk., 2005) Penyokong dari suatu variabel random, X, adalah nilai-nilai X yang memungkinkan, x, sedemikian sehingga $f_X(x) > 0$.*

Dengan kata lain, penyokong dari suatu variabel random ialah himpunan nilai variabel random tersebut yang mempunyai probabilitas positif.

2.5.4. Distribusi Probabilitas Gabungan

Dalam menyelesaikan berbagai permasalahan yang melibatkan lebih dari satu variabel random, misalnya p variabel random yang termuat dalam vektor $\mathbf{X} = (X_1, X_2, \ldots, X_p)$ dengan nilai-nilai termuat dalam vektor $\mathbf{x} = (x_1, x_2, \ldots, x_p)$, umumnya distribusi probabilitas gabungan (*joint probability distribution*) akan dilibatkan. Untuk kasus diskret, PDF gabungan didefinisikan sebagai berikut.

Definisi 2.5.5 *(Bain dan Engelhardt, 1992) Fungsi kepadatan peluang gabungan (joint probability density function atau joint PDF) dari variabel random diskret berdimensi p, $\mathbf{X} = (X_1, X_2, \ldots, X_p)$, didefinisikan sebagai:*

$$f_{\mathbf{X}}(x_1, x_2, \ldots, x_p) = P(X_1 = x_1, X_2 = x_2, \ldots, X_p = x_p)$$

untuk semua nilai $\mathbf{X}$ yang mungkin, yaitu $\mathbf{x} = (x_1, x_2, \ldots, x_p)$.

Notasi $(X_1 = x_1, X_2 = x_2, \ldots, X_p = x_p)$ dapat dipahami sebagai irisan dari p kejadian, $(X_1 = x_1) \cap (X_2 = x_2) \cap \cdots \cap (X_p = x_p)$.

Suatu PDF gabungan diskret memenuhi sifat-sifat yang tertuang pada teorema berikut.

Teorema 2.5.6 *(Bain dan Engelhardt, 1992) Suatu fungsi, $f_{\mathbf{X}}(x_1, x_2, \ldots, x_p)$, merupakan PDF gabungan diskret dari beberapa vektor variabel random, $\mathbf{X} = (X_1, X_2, \ldots, X_p)$, jika dan hanya jika dipenuhi sifat-sifat berikut:*

$f_{\mathbf{X}}(x_1, x_2, \ldots, x_p) \geq 0$ *untuk semua nilai yang mungkin,* $(x_1, x_2, \ldots, x_p)$,

dan

$$\sum_{\forall x_1} \cdots \sum_{\forall x_p} f_{\mathbf{X}}(x_1, x_2, \ldots, x_p) = 1.$$

Lebih lanjut, CDF gabungan diskret didefinisikan sebagai berikut.

Definisi 2.5.7 *(Bain dan Engelhardt, 1992) Fungsi distribusi kumulatif gabungan (joint cumulative distribution function) dari p variabel random, $\mathbf{X} = (X_1, X_2, \ldots, X_p)$, didefinisikan sebagai:*

$$F_{\mathbf{X}}(x_1, x_2, \ldots, x_p) = P(X_1 \leq x_1, X_2 \leq x_2, \ldots, X_p \leq x_p).$$

Sifat-sifat CDF gabungan dinyatakan dalam teorema di bawah ini.

Teorema 2.5.8 *(Bain dan Engelhardt, 1992) Suatu fungsi, $F_{\mathbf{X}}(x_1, x_2, \ldots, x_p)$, merupakan CDF gabungan dari p variabel random, $\mathbf{X} = (X_1, X_2, \ldots, X_p)$, jika dan hanya jika dipenuhi sifat-sifat berikut:*

$$\lim_{x_i \to -\infty} F_{\mathbf{X}}(x_1, x_2, \ldots, x_p) = 0 \quad \textit{untuk semua } x_i,\ i = 1, \ldots, p;$$

$$\lim_{(x_1, x_2, \ldots, x_p) \to (\infty, \infty, \ldots, \infty)} F_{\mathbf{X}}(x_1, x_2, \ldots, x_p) = 1;$$

$$P(x_{1a} < X_1 \leq x_{1b},\ x_{2a} < X_2 \leq x_{2b},\ \ldots,\ x_{pa} < X_p \leq x_{pb}) \geq 0$$

untuk semua $x_{1a} < x_{1b},\ x_{2a} < x_{2b},\ \ldots,\ x_{pa} < x_{pb}$;

dan

$$\begin{aligned}\lim_{h\to 0^+} F_{\mathbf{X}}(x_1+h, x_2, \ldots, x_p) &= \lim_{h\to 0^+} F_{\mathbf{X}}(x_1, x_2+h, \ldots, x_p) \\ &= \cdots = \lim_{h\to 0^+} F_{\mathbf{X}}(x_1, x_2, \ldots, x_p+h) \\ &= F_{\mathbf{X}}(x_1, x_2, \ldots, x_p)\end{aligned}$$

untuk semua $x_1, x_2, \ldots, x_p$.

Di sisi lain, untuk kumpulan variabel random kontinu, suatu PDF gabungan kontinu memenuhi sifat-sifat yang tertuang pada teorema berikut.

Teorema 2.5.9 *(Bain dan Engelhardt, 1992) Suatu fungsi,* $f_{\mathbf{X}}(x_1, x_2, \ldots, x_p)$*, merupakan PDF gabungan kontinu dari beberapa vektor variabel random,* $\mathbf{X} = (X_1, X_2, \ldots, X_p)$*, jika dan hanya jika dipenuhi sifat-sifat berikut:*

$f_{\mathbf{X}}(x_1, x_2, \ldots, x_p) \geq 0$ *untuk semua nilai yang mungkin,* $(x_1, x_2, \ldots, x_p)$,

dan

$$\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f_{\mathbf{X}}(x_1, x_2, \ldots, x_p)\, dx_1 \cdots dx_p = 1.$$

Lebih lanjut, CDF gabungan kontinu didefinisikan sebagai berikut.

Definisi 2.5.10 *(Bain dan Engelhardt, 1992) Fungsi distribusi kumulatif gabungan (joint cumulative distribution function) dari* p *variabel random,* $\mathbf{X} = (X_1, X_2, \ldots, X_p)$*, didefinisikan sebagai:*

$$F_{\mathbf{X}}(x_1, x_2, \ldots, x_p) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_p} f_{\mathbf{X}}(t_1, t_2, \ldots, t_p)\, dt_1 \cdots dt_p$$

untuk semua $\mathbf{x} = (x_1, \ldots, x_k)$.

Sama halnya pada kasus variabel random tunggal, PDF gabungan kontinu dapat diperoleh sebagai derivatif parsial dari CDF gabungan, yaitu:

$$f_{\mathbf{X}}(x_1, x_2, \ldots, x_p) = \frac{\partial^k}{\partial x_1 \cdots \partial x_p} F_{\mathbf{X}}(x_1, x_2, \ldots, x_p)$$

jika nilai derivatif parsial tersebut ada.

2.5.5. Distribusi Probabilitas Marginal

Nilai-nilai distribusi probabilitas gabungan dari dua buah variabel random umumnya dirangkum dalam sebuah tabel. Pada tabel tersebut, tepi (*margin*) kanan dan bawah menyajikan probabilitas dari tiap nilai yang memungkinkan dari tiap variabel random. Oleh karena itu, dapat didefinisikan suatu fungsi bernama PDF marginal sebagai berikut.

Definisi 2.5.11 *(Bain dan Engelhardt, 1992) Diberikan* $\mathbf{X} = (X_1, X_2, \ldots, X_p)$*, variabel random berdimensi* p *dengan PDF gabungan* $f_{\mathbf{X}}(x_1, x_2, \ldots, x_p)$*. Jika* $\mathbf{X}$ *diskret, PDF marginal dari* X_j *adalah:*

$$f_{X_j}(x_j) = \sum_{\forall i \neq j} \cdots \sum f_{X_1,\ldots,X_j,\ldots,X_p}(x_1, \ldots, x_j, \ldots, x_p),$$

sedangkan jika $\mathbf{X}$ *kontinu, PDF marginal dari* X_j *adalah:*

$$f_{X_j}(x_j) = \int_{\forall i \neq j} \cdots \int f_{X_1,\ldots,X_j,\ldots,X_p}(x_1, \ldots, x_j, \ldots, x_p)\, dx_1 \cdots dx_p.$$

Secara umum, pendekatan umum untuk mendefinisikan distribusi marginal ialah melalui CDF marginal yang didefinisikan sebagai berikut.

Definisi 2.5.12 *(Bain dan Engelhardt, 1992) Diberikan* $\mathbf{X} = (X_1, X_2, \ldots, X_p)$*, variabel random berdimensi* p *dengan CDF gabungan* $F_{\mathbf{X}}(x_1, x_2, \ldots, x_p)$*. CDF marginal dari* X_j *adalah:*

$$F_{X_j}(x_j) = \lim_{x_i \to \infty} F_{\mathbf{X}}(x_1, x_2, \ldots, x_p), \quad \forall i \neq j.$$

2.6. Sifat-Sifat Variabel Random

Variabel random mempunyai berbagai sifat yang dinyatakan sebagai ukuran-ukuran deskriptif. Beberapa sifat tersebut ialah ekspektasi, variansi, deviasi standar, kovariansi, dan korelasi.

2.6.1. Ekspektasi

Ekspektasi dari suatu variabel random diskret didefinisikan sebagai berikut.

Definisi 2.6.1 *(Bain dan Engelhardt, 1992) Ekspektasi dari suatu variabel random diskret, X, dengan PDF diskret $f_X(x)$ didefinisikan sebagai:*

$$E[X] = \sum_{\forall x} x f_X(x) \tag{2.8}$$

dengan x adalah semua nilai yang mungkin dari X, $x = x_1, x_2, \ldots$.

Sementara, ekspektasi dari suatu variabel random kontinu diberikan sebagai berikut.

Definisi 2.6.2 *(Bain dan Engelhardt, 1992) Untuk suatu variabel random kontinu, X, dengan PDF kontinu $f_X(x)$, ekspektasi dari X didefinisikan sebagai:*

$$E[X] = \int_{-\infty}^{\infty} x f_X(x)\, dx \tag{2.9}$$

jika integralnya konvergen.

Akibat dari Definisi 2.6.2 ialah jika integral tidak konvergen, maka $E[X]$ tidak ada. Ekspektasi juga disebut sebagai "mean" atau "nilai harapan" dan untuk sembarang variabel random, X, ekspektasi dapat dinotasikan pula sebagai μ_X.

Salah satu sifat yang terdapat pada ekspektasi ialah linearitas, yang diberikan pada teorema berikut.

Teorema 2.6.3 *(Bain dan Engelhardt, 1992) Jika X adalah suatu variabel random dengan PDF $f_X(x)$, nilai-nilai yang mungkin $x_1, x_2, \ldots$, dan suatu fungsi bernilai real $u(x)$ yang domainnya adalah $x = \{x_1, x_2, \ldots\}$, maka:*

$$E[u(X)] = \sum_{\forall x} u(x) f_X(x), \qquad \textit{jika } X \textit{ diskret; dan} \tag{2.10}$$

$$E[u(X)] = \int_{-\infty}^{\infty} u(x) f_X(x)\, dx, \qquad \textit{jika } X \textit{ kontinu.} \tag{2.11}$$

2.6.2. Variansi

Variansi dari suatu variabel random didefinisikan sebagai berikut.

Definisi 2.6.4 *(Bain dan Engelhardt, 1992) Variansi dari suatu variabel random, X, dirumuskan sebagai:*

$$\mathrm{Var}(X) = E\big[(X - E[X])^2\big]. \tag{2.12}$$

Variansi dapat dipandang sebagai bentuk khusus dari sifat linearitas ekspektasi, yaitu Persamaan (2.10) atau (2.11) dengan $u(x) = (x - \mu_X)^2$. Variansi dari suatu variabel random, X, juga dapat dinotasikan sebagai σ_X^2 atau $V(X)$. Variansi menyatakan ukuran variabilitas atau sebaran dari distribusi suatu variabel random.

2.6.3. Deviasi Standar

Definisi deviasi standar diberikan sebagai berikut.

Definisi 2.6.5 *(Bain dan Engelhardt, 1992) Deviasi standar dari suatu variabel random, X, adalah akar kuadrat positif dari variansinya, yaitu:*

$$\sigma_X = \sqrt{\mathrm{Var}(X)}.$$

Deviasi standar dari suatu variabel random, X, juga dapat dinotasikan sebagai $\mathrm{SD}(X)$.

2.6.4. Kovariansi

Kovariansi merupakan salah satu sifat variabel random yang melibatkan dua buah variabel random. Kovariansi didefinisikan sebagai berikut.

Definisi 2.6.6 *(Bain dan Engelhardt, 1992) Kovariansi dari dua buah variabel random, X dan Y, ialah ukuran hubungan antara kedua variabel random yang dirumuskan sebagai:*

$$\mathrm{Cov}(X, Y) = E\big[(X - E[X])(Y - E[Y])\big] = E[XY] - E[X]E[Y]. \qquad (2.13)$$

Kovariansi dari dua buah variabel random, X dan Y, juga dapat dinotasikan dengan lambang σ_{XY}.

Sifat-sifat kovariansi diberikan sebagai berikut.

Teorema 2.6.7 *(Bain dan Engelhardt, 1992) Jika X dan Y adalah dua buah variabel random serta a dan b adalah dua buah konstanta, maka terpenuhi sifat-sifat kovariansi berikut:*

$$\mathrm{Cov}(aX, bY) = ab\,\mathrm{Cov}(X, Y);$$

$$\mathrm{Cov}(X + a, Y + b) = \mathrm{Cov}(X, Y);\ \textit{dan}$$
$$\mathrm{Cov}(X, aX + b) = a\mathrm{Var}(X).$$

Selain itu, untuk dua buah variabel random yang saling independen, berlaku pula sifat kovariansi berikut.

Teorema 2.6.8 *(Bain dan Engelhardt, 1992) Jika X dan Y adalah dua buah variabel random yang saling independen, maka* $\mathrm{Cov}(X, Y) = 0$.

2.6.5. Korelasi

Korelasi antara dua buah variabel random didefinisikan sebagai berikut.

Definisi 2.6.9 *(Bain dan Engelhardt, 1992) Jika X dan Y adalah dua buah variabel random dengan variansi berturut-turut σ_X^2 dan σ_Y^2 serta kovariansi σ_{XY}, maka koefisien korelasi dari X dan Y diberikan sebagai:*

$$\rho_{XY} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}. \tag{2.14}$$

Korelasi dari dua buah variabel random, X dan Y, juga dapat dinotasikan sebagai $\mathrm{Cor}(X, Y)$.

Jika variabel random X dan Y mempunyai $\rho = 0$, kedua variabel random tersebut dikatakan tidak berkorelasi. Pada keadaan lainnya, kedua variabel random disebut berkorelasi.

2.7. Analisis Multivariat

Menurut Johnson dan Winchern (2007), analisis multivariat adalah metode-metode statistik dan pengukuran terhadap data yang terdiri atas banyak variabel. Analisis multivariat bertujuan untuk mengumpulkan informasi berdasarkan kumpulan variabel yang terlibat dalam penelitian-penelitian ilmiah.

Berdasarkan tujuannya, terdapat lima kelompok analisis multivariat, yaitu:

1. Reduksi data atau penyederhanaan struktur data, yang ditujukan untuk memaparkan suatu fenomena dengan cara yang sesederhana mungkin tanpa menghilangkan informasi yang bernilai;

2. Pengurutan dan pengelompokan objek atau variabel berdasarkan kesamaan ciri-ciri tertentu;
3. Identifikasi dependensi antarvariabel;
4. Prediksi yang didasarkan pada hubungan antarvariabel; dan
5. Penyusunan dan pengujian hipotesis atas parameter-parameter populasi multivariat, yang ditujukan untuk memvalidasi asumsi-asumsi tertentu atau memperkuat temuan-temuan ilmiah terdahulu.

Data yang dilibatkan dalam analisis multivariat terdiri atas banyak variabel. Secara umum, data multivariat tersaji dalam wujud larik $\mathbf{X}$ sebagai berikut:

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1k} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2k} & \cdots & x_{2p} \\ \vdots & \vdots & & \vdots & & \vdots \\ x_{j1} & x_{j2} & \cdots & x_{jk} & \cdots & x_{jp} \\ \vdots & \vdots & & \vdots & & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nk} & \cdots & x_{np} \end{bmatrix}.$$

Larik $\mathbf{X}$ di atas terdiri atas n baris dan $p \geq 1$ kolom. Baris melambangkan *item*, individu, atau unit eksperimen, sedangkan kolom mewakili variabel atau karakteristik yang diamati dari tiap *item*. Notasi x_{jk} dapat diinterpretasikan sebagai nilai variabel ke-k dari *item* ke-j.

Serupa halnya dengan data multivariat itu sendiri, statistik-statistik deskriptif dari suatu data multivariat, seperti mean, variansi, dan kovariansi, juga disajikan sebagai larik. Vektor mean dan matriks kovariansi didefinisikan pada subbab-subbab di bawah ini.

2.7.1. Vektor Mean

Misalkan p variabel random terkumpul dalam sebuah vektor,

$$\mathbf{X}' = [X_1, X_2, \ldots, X_p]. \tag{2.15}$$

Maka, tiap elemen $\mathbf{X}'$, yaitu $X_i,\ i = 1, \ldots, p$, adalah suatu variabel random dengan distribusi probabilitas marginal masing-masing. Ekspektasi marginal dari tiap X_i

didefinisikan sebagai:

$$\mu_i = E[X_i] = \begin{cases} \sum_{\forall x_i} x_i f_{X_i}(x_i), & \text{jika } X_i \text{ adalah variabel random diskret;} \\ \int_{-\infty}^{\infty} x_i f_{X_i}(x_i)\, dx_i, & \text{jika } X_i \text{ adalah variabel random kontinu;} \end{cases}$$

dengan $f_{X_i}(x_i)$ adalah PDF dari X_i.

Kumpulan ekspektasi dari vektor random $\mathbf{X}$ pada Persamaan (2.15) dapat dinyatakan sebagai vektor mean berikut:

$$E[\mathbf{X}] = \begin{bmatrix} E[X_1] \\ E[X_2] \\ \vdots \\ E[X_p] \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} = \boldsymbol{\mu}.$$

(Johnson dan Winchern, 2007)

2.7.2. Matriks Kovariansi

Misalkan p variabel random dikumpulkan dalam sebuah vektor sebagaimana diberikan pada Persamaan (2.15). Variansi dari tiap X_i didefinisikan sebagai:

$$\sigma_i^2 = \begin{cases} \sum_{\forall x_i} (x_i - \mu_i)^2 f_{X_i}(x_i), & \text{jika } X_i \text{ adalah variabel random diskret;} \\ \int_{-\infty}^{\infty} (x_i - \mu_i)^2 f_{X_i}(x_i)\, dx_i, & \text{jika } X_i \text{ adalah variabel random kontinu;} \end{cases}$$

dengan $f_{X_i}(x_i)$ adalah PDF dari X_i. Lebih lanjut, hubungan antara tiap pasang variabel random, X_i dan X_k, dapat dinyatakan sebagai kovariansi yang dirumuskan sebagai berikut:

$$\sigma_{ik} = E[(X_i - \mu_i)(X_k - \mu_k)] \tag{2.16}$$

$$= \begin{cases} \sum_{\forall x_i} \sum_{\forall x_k} (x_i - \mu_i)(x_k - \mu_k) f_{X_i,X_k}(x_i, x_k); \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x_i - \mu_i)(x_k - \mu_k) f_{X_i,X_k}(x_i, x_k)\, dx_i\, dx_k \end{cases} \tag{2.17}$$

dengan $f_{X_i,X_k}(x_i, x_k)$ adalah PDF gabungan dari X_i dan X_k serta $i, k = 1, \ldots, p$. Kasus pertama berlaku untuk X_i dan X_k merupakan variabel-variabel random diskret, sedangkan kasus kedua untuk X_i dan X_k merupakan variabel-variabel random

kontinu. Melalui definisi kovariansi pada Persamaan (2.17), variansi marginal dari tiap X_i juga dapat dinotasikan sebagai σ_{ii}.

Serupa halnya dengan vektor mean, berdasarkan Johnson dan Winchern (2007), kumpulan variansi dan kovariansi dari vektor random, $\mathbf{X}$, dapat dinyatakan sebagai matriks variansi-kovariansi yang didefinisikan sebagai berikut:

$$
\begin{aligned}
\boldsymbol{\Sigma} &= \mathrm{Cov}(\mathbf{X}) \\
&= E\big[(\mathbf{X}-\boldsymbol{\mu})(\mathbf{X}-\boldsymbol{\mu})'\big] \\
&= E\left[\begin{bmatrix} X_1-\mu_1 \\ X_2-\mu_2 \\ \vdots \\ X_p-\mu_p \end{bmatrix}\begin{bmatrix} X_1-\mu_1 & X_2-\mu_2 & \cdots & X_p-\mu_p \end{bmatrix}\right] \\
&= E\begin{bmatrix} (X_1-\mu_1)^2 & (X_1-\mu_1)(X_2-\mu_2) & \cdots & (X_1-\mu_1)(X_p-\mu_p) \\ (X_2-\mu_2)(X_1-\mu_1) & (X_2-\mu_2)^2 & \cdots & (X_2-\mu_2)(X_p-\mu_p) \\ \vdots & \vdots & \ddots & \vdots \\ (X_p-\mu_p)(X_1-\mu_1) & (X_p-\mu_p)(X_2-\mu_2) & \cdots & (X_p-\mu_p)^2 \end{bmatrix} \\
&= \begin{bmatrix} E[(X_1-\mu_1)^2] & E[(X_1-\mu_1)(X_2-\mu_2)] & \cdots & E[(X_1-\mu_1)(X_p-\mu_p)] \\ E[(X_2-\mu_2)(X_1-\mu_1)] & E[(X_2-\mu_2)^2] & \cdots & E[(X_2-\mu_2)(X_p-\mu_p)] \\ \vdots & \vdots & \ddots & \vdots \\ E[(X_p-\mu_p)(X_1-\mu_1)] & E[(X_p-\mu_p)(X_2-\mu_2)] & \cdots & E[(X_p-\mu_p)^2] \end{bmatrix} \\
&= \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix}. \qquad (2.18)
\end{aligned}
$$

Salah satu sifat matriks kovariansi ialah semidefinit positif. Jika ditentukan suatu vektor sembarang berukuran $m \times 1$, $\mathbf{a}$, diperoleh bentuk kuadrat dari suatu matriks kovariansi yang dibangun dari p variabel random, $\boldsymbol{\Sigma}$, sebagai:

$$\mathbf{a}'\boldsymbol{\Sigma}\mathbf{a} = \mathbf{a}'E\big[(\mathbf{X}-\boldsymbol{\mu})(\mathbf{X}-\boldsymbol{\mu})'\big]\mathbf{a}. \qquad (2.19)$$

Oleh karena sifat linearitas ekspektasi, Persamaan (2.19) dapat dituliskan kembali

sebagai:

$$\mathbf{a}'\boldsymbol{\Sigma}\mathbf{a} = E\big[\mathbf{a}'(\mathbf{X}-\boldsymbol{\mu})(\mathbf{X}-\boldsymbol{\mu})'\mathbf{a}\big].$$

Diperhatikan bahwa $\mathbf{a}'(\mathbf{X}-\boldsymbol{\mu})$ dan $(\mathbf{X}-\boldsymbol{\mu})'\mathbf{a}$ merupakan dua buah skalar yang sama. Jika kedua skalar tersebut dinyatakan sebagai suatu variabel random, Y, maka:

$$\mathbf{a}'\boldsymbol{\Sigma}\mathbf{a} = E\big[Y^2\big]. \tag{2.20}$$

Y^2 juga dapat dipandang sebagai suatu variabel random yang nonnegatif. Mengingat bahwa PMF dan PDF selalu bernilai nonnegatif untuk tiap nilai yang mungkin dari suatu variabel random, ekspektasi dari Y^2 bernilai nonnegatif. Dengan demikian, bentuk kuadrat pada Persamaan (2.20) bernilai nonnegatif, membuktikan bahwa matriks kovariansi merupakan sebuah matriks semidefinit positif.

Selayaknya matriks persegi lainnya, matriks kovariansi invers, $\boldsymbol{\Sigma}^{-1}$, terdefinisi untuk suatu matriks kovariansi, $\boldsymbol{\Sigma}$, jika $\boldsymbol{\Sigma}$ nonsingular.

2.7.3. Jarak Euclid

Johnson dan Winchern (2007) menyebutkan bahwa kebanyakan analisis multivariat didasarkan pada konsep sederhana tentang jarak. Salah satu ukuran jarak yang cukup terkenal adalah jarak Euclid (*Euclidean distance*). Rumusan jarak Euclid diberikan sebagai berikut.

Definisi 2.7.1 *(Johnson dan Winchern, 2007) Jarak garis lurus atau jarak Euclid antara dua titik sembarang, $P = (x_1, x_2, \ldots, x_p)$ dan $Q = (y_1, y_2, \ldots, y_p)$, diberikan sebagai:*

$$d(P,Q) = \sqrt{(x_1-y_1)^2 + (x_2-y_2)^2 + \ldots + (x_p-y_p)^2}. \tag{2.21}$$

Dengan memandang titik P sebagai vektor $\mathbf{p}$ dan titik Q sebagai vektor $\mathbf{q}$, Persamaan (2.21) ekuivalen dengan operasi vektor berikut:

$$d(\mathbf{p},\mathbf{q}) = \sqrt{(\mathbf{p}-\mathbf{q})'(\mathbf{p}-\mathbf{q})}.$$

2.7.4. Analisis Klaster

Menurut Johnson dan Winchern (2007), analisis klaster adalah metode pengelompokan data yang tidak mengasumsikan banyak atau struktur kelompok. Pe-

ngelompokan dilakukan berdasarkan kesamaan atau ketaksamaan yang umumnya diindikasikan oleh jarak. Jarak Euclid merupakan pilihan jarak yang baik dalam analisis klaster.

Secara umum, Han dkk. (2012) mengelompokkan metode-metode analisis klaster menjadi empat, yaitu partisi, hierarkis, berbasis kepadatan, dan berbasis *grid*. Metode-metode partisi mempartisi sekumpulan data mula-mula menjadi K klaster, lalu mengembangkan kualitas klaster-klaster yang terbentuk melalui relokasi iteratif. Partisi yang baik mengelompokkan objek-objek yang serupa dalam satu klaster dan objek-objek yang berbeda dalam klaster yang berbeda. Metode-metode hierarkis melibatkan peleburan (aglomerasi) atau pembagian (divisi) dari sekumpulan data. Sementara, metode-metode berbasis kepadatan merupakan pengembangan dari metode-metode partisi. Metode-metode berbasis kepadatan membentuk klaster-klaster sedemikian sehingga jumlah objek tetangga di sekitar suatu objek pada radius tertentu setidaknya mencapai batas jumlah tertentu. Adapun metode-metode berbasis *grid* menguantisasi ruang objek menjadi sejumlah sel yang membentuk suatu struktur *grid*. Metode-metode ini efisien untuk permasalahan-permasalahan data spasial.

2.8. Distribusi Probabilitas

Berikut merupakan beberapa jenis distribusi probabilitas.

2.8.1. Distribusi Bernoulli

Menurut Bain dan Engelhardt (1992), percobaan Bernoulli ialah pelaksanaan suatu eksperimen dengan hanya dua kemungkinan luaran. Jika kemungkinan luaran tersebut dilambangkan dengan E dan E', maka variabel Bernoulli dapat didefinisikan melalui persamaan:

$$X(e) = \begin{cases} 1, & \text{jika } e \in E \\ 0, & \text{jika } e \in E' \end{cases}.$$

Distribusi yang berkorespondensi dengan variabel Bernoulli disebut distribusi Bernoulli, yang didefinisikan sebagai berikut.

Definisi 2.8.1 *(Bain dan Engelhardt, 1992) Suatu variabel random, X, mengikuti distribusi Bernoulli jika variabel random tersebut mempunyai PDF:*

$$f_X(x) = p^x q^{1-x}, \quad x = 0, 1.$$

Dengan kata lain, $f_X(0) = q$ dan $f_X(1) = p$.

2.8.2. Distribusi Binomial

Percobaan Bernoulli sering kali dilakukan secara berulang dan saling independen. Jika terdapat n percobaan Bernoulli yang saling independen dan peluang sukses pada tiap percobaan ialah p, maka dapat didefinisikan suatu variabel random, X, yang menyatakan banyaknya sukses dari serangkaian percobaan tersebut. Variabel random X tersebut mempunyai distribusi binomial yang didefinisikan sebagai berikut.

Definisi 2.8.2 *(Bain dan Engelhardt, 1992) Suatu variabel random, X, mengikuti distribusi binomial jika variabel random tersebut mempunyai PDF:*

$$f_X(x; n, p) = \binom{n}{x} p^x q^{n-x}, \quad x = 0, 1, \ldots, n.$$

Variabel random pada Definisi 2.8.2 di atas dapat dinotasikan sebagai $X \sim \text{BIN}(n, p)$.

2.8.3. Distribusi Poisson

Distribusi Poisson didefinisikan sebagai berikut.

Definisi 2.8.3 *(Bain dan Engelhardt, 1992) Suatu variabel random diskret, X, mengikuti distribusi Poisson dengan parameter $\mu > 0$ jika variabel random tersebut mempunyai PDF:*

$$f_X(x; \mu) = \frac{e^{-\mu}\mu^x}{x!}, \quad x = 0, 1, 2, \ldots.$$

Variabel random pada Definisi 2.8.3 di atas dapat dinotasikan sebagai $X \sim \text{POI}(\mu)$.

2.8.4. Distribusi Uniform

Barisan bilangan random berkaitan erat dengan distribusi uniform. Definisi dari distribusi uniform diberikan sebagai berikut.

Definisi 2.8.4 *(Bain dan Engelhardt, 1992) Suatu variabel random, X, mengikuti distribusi uniform pada interval (a, b) jika variabel random tersebut mempunyai PDF:*

$$f_X(x; a, b) = \frac{1}{b-a}, \quad a < x < b,$$

dan bernilai nol untuk nilai x lainnya.

Variabel random pada Definisi 2.8.4 di atas dapat dinotasikan sebagai $X \sim$ UNIF(a, b).

2.8.5. Distribusi Normal

Distribusi normal didefinisikan sebagai berikut.

Definisi 2.8.5 *(Bain dan Engelhardt, 1992) Suatu variabel random, X, mengikuti distribusi normal atau distribusi Gauss dengan mean μ dan variansi σ^2 jika variabel random tersebut mempunyai PDF (kontinu):*

$$f_X(x; \mu, \sigma^2) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{(\frac{x-\mu}{\sigma})^2}{2}\right\} \tag{2.22}$$

untuk $-\infty < x < \infty$, dengan $-\infty < \mu < \infty$ dan $0 < \sigma < \infty$.

Variabel random pada Definisi 2.8.5 dapat dinotasikan sebagai $X \sim \text{N}(\mu, \sigma^2)$.

Dengan melakukan substitusi $z = (x - \mu)/\sigma$ terhadap PDF normal pada Persamaan (2.22), diperoleh PDF normal standar yang dinotasikan sebagai $\phi(z)$ dan dirumuskan sebagai:

$$\phi(z) = \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{z^2}{2}\right\}, \quad -\infty < z < \infty. \tag{2.23}$$

CDF normal standar yang berkorespondensi dirumuskan sebagai:

$$\Phi(z) = \int_{-\infty}^{z} \phi(t)\, dt. \tag{2.24}$$

Suatu variabel random, Z, yang berdistribusi normal standar dapat dinotasikan sebagai $Z \sim \mathrm{N}(0,1)$.

Suatu variabel random yang berdistribusi normal memenuhi teorema berikut.

Teorema 2.8.6 *(Bain dan Engelhardt, 1992) Jika suatu variabel random* $X \sim N(\mu, \sigma^2)$*, maka terpenuhi teorema bahwa:*

$$Z = \frac{X - \mu}{\sigma} \sim N(0,1)$$

dan

$$F_X(x) = \Phi\left(\frac{X - \mu}{\sigma}\right).$$

Distribusi normal umum digunakan dalam pengambilan keputusan, penentuan jenis uji hipotesis, hingga pembangkitan bilangan random.

2.9. Bilangan *Pseudo-Random*

Sebagai istilah yang lebih umum, barisan bilangan random perlu dipahami terlebih dahulu.

Definisi 2.9.1 *(Ripley, 1987) Barisan bilangan random,* $\{U_i\}$*, adalah sebuah barisan beranggotakan variabel-variabel random independen yang berdistribusi uniform pada interval* $(0,1)$.

Dari segi kebahasaan, awalan "*pseudo-*" berarti palsu. Maka, definisi bilangan *pseudo-random* sangat erat dengan bilangan random, tetapi tidak serupa.

Definisi 2.9.2 *(Ripley, 1987) Suatu barisan bilangan pseudo-random,* $\{U_i\}$*, adalah sebuah barisan bilangan deterministik dalam interval* $[0,1]$ *yang mempunyai sifat-sifat statistik yang relevan dengan suatu barisan bilangan random.*

Pada Definisi 2.9.2 di atas, "sifat statistik yang relevan" bermaksud bahwa pengujian statistik apapun yang bertujuan untuk menguji kerandoman terhadap bagian berhingga dari $\{U_i\}$ tidak menolak hipotesis nol, yaitu bahwa data bilangan tersebut bersifat random (Ripley, 1987).

2.10. Sampel Random

Suatu kumpulan variabel random dapat disebut sebagai sampel random jika memenuhi definisi berikut.

Definisi 2.10.1 *(Bain dan Engelhardt, 1992) Suatu himpunan variabel random, $X_1, \ldots, X_n$, disebut sampel random berukuran n dari sebuah populasi dengan PDF $f_X(x)$ jika PDF gabungan dari himpunan variabel random tersebut berbentuk:*

$$f_{X_1,\ldots,X_n}(x_1, x_2, \ldots, x_n) = f_{X_1}(x_1) f_{X_2}(x_2) \cdots f_{X_n}(x_n) = \prod_{i=1}^{n} f_{X_i}(x_i).$$

Dengan kata lain, himpunan variabel random, $X_1, \ldots, X_n$, disebut sampel random dari suatu variabel random, X, jika variabel-variabel random tersebut saling independen dan mempunyai distribusi yang sama dengan X. Pada peristiwa ini, dapat disebutkan bahwa $X_1, \ldots, X_n$ bersifat IID (*independent and identically distributed*).

2.11. Pengujian Hipotesis

Berdasarkan Hogg dkk. (2005), salah satu permasalahan dalam bidang statistik adalah diberikan suatu variabel random, X, dengan PDF $f_X(x; \theta)$, tetapi parameter distribusinya, yaitu θ, tidak diketahui. Parameter θ adalah elemen dari suatu himpunan tertentu, Ω. Jika ditentukan ω_0 dan ω_1 adalah dua buah sub-himpunan dari Ω serta $\omega_0 \cup \omega_1 = \Omega$, pasangan hipotesis diberikan sebagai berikut:

$$H_0 : \theta \in \omega_0 \text{ versus } H_1 : \theta \in \omega_1.$$

H_0 disebut hipotesis nol (*null hypothesis*), sedangkan H_1 disebut hipotesis alternatif.

Misalkan $\mathcal{S}$ adalah penyokong dari sampel random, $\mathbf{X}' = (X_1, \ldots, X_n)$. Pengujian H_0 terhadap H_1 didasarkan pada himpunan $C \subseteq \mathcal{S}$ yang disebut daerah kritik. Daerah kritik berkorespondensi dengan penolakan hipotesis nol sehingga aturan pengambilan keputusan dari suatu pengujian hipotesis ialah:

$$\text{tolak } H_0, \text{ jika } \mathbf{X} \in C;$$

$$\text{terima } H_0, \text{ jika } \mathbf{X} \in C^c.$$

Untuk suatu daerah kritik, terdapat empat kemungkinan hasil yang terangkum pada Tabel 2.1. Galat tipe I (*type I error*) terjadi apabila H_0 ditolak ketika H_0

Tabel 2.1 Tabel Keputusan 2 $\times$ 2 Pengujian Hipotesis

Keputusan	Kejadian Sesungguhnya	
	H_0 benar	H_1 benar
Tolak H_0	Galat tipe I	Keputusan tepat
Terima H_0	Keputusan tepat	Galat tipe II

benar, sedangkan galat tipe II (*type II error*) terjadi apabila H_0 diterima ketika H_1 benar. Galat tipe I sering kali dipandang lebih buruk daripada galat tipe II sehingga dalam suatu pengujian hipotesis, dipilih daerah-daerah kritik dengan batasan α yang didefinisikan sebagai berikut.

Definisi 2.11.1 *(Hogg dkk., 2005) Suatu daerah kritik, C, dikatakan berukuran α jika*

$$\alpha = \max_{\theta \in \omega_0} P_\theta[(X_1, \ldots, X_n) \in C].$$

Selain sebagai ukuran uji, α juga dapat dipahami sebagai probabilitas terjadinya galat tipe I yang disebut juga tingkat signifikansi suatu uji hipotesis (Bain dan Engelhardt, 1992). Dari antara daerah-daerah kritik berukuran α ini, dipilih daerah kritik yang meminimalkan probabilitas galat tipe II, yaitu β. Dengan kata lain, daerah kritik yang dipilih memaksimalkan probabilitas H_0 ditolak ketika H_1 benar, yaitu memaksimalkan:

$$1 - \beta = P_\theta[(X_1, \ldots, X_n) \in C], \quad \theta \in \omega_1. \tag{2.25}$$

Probabilitas pada ruas kanan Persamaan (2.25) disebut kekuatan pengujian di θ. Probabilitas ini dapat didefinisikan sebagai fungsi kekuatan (*power function*) sebagai berikut.

Definisi 2.11.2 *(Hogg dkk., 2005) Fungsi kekuatan dari suatu daerah kritik, C,*

didefinisikan sebagai:

$$\gamma_C(\theta) = P_\theta[(X_1, \ldots, X_n) \in C], \quad \theta \in \omega_1.$$

Jika diberikan dua buah daerah kritik, C_1 dan C_2, yang keduanya berukuran α, C_1 dikatakan lebih baik daripada C_2 jika $\gamma_{C_1}(\theta) > \gamma_{C_2}(\theta)$ untuk seluruh $\theta \in \omega_1$.

Sejauh perkembangan ilmu statistika dan implementasinya pada penelitian di berbagai bidang ilmu, tidak pernah ditentukan ukuran α yang terbaik untuk menolak H_0 dan mendukung H_1 secara kuat, maka tiap peneliti dapat menentukan nilai α secara subjektif dan memperoleh kesimpulan yang berbeda untuk sekumpulan data yang sama dan penelitian yang sama. Guna menangani permasalahan ini, diperlukan suatu ukuran bernama *p-value* (nilai *p*) yang didefinisikan sebagai berikut.

Definisi 2.11.3 *(Bain dan Engelhardt, 1992) Suatu p-value dari suatu pengujian hipotesis ialah nilai α terkecil yang mampu menolak H_0 berdasarkan nilai teramati dari statistik uji yang bersangkutan.*

2.12. Uji Kolmogorov-Smirnov

Uji Kolmogorov-Smirnov merupakan suatu uji *goodness-of-fit*, yaitu uji statistik yang membandingkan kesamaan distribusi suatu sampel data teramati dengan suatu distribusi populasi teoritis yang diharapkan berdasarkan distribusi frekuensi kumulatif dari kedua distribusi tersebut. Data yang dilibatkan dalam suatu uji Kolmogorov-Smirnov diasumsikan berasal dari suatu distribusi kumulatif kontinu sehingga uji ini dapat digunakan untuk data yang setidaknya berskala ordinal (Kraska-Miller, 2013).

Dalam menguji normalitas data, yaitu apakah suatu sampel data mengikuti distribusi normal dengan parameter-parameter tertentu, pasangan hipotesis uji Kolmogorov-Smirnov dinyatakan sebagai:

H_0 : Data terdistribusi normal;

H_1 : Data tidak terdistribusi normal.

Statistik uji yang digunakan adalah selisih maksimum antara distribusi sampel dengan distribusi teoritis yang disebut deviansi maksimum (D) dan didefinisikan sebagai:

$$D = \max |F_0(x_i) - S_n(x_i)|, \quad i = 1, 2, \ldots, N$$

dengan $F_0(x_i)$ adalah nilai terduga (terhipotesis) dari x_i dan $S_n(x_i)$ adalah nilai teramati dari x_i. Hipotesis nol ditolak jika D bernilai lebih besar dari nilai kritik, $D_{\alpha,N}$, yang bergantung pada ukuran uji, α, dan ukuran sampel, N.

Uji-uji *goodness-of-fit*, seperti uji Kolmogorov-Smirnov, berperan penting ketika terdapat asumsi distribusi teoritis yang perlu dipenuhi oleh data sampel dalam kerangka suatu metode statistik. Akan tetapi, ketika berhadapan dengan sampel data runtun waktu, diperlukan metode-metode lain untuk menginterpretasikan dan memodelkan dinamika data tersebut dalam kurun waktu data yang bersangkutan. Pada umumnya, metode-metode dengan kapabilitas tersebut didasari oleh konsep proses stokastik, yang diberikan pada subbab berikut.

2.13. Proses Stokastik

Menurut Ross (2010), proses stokastik adalah sekumpulan variabel random yang menjelaskan evolusi suatu proses seiring waktu. Secara umum, proses stokastik dinotasikan sebagai $\{X(t), t \in T\}$. t sering kali diinterpretasikan sebagai waktu yang termuat dalam himpunan indeks, T. Jika T adalah himpunan tercacah, maka proses stokastik disebut proses waktu diskret (*discrete-time process*). Sementara, jika T adalah himpunan nilai dalam suatu interval bilangan real, maka proses stokastik disebut proses waktu kontinu (*continuous-time process*). $X(t)$ dimaknai sebagai *state* proses pada waktu ke-t dan juga dapat dinotasikan sebagai X_t. Himpunan semua nilai yang memungkinkan dari $X(t)$ disebut ruang *state* (*state space*) dari proses stokastik.

2.13.1. Rantai Markov

Rantai Markov merupakan salah satu proses stokastik khusus dengan definisi diberikan sebagai berikut.

Definisi 2.13.1 *(Ross, 2010) Diberikan suatu proses stokastik,* $\{X_t, t = 0, 1, 2, \ldots\}$*, dengan ruang state tercacah. Rantai Markov adalah sebuah model probabilitas dari suatu barisan nilai proses stokastik yang berurutan,* $X_0, X_1, X_2, \ldots$*, yang memenuhi asumsi berikut:*

$$P\big(X_{t+1} = j | X_t = i,\, X_{t-1} = i_{t-1}, \ldots,\, X_1 = i_1,\, X_0 = i_0\big) = P_{ij},$$

dengan $X_t = i$ *berarti proses berada pada state* i *pada waktu* t *dan* P_{ij} *adalah probabilitas proses pada state* i *menuju state* j*, untuk seluruh state,* $i_0, i_1, \ldots, i_{t-1}, i, j \geq 0$*, dan seluruh* $t \geq 0$*.*

Dengan kata lain, rantai Markov memenuhi asumsi bahwa jika diberikan proses-proses saat ini dan masa lalu, probabilitas bersyarat dari proses yang akan datang, X_{t+1}, hanya bergantung pada proses saat ini, X_t.

Dengan adanya sifat probabilitas, rantai Markov memenuhi:

$$\begin{aligned} &P_{ij} \geq 0; \\ &i, j \geq 0; \text{ dan} \\ &\sum_{j=0}^{\infty} P_{ij} = 1, \quad i = 0, 1, \ldots. \end{aligned}$$

Nilai-nilai probabilitas transisi satu tahap, P_{ij}, dapat dikumpulkan dalam matriks $\mathbf{P}$ yang didefinisikan sebagai:

$$\mathbf{P} = \begin{bmatrix} P_{00} & P_{01} & P_{02} & \cdots \\ P_{10} & P_{11} & P_{12} & \cdots \\ \vdots & \vdots & \vdots & \\ P_{i0} & P_{i1} & P_{i2} & \cdots \\ \vdots & \vdots & \vdots & \end{bmatrix}.$$

Matriks $\mathbf{P}$ di atas disebut sebagai matriks transisi.

2.13.2. Proses *Random Walk*

Definisi proses *random walk* diberikan sebagai berikut.

Definisi 2.13.2 *(Ross, 2010) Suatu rantai Markov dengan ruang state berupa bilangan-bilangan bulat,* $i = 0, \pm 1, \pm 2, \ldots$*, disebut random walk jika untuk beberapa bilangan,* $0 < p < 1$*, dipenuhi:*

$$P_{i,i+1} = p = 1 - P_{i,i-1}, \quad i = 0, \pm 1, \ldots .$$

Proses *random walk* dinamakan demikian karena dapat dimodelkan seperti seseorang yang berjalan pada suatu garis lurus yang pada tiap titik waktu akan berjalan ke salah satu arah dengan peluang p atau ke arah lainnya dengan peluang $(1 - p)$.

Salah satu aplikasi umum dari proses *random walk* ialah peramalan harga aset perusahaan. Dalam hal ini, proses *random walk* mendasari bahwa harga aset merupakan suatu nilai acak yang tidak dapat diprediksi menggunakan informasi historisnya. Keacakan ini dipengaruhi oleh situasi ekonomi yang tidak terlepas dari peran dan kondisi perusahaan-perusahaan dalam suatu negara. Bahasan mengenai perusahaan termuat pada subbab berikut.

2.14. Perusahaan

Menurut Berk dan DeMarzo (2016), perusahaan atau korporasi merupakan salah satu bentuk badan usaha yang diakui secara hukum sebagai suatu entitas hukum yang terpisah dari pemilik-pemilik-nya. Perusahaan dicirikan dengan tidak adanya batasan jumlah pemilik. Ke-pemilikan perusahaan terbagi-bagi dalam wujud saham.

Perusahaan melaporkan performa keuangannya secara triwulanan (*quarterly*) atau tahunan melalui pelaporan akuntansi yang disebut laporan keuangan (*financial statement*). Salah satu laporan keuangan yang perlu disusun oleh perusahaan adalah neraca keuangan (*balance sheet*). Neraca keuangan adalah pernyataan posisi keuangan perusahaan yang memuat harta, utang, dan modal. Dalam ilmu ekonomi, ketiga komponen neraca keuangan ini disebut juga aset, liabilitas, dan ekuitas. Selanjutnya, Penulis hanya akan memperdalam bahasan mengenai aset.

Aset terbagi menjadi aset tetap dan aset jangka panjang. Aset tetap ialah kas atau aset yang dapat dialihkan menjadi kas dalam kurun waktu satu tahun, seperti

sekuritas, piutang, persediaan, sewa, dan pembayaran di muka. Di sisi lain, aset jangka panjang termasuk peralatan, *plant* (meliputi tanah, bangunan, dan mesin), dan perlengkapan.

2.15. Investasi

Menurut Virlics (2013), investasi adalah pengeluaran yang dikeluarkan oleh seseorang atau sebuah perusahaan untuk memperoleh keuntungan pada waktu mendatang. Pertimbangan untuk melakukan suatu investasi didasarkan pada *return* dan risiko yang mungkin diperoleh dari suatu aset perusahaan atau sekuritas keuangan.

Return didefinisikan sebagai persentase peningkatan nilai untuk tiap satuan mata uang yang diinvestasikan, sedangkan risiko, ialah hal-hal yang menghambat kembalinya *return* dalam berinvestasi, seperti situasi ekonomi dan finansial yang sedang terjadi (Virlics, 2013). Terdapat dua jenis risiko investasi, yaitu risiko umum (*common risk*) dan risiko independen. Risiko umum ialah risiko dengan korelasi sempurna. Di sisi lain, risiko independen ialah risiko yang tidak berkorelasi. Berk dan DeMarzo (2016) mengangkat contoh kasus di suatu permukiman untuk memperjelas pemahaman dari kedua risiko ini. Gempa bumi yang menyerang wilayah suatu permukiman merupa-kan contoh risiko umum karena merugikan semua rumah secara merata, sedangkan perampokan merupakan risiko independen karena kejadian perampokan untuk satu rumah independen terhadap rumah lainnya, menurut tingkat ketidakberuntungan yang menimpa pemilik tiap rumah.

Berdasarkan adanya risiko yang dimiliki, instrumen investasi dapat dibedakan menjadi instrumen berisiko (*risky*) dan bebas risiko (*risk-free*). Instrumen berisiko mempunyai risiko atau volatilitas senilai tertentu. Contoh instrumen berisiko ialah ekuitas, komoditas, obligasi, lahan yasan (*real estate*), dan valuta asing (Chen, 2022). Di sisi lain, instrumen bebas risiko menjamin sejumlah *return* tertentu tanpa probabilitas kerugian apapun. Contoh instrumen bebas risiko adalah obligasi dan surat utang yang diterbitkan oleh negara (Chen, 2021).

Bagi suatu perusahaan, investasi ditujukan untuk mempertahankan keberadaannya di tengah pasar kompetitif. Melalui peran manajer finansial, suatu peru-

sahaan dapat mengambil keputusan-keputusan investasi dengan menimbang biaya, keuntungan, dan risiko yang ada (Berk dan DeMarzo, 2016). Di sisi lain, bagi perorangan, salah satu tujuan investasi ialah memperoleh penghasilan pasif.

Salah satu sekuritas yang umum dilibatkan sebagai instrumen bagi para investor individu muda di Indonesia ialah saham. Selain karena adanya jaminan keamanan melalui perlindungan Otoritas Jasa Keuangan (OJK), investasi saham juga dipermudah melalui keberadaan berbagai aplikasi digital. Pemahaman akan saham dapat disimak pada subbab berikut.

2.16. Saham

Menurut Berk dan DeMarzo (2016), saham adalah porsi kepemilikan seseorang atas suatu perusahaan. Saham merupakan instrumen investasi yang bersifat likuid karena mampu dijual dengan cepat dan mudah dengan harga jual yang cukup dekat dengan harga beli pada suatu waktu tertentu. Pemilik saham suatu perusahaan dikenal juga sebagai *shareholder*, *stakeholder*, atau *equity holder*. Pemilik saham berhak atas deviden, yaitu pembayaran sejumlah keuntungan perusahaan kepada pemilik saham pada frekuensi tertentu atas dasar kebijakan tertentu. Besar deviden yang dibayarkan umumnya proporsional dengan banyak saham yang dimiliki seorang pemilik saham.

Nilai suatu saham dan deviden yang terasosiasi dengan saham tersebut selalu berfluktuasi seiring waktu. Fenomena ini terjadi karena saham merupakan instrumen investasi yang berisiko (*risky*). Wujud risiko umum saham ialah berita-berita meluas dari pasar ekonomi (*market-wide news*), sedangkan risiko independennya berupa berita-berita spesifik dari perusahaan emiten saham (*firm-specific news*). Dalam konteks investasi saham, risiko umum disebut juga risiko tak terdiversifikasi atau risiko sistematis, sedangkan risiko independen disebut juga risiko terdiversifikasi atau risiko *firm-specific*. Karena memengaruhi seluruh saham, risiko sistematis tidak dapat didiversifikasi. Sementara, risiko *firm-specific* dapat didiversifikasi melalui portofolio saham.

2.16.1. *Return* dan Risiko Saham

Sebagai suatu instrumen investasi yang berisiko, investasi saham dapat mengembalikan bermacam nilai *return* dengan besar kemungkinan (*likelihood*) masing-masing. Maka, tiap nilai *return* yang memungkinkan, R, terasosiasi dengan suatu nilai probabilitas, p_R, membentuk suatu distribusi probabilitas. Ekspektasi *return* dapat dihitung melalui rumus:

$$E[R] = \sum_R p_R R$$

sebagai rata-rata terbobot dari tiap nilai *return* yang memungkinkan. Sementara, risiko dapat diukur sebagai variansi *return*, yaitu:

$$\mathrm{Var}(R) = E\big[(R - E[R])^2\big] = \sum_R p_R (R - E[R])^2,$$

atau deviasi standar *return*, yaitu:

$$\mathrm{SD}(R) = \sqrt{\mathrm{Var}(R)}.$$

Deviasi standar *return* dikenal juga sebagai volatilitas.

Return yang dapat dihitung berdasarkan riwayat harga saham dalam periode waktu tertentu disebut *return* terealisasi (*realized return*). *Return* terealisasi mempunyai suatu distribusi empiris dan merupakan komponen dasar untuk mengestimasi volatilitas. Jika investasi pada suatu saham dilakukan pada waktu t dengan harga P_t, kemudian pada waktu $t + 1$, dividen sebesar Div_{t+1} dibayarkan dan saham dijual dengan harga P_{t+1}, *return* terealisasi dari investasi saham dari waktu t ke $t + 1$ dirumuskan sebagai:

$$R_{t+1} = \frac{Div_{t+1}}{P_t} + \frac{P_{t+1} - P_t}{P_t}. \tag{2.26}$$

Pada umumnya, waktu diukur dalam satuan tahun. Dengan mengasumsikan satuan ini, rata-rata *return* tahunan untuk tahun investasi pertama hingga tahun ke-T dapat dihitung sebagai:

$$\bar{R} = \frac{1}{T} \sum_{t=1}^{T} R_t. \tag{2.27}$$

Estimasi variansi *return* diberikan oleh rumus:

$$\mathrm{Var}(R) = \frac{1}{T-1}\sum_{t=1}^{T}(R_t - \bar{R})^2. \tag{2.28}$$

Di sisi lain, kovariansi antara dua buah kumpulan *return* dapat dirumuskan sebagai:

$$\mathrm{Cov}(R_1, R_2) = \frac{1}{T-1}\sum_{t=1}^{T}(R_{1t} - \bar{R}_1)(R_{2t} - \bar{R}_2). \tag{2.29}$$

2.16.2. *Short Sale*

Short sale atau *shortselling* merupakan perilaku menjual sekuritas yang seorang investor tidak miliki. Dalam suatu *short sale*, seorang investor meminjam sekuritas yang hendak ia jual kepada investor lain yang sudah mempunyai sekuritas tersebut. Pada kemudian hari, sekuritas tersebut akan dikembalikan melalui pembelian senilai harga asli sekuritas tersebut atau disertai dengan arus kas yang menyertainya (Berk dan DeMarzo, 2016).

2.17. Pasar Saham

Menurut Berk dan DeMarzo (2016), pasar saham (*stock market*) atau bursa efek (*stock exchange*) merupakan tempat terjadinya jual-beli saham dari perusahaan-perusahaan terbuka. Pasar saham menyediakan likuiditas bagi saham perusahaan-perusahaan yang terlibat di dalamnya. Terdapat dua jenis pasar saham, yaitu pasar primer dan pasar sekunder. Pasar primer terjadi ketika suatu perusahaan menjual lembar-lembar saham terbarunya kepada investor, sedangkan pasar sekunder terjadi ketika saham diperjualbelikan antarinvestor.

Pasar saham mengunggah dua buah harga selama jam tertentu pada hari-hari kerja, yaitu harga penawaran (*bid price*) dan harga permintaan (*ask price*). Harga penawaran adalah harga saham tertinggi yang bersedia dibayar oleh pembeli. Di sisi lain, harga permintaan adalah harga saham terendah yang dapat diterima oleh penjual. Kedua harga ini diperhitungkan oleh para pembuat pasar (*market makers*). Harga permintaan selalu bernilai lebih tinggi daripada harga penawaran. Selisih antara kedua harga ini disebut *bid-ask spread* dan merupakan keuntungan bagi pembuat pasar yang dibayar oleh investor sebagai biaya transaksi.

2.18. Portofolio Saham

Portofolio adalah gabungan dari dua sekuritas keuangan atau lebih (Berk dan DeMarzo, 2016). Portofolio merupakan sarana untuk memeratakan risiko *firm-specific* dari tiap sekuritas yang tergabung di dalamnya. Pemerataan risiko ini dikenal sebagai diversifikasi. Risiko *firm-specific* hadir dalam rupa informasi maupun peristiwa yang dapat bersifat baik atau buruk. Melalui diversifikasi, dampak risiko-risiko ini akan lebih merata dan relatif konstan.

2.18.1. *Return* dan Risiko Portofolio Saham

Suatu portofolio didefinisikan menurut bobot-bobot (*weights*) portofolio, w_i, yang didefinisikan proporsi suatu investasi sekuritas tunggal terhadap nilai total yang diinvestasikan dalam portofolio tersebut, yaitu:

$$w_i = \frac{\text{Nilai investasi } i}{\text{Nilai total portofolio}}$$

dengan:

$$\sum_{\forall i} w_i = 1. \tag{2.30}$$

Jika suatu portofolio memuat n investasi dengan nilai-nilai bobot termuat dalam vektor $\mathbf{w}' = [w_1, w_2, \ldots, w_n]$ dan *return* dalam vektor $\mathbf{R}' = [R_1, R_2, \ldots, R_n]$, maka Persamaan (2.30) dapat dinyatakan juga sebagai operasi vektor:

$$\mathbf{w}'\mathbf{1}_n = 1. \tag{2.31}$$

Selain itu, *return* portofolio dapat dihitung sebagai:

$$\begin{aligned} R_P &= w_1R_1 + w_2R_2 + \ldots + w_nR_n \\ &= \sum_{i=1}^{n} w_iR_i \\ &= \mathbf{w}'\mathbf{R}. \end{aligned}$$

Jika dimisalkan $E[R_i] = \mu_i$ dan dibentuk vektor $\boldsymbol{\mu}' = [\mu_1, \mu_2, \ldots, \mu_n]$, ekspektasi *return* portofolio dirumuskan sebagai:

$$\mu_P = E[R_P] = E\left[\sum_{i=1}^{n} w_iR_i\right]$$

$$
\begin{aligned}
&= \sum_{i=1}^{n} E[w_i R_i] \\
&= \sum_{i=1}^{n} w_i E[R_i] \\
&= \sum_{i=1}^{n} w_i \mu_i \\
&= \mathbf{w}'\boldsymbol{\mu}. \qquad (2.32)
\end{aligned}
$$

Derajat pergerakan risiko umum dan *return* saham diukur melalui kovariansi *return*. Antara *return* dari dua buah investasi, R_i dan R_j, kovariansi dirumuskan:

$$\sigma_{ij} = E\big[(R_i - E[R_i])(R_j - E[R_j])\big].$$

Jika diestimasi secara empiris dari data riwayat harga saham, estimasi kovariansi diberikan sebagai berikut:

$$\hat{\sigma}_{ij} = \frac{1}{T-1} \sum_{t=1}^{T} (R_{i,t} - \bar{R}_i)(R_{j,t} - \bar{R}_j)$$

dengan $\bar{R}_i$ dan $\bar{R}_j$ berturut-turut merupakan rata-rata *return* dari investasi ke-i dan j berdasarkan Persamaan (2.27).

Jika dimisalkan $\mathrm{Cov}(R_i, R_j) = \sigma_{ij}$ dan dibentuk matriks kovariansi, $\boldsymbol{\Sigma}$, sebagaimana didefinisikan oleh Persamaan (2.18), maka variansi portofolio dapat dipandang sebagai kovariansi *return* portofolio dengan dirinya sendiri, yaitu:

$$
\begin{aligned}
\sigma_P^2 &= \mathrm{Cov}(R_P, R_P) \\
&= \mathrm{Cov}\left(\sum_{i=1}^{n} w_i R_i, R_P \right) \\
&= \sum_{i=1}^{n} w_i \mathrm{Cov}(R_i, R_P) \qquad (2.33) \\
&= \sum_{i=1}^{n} w_i \mathrm{Cov}\left(R_i, \sum_{j=1}^{n} w_j R_j \right) \\
&= \sum_{i=1}^{n} \sum_{j=1}^{n} w_i w_j \mathrm{Cov}(R_i, R_j) \\
&= \sum_{i=1}^{n} \sum_{j=1}^{n} w_i w_j \sigma_{ij}
\end{aligned}
$$

$$= \mathbf{w}'\boldsymbol{\Sigma}\mathbf{w}. \tag{2.34}$$

Dengan demikian, volatilitas portofolio diperoleh sebagai berikut:

$$\begin{aligned}\sigma_P &= \sqrt{\sigma_P^2} \\ &= \sqrt{\sum_{i=1}^{n}\sum_{j=1}^{n} w_i w_j \mathrm{Cov}(R_i, R_j)}.\end{aligned} \tag{2.35}$$

Ekspektasi *return* pada Persamaan (2.32) dan volatilitas portofolio pada Persamaan (2.35) dibangun dari *return* harian. Keduanya dapat distandarisasi kembali untuk jangka waktu tahunan melalui proses penyetahunan (*annualization*). Menurut Bodie, Kane, dan Marcus (2014), penyetahunan ekspektasi *return* dan volatilitas diestimasi melalui asumsi bahwa mean dan variansi bertumbuh secara proporsional terhadap waktu. Dalam hal ini, waktu merujuk pada kelipatan durasi dari data sampel dalam satu tahun. Oleh karena itu, jika diberikan ekspektasi *return* portofolio, μ_D, dan volatilitas portofolio, σ_D, yang masing-masing diperoleh dari *return* harian serta asumsi bahwa terdapat 252 hari kerja dalam satu tahun, estimasi untuk ekspektasi *return* dan volatilitas yang telah disetahunkan ialah:

$$\mu_A = 252\mu_D$$

dan:

$$\begin{aligned}\sigma_A^2 &= 252\sigma_D^2 \\ \iff \sigma_A &= \sqrt{252}\sigma_D,\end{aligned}$$

secara berturut-turut.

Adapun nilai kovariansi cukup sulit untuk diinterpretasikan sehingga ukuran risiko portofolio alternatif, yaitu korelasi, dapat digunakan. Korelasi antara *return* dua buah saham, R_i dan R_j, didefinisikan sebagai:

$$\rho_{ij} = \frac{\sigma_{ij}}{\sigma_i \sigma_j}. \tag{2.36}$$

Melalui ukuran korelasi, dapat dibuktikan bahwa portofolio mendiversifikasi risiko dalam berinvestasi. Pertama, Persamaan (2.36) disubstitusikan ke Persamaan (2.33)

sehingga diperoleh:

$$\begin{aligned}\sigma_P^2 &= \sum_{i=1}^{n} w_i \mathrm{Cov}(R_i, R_P) \\ &= \sum_{i=1}^{n} w_i \sigma_{iP} \\ &= \sum_{i=1}^{n} w_i \sigma_i \sigma_P \rho_{iP}.\end{aligned}$$

Dengan membagi kedua ruas dengan σ_P, diperoleh:

$$\begin{aligned}\frac{\sigma_P^2}{\sigma_P} &= \frac{\sum_{i=1}^{n} w_i \sigma_i \sigma_P \rho_{iP}}{\sigma_P} \\ \iff \quad \sigma_P &= \sum_{i=1}^{n} w_i \sigma_i \rho_{ij} \\ &\leq \sum_{i=1}^{n} w_i \sigma_i,\end{aligned}$$

dengan $\sum_{i=1}^{n} w_i \sigma_i$ adalah jumlah volatilitas tiap saham secara independen.

2.18.2. Beta Portofolio

Beta dari suatu investasi pada sekuritas i dalam portofolio P dirumuskan:

$$\beta_i^P = \frac{\sigma_i \rho_{iP}}{\sigma_P} \tag{2.37}$$

dengan σ_i melambangkan volatilitas sekuritas, σ_P melambangkan volatilitas portofolio, dan ρ_{iP} melambangkan korelasi antara *return* sekuritas dan *return* portofolio. Dengan mensubstitusikan Persamaan (2.36), Persamaan (2.37) dapat dirumuskan juga sebagai:

$$\begin{aligned}\beta_i^P &= \frac{\sigma_i \frac{\sigma_{iP}}{\sigma_i \sigma_P}}{\sigma_P} \\ &= \frac{\sigma_{iP}}{\sigma_P^2}\end{aligned} \tag{2.38}$$

dengan σ_{iP} adalah kovariansi antara *return* sekuritas dan *return* portofolio serta σ_P^2 adalah variansi portofolio. Beta adalah ukuran risiko sistematis berupa sensitivitas *return* sekuritas terhadap *return* portofolio.

Beta dapat digunakan untuk menghitung *return* yang dibutuhkan (*required return*), yaitu ekspektasi *return* yang diperlukan sebagai kompensasi atas risiko suatu investasi dalam suatu portofolio. *Required return*, r_i, dirumuskan:

$$r_i = r_f + \beta_i^P (E[R_P] - r_f)$$

dengan r_f adalah suku bunga bebas risiko (disebut juga tingkat *return* bebas risiko) dan $E[R_P]$ adalah ekspektasi *return* portofolio. Di Indonesia, sebagaimana diatur oleh Bank Indonesia, BI-Rate (dahulu bernama BI7DRR) adalah suku bunga kebijakan yang diterapkan sebagai acuan utama di pasar keuangan (Bank Indonesia, t.t.). Dengan demikian, r_f yang berlaku di Indonesia sama dengan BI-Rate yang berlaku pada suatu periode.

2.18.3. Ukuran Performa Portofolio

Portofolio dengan *return* yang lebih tinggi dan risiko yang lebih rendah merupakan sesuatu yang memungkinkan. Untuk mencapainya, *return* terhadap risiko portofolio dengan berbagai variasi bobot dapat dipetakan sebagai suatu kurva hiperbola. Secara visual, seorang investor dapat menemukan portofolio yang diharapkan berdasarkan *return* dan risiko yang diinginkan melalui kurva ini. Hal ini akan dibahas lebih lanjut pada subbab-subbab selanjutnya.

Cara lain untuk menilai kualitas suatu portofolio ialah menggunakan berbagai ukuran performa. Cogneau dan Hübner (2009) mengelompokkan ukuran-ukuran performa portofolio berdasarkan empat acuan, yaitu kemampuan investor (pemilihan aset atau waktu pasar), individualisasi (standarisasi atau preferensi subjektif investor), penciptaan nilai (*gain* atau *return*), dan translasi (rasio atau selisih).

Pada penelitian ini, Penulis akan berfokus pada *Sharpe ratio* (SR), *Treynor ratio* (TR), dan *Jensen's alpha*, yaitu tiga ukuran performa portofolio berbasis *return* yang diutamakan dalam berbagai literatur terdahulu (Marhfor, 2016). Ketiga ukuran tersebut berlaku di bawah asumsi bahwa risiko bernilai konstan selama kurun waktu yang dilibatkan dalam penilaian performa portofolio.

2.18.4. *Sharpe Ratio*

Sharpe ratio merupakan salah satu ukuran performa portofolio pertama di dunia yang ditemukan oleh William F. Sharpe pada tahun 1966. *Sharpe ratio* dirumuskan sebagai:

$$S_P = \frac{E[R_P] - r_f}{\mathrm{SD}(R_P)} \tag{2.39}$$

dengan $E[R_P]$ adalah ekspektasi *return* portofolio yang telah disetahunkan, r_f adalah tingkat *return* bebas risiko, dan $\mathrm{SD}(R_P)$ adalah volatilitas portofolio yang telah disetahunkan. Pembilang pada rumusan *Sharpe ratio* disebut *excess return* sehingga *Sharpe ratio* dapat dipandang sebagai rasio *return* terhadap volatilitas yang diberikan oleh suatu portofolio. Nilai rasio yang semakin tinggi menandakan *return* dari suatu portofolio bernilai lebih tinggi dengan besar risiko tertentu. Portofolio yang optimal mempunyai *Sharpe ratio* yang tinggi, yaitu mempunyai *excess return* yang tinggi dan volatilitas yang rendah (Berk dan DeMarzo, 2016).

Sharpe ratio juga dapat digunakan untuk menilai kualitas saham. Rumus *Sharpe ratio* untuk menilai kualitas saham diperoleh dengan mengganti ekspektasi *return* dan volatilitas portofolio menjadi ekspektasi *return* dan volatilitas saham, yaitu:

$$S_i = \frac{E[R_i] - r_f}{\mathrm{SD}(R_i)} \tag{2.40}$$

dengan S_i adalah *Sharpe ratio* suatu saham i dan R_i adalah *return* saham i.

2.18.5. Portofolio Tangen

Pemahaman akan portofolio tangen berawal dari studi kasus investasi pada portofolio aset-aset berisiko dan aset bebas risiko, seperti Surat Utang Negara (SUN). Portofolio atas aset-aset berisiko mempunyai ekspektasi *return* senilai $E[R_P]$ dan volatilitas sebesar σ_P^2, sedangkan SUN mempunyai tingkat *return* sebesar r_f dan tidak mempunyai risiko. Jika seorang investor menabung kepemilikannya sebesar x pada portofolio dan $(1 - x)$ pada SUN, ekspektasi *return* dari portofolio baru dapat dihitung sebagai:

$$E[R_{P'}] = E[xR_P + (1 - x)r_f]$$

$$
\begin{aligned}
&= xE[R_P] + (1-x)r_f \\
&= xE[R_P] + r_f - xr_f \\
&= r_f + x(E[R_P] - r_f).
\end{aligned}
$$

Di sisi lain, volatilitas portofolio baru dapat dihitung sebagai:

$$
\begin{aligned}
\sigma_{P'} &= \sqrt{\mathrm{Var}\big(xR_P + (1-x)r_f\big)} \\
&= \sqrt{x^2\mathrm{Var}(R_P) + (1-x)^2\mathrm{Var}(r_f) + 2x(1-x)\mathrm{Cov}(R_P, r_f)} \\
&= \sqrt{x^2\mathrm{Var}(R_P) + (1-x)^2(0) + 2x(1-x)(0)} \\
&= \sqrt{x^2\mathrm{Var}(R_P)} \\
&= x\sigma_P.
\end{aligned}
$$

Dengan demikian, jika suatu portofolio terdiri atas aset-aset berisiko dan aset bebas risiko, ekspektasi *return* dan volatilitasnya berbanding lurus terhadap jumlah bobot investasi pada aset-aset berisiko saja.

Jika ekspektasi *return* dan volatilitas dari portofolio baru ini dipetakan, kurva yang terbentuk ialah sebuah garis dengan kemiringan senilai *Sharpe ratio* portofolio tersebut. Kurva hiperbola dari portofolio-portofolio lain yang hanya memuat aset-aset berisiko terletak di bawah garis ini dan hanya menyinggung garis tersebut pada satu titik. Oleh karena itu, portofolio yang menghasilkan garis ini disebut portofolio tangen. Kurva garis dari portofolio tangen merupakan garis dengan kemiringan paling curam atau nilai *Sharpe ratio* tertinggi (Berk dan DeMarzo, 2016).

2.18.6. Portofolio Efisien

Secara umum, portofolio efisien dapat dimaknai sebagai portofolio yang tidak dapat didiversifikasi lebih jauh. Pada portofolio efisien, risiko tidak dapat dikurangi jika ekspektasi *return* tidak dikurangi. Jika divisualisasikan sebagai kurva yang memetakan ekspektasi *return* terhadap volatilitas, portofolio efisien merupakan portofolio yang bersinggungan dengan portofolio tangen.

Secara matematis, suatu portofolio bersifat efisien jika dan hanya jika untuk

tiap sekuritas di dalamnya, ekspektasi *return* sama dengan *required return*, yaitu:

$$E[R_i] = r_i = r_f + \beta_i^{\text{eff}}(E[R_{\text{eff}}] - r_f) \tag{2.41}$$

dengan r_f adalah suku bunga bebas risiko, β_i^{eff} adalah beta sekuritas i pada portofolio efisien, dan $E[R_{\text{eff}}]$ adalah ekspektasi *return* portofolio efisien.

Potensi diversifikasi yang dimiliki suatu portofolio semakin berkembang seiring bertambah banyaknya saham yang termuat dalam portofolio tersebut. Oleh karena itu, salah satu kandidat portofolio efisien adalah portofolio pasar, yaitu portofolio dari semua saham dan sekuritas yang diperdagangkan di pasar saham (Berk dan DeMarzo, 2016).

2.18.7. *Capital Asset Pricing Model*

Capital Asset Pricing Model (CAPM) merupakan model yang memampukan identifikasi portofolio atas sekuritas-sekuritas berisiko jika ekspektasi *return* dan volatilitas dari tiap sekuritas serta korelasi antarsekuritas yang termuat di dalam portofolio tersebut tidak diketahui. Menurut Berk dan DeMarzo (2016), terdapat tiga asumsi yang mendasari CAPM, yaitu:

1. Semua investor dapat membeli dan menjual semua sekuritas pada harga pasar kompetitif (tanpa pajak dan biaya transaksi) serta meminjam dan memberi pinjaman pada tingkat suku bunga bebas risiko.
2. Semua investor hanya bergantung pada portofolio efisien atas sekuritas-sekuritas yang ia perjualbelikan.
3. Semua investor mempunyai ekspektasi yang homogen akan volatilitas, korelasi, dan ekspektasi *return* sekuritas, yakni estimasi yang seragam akan investasi mendatang dan *return*.

Asumsi-asumsi CAPM memuat pola perilaku investor yang menjadikan pasar dalam keadaan setimbang dan portofolio pasar berlaku sebagai portofolio efisien. Akibatnya, Persamaan (2.41) dapat didefinisikan kembali sebagai Persamaan CAPM berikut:

$$E[R_i] = r_i = r_f + \beta_i^{M}(E[R_M] - r_f) \tag{2.42}$$

dengan β_i^M adalah beta sekuritas i pada portofolio pasar dan $E[R_M]$ adalah ekspektasi *return* portofolio pasar. Dengan memandang Persamaan (2.42) di atas sebagai suatu persamaan linear, beta dapat diinterpretasikan sebagai persentase ekspektasi perubahan *return* sekuritas tersebut untuk tiap perubahan *return* portofolio pasar sebesar satu persen (Berk dan DeMarzo, 2016).

Jika portofolio pasar diacu sebagai portofolio efisien, maka perubahan nilai portofolio pasar mencerminkan guncangan perekonomian negara tempat diperjualbelikannya sekuritas-sekuritas dalam portofolio tersebut. Oleh karena itu, notasi β_i^M sering disederhanakan menjadi β_i. Lebih lanjut, sebuah portofolio dapat dipandang sebagai aset tersendiri karena ia mempunyai *return* dan risiko selayaknya sekuritas-sekuritas yang termuat di dalamnya. Dengan demikian, dapat didefinisikan ukuran beta portofolio yang relatif terhadap portofolio pasar, β_P.

2.18.8. *Jensen's Alpha*

Pada kasus di mana asumsi-asumsi CAPM tidak berlaku, terdapat selisih antara ekspektasi *return* dan *required return* dari suatu saham yang dikenal sebagai alfa saham (*stock's alpha*). Alfa suatu saham, i, dilambangkan dengan α_i dan dirumuskan sebagai:

$$\begin{aligned}\alpha_i &= E[R_i] - r_i \\ &= E[R_i] - \big(r_f + \beta_i(E[R_M] - r_f)\big)\end{aligned}$$

dengan $E[R_i]$ adalah ekspektasi *return* dari saham i, r_f adalah tingkat *return* bebas risiko, β_i adalah beta saham, dan $E[R_M]$ adalah ekspektasi *return* dari indeks pasar acuan.

Berdasarkan Marhfor (2016), alfa saham dapat digeneralisasi untuk suatu portofolio menjadi suatu ukuran yang disebut *Jensen's alpha*. Ukuran ini dilambangkan dengan α_P dan dirumuskan sebagai:

$$\alpha_P = E[R_P] - \big(r_f + \beta_P(E[R_M] - r_f)\big) \tag{2.43}$$

dengan $E[R_P]$ adalah ekspektasi *return* portofolio dan β_P adalah beta portofolio.

Alfa saham dan *Jensen's alpha* yang bernilai positif merupakan salah satu dasar untuk melahirkan lebih banyak persaingan pada pasar sehingga pasar mendekati keadaan efisien. Oleh karena itu, portofolio yang optimal turut dicirikan dengan *Jensen's alpha* yang positif (Berk dan DeMarzo, 2016).

2.18.9. *Treynor Ratio*

Treynor ratio ditemukan oleh Jack Treynor, seorang ekonom asal Amerika Serikat. *Treynor ratio* melibatkan risiko sistematis portofolio pada rumusannya, menjadikannya berbeda dari *Sharpe ratio* yang menggunakan risiko keseluruhan. *Treynor ratio* dirumuskan sebagai:

$$T_P = \frac{E[R_P] - r_f}{\beta_P} \tag{2.44}$$

dengan T_P adalah *Treynor ratio* portofolio, $E[R_P]$ adalah ekspektasi *return* portofolio yang telah disetahunkan, r_f adalah tingkat *return* bebas risiko, dan β_P adalah beta portofolio (Marhfor, 2016).

Treynor ratio yang semakin tinggi bermakna bahwa *return* suatu portofolio bernilai lebih tinggi untuk risiko sistematis dengan besar tertentu.

2.19. Indeks Saham LQ45

Menurut Berk dan DeMarzo (2016), indeks saham merupakan portofolio umum atas sekumpulan saham tertentu. Mayoritas indeks saham dibobotkan atas dasar nilai (*value-weighted*), yaitu bahwa bobot tiap saham bergantung pada harga pasar tiap perusahaan yang mengeluarkan saham yang terlibat dalam indeks saham tersebut. Akan tetapi, terdapat pula indeks-indeks saham yang dibobotkan atas dasar harga (*price-weighted*), yaitu bahwa bobot tiap saham bergantung pada nilai tiap saham yang sedang berlaku.

Selayaknya saham, seorang investor juga dapat melakukan jual-beli atas indeks saham. Investasi indeks saham sejatinya merupakan suatu bentuk strategi arbitrase, yaitu membeli dan menjual suatu instrumen investasi di pasar-pasar yang berbeda untuk meraih keuntungan dari selisih harga yang ada. Arbitrase melalui indeks saham dapat dilakukan dengan membeli indeks dan menjual saham-saham

tersebut secara terpisah-pisah, jika diketahui harga indeks lebih rendah daripada total harga saham-saham yang tergabung di dalamnya.

Dikarenakan data *return* berbagai sekuritas dan saham kecil sering kali tidak tersedia, portofolio pasar yang sempurna tidak mudah untuk diperoleh. Dalam hal ini, indeks saham dapat digunakan sebagai aproksimasi untuk portofolio pasar (Berk dan DeMarzo, 2016). Beberapa contoh indeks saham yang berlaku di Indonesia ialah antara lain Indeks Harga Saham Gabungan (IHSG), IDX30, LQ45, dan KOMPAS100.

Indeks LQ45 (Liquid 45) merupakan indeks saham yang terdiri atas 45 saham dengan likuiditas yang tinggi. Indeks LQ45 diluncurkan oleh Bursa Efek Indonesia (BEI) pada bulan Februari 1977 dan telah menjadi salah satu indikator penting bagi investor-investor saham di Indonesia.

Secara spesifik, tiga puluh saham pertama yang digolongkan dalam indeks LQ45 harus memenuhi kriteria-kriteria berikut:

1. Saham resmi tercatat di BEI selama tiga bulan terakhir.
2. Perusahaan emiten saham mempunyai kondisi finansial dan prospek pertumbuhan yang baik.
3. Perusahaan mempunyai kapitalisasi pasar yang tinggi selama satu hingga dua bulan terakhir.
4. Dalam dua belas bulan terakhir, saham tergabung dalam enam puluh saham dengan nilai transaksi tertinggi dalam pasar reguler.

Setelahnya, lima belas saham tambahan akan ditentukan berdasarkan kriteria-kriteria tambahan, yaitu hari transaksi dan frekuensi transaksi di pasar reguler serta kapitalisasi pasar. Melalui kriteria-kriteria ini, saham-saham dalam indeks LQ45 berpotensi memberikan *return* yang stabil dalam jangka panjang. Oleh karena itu, indeks LQ45 merupakan indikator yang baik untuk mendukung investasi yang cermat, khususnya bagi investor-investor pemula (Nurawan dan Mahendra, 2023).

Saham-saham yang termuat dalam indeks LQ45 pada periode Agustus 2024 hingga Januari 2025 dijabarkan pada Lampiran 1.

2.20. Metode Pengali Lagrange

Suatu permasalahan optimisasi klasik dirumuskan sebagai:

$$\begin{aligned} &\max \text{ (atau } \min) && f_0(\mathbf{x}) \\ &\text{dengan kendala} && f_i(\mathbf{x}) = 0, \quad i = 1, 2, \ldots, m \end{aligned} \tag{2.45}$$

dengan f_0 adalah fungsi objektif, $\mathbf{x}' = [x_1, x_2, \ldots, x_n]$ adalah vektor atas variabel-variabel keputusan, dan f_i adalah fungsi-fungsi kendala (*constraint*). Didefinisikan pula himpunan kesempatan:

$$K = \{\mathbf{x} \,|\, \mathbf{x} \in \mathbb{R}^n, f_i(\mathbf{x}) \leq 0, i = 1, 2, \ldots, m\}, \tag{2.46}$$

yaitu himpunan atas solusi-solusi fisibel (*feasible solutions*). Secara umum, himpunan K diasumsikan tidak kosong sehingga terdapat suatu vektor, $\mathbf{x}$, yang layak jika dan hanya jika $\mathbf{x} \in K$ (Luptáčik, 2010).

Menurut Schott (2017), metode pengali Lagrange ialah metode penyelesaian permasalahan optimisasi dengan persamaan-persamaan kendala tertentu menggunakan fungsi Lagrange. Fungsi Lagrange memuat vektor atas variabel-variabel keputusan, $\mathbf{x}_n$, dan vektor pengali Lagrange, $\mathbf{u}' = [u_1, u_2, \ldots, u_m]$. Dengan mendefinisikan vektor $\mathbf{f}' = [f_1, f_2, \ldots, f_m]$, fungsi Lagrange untuk permasalahan optimisasi pada Persamaan (2.45) dirumuskan:

$$\begin{aligned} \mathcal{L}(\mathbf{x}, \mathbf{u}) &= f_0(\mathbf{x}) + \mathbf{u}'\mathbf{f}(\mathbf{x}) \\ &= f_0(\mathbf{x}) + \sum_{i=1}^{m} u_i f_i(\mathbf{x}) \end{aligned} \tag{2.47}$$

dengan Nilai-nilai stasioner $\mathcal{L}(\mathbf{x}, \mathbf{u})$ adalah solusi berpasangan, $(\mathbf{x}, \mathbf{u})$, yang memenuhi:

$$\frac{\partial}{\partial \mathbf{x}'}\mathcal{L}(\mathbf{x}, \mathbf{u}) = \frac{\partial}{\partial \mathbf{x}'} f_0(\mathbf{x}) + \mathbf{u}'\left(\frac{\partial}{\partial \mathbf{x}'}\mathbf{f}(\mathbf{x})\right) = \mathbf{0}' \text{ dan} \tag{2.48}$$

$$\frac{\partial}{\partial \mathbf{u}'}\mathcal{L}(\mathbf{x}, \mathbf{u}) = \mathbf{f}(\mathbf{x}) = \mathbf{0}'. \tag{2.49}$$

Perumuman dari permasalahan optimisasi klasik ialah model pemrograman matematis. Perumuman ditunjukkan pada bentuk kendala yang tidak terkhusus pada

persamaan, tetapi juga pertidaksamaan, yakni sebagai berikut:

$$\begin{aligned} &\max \text{ (atau } \min) && f_0(\mathbf{x}) \\ &\text{dengan kendala} && f_i(\mathbf{x}) \leq 0, \quad i = 1, 2, \ldots, m \end{aligned} \tag{2.50}$$

dengan f_0 adalah fungsi objektif, $\mathbf{x}' = [x_1, x_2, \ldots, x_n]$ adalah vektor atas variabel-variabel keputusan, dan f_i adalah fungsi-fungsi kendala. Metode pengali Lagrange dapat diterapkan untuk menyelesaikan program matematis dengan didahului transformasi terhadap bentuk kendala menjadi persamaan. Transformasi dilakukan dengan menambahkan m variabel *slack* sedemikian sehingga program matematis dapat dituliskan kembali sebagai:

$$\begin{aligned} &\max \text{ (atau } \min) && f_0(\mathbf{x}) \\ &\text{dengan kendala} && f_i(\mathbf{x}) + y_i^2 = 0, \quad i = 1, 2, \ldots, m, \end{aligned} \tag{2.51}$$

menjadikannya suatu permasalahan optimisasi klasik. Dengan cara yang sama, fungsi Lagrange yang berkorespondensi dengan permasalahan optimisasi pada Persamaan (2.51) ialah:

$$\begin{aligned} \mathcal{L}(\mathbf{x}, \mathbf{y}, \mathbf{u}) &= f_0(\mathbf{x}) + \mathbf{u}'\mathbf{f}(\mathbf{x}) \\ &= f_0(\mathbf{x}) + \sum_{i=1}^{m} u_i \big(f_i(\mathbf{x}) + y_i^2\big). \end{aligned} \tag{2.52}$$

Permasalahan pemrograman matematis dapat diperumum dengan adanya kendala-kendala pertidaksamaan. Dalam menyelesaikan pemrograman matematis umum, metode pengali Lagrange juga diperumum menuju syarat-syarat Kuhn-Tucker.

2.21. Syarat-Syarat Kuhn-Tucker untuk Permasalahan Minimisasi

Secara matematis, permasalahan pemrograman matematis umum dinotasikan:

$$\begin{aligned} &\max \text{ (atau } \min) && f_0(\mathbf{x}, \mathbf{y}) \\ &\text{dengan kendala} && f_i(\mathbf{x}, \mathbf{y}) \leq 0, \quad i = 1, 2, \ldots, m, \end{aligned}$$

$$
\begin{aligned}
& g_h(\mathbf{x}, \mathbf{y}) = 0, \quad h = m+1, \ldots, r, \\
& \mathbf{x} \geq \mathbf{0}, \text{ dan} \\
& \mathbf{y} \in \mathbb{R}^l. \qquad (2.53)
\end{aligned}
$$

Fungsi Lagrange yang berkorespondensi dengan program matematis umum pada Persamaan (2.53) didefinisikan sebagai:

$$\mathcal{L}(\mathbf{x}, \mathbf{y}, \mathbf{u}, \mathbf{v}) = f_0(\mathbf{x}, \mathbf{y}) + \sum_{i=1}^{m} u_i f_i(\mathbf{x}, \mathbf{y}) + \sum_{h=m+1}^{r} v_h g_h(\mathbf{x}, \mathbf{y})$$

dengan $\mathbf{u}' = [u_1, \ldots, u_m]$ dan $\mathbf{v}' = [v_{m+1}, \ldots, v_r]$ berturut-turut merupakan vektor atas pengali-pengali Lagrange yang berkorespondensi dengan kendala-kendala berbentuk pertidaksamaan dan persamaan.

Diasumsikan bahwa fungsi $f_0, f_1, \ldots, f_m, g_{m+1}, \ldots g_r$ seluruhnya diferensiabel. Jika fungsi objektif f_0 mencapai minimum lokal pada $(\mathbf{x}^0, \mathbf{y}^0)$ terhadap himpunan fisibel:

$$K = \{(\mathbf{x}, \mathbf{y}) | f_i(\mathbf{x}, \mathbf{y}) \leq 0, i = 1, 2, \ldots, m \text{ dan } g_h(\mathbf{x}, \mathbf{y}) = 0, h = m+1, \ldots, r\},$$

maka terdapat vektor pengali Lagrange $\mathbf{u}^0$ dan $\mathbf{v}^0$ sedemikian sehingga syarat-syarat berikut terpenuhi:

$$\frac{\partial \mathcal{L}^0}{\partial \mathbf{x}} \geq \mathbf{0}, \qquad (2.54)$$

$$\mathbf{x}^0 \frac{\partial \mathcal{L}^0}{\partial \mathbf{x}} = 0, \qquad (2.55)$$

$$\frac{\partial \mathcal{L}^0}{\partial \mathbf{u}} \leq \mathbf{0}, \qquad (2.56)$$

$$\mathbf{u}^0 \frac{\partial \mathcal{L}^0}{\partial \mathbf{u}} = 0, \qquad (2.57)$$

$$\frac{\partial \mathcal{L}^0}{\partial \mathbf{y}} = \mathbf{0}, \qquad (2.58)$$

$$\frac{\partial \mathcal{L}^0}{\partial \mathbf{v}} = \mathbf{0}, \qquad (2.59)$$

$$\mathbf{x}^0 \geq \mathbf{0}, \text{ dan} \qquad (2.60)$$

$$\mathbf{u}^0 \geq \mathbf{0}, \qquad (2.61)$$

dengan $\mathcal{L}^0 = \mathcal{L}(\mathbf{x}^0, \mathbf{y}^0, \mathbf{u}^0, \mathbf{v}^0)$. Kedelapan syarat pada Persamaan (2.54) hingga Persamaan (2.61) di atas disebut syarat-syarat Kuhn-Tucker (Luptáčik, 2010). Dengan kata lain, penurunan syarat-syarat Kuhn-Tucker untuk permasalahan minimisasi dapat dirangkum dalam tiga tahap berikut:

1. Notasikan semua kendala pertidaksamaan dalam bentuk:

$$f_i(\mathbf{x}, \mathbf{y}) \leq 0.$$

2. Susun fungsi Lagrange yang terdiri dari jumlah fungsi objektif dan kendala-kendala terbobot.
3. Hitung derivatif-derivatif parsial dari fungsi Lagrange, dengan derivatif parsial:
   a. terhadap variabel-variabel nonnegatif, $\mathbf{x}$, bersifat nonnegatif dan kondisi kelampaian komplementer (*complementary slackness*) pada Persamaan (2.55) terpenuhi;
   b. terhadap variabel-variabel bebas, $\mathbf{y}$, sama dengan nol;
   c. terhadap pengali-pengali Lagrange yang berkorespondensi dengan kendala pertidaksamaan, $\mathbf{u}$, bersifat nonpositif dan kondisi kelampaian komplementer pada Persamaan (2.57) terpenuhi; dan
   d. terhadap pengali-pengali Lagrange yang berkorespondensi dengan kendala persamaan, $\mathbf{v}$, sama dengan nol.

Luptáčik (2010) menyebutkan bahwa tidak terdapat cara yang sederhana dalam menyelesaikan syarat-syarat Kuhn-Tucker, bahkan secara komputasional sekalipun. Salah satu pendekatan yang dapat dimanfaatkan untuk menyelesaikan permasalahan ini ialah pemrograman kuadratik.

2.22. Pemrograman Kuadratik

Menurut Nocedal dan Wright (2006), program kuadratik merupakan sebuah permasalahan optimisasi yang mengandung fungsi objektif berbentuk kuadrat dan kendala-kendala linear. Secara umum, suatu program kuadratik dinyatakan sebagai:

$$\min_{\mathbf{x}} q(\mathbf{x}) = \frac{1}{2}\mathbf{x}'\mathbf{D}\mathbf{x} + \mathbf{x}'\mathbf{d}$$

dengan kendala $\quad \mathbf{p}_i'\mathbf{x} \geq q_i, \quad i = 1, 2, \ldots, l,$

$$\mathbf{r}_j'\mathbf{x} = s_j, \quad j = 1, 2, \ldots, m, \tag{2.62}$$

dengan $\mathbf{x}$, $\mathbf{d}$, $\mathbf{p}_i$, dan $\mathbf{r}_j$ merupakan vektor berukuran $n \times 1$, $\mathbf{D}$ merupakan matriks simetris berukuran $n \times n$, serta q_i dan s_j merupakan skalar. Beberapa sumber pustaka lain, seperti Taha (2007), menotasikan kendala sebagai:

$$\mathbf{P}\mathbf{x} = \mathbf{q} \tag{2.63}$$

dan

$$\mathbf{R}\mathbf{x} = \mathbf{s}, \tag{2.64}$$

dengan $\mathbf{P}$, $\mathbf{q}$, $\mathbf{R}$, dan $\mathbf{s}$ berturut-turut memuat $\mathbf{p}_i$, q_i, dan $\mathbf{r}_j$, dan s_j yang ditumpuk secara vertikal. Dengan demikian, $\mathbf{P}$ berdimensi $l \times n$, $\mathbf{q}$ berdimensi $l \times 1$, $\mathbf{R}$ berdimensi $m \times n$, dan $\mathbf{s}$ berdimensi $m \times 1$.

2.23. Algoritma Optimisasi Metaheuristik

Istilah ”metaheuristik” bersumber dari dua kata, yaitu ”meta” dan ”heuristik”. Dikutip dari Rajwar dkk. (2023), algoritma heuristik adalah suatu metode untuk menghasilkan solusi-solusi terhadap permasalahan-permasalahan optimisasi melalui percobaan dan kegagalan (*trial and error*). Di sisi lain, kata ”meta” berarti ”di atas” atau ”pada tingkat yang lebih tinggi”. Oleh karena itu, algoritma optimisasi metaheuristik dapat didefinisikan sebagai metode tingkat lanjut dari pencarian solusi optimal atas suatu permasalahan.

Algoritma-algoritma metaheuristik yang berbasis perilaku dan seleksi alamiah mulai dikembangkan oleh para ilmuwan sejak tahun 1950-an. Penemuan ini ditujukan untuk menggantikan metode-metode konvensional yang tidak lagi efisien, tangguh (*robust*), dan akurat dalam menangani permasalahan-permasalahan optimisasi yang semakin diskontinu dan nonlinear. Alam menjadi dasar inspirasi algoritma-algoritma metaheuristik karena berbagai fenomena alam yang dinilai optimal dalam menyelesaikan permasalahan yang bersumber dari alam itu sendiri.

Secara umum, sebuah algoritma metaheuristik bergantung pada pergerakan individu dan interaksi antarindividu dalam populasi. Secara matematis, ”individu”

dan ”populasi” dapat dimaknai sebagai kandidat solusi dan himpunan penyelesaian suatu fungsi matematika. Pergerakan individu dapat melibatkan operasi-operasi evolusioner atau metode *random walk* yang didasarkan pada distribusi probabilitas tertentu, sedangkan interaksi antarindividu umumnya didasarkan pada teori evolusi makhluk hidup, fenomena alamiah, atau perilaku hewan (Suyanto dkk., 2022).

Berdasarkan sumber inspirasi yang lebih spesifik terhadap penemuannya, Rajwar dkk. (2023) menggolongkan algoritma-algoritma metaheuristik menjadi empat kelompok, yaitu:

1. Algoritma-algoritma evolusioner

   Algoritma-algoritma evolusioner dikembangkan dari teori evolusi Darwin. Alur algoritma-algoritma dalam kelompok ini bermula dari simulasi reproduksi seksual dan mutasi pada sekelompok individu secara berulang guna menemukan dan mempertahankan materi genetik yang menjadikan suatu individu lebih tangguh dalam beradaptasi dan bertahan hidup.
2. Algoritma-algoritma kecerdasan kawanan (*swarm intelligence algorithms*)

   Algoritma-algoritma *swarm intelligence* terinspirasi dari perilaku hewan yang membentuk kawanan pada fenomena-fenomena tertentu, seperti melindungi diri dari pemangsa, berburu, dan mencari makan. Kualitas-kualitas yang diperhatikan dari suatu kawanan hewan ialah kemampuan beradaptasi, komunikasi, dan cara berbagi pengetahuan.
3. Algoritma-algoritma berbasis hukum fisik

   Algoritma-algoritma berbasis hukum fisik dikembangkan dari hukum-hukum fisika dan kimia.
4. Algoritma-algoritma lainnya

   Algoritma-algoritma dalam kelompok ini dikembangkan dari berbagai dasar, mulai dari fenomena dalam kehidupan sehari-hari, perilaku manusia, hingga teorema matematik dan politik.

BAB III

ANALISIS KLASTER *K-MEANS* DAN ALGORITMA-ALGORITMA OPTIMISASI PORTOFOLIO

3.1. Analisis Klaster *K-Means*

Analisis klaster *K-Means* merupakan salah satu metode analisis klaster partisi yang mengelompokkan tiap objek menuju klaster dengan pusat klaster yang berjarak paling dekat. Pusat klaster disebut juga sentroida. Pada analisis klaster *K-means*, sentroida diperoleh sebagai mean dari objek-objek dalam klaster yang bersesuaian (Johnson dan Winchern, 2007).

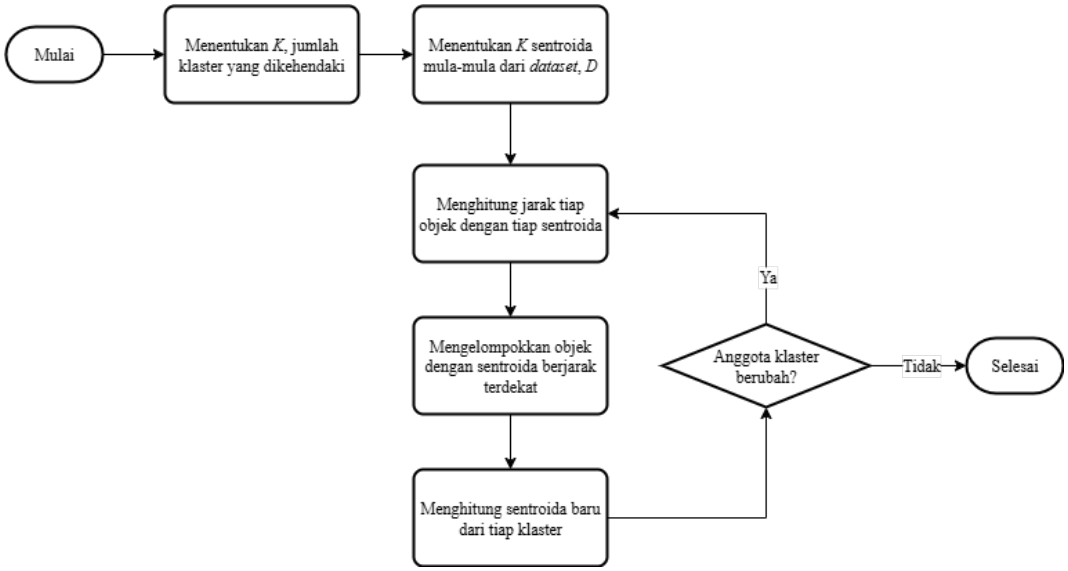
Johnson dan Winchern (2007) dan Han dkk. (2012) menjabarkan metode analisis klaster *K-means* sebagai berikut:

1. Tentukan K, jumlah klaster ideal atau jumlah klaster yang dikehendaki.
2. Tentukan K objek sembarang dari *dataset* D sebagai K sentroida mula-mula.
3. Kelompokkan objek dengan klaster yang mempunyai sentroida terdekat dengan objek tersebut. Umumnya, digunakan jarak Euklides.
4. Hitung kembali sentroida klaster setelah menerima objek baru dan melepas-kan objek lama.
5. Ulangi langkah 3 dan 4 hingga tidak terjadi perubahan klaster pada semua objek.

Langkah-langkah di atas juga diberikan pada diagram alur pada Gambar 3.1.

Salah satu cara memperoleh nilai K optimal ialah melalui koefisien *silhouette* atau *silhouette score*. Misalkan diberikan suatu *dataset*, D, yang terdiri atas n objek dan dipartisi menjadi K klaster, $C_1, C_2, \ldots, C_k$. Objek dalam *dataset* merupakan data multivariat yang disusun sebagai suatu vektor. Dimisalkan juga $d(\mathbf{p}, \mathbf{q})$ sebagai ukuran jarak antara dua buah vektor objek, $\mathbf{p}$ dan $\mathbf{q}$. Untuk tiap objek, $\mathbf{o} \in D$, dan misalkan $\mathbf{o} \in C_i$, dirumuskan $a(\mathbf{o})$ dan $b(\mathbf{o})$ sebagai:

$$a(\mathbf{o}) = \frac{\sum_{\mathbf{o}' \in C_i, \mathbf{o} \neq \mathbf{o}'} d(\mathbf{o}, \mathbf{o}')}{|C_i| - 1}$$



Gambar 3.1 Diagram alur analisis klaster *K-Means*.

dan

$$b(\mathbf{o}) = \min_{C_j:1\leq j\leq k, j\neq i} \left\{ \frac{\sum_{\mathbf{o}'\in C_j} d(\mathbf{o},\mathbf{o}')}{|C_j|} \right\}.$$

$a(\mathbf{o})$ adalah jarak rata-rata antara $\mathbf{o}$ dengan semua objek lain dalam klasternya, sedangkan $b(\mathbf{o})$ adalah jarak rata-rata minimum antara $\mathbf{o}$ dengan klaster lain yang tidak memuat $\mathbf{o}$. Nilai $a(\mathbf{o})$ mencerminkan kepadatan klaster yang memuat $\mathbf{o}$. Semakin kecil nilai $a(\mathbf{o})$, klaster tersebut semakin padat. Sementara, nilai $b(\mathbf{o})$ mencerminkan seberapa terpisah $\mathbf{o}$ dari klaster-klaster lain. Semakin besar nilai $b(\mathbf{o})$, objek $\mathbf{o}$ semakin terpisah dari klaster-klaster lain. *Silhouette score* dari $\mathbf{o}$ selanjutnya dirumuskan sebagai:

$$s(\mathbf{o}) = \frac{b(\mathbf{o}) - a(\mathbf{o})}{\max\{a(\mathbf{o}), b(\mathbf{o})\}}. \tag{3.1}$$

Jika $d(\mathbf{o},\mathbf{o}')$ merujuk pada jarak Euclid antara objek $\mathbf{o}$ dan $\mathbf{o}'$ sebagaimana dirumuskan pada Persamaan (2.21), $d(\mathbf{o},\mathbf{o}')$ bernilai nonnegatif sehingga $a(\mathbf{o})$ maupun $b(\mathbf{o})$ bernilai nonnegatif. Maka, nilai minimum dari $a(\mathbf{o})$ maupun $b(\mathbf{o})$ adalah nol. Lebih lanjut, rumusan *silhouette score* pada Persamaan (3.1) di atas dapat didefinisikan kembali untuk kasus: $a(\mathbf{o})$ lebih besar dari $b(\mathbf{o})$, $a(\mathbf{o})$ sama dengan $b(\mathbf{o})$, dan $a(\mathbf{o})$ kurang dari $b(\mathbf{o})$. Untuk kasus $a(\mathbf{o})$ lebih besar dari $b(\mathbf{o})$, *silhouette score*

dapat didefinisikan kembali sebagai:

$$\begin{aligned} s(\mathbf{o}) &= \frac{b(\mathbf{o}) - a(\mathbf{o})}{b(\mathbf{o})} \\ &= \frac{b(\mathbf{o})}{b(\mathbf{o})} - \frac{a(\mathbf{o})}{b(\mathbf{o})} \\ &= 1 - \frac{a(\mathbf{o})}{b(\mathbf{o})}. \end{aligned}$$

Karena syarat kasus dan $a(\mathbf{o})$ nonnegatif, maka:

$$0 \leq \frac{a(\mathbf{o})}{b(\mathbf{o})} < 1$$

sehingga

$$0 < s(\mathbf{o}) \leq 1.$$

Untuk kasus $a(\mathbf{o})$ sama dengan $b(\mathbf{o})$, *silhouette score* dapat didefinisikan kembali sebagai:

$$\begin{aligned} s(\mathbf{o}) &= \frac{b(\mathbf{o}) - a(\mathbf{o})}{b(\mathbf{o})} \\ &= \frac{b(\mathbf{o}) - b(\mathbf{o})}{b(\mathbf{o})} \\ &= 0. \end{aligned}$$

Terakhir, untuk kasus $a(\mathbf{o})$ kurang dari $b(\mathbf{o})$, *silhouette score* dapat didefinisikan kembali sebagai:

$$\begin{aligned} s(\mathbf{o}) &= \frac{b(\mathbf{o}) - a(\mathbf{o})}{a(\mathbf{o})} \\ &= \frac{b(\mathbf{o})}{a(\mathbf{o})} - \frac{a(\mathbf{o})}{a(\mathbf{o})} \\ &= \frac{b(\mathbf{o})}{a(\mathbf{o})} - 1. \end{aligned}$$

Karena syarat kasus dan $b(\mathbf{o})$ nonnegatif, maka:

$$0 \leq \frac{b(\mathbf{o})}{a(\mathbf{o})} < 1$$

sehingga

$$-1 < s(\mathbf{o}) \leq 0.$$

Dengan menggabungkan interval nilai $s(\mathbf{o})$ dari ketiga kasus tersebut, telah dibuktikan dan disimpulkan bahwa nilai *silhouette score* berkisar antara -1 hingga 1.

Analisis klaster yang baik diharapkan terasosiasi dengan nilai $a(\mathbf{o})$ yang kecil dan $b(\mathbf{o})$ yang besar sehingga *silhouette score* bernilai mendekati 1. Untuk menilai kebaikan hasil analisis klaster secara umum, nilai rata-rata *silhouette score* dari semua objek dalam *dataset* juga dapat digunakan (Han dkk., 2012).

Untuk suatu *dataset* tertentu, perbedaan hasil akhir analisis klaster dapat terjadi karena bergantung pada pemilihan sentroida mula-mula (Johnson dan Winchern, 2007) . Namun, kualitas klaster yang lebih baik dapat diperoleh pada data yang terdistribusi normal atau normal standar. Hal ini dikarenakan normalisasi atau standarisasi data mampu menghilangkan variabilitas dengan mempertahankan karakteristik intrinsik data yang diperlukan untuk pembentukan klaster (Stoddard, 1979). Eltibi dan Ashour (2011) juga mendapati bahwa analisis klaster *K-Means* pada data terdistribusi normal berlangsung lebih cepat dan menghasilkan taraf galat yang lebih rendah.

3.2. Metode Portofolio *Minimum Variance*

Dalam berinvestasi, seorang investor pasti mengharapkan *return* semaksimal mungkin dengan tingkat volatilitas yang ia dapat terima. Model portofolio *minimum variance*, yang dikenal juga sebagai model *mean-variance* atau model Markowitz, merupakan suatu metode statistik yang ditemukan oleh Harry Markowitz, seorang ekonom asal Amerika Serikat, pada tahun 1952 yang ditujukan untuk membentuk portofolio optimal.

Misalkan suatu portofolio mengandung n saham. Ditentukan $\mathbf{r}$ adalah vektor *return*, $\boldsymbol{\mu}$ adalah vektor ekspektasi *return*, $\boldsymbol{\Sigma}$ adalah matriks kovariansi yang dibangun dari *return* yang didefinisikan menurut Persamaan (2.18), dan $\mathbf{w}$ adalah vektor bobot yang memenuhi batasan pada Persamaan (2.31). Rumusan ekspektasi *return* dan variansi portofolio telah dirumuskan pada Persamaan (2.32) dan Persamaan (2.34). Model portofolio *minimum variance* dengan batasan tidak ada

shortselling (*no-short-sale-constrained*) dirumuskan sebagai:

$$\begin{aligned} &\min_{\mathbf{w}\in\mathbb{R}^n} \frac{1}{2}\mathbf{w}'\boldsymbol{\Sigma}\mathbf{w}, \\ \text{dengan kendala } &\sum_{i=1}^{n} w_i = 1 \text{ dan} \\ &w_i \geq 0, \quad i = 1, \ldots, n, \end{aligned} \tag{3.2}$$

dengan $w_i, i = 1, \ldots, n$ merupakan elemen dari vektor $\mathbf{w}$. Model ini disebut juga *constrained minimum variance portfolio* (disingkat CMVP) (Dai, 2019).

Dengan memandang kendala pertidaksamaan pada Persamaan (3.2) sebagai:

$$-\mathbf{w} \leq \mathbf{0}_n,$$

fungsi pengali Lagrange yang berkorespondensi dengan model CMVP tersebut diberikan sebagai:

$$\begin{aligned} \mathcal{L}(\mathbf{w}, \lambda, \boldsymbol{\Lambda}) &= \frac{1}{2}\mathbf{w}'\boldsymbol{\Sigma}\mathbf{w} + \lambda(1 - \mathbf{w}'\mathbf{1}_n) + (-\mathbf{w}')\boldsymbol{\Lambda} \\ &= \frac{1}{2}\mathbf{w}'\boldsymbol{\Sigma}\mathbf{w} - \lambda(\mathbf{w}'\mathbf{1}_n - 1) - \mathbf{w}'\boldsymbol{\Lambda} \end{aligned}$$

dengan $\boldsymbol{\Lambda}' = [\lambda_1, \ldots, \lambda_n]$ adalah vektor pengali Lagrange yang berkorespondensi dengan kendala pertidaksamaan. Maka, syarat-syarat Kuhn-Tucker yang bersesuaian ialah:

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial \mathbf{w}'} &= \frac{\partial}{\partial \mathbf{w}'}\left(\frac{1}{2}\mathbf{w}'\boldsymbol{\Sigma}\mathbf{w} - \lambda(\mathbf{w}'\mathbf{1}_n - 1) - \mathbf{w}'\boldsymbol{\Lambda}\right) \\ &= \boldsymbol{\Sigma}\mathbf{w} - \lambda\mathbf{1}_n - \boldsymbol{\Lambda} \\ &\geq \mathbf{0}_n, \end{aligned} \tag{3.3}$$

$$\begin{aligned} \mathbf{w}'\frac{\partial \mathcal{L}}{\partial \mathbf{w}'} &= \mathbf{w}'(\boldsymbol{\Sigma}\mathbf{w} - \lambda\mathbf{1}_n - \boldsymbol{\Lambda}) \\ &= \mathbf{w}'\boldsymbol{\Sigma}\mathbf{w} - \lambda\mathbf{w}'\mathbf{1}_n - \mathbf{w}'\boldsymbol{\Lambda} \\ &= 0, \end{aligned} \tag{3.4}$$

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial \boldsymbol{\Lambda}} &= \frac{\partial}{\partial \boldsymbol{\Lambda}}\left(\frac{1}{2}\mathbf{w}'\boldsymbol{\Sigma}\mathbf{w} - \lambda(\mathbf{w}'\mathbf{1}_n - 1) - \mathbf{w}'\boldsymbol{\Lambda}\right) \\ &= -\mathbf{w}' \\ &\leq \mathbf{0}'_n, \end{aligned} \tag{3.5}$$

$$\begin{aligned}
\boldsymbol{\Lambda}\frac{\partial \mathcal{L}}{\partial \boldsymbol{\Lambda}} &= (-\mathbf{w}')\boldsymbol{\Lambda} \\
&= -\mathbf{w}'\boldsymbol{\Lambda} \\
&= 0, \qquad (3.6) \\
\frac{\partial \mathcal{L}}{\partial \lambda} &= \frac{\partial}{\partial \lambda}\left(\frac{1}{2}\mathbf{w}'\boldsymbol{\Sigma}\mathbf{w} - \lambda(\mathbf{w}'\mathbf{1}_n - 1) - \mathbf{w}'\boldsymbol{\Lambda}\right) \\
&= -(\mathbf{w}'\mathbf{1}_n - 1) \\
&= 0, \qquad (3.7) \\
\mathbf{w} &\geq \mathbf{0}_n, \text{ dan} \qquad (3.8) \\
\lambda &\geq 0. \qquad (3.9)
\end{aligned}$$

Dengan banyak dan kompleksnya syarat-syarat Kuhn-Tucker, solusi optimum untuk model CMVP dapat diselesaikan dengan lebih mudah melalui pendekatan metode pengali Lagrange dengan fungsi Lagrange termodifikasi:

$$\mathcal{L}(\mathbf{w}, \lambda) = \frac{1}{2}\mathbf{w}'\boldsymbol{\Sigma}\mathbf{w} - \lambda(\mathbf{w}'\mathbf{1}_n - 1), \qquad (3.10)$$

yaitu fungsi Lagrange yang hanya melibatkan kendala persamaan. Mengacu pada Persamaan (2.48) dan Persamaan (2.49), solusi optimum fungsi Lagrange pada Persamaan (3.10) di atas dapat diperoleh melalui derivatif-derivatif parsial terhadap tiap parameter fungsi, yaitu:

$$\begin{aligned}
\frac{\partial \mathcal{L}(\mathbf{w}, \lambda)}{\partial \mathbf{w}} &= \frac{\partial}{\partial \mathbf{w}}\left[\frac{1}{2}\mathbf{w}'\boldsymbol{\Sigma}\mathbf{w} - \lambda(\mathbf{w}'\mathbf{1}_n - 1)\right] \\
&= \boldsymbol{\Sigma}\mathbf{w} - \lambda\mathbf{1}_n \\
&= \mathbf{0}_n \qquad (3.11)
\end{aligned}$$

dan

$$\begin{aligned}
\frac{\partial \mathcal{L}(\mathbf{w}, \lambda)}{\partial \lambda} &= \frac{\partial}{\partial \lambda}\left[\frac{1}{2}\mathbf{w}'\boldsymbol{\Sigma}\mathbf{w} - \lambda(\mathbf{w}'\mathbf{1}_n - 1)\right] \\
&= \mathbf{w}'\mathbf{1}_n - 1 \\
&= 0. \qquad (3.12)
\end{aligned}$$

Persamaan (3.11) diselesaikan untuk memperoleh $\mathbf{w}$ sebagai berikut:

$$\boldsymbol{\Sigma}\mathbf{w} - \lambda\mathbf{1}_n = \mathbf{0}_n$$

$$\begin{aligned} &\iff \boldsymbol{\Sigma}\mathbf{w} = \lambda \mathbf{1}_n \\ &\iff \mathbf{w} = \lambda \boldsymbol{\Sigma}^{-1}\mathbf{1}_n. \end{aligned} \tag{3.13}$$

Nilai $\mathbf{w}$ pada Persamaan (3.13) disubstitusikan ke Persamaan (3.10) sehingga diperoleh:

$$\begin{aligned} \mathcal{L}(\mathbf{w}, \lambda) &= \frac{1}{2}\mathbf{w}'\boldsymbol{\Sigma}\mathbf{w} - \lambda(\mathbf{w}'\mathbf{1}_n - 1) \\ &= \frac{1}{2}(\lambda\boldsymbol{\Sigma}^{-1}\mathbf{1}_n)'\boldsymbol{\Sigma}(\lambda\boldsymbol{\Sigma}^{-1}\mathbf{1}_n) - \lambda\big((\lambda\boldsymbol{\Sigma}^{-1}\mathbf{1}_n)'\mathbf{1}_n - 1\big) \\ &= \frac{1}{2}\lambda^2\mathbf{1}_n'(\boldsymbol{\Sigma}^{-1})'\boldsymbol{\Sigma}\boldsymbol{\Sigma}^{-1}\mathbf{1}_n - \lambda\big(\lambda\mathbf{1}_n'(\boldsymbol{\Sigma}^{-1})'\mathbf{1}_n - 1\big) \\ &= \frac{1}{2}\lambda^2\mathbf{1}_n'\boldsymbol{\Sigma}^{-1}\boldsymbol{\Sigma}\boldsymbol{\Sigma}^{-1}\mathbf{1}_n - \lambda(\lambda\mathbf{1}_n'\boldsymbol{\Sigma}^{-1}\mathbf{1}_n - 1) \\ &= \frac{1}{2}\lambda^2\mathbf{1}_n'\mathbf{I}_n\boldsymbol{\Sigma}^{-1}\mathbf{1}_n - \lambda^2\mathbf{1}_n'\boldsymbol{\Sigma}^{-1}\mathbf{1}_n + \lambda \\ &= \frac{1}{2}\lambda^2\mathbf{1}_n'\boldsymbol{\Sigma}^{-1}\mathbf{1}_n - \lambda^2\mathbf{1}_n'\boldsymbol{\Sigma}^{-1}\mathbf{1}_n + \lambda \\ &= -\frac{1}{2}\lambda^2\mathbf{1}_n'\boldsymbol{\Sigma}^{-1}\mathbf{1}_n + \lambda. \end{aligned}$$

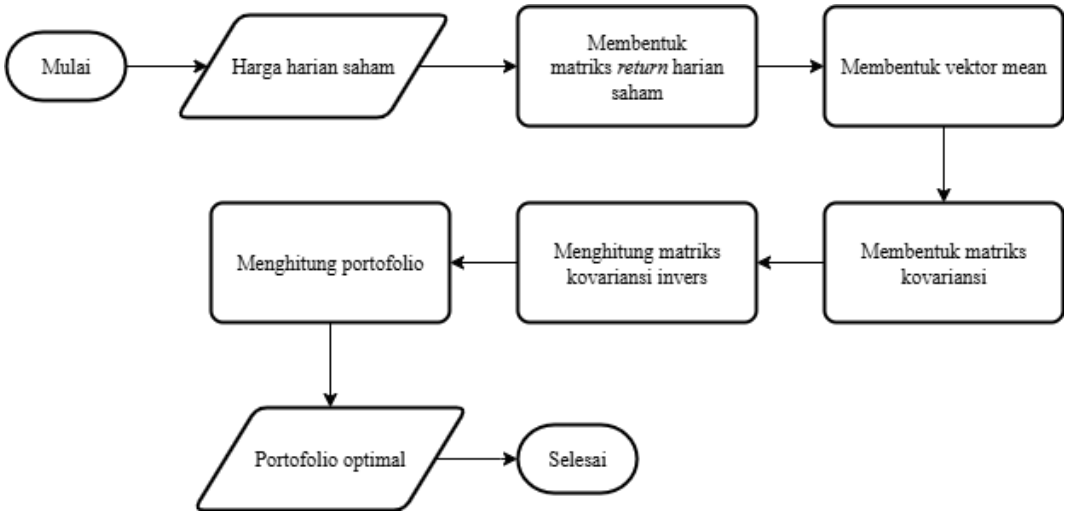
Maka, Persamaan (3.12) dapat dikerjakan kembali sebagai:

$$\begin{aligned} \frac{\partial\mathcal{L}(\mathbf{w}, \lambda)}{\partial\lambda} &= 0 \\ \iff \frac{\partial}{\partial\lambda}\left[-\frac{1}{2}\lambda^2\mathbf{1}_n'\boldsymbol{\Sigma}^{-1}\mathbf{1}_n + \lambda\right] &= 0 \\ \iff -\lambda\mathbf{1}_n'\boldsymbol{\Sigma}^{-1}\mathbf{1}_n + 1 &= 0 \\ \iff -\lambda\mathbf{1}_n'\boldsymbol{\Sigma}^{-1}\mathbf{1}_n &= -1 \\ \iff \lambda\mathbf{1}_n'\boldsymbol{\Sigma}^{-1}\mathbf{1}_n &= 1 \\ \iff \lambda &= \frac{1}{\mathbf{1}_n'\boldsymbol{\Sigma}^{-1}\mathbf{1}_n}. \end{aligned} \tag{3.14}$$

Dengan menyubstitusikan λ pada Persamaan (3.14) ke Persamaan (3.13), diperoleh vektor bobot yang meminimalisasi variansi portofolio sebagai:

$$\begin{aligned} \mathbf{w}_{\min} &= \lambda\boldsymbol{\Sigma}^{-1}\mathbf{1}_n \\ &= \left(\frac{1}{\mathbf{1}_n'\boldsymbol{\Sigma}^{-1}\mathbf{1}_n}\right)\boldsymbol{\Sigma}^{-1}\mathbf{1}_n \\ &= \frac{\boldsymbol{\Sigma}^{-1}\mathbf{1}_n}{\mathbf{1}_n'\boldsymbol{\Sigma}^{-1}\mathbf{1}_n}. \end{aligned} \tag{3.15}$$

Langkah-langkah penyelesaian fungsi pengali Lagrange termodifikasi di atas dirangkum pada diagram alur pada Gambar 3.2 berikut.



Gambar 3.2 Diagram alur penyelesaian fungsi pengali Lagrange termodifikasi untuk CMVP.

Pendekatan lain untuk menyelesaikan syarat-syarat Kuhn-Tucker ialah pemrograman kuadratik yang penyelesaiannya dapat diperantarai oleh aplikasi komputasi statistik.

3.3. *Genetic Algorithm*

Genetic Algorithm (GA) merupakan algoritma optimisasi yang ditemukan oleh John Holland pada tahun 1975. Sebagaimana namanya, inspirasi Holland dalam menemukan GA ialah bermacam karakteristik makhluk hidup yang dihasilkan dari rekombinasi genetik. GA melibatkan populasi dengan anggota-anggota yang disebut *string* yang dianalogikan sebagai kromosom (Reeves, 2010).

3.3.1. Terminologi Genetika

Suatu kromosom terdiri atas serangkaian gen. Suatu gen mempunyai posisi fisik tertentu yang disebut lokus. Berbagai kemungkinan variasi gen-gen pada lokus tertentu disebut alel. Kumpulan informasi genetik pada kromosom disebut genotipe. Fenotipe adalah ciri-ciri fisik yang teramati pada suatu makhluk hidup yang terasosiasi dengan genotipe tertentu (Mahner dan Kary, 1997).

Rekombinasi genetik dapat terjadi ketika dua buah kromosom mengalami persilangan (*crossover*) atau mutasi. Persilangan adalah peristiwa bertukarnya sekumpulan gen di lokus tertentu pada sebuah kromosom dengan gen-gen di lokus yang sama pada kromosom lain. Sementara, mutasi adalah peristiwa sekumpulan gen yang terpilih secara acak mengalami pergantian nilai alel (Reeves, 2010).

3.3.2. Konsep Matematis *Genetic Algorithm*

Pemahaman terhadap GA diawali dengan memahami permasalahan optimisasi kombinatorial (*combinatorial optimization problem*, disingkat COP).

Definisi 3.3.1 *(Reeves, 2010) Diberikan ruang pencarian (search space) diskrit, $\mathcal{X}$, dan suatu fungsi, f, yang memetakan $\mathcal{X}$ menuju $\mathbb{R}$. Permasalahan optimisasi kombinatorial didefinisikan sebagai:*

$$\min_{\mathbf{x}\in\mathcal{X}} f(\mathbf{x}),$$

dengan $\mathbf{x}$ adalah vektor yang memuat variabel-variabel keputusan (decision variables) dan f disebut fungsi objektif.

Pada GA, kandidat solusi terhadap suatu COP dinyatakan sebagai representasi dari variabel-variabel keputusan yang sesungguhnya. Kumpulan variabel keputusan ini diibaratkan sebagai fenotipe, sedangkan representasinya diibaratkan sebagai genotipe. Secara matematis, vektor representasi variabel keputusan didefinisikan sebagai berikut.

Definisi 3.3.2 *(Reeves, 2010) Diberikan suatu permasalahan optimisasi kombinatorial yang melibatkan ruang pencarian diskrit, $\mathcal{X}$, fungsi objektif, f, dan vektor variabel keputusan, $\mathbf{x}$. Vektor representasi variabel keputusan dilambangkan oleh larik $\mathbf{s}$ dengan panjang l dan beranggotakan simbol-simbol dari ruang alfabet, $\mathcal{A}$, melalui pemetaan:*

$$c : \mathcal{A}^l \mapsto \mathcal{X}.$$

Pada Definisi 3.3.2, elemen larik $\mathbf{s}$ diibaratkan sebagai gen. Selain itu, pemetaan c sering disebut pemetaan genotipe-fenotipe. Pada beberapa kasus, digunakan ruang

pencarian $\mathcal{S} \subseteq \mathcal{A}^l$ karena beberapa solusi umum mula-mula mengakibatkan fungsi menjadi tidak terdefinisi setelah melalui pemetaan c. Melalui representasi variabel, permasalahan optimisasi pada Definisi 3.3.1 berubah menjadi

$$\min_{\mathbf{s} \in \mathcal{S}} g(\mathbf{s})$$

dengan $g(\mathbf{s}) = f(c(\mathbf{s}))$.

Pada GA, persilangan ekuivalen dengan pertukaran sekumpulan elemen suatu *string* pada urutan tertentu dengan kumpulan elemen *string* lain pada urutan yang sama, sedangkan mutasi sama dengan mengubah sekumpulan elemen random pada suatu *string* dengan nilai-nilai komplemennya.

3.3.3. Struktur *Genetic Algorithm* dan Variasinya

Secara garis besar, langkah-langkah GA tersusun atas inisiasi populasi, seleksi, persilangan, mutasi, dan evaluasi populasi baru. Langkah-langkah ini dirangkum dalam *pseudocode* yang dapat dilihat pada Lampiran 2. Seiring berjalannya waktu, GA mengalami berbagai modifikasi dan pengembangan. Mengacu pada Reeves (2010), penjelasan dari tiap langkah GA beserta variasi pada masing-masing langkah ialah sebagai berikut:

1. Inisiasi populasi

   Terdapat dua buah aspek yang perlu diperhatikan dalam menginisiasi populasi, yaitu ukuran populasi dan metode pemilihan populasi. Menurut Reeves (1993, dalam Reeves, 2010), ukuran populasi minimum harus mampu menjangkau tiap titik dalam ruang pencarian hanya dengan persilangan. Hal ini mampu dicapai jika setidaknya satu elemen alel di suatu lokus pada suatu populasi *string* bernilai sama. Di sisi lain, metode pemilihan populasi sangat disarankan untuk bersifat random, seperti pengambilan sampel tanpa pengembalian atau *Latin hypercube sampling* (LHS).
2. Seleksi

   Pada mulanya, Holland mendasarkan seleksi pada metode roda rolet (*roulette wheel selection*, disingkat RWS). Konsep di balik metode RWS mencermikan putaran panah pada suatu roda rolet yang berakhir di antara batas-batas nilai ter-

tentu. Pada metode ini, setelah memperoleh *fitness*, yaitu kualitas atau kebaikan suatu *string* sebagai solusi optimum dari suatu fungsi objektif, dibangun suatu fungsi sepenggal (*piecewise function*) yang didasarkan pada distribusi probabilitas kumulatif yang proporsional terhadap nilai-nilai *fitness* tersebut. Kemudian, bilangan-bilangan *pseudo-random* dibangkitkan untuk memilih *string-string* yang kemudian menjadi kumpulan *string* induk. Pemilihan didasarkan pada interval-interval probabilitas pada fungsi sepenggal tersebut.

Metode RWS identik dengan variabilitas stokastik yang tinggi. Salah satu metode alternatif yang mampu menangkal kekurangan ini ialah pemeringkatan (*ranking*). Metode pemeringkatan paling sederhana adalah pemeringkatan linear yang mendefinisikan peluang suatu *string* berada pada peringkat k dalam suatu populasi berukuran M sebagai:

$$P[k] = \alpha + \beta k,$$

dengan α dan β merupakan dua buah konstanta. Agar $P[k]$ merupakan distribusi probabilitas, diperlukan syarat:

$$\sum_{k=1}^{M} (\alpha + \beta k) = 1.$$

Selanjutnya, kumpulan kromosom induk akan melalui tahap persilangan dan/atau mutasi.

3. Persilangan (*crossover*)

   Persilangan dijalankan dengan suatu aturan terandomisasi, yaitu jika suatu bilangan *pseudo-random* uniform bernilai lebih dari taraf persilangan (*crossover rate*), χ. Persilangan dapat terjadi di satu atau lebih titik pada suatu *string*. Dalam hal ini, persilangan multititik dinilai lebih baik karena mampu mencegah bias (Eshelman dkk., 1989 dalam Reeves, 2010).

   Aturan randomisasi ini juga dapat dimodifikasi melalui metode persilangan uniform (*uniform crossover*). Pada metode ini, dilakukan *masking* dengan memanipulasi operator persilangan menjadi suatu *string* biner, yaitu bernilai 0 untuk menukar dan 1 untuk tidak menukar. Pola nilai 0 dan 1 dalam *string* tersebut dibangkitkan dari distribusi Bernoulli dengan parameter p yang bernilai

umum 0,5. Nilai p dapat diubah-ubah untuk menghasilkan bias terhadap salah satu kromosom yang terlibat dalam persilangan (Syswerda, 1989 dalam Reeves, 2010).

4. Mutasi

   Tahap mutasi melibatkan *masking*, yaitu dengan memanipulasi operator mutasi menjadi nilai 0 dan 1, dengan 0 berarti mutasi tidak dilakukan dan 1 berarti mutasi dilakukan. Mutasi dapat dipraktikkan dengan membangkitkan bilangan random untuk tiap elemen pada *string* dan dibandingkan terhadap taraf mutasi, μ. Mutasi dijalankan jika bilangan random tersebut bernilai lebih dari μ. Konsep ini serupa dengan aturan terandomisasi pada tahap persilangan.

   Algoritma di balik aturan randomisasi ini memerlukan komputasi yang mahal (*computationally expensive*), terlebih jika *string* berukuran panjang dan populasi berukuran besar. Oleh karena itu, salah satu alternatif yang dapat dilakukan ialah dengan membandingkan suatu bilangan random yang dibangkitkan dari distribusi POI(λ) dengan tingkat mutasi yang dihitung berdasarkan rumus $\mu = \lambda/l$, dengan λ adalah rata-rata banyak mutasi per kromosom dan l adalah panjang *string*. Melalui alternatif ini, jika terdapat m mutasi pada suatu kromosom, diambil m bilangan random yang terdistribusi uniform antara λ hingga l, lalu tiap bilangan random dibandingkan dengan μ guna menentukan lokus-lokus di mana mutasi akan dijalankan. Adapun λ umumnya bernilai 1.

5. Populasi baru

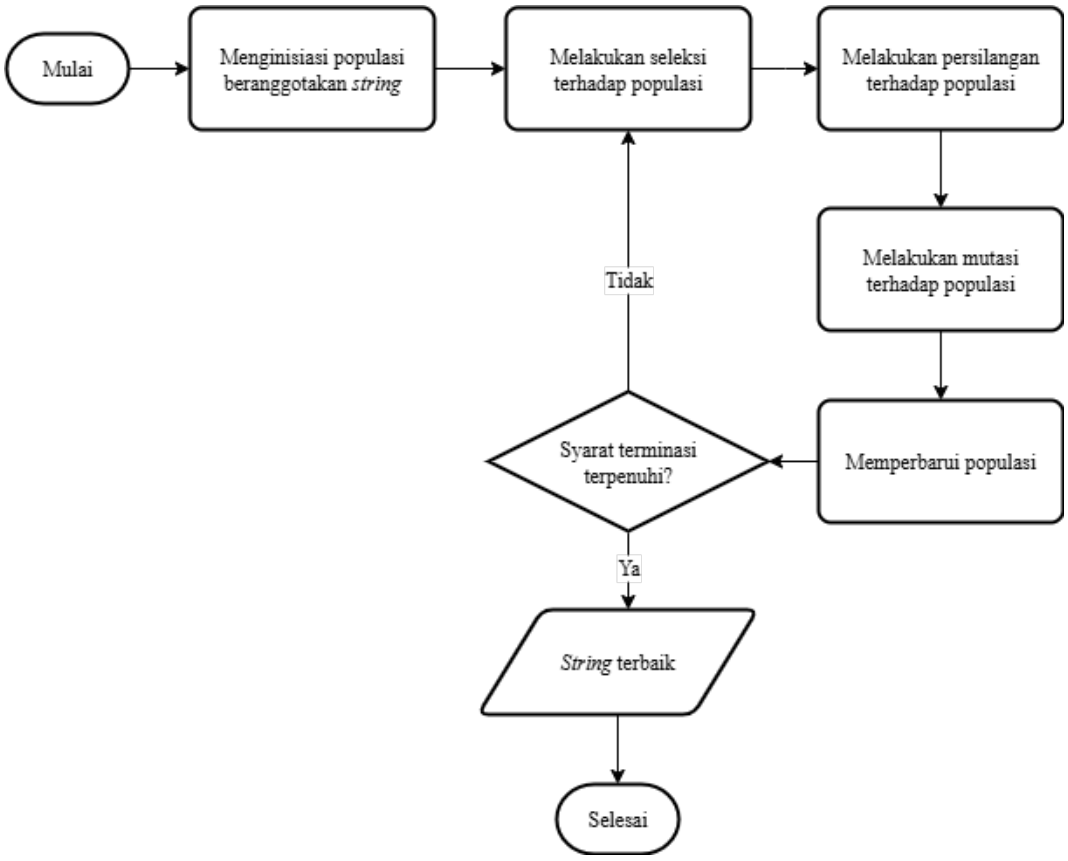
   Pendekatan umum Holland menerapkan seleksi, persilangan, dan mutasi pada suatu populasi beranggotakan M kromosom secara berulang hingga memperoleh M kromosom baru sebagai populasi baru. De Jong (1975, dalam Reeves, 2010) mengembangkan pendekatan yang melibatkan konsep elitisme dan penumpangtindihan populasi (*population overlapping*). Konsep elitisme mempertahankan satu *string* terbaik dan menggantikan $(M - 1)$ *string* lainnya dengan *string* baru. Di sisi lain, konsep penumpangtindihan populasi menggantikan hanya sebanyak suatu pecahan, G, dari populasi pada tiap iterasi pembangkitan.

6. Terminasi

   Syarat terminasi diperlukan untuk memastikan GA berlangsung dalam interval

waktu yang terbatas. Batasan yang umumnya digunakan sebagai syarat terminasi adalah perulangan evaluasi, waktu, atau tingkat keberagaman di dalam populasi. Tingkat keberagaman yang cukup umum adalah statistik genotipe, seperti proporsi suatu nilai alel tertentu.

Langkah-langkah GA di atas dirangkum pada diagram alur pada Gambar 3.3 berikut.



Gambar 3.3 Diagram alur *Genetic Algorithm*.

Beragamnya variasi GA beriringan dengan berkembangnya aplikasi dan penelitian terhadap algoritma ini. Terlebih, GA juga dirujuk dalam berbagai jurnal terkait kecerdasan buatan dan riset operasi (Reeves, 2010).

3.4. *Komodo Mlipir Algorithm*

Komodo Mlipir Algorithm (KMA) merupakan salah satu metode optimisasi matematis metaheuristik terbaru. Algoritma ini ditemukan oleh Prof. Dr. Suyanto,

S.T., M.Sc. dan dipresentasikan pada pengukuhannya sebagai guru besar bidang Kecerdasan Buatan di Telkom University pada akhir tahun 2021.

Kelahiran KMA terinspirasi dari perilaku dan interaksi komodo di alam liar serta gerakan *mlipir* yang berasal dari bahasa Jawa. Terdapat tiga jenis individu yang diperkenalkan dalam KMA, yaitu komodo jantan dewasa, komodo betina, dan komodo jantan muda. Adaptasi perilaku komodo pada algoritma ini ditujukan agar terdapat keseimbangan perilaku eksplorasi dan eksploitasi di antara ketiga jenis komodo. Eksplorasi berarti pencarian solusi secara meluas pada himpunan penyelesaian untuk menghindari solusi optimum lokal, sedangkan eksploitasi adalah pencarian di sekitar kandidat-kandidat solusi yang mendekati optimum global.

3.4.1. Komodo

Komodo (*Varanus komodoensis*) atau biawak komodo merupakan reptil endemik yang berasal dari Nusa Tenggara Timur, Indonesia. Sebagaimana diatur dalam Peraturan Menteri Lingkungan Hidup dan Kehutanan (LHK) Nomor 92 Tahun 2018, komodo termasuk salah satu spesies satwa dilindungi di Indonesia. Populasi komodo saat ini hanya tersebar di Taman Nasional Komodo, Pulau Flores, dan sejumlah pulau di sekitarnya (Fauzia dkk., 2024). Seekor komodo dewasa dapat berkembang hingga mencapai panjang tiga meter dan berat 135 kilogram (The Editors of Encyclopaedia Britannica, 2024). Perawakan komodo yang besar menjadikannya suatu daya tarik bagi turis lokal hingga mancanegara.

Habitat yang cocok untuk kelangsungan hidup komodo ialah ekosistem sabana tropis dan hutan kering. Sutomo (2020) mencatat bahwa terdapat tujuh belas spesies tumbuhan yang mencirikan habitat komodo. Tumbuh-tumbuhan ini didominasi dari famili Asteraceae (kenikir-nikiran), Fabaceae (polong-polongan), dan Poaceae (rumput). Sayangnya, beberapa spesies tumbuhan ini mulai tergeser dengan spesies-spesies asing invasif (*invasive alien species*) yang berpotensi mengancam ekosistem habitat komodo menjadi hutan tropis kering musiman (*seasonally dry tropical forest*). Ditambah dengan kehadiran sumber daya manusia yang tidak bertanggung jawab, konservasi komodo merupakan upaya yang menantang.

3.4.2. Perilaku Komodo

Fauzia dkk. (2024) mengelompokkan perilaku komodo secara umum menjadi tujuh golongan, yaitu pemeliharaan diri, pencernaan, investigatif, perlindungan diri, agonistik (berkelahi), bergerak, dan beristirahat. Sehari-hari, komodo gemar berjemur di bawah sinar matahari, biasanya pada pagi dan sore hari. Untuk memperoleh sumber energi, komodo berpindah-pindah (*forage*) untuk mencari sumber makanan dan minuman dengan berjalan, berlari, atau melompat. Ketika komodo merasa terganggu, ia akan menunjukkan sikap siaga pada kakinya, mengangkat kepalanya, dan menjulurkan lidahnya. Sementara, dalam keadaan bahaya, komodo akan bersikap agresif dengan menghampiri sumber bahaya atau justru menjauhinya. Sikap agresif dicirikan dengan mengejar, mendengus, mengibaskan ekor, dan melakukan perlawanan. Di sisi lain, pergerakan menjauh lebih umum ditunjukkan oleh komodo-komodo muda. Pada waktu beristirahat, komodo dapat berteduh di bawah pohon yang rindang atau hinggap dan tidur di atas dahan pohon.

Komodo yang telah mencapai usia dewasa juga mampu melakukan perilaku seksual dan parental. Perilaku seksual komodo meliputi pendekatan komodo jantan kepada komodo betina dan bersetubuh. Perilaku seksual hanya dilakukan saat musim kawin. Oleh karenanya, komodo betina mempunyai perilaku reproduksi yang bersifat fakultatif. Hal ini berarti bahwa komodo betina tidak selalu berkembang biak secara seksual, tetapi juga dapat melakukan reproduksi aseksual melalui partenogenesis. Pada partenogenesis, anakan yang dihasilkan akan menurunkan susunan gen (genotipe) yang sepenuhnya berasal dari induk betinanya. Meskipun dapat memperbanyak jumlah populasi komodo sebagai satwa dilindungi, partenogenesis secara terus-menerus mampu mengurangi keberagaman genetika. Selain itu, partenogenesis juga terasosiasi dengan risiko pengurangan *fitness* pada anakan, yaitu kualitas dirinya untuk melakukan reproduksi. Dalam hal ini, partenogenesis justru berisiko meningkatkan probabilitas kepunahan hewan yang melakukannya (Watts dkk., 2007). Adapun ketika sudah mencapai waktunya untuk bertelur, komodo betina akan membangun sarang untuk menampung telur-telurnya dan menjaga sarang tersebut dari pemangsa.

Dalam *Komodo Mlipir Algorithm*, Suyanto dkk. (2022) hanya memfokuskan beberapa ciri perilaku komodo jantan dewasa, komodo betina, dan komodo jantan muda yang terkait dengan keseimbangan eksplorasi dan eksploitasi solusi dalam menyelesaikan permasalahan optimisasi. Komodo jantan dewasa gemar memakan mangsa, baik hewan lain, komodo jantan muda, maupun sesama komodo jantan dewasa. Ia memiliki naluri bertarung untuk mempertahankan mangsanya atau memperebutkan seekor komodo betina. Antara dua ekor komodo jantan dewasa, komodo yang berkualitas lebih rendah akan dikuasai oleh komodo yang berkualitas lebih tinggi. Sementara, komodo yang berkualitas lebih tinggi dapat menghampiri atau menjauh dari komodo berkualitas rendah. Oleh karena itu, komodo jantan dewasa berpeluang lebih tinggi untuk melakukan eksploitasi daripada eksplorasi dan mempunyai perilaku *high-exploitation low-exploration* (HILE).

Jika seekor komodo jantan dewasa menang, komodo betina dapat dikawini olehnya dan melakukan reproduksi seksual secara ovipar. Akan tetapi, jika komodo betina tersebut tidak merasakan ketertarikan akan sang komodo jantan, ia dapat melakukan reproduksi aseksual melalui partenogenesis. Oleh karenanya, peluang eksploitasi komodo betina sama dengan peluang eksplorasinya sehingga ia mempunyai perilaku *medium-exploitation medium-exploration* (MIME).

Sementara itu, komodo jantan muda menjaga jarak dari komodo jantan dewasa dan melahap mangsa yang tersisa ketika sudah merasa aman. Strategi pergerakan komodo jantan muda ini dijuluki sebagai *mlipir* yang berarti ”bergerak di tepi secara berhati-hati”. Berdasarkan perilaku ini, komodo jantan muda cenderung melakukan eksplorasi daripada eksploitasi. Perilaku ini dinamakan *low-exploitation high-exploration* (LIHE).

Ketiga jenis komodo dipandang sebagai tiga strata dengan kualitas yang berurutan berdasarkan tingkat perilaku eksploitasinya. Oleh karena itu, komodo jantan dewasa, komodo betina, dan komodo jantan muda acap kali juga dijuluki sebagai komodo strata tinggi, sedang, dan rendah secara berturut-turut. Selanjutnya, agar lebih sederhana, komodo jantan dewasa akan disebut ”komodo dewasa” dan komodo jantan muda akan dirujuk sebagai ”komodo muda”.

3.4.3. Konsep Matematis *Komodo Mlipir Algorithm*

Tiap individu komodo dinyatakan sebagai vektor bernilai real, $\mathbf{k}$, dengan m dimensi yang menyatakan posisi komodo tersebut pada ruang permasalahan. Kualitas seekor komodo ialah nilai fungsi yang hendak dioptimisasi atas vektor posisi komodo tersebut, yaitu $f(\mathbf{k})$. Untuk tiap kasus optimisasi, ditentukan n individu komodo sebagai populasi. Populasi komodo ini akan dibagi menjadi tiga kelompok dengan porsi komodo dewasa sebesar p, yaitu suatu bilangan random dalam interval $(0, 1)$, sedemikian sehingga terdapat q komodo dewasa, satu komodo betina, dan s komodo muda dengan:

$$q = \lfloor (1 - p)n \rfloor \tag{3.16}$$

dan

$$s = n - q - 1. \tag{3.17}$$

p umumnya ditentukan sebesar 0,5 agar q dan s tidak konvergen menuju nol. Sementara, fungsi *floor* digunakan karena q harus merupakan bilangan bulat.

Pergerakan komodo dewasa ke-i dari posisi awal, $\mathbf{k}_i$, menuju posisi baru, $\mathbf{k}'_i$, didefinisikan sebagai berikut:

$$\mathbf{w}_{ij} = \begin{cases} r_1(\mathbf{k}_j - \mathbf{k}_i), & \text{jika } f(\mathbf{k}_j) < f(\mathbf{k}_i) \text{ atau } r_2 < 0{,}5 \\ r_1(\mathbf{k}_i - \mathbf{k}_j), & \text{lainnya,} \end{cases}$$

$$\mathbf{k}'_i = \mathbf{k}_i + \sum_{j=1}^{q} \mathbf{w}_{ij}, \qquad j \neq i \tag{3.18}$$

dengan $\mathbf{w}_{ij}$ melambangkan vektor pergerakan komodo dewasa ke-i terhadap komodo dewasa ke-j, $f(\mathbf{k}_i)$ dan $f(\mathbf{k}_j)$ berturut-turut melambangkan kualitas komodo dewasa ke-i dan ke-j, serta r_1 dan r_2 merupakan bilangan-bilangan random dari distribusi normal dalam interval $[0, 1]$.

Pergerakan komodo betina ditentukan dari metode reproduksi yang dilakukan, yaitu reproduksi seksual (perkawinan) atau aseksual (partenogenesis). Reproduksi seksual digambarkan melalui persamaan-persamaan berikut:

$$k'_{il} = r_l \cdot k_{il} + (1 - r_l) \cdot k_{jl} \tag{3.19}$$

$$k'_{jl} = r_l \cdot k_{jl} + (1 - r_l) \cdot k_{il} \tag{3.20}$$

dengan $l = 1, 2, \ldots, m$; k_{il} dan k_{jl} merupakan dimensi ke-l dari komodo jantan dewasa ke-i dan komodo betina ke-j, k'_{il} dan k'_{jl} merupakan dimensi ke-l dari dua ekor komodo anakan, serta r_l adalah bilangan random dari distribusi normal dalam interval $[0, 1]$. Di sisi lain, reproduksi aseksual digambarkan sebagai penambahan nilai kecil pada tiap dimensi posisi komodo betina, yaitu untuk komodo betina ke-i, $\mathbf{k}_i$:

$$(k_{i1}, k_{i2}, \ldots, k_{im}) \rightarrow (k'_{i1}, k'_{i2}, \ldots, k'_{im}).$$

Perubahan nilai tiap dimensi dirumuskan sebagai berikut:

$$k'_{il} = k_{il} + (2r - 1)\alpha|a_l - b_l|, \tag{3.21}$$

dengan $l = 1, \ldots, m$; $k_{i1}, k_{i2}, \ldots, k_{im} \in [b_l, a_l]$; b_l dan a_l berturut-turut melambangkan batas bawah dan batas atas dimensi ke-l, r adalah bilangan random yang dibangkitkan dari distribusi normal, dan α adalah jari-jari partenogenesis senilai 0,1 yang berarti penyelesaian baru dapat dibangkitkan dalam jari-jari sebesar sepuluh persen dari ruang pencarian (*search space*). Komodo betina akan membersamai komodo anakan dengan kualitas terbaik. Maka, posisi baru komodo betina sama dengan posisi komodo anakan tersebut.

Pergerakan komodo muda dirancang untuk mencari penyelesaian secara meluas dengan sedikit eksploitasi. Gerakan *mlipir* diaplikasikan sebagai gerakan pada salah satu dimensi komodo dengan probabilitas tertentu yang disebut tingkat *mlipir* (*mlipir rate*), d. d umumnya ditentukan sebesar 0,5. Pergerakan *mlipir* komodo muda ke-i untuk mengikuti komodo dewasa ke-j dirumuskan:

$$\begin{aligned}
w_{ijl} &= \begin{cases} r_1(k_{jl} - k_{il}), & \text{jika } l \text{ terpilih dan } r_2 < d; \\ 0, & \text{lainnya} \end{cases} \\
\mathbf{w}_{ij} &= [w_{ij1}, w_{ij2}, \cdots, w_{ijm}] \\
\mathbf{k}'_i &= \mathbf{k}_i + \sum_{j=1}^{q} \mathbf{w}_{ij}
\end{aligned} \tag{3.22}$$

dengan w_{ij} adalah gerakan komodo muda ke-i mengikuti komodo dewasa ke-j, k_{il} dan k_{jl} adalah dimensi ke-l dari komodo muda ke-i dan komodo dewasa ke-j, $\mathbf{k}_i$ dan $\mathbf{k}'_i$ adalah vektor posisi lama dan baru dari komodo muda ke-i, r_1 dan r_2 adalah bilangan-bilangan random dalam interval $[0, 1]$ yang dibangkitkan dari distribusi normal; dan l adalah indeks dimensi yang dipilih secara random berdasarkan distribusi uniform, $l = 1, 2, \ldots, m$. r_1 berperan sebagai pengali pergerakan komodo muda. Dengan nilai kurang dari satu, r_1 mengakibatkan pergerakan seekor komodo muda menuju komodo dewasa pada tiap dimensi tidak melebihi jarak di antara dimensi keduanya. Sementara, r_2 digunakan untuk menentukan apakah pergerakan pada dimensi komodo muda yang terpilih akan dilakukan.

Kualitas tiap komodo dihitung kembali. Kemudian, satu komodo dengan kualitas terbaik dipilih sebagai solusi optimum sementara. Komodo ini dinotasikan sebagai $\mathbf{k}_{\text{best}}$.

Pada tiap iterasi dari KMA, ukuran populasi n diperbarui menjadi n' melalui rumus berikut:

$$n' = \begin{cases} n - a, & \text{jika } \delta f_1 > 0 \text{ dan } \delta f_2 > 0, \\ n + a, & \text{jika } \delta f_1 = 0 \text{ dan } \delta f_2 = 0 \end{cases} \tag{3.23}$$

dengan:

$$\delta f_1 = \frac{|f_{i-2}(\mathbf{k}_{\text{best}}) - f_{i-1}(\mathbf{k}_{\text{best}})|}{f_{i-2}(\mathbf{k}_{\text{best}})}, \tag{3.24}$$

yaitu selisih kualitas solusi optimum antara pembangkitan ke-$(i-2)$ dan pembangkitan ke-$(i-1)$,

$$\delta f_2 = \frac{|f_{i-1}(\mathbf{k}_{\text{best}}) - f_i(\mathbf{k}_{\text{best}})|}{f_{i-1}(\mathbf{k}_{\text{best}})}, \tag{3.25}$$

yaitu selisih kualitas solusi optimum antara pembangkitan ke-$(i-1)$ dan pembangkitan ke-i, dan a melambangkan banyak komodo yang akan dikeluarkan atau dibangkitkan. Dalam kata-kata, jika dua pembangkitan berturut-turut meningkatkan kualitas, ukuran populasi dikurangi sebanyak a komodo, sedangkan jika dua pembangkitan berturut-turut justru menurunkan kualitas, ukuran populasi akan bertambah sebanyak a komodo. Pada umumnya, a ditentukan sebesar lima karena penemu menganggap nilai ini cukup kecil dibandingkan dengan ukuran populasi optimal, n, yang umumnya bernilai antara dua puluh hingga dua ratus ekor komodo.

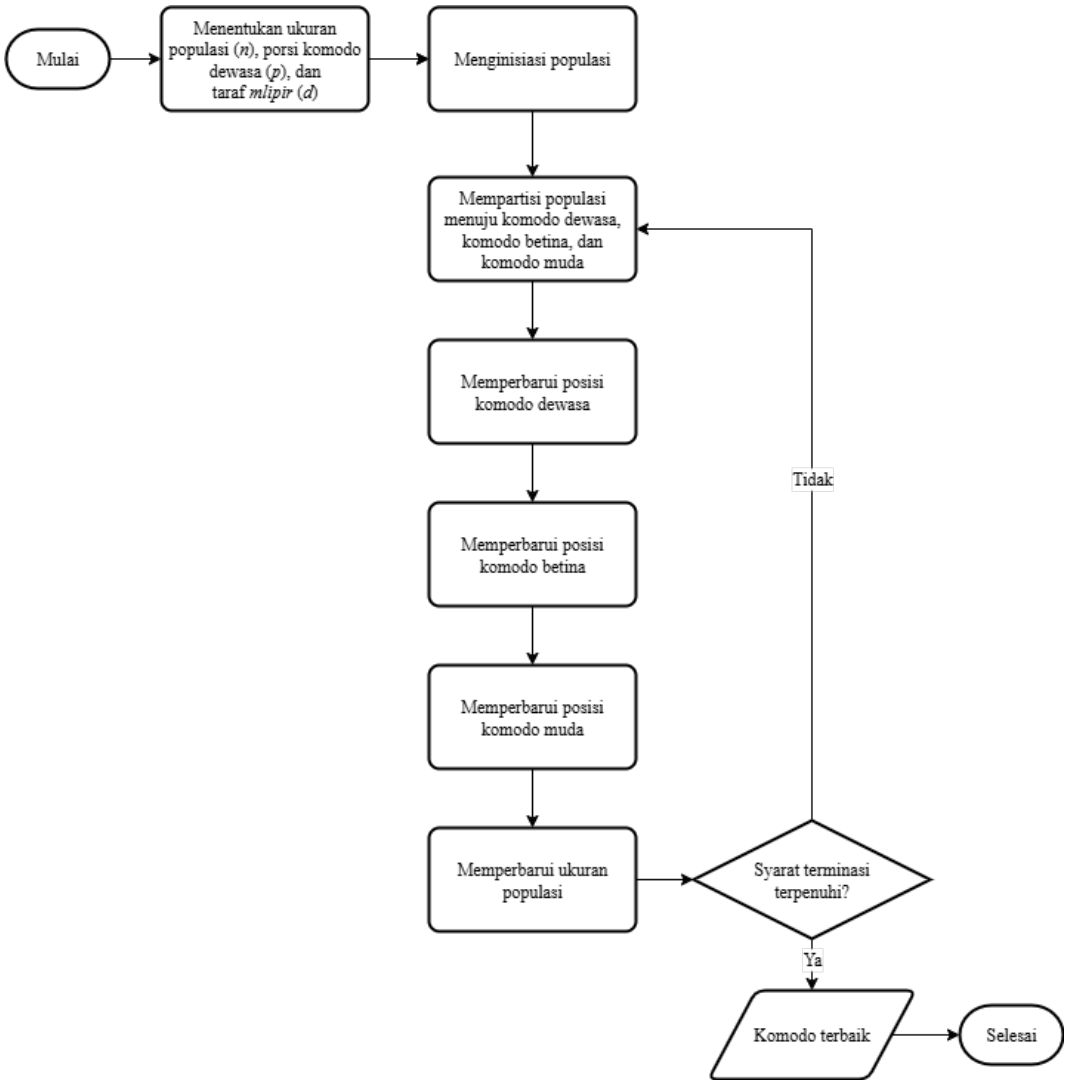
3.4.4. Struktur Umum *Komodo Mlipir Algorithm*

Langkah awal *Komodo Mlipir Algorithm* (KMA) diawali dengan menentukan n, p, dan d, yaitu banyak individu dalam populasi komodo, porsi komodo dewasa, dan tingkat *mlipir* secara berturut-turut. Kemudian, n individu komodo atas m dimensi diinisiasikan. Selanjutnya, kualitas tiap komodo, yaitu nilai fungsi objektif atas tiap komodo, dihitung dan diurutkan sesuai peringkat. Pada permasalahan minimisasi, semakin kecil nilai fungsi objektif, semakin besar peringkat suatu komodo. Berdasarkan peringkat dan porsi p, individu-individu komodo dipisahkan menjadi q komodo dewasa, satu komodo betina, dan s komodo muda menurut Persamaan (3.16) dan Persamaan (3.17).

Selanjutnya, posisi tiap komodo, yaitu nilai tiap vektor, diperbarui menurut jenis komodo yang bersesuaian. Vektor-vektor yang terasosiasi sebagai komodo dewasa akan bergerak menurut Persamaan (3.18). Vektor posisi komodo betina akan diperbarui menurut Persamaan (3.19) atau Persamaan (3.21), yaitu secara berturut-turut jika komodo betina memutuskan untuk mengawini komodo dewasa atau melakukan partenogenesis. Masing-masing keputusan ini memiliki probabilitas untuk terjadi sebesar 0,5. Terakhir, tiap vektor yang terasosiasi dengan komodo muda akan diperbarui menurut Persamaan (3.22). Kualitas seluruh komodo diukur kembali dan ditentukan satu komodo dengan kualitas terbaik, $\mathbf{k}_{\text{best}}$, sebagai solusi terbaik sementara.

Pembaruan posisi komodo dalam KMA akan dijalankan setidaknya selama tiga kali. Hal ini dikarenakan pembaruan ukuran populasi bergantung pada kualitas solusi terbaik sementara dari tiga iterasi sebelum suatu iterasi. Setelah iterasi ketiga, ukuran populasi diperbarui menurut Persamaan (3.23). Jika populasi dikurangi, a komodo dengan kualitas terburuk akan dikeluarkan dari populasi. Sementara, jika populasi bertambah, a komodo akan dibangkitkan selayaknya inisiasi pada langkah awal algoritma. Kondisi terminasi dicapai seandainya ukuran populasi baru untuk iterasi berikutnya, $n' = n - a$, bernilai nonpositif. Jika syarat ini terjadi, iterasi tersebut merupakan iterasi terakhir dan algoritma berhenti. Solusi terbaik yang diperoleh dari iterasi terakhir menjadi solusi optimum untuk fungsi objektif.

Langkah-langkah KMA terangkum melalui diagram alur pada Gambar 3.4 di bawah dan *pseudocode* yang terdapat pada Lampiran 3.



Gambar 3.4 Diagram alur *Komodo Mlipir Algorithm*.

3.4.5. Percobaan *Komodo Mlipir Algorithm*

Suyanto dkk. (2022) menguji performa *Komodo Mlipir Algorithm* (KMA) dalam mengoptimisasi 23 fungsi acuan yang termuat dalam Rao (2020). Fungsi-fungsi acuan tersebut dikelompokkan menjadi tiga golongan, yaitu fungsi-fungsi *high-dimension unimodal* (HDU), *high-dimension multimodal* (HDM), dan *fixed-dimen-sion multimodal* (FDM). Fungsi-fungsi *high-dimension* mempunyai dimensi yang nilainya perlu ditentukan oleh pengguna, sedangkan fungsi-fungsi *fixed-*

dimension mempunyai besar dimensi yang tentu dan konstan. Di sisi lain, *unimodal* dan *multimodal* merujuk pada banyaknya nilai optimum pada suatu fungsi, yaitu satu atau lebih dari satu.

Pengujian kemampuan KMA terhadap fungsi-fungsi *unimodal* dirujuk sebagai ”evolusi fase pertama” atau fase pertama dari keseluruhan percobaan yang dilakukan. Pada fase ini, ditentukan $n = 5$, $p =$ 0,5, dan $d = (m - 1)/m$, yaitu ”taraf *mlipir* maksimum”, dengan algoritma dilaksanakan sebanyak seribu iterasi. Pada fase kedua, yaitu implementasi KMA pada fungsi-fungsi *multimodal*, digunakan ukuran populasi mula-mula sebesar $n = 200$, $p =$ 0,5, dan $d =$ 0,5. Fase ini juga melibatkan penyetelan (*tuning*) mandiri terhadap ukuran populasi dalam interval $n_{\min} = 20$ sampai dengan $n_{\max} = 200$ sebagai wujud *self-adaptation*. Prosedur penyetelan mandiri ini tidak dijelaskan dalam literatur Suyanto dkk. (2022) maupun penelitian-penelitian aplikatif yang terkait.

BAB IV

STUDI KASUS

4.1. Deskripsi Data

Data riwayat harga keempat puluh lima saham dalam indeks saham LQ45 pada periode Desember 2023 sampai dengan November 2024 diunduh dari situs web *investing.com* dan termuat pada Lampiran 4. Dalam bahasa pemrograman R, data tersaji sebagai suatu *dataframe* berukuran 237 baris dan 45 kolom. Artinya, jual-beli saham berlangsung selama 237 hari kerja dalam periode waktu yang telah ditentukan. Selain itu, dari situs web Bank Indonesia, diperoleh bahwa BI-Rate, yang ekuivalen dengan tingkat bunga bebas risiko (r_f), pada periode pengambilan data ialah sebesar 6,00%.

4.2. *Return* Terealisasi Harian Saham

Dari data riwayat harga saham, nilai *return* terealisasi harian untuk tiap saham dihitung menurut Persamaan (2.26). Karena melangkahi satu satuan waktu, *dataframe return* hanya terdiri atas 236 baris. *Dataframe return* saham terdapat pada Lampiran 5.

4.3. Uji Normalitas *Return* Harian Saham

Guna menghasilkan klaster *K-Means* dengan kualitas yang baik, *return* harian saham diharapkan berdistribusi normal. Oleh karena itu, dilakukan uji Kolmogorov-Smirnov terhadap *return* harian saham dengan distribusi normal. Sintaksis dan luaran uji Kolmogorov-Smirnov tersaji pada Lampiran 6. Berdasarkan luaran yang ada, terdapat hanya sembilan belas saham yang *return* hariannya berdistribusi normal. Saham-saham ini sajalah yang selanjutnya akan dilibatkan dalam analisis klaster *K-Means*.

Dari data *return* yang ada, diperoleh vektor mean *return* dan deviasi standar

yang selanjutnya digunakan untuk menghitung *Sharpe ratio* tiap saham, sebagaimana termuat pada Lampiran 7. Sebaran saham menurut mean *return* dan deviasi standar divisualisasikan melalui diagram pencar pada Lampiran 8.

4.4. Analisis Klaster *K-Means*

Pada penelitian ini, pemilihan saham didasari oleh analisis klaster *K-Means* dan *Sharpe ratio*. Bulani dkk. (2025) mengusulkan empat strategi pemilihan aset untuk membentuk suatu portofolio melalui analisis klaster, yaitu sejumlah klaster ataupun dengan penambahan beberapa aset menurut kedekatan aset dengan pusat klasternya, performa aset, atau kriteria-kriteria evaluasi tertentu. Pada penelitian ini, *Sharpe ratio* digunakan sebagai ukuran acuan yang mampu mengevaluasi rasio *return* terhadap risiko yang terasosiasi dengan suatu saham.

Meski demikian, strategi Bulani dkk. (2025) tidak meliputi penentuan jumlah aset yang optimal dalam portofolio akhir. Hal ini didukung oleh ulasan literatur oleh Zaimovic dkk. (2021), yaitu bahwa tidak terdapat definisi yang eksak akan ukuran portofolio optimal untuk pasar, periode, maupun kalangan investor tertentu. Selain karena beragamnya opini ahli tentang diversifikasi risiko yang efektif, besarnya risiko-risiko tak sistematis dipengaruhi oleh berbagai faktor, mulai dari jenis kelamin investor, tingkat kepercayaan diri investor terhadap risiko, daya beli investor yang dipengaruhi oleh besar pendapatan dan tingkat inflasi di negara asal investor yang bersangkutan, hingga perubahan karakteristik aset seiring berjalannya waktu. Karena penelitian ini dilatarbelakangi oleh karakter Generasi Z yang minim modal dalam berinvestasi, Penulis menentukan jumlah saham akhir sebanyak dua kali jumlah klaster yang terbentuk.

Jumlah klaster optimal dalam analisis klaster *K-Means* ditentukan berdasarkan *silhouette score*. Angka klaster dengan *silhouette score* tertinggi menandakan jumlah klaster yang paling optimal. Percobaan pembentukan klaster dilakukan untuk K bernilai dua hingga sepuluh. Nilai K beserta *silhouette score* yang bersesuaian dipetakan pada diagram pada Lampiran 9. Diagram tersebut menunjukkan bahwa berdasarkan mean *return* dan risiko, pengelompokkan saham menjadi dua

klaster akan menghasilkan klaster-klaster dengan kualitas terbaik. Diperoleh *silhouette score* untuk $K = 2$ sebesar 0,6767037.

Analisis klaster *K-Means* dilakukan dengan $K = 2$. Diperoleh pembagian klaster pada Tabel 4.1 di bawah ini.

Tabel 4.1 Pembagian klaster untuk saham-saham dengan *return* berdistribusi normal.

Saham	**Klaster**
AMMN	1
AMRT	2
ANTM	2
ASII	2
BBCA	2
BBNI	2
BBRI	2
BBTN	2
BMRI	2
HRUM	1
ICBP	2
INDF	2
INKP	2
ITMG	2
MBMA	1
PGAS	2
SMGR	2
TLKM	2
UNTR	2

Visualisasi hasil analisis klaster *K-Means* terdapat pada Lampiran 10.

Berdasarkan *Sharpe ratio* tiap saham dan hasil analisis klaster *K-Means*, dua saham dari tiap klaster dengan *Sharpe ratio* tertinggi dipilih untuk digabungkan sebagai suatu portofolio saham. Empat saham yang terpilih ialah MBMA dan

AMMN dari klaster 1 serta ANTM dan BBTN dari klaster 2 dengan *Sharpe ratio* berturut-turut senilai –1,748777, –2,027074, –2,637897, dan –2,783715. Nilai *Sharpe ratio* dari saham-saham dengan *return* harian berdistribusi normal termuat pada Lampiran 7.

4.5. Pembobotan Portofolio *Minimum Variance*

Sebagaimana disebutkan pada Subbab 3.2, pembobotan portofolio *constrained minimum variance portfolio* (CMVP) dapat dilakukan melalui dua pendekatan yang lebih mudah, yaitu metode pengali Lagrange dengan fungsi Lagrange termodifikasi dan pemrograman kuadratik. Kedua pendekatan tersebut akan digunakan pada penelitian ini. Lebih lanjut, Penulis akan membuktikan bahwa keduanya menghasilkan pembobotan yang sama atas kasus dan data yang sama.

Pendekatan metode Lagrange diawali dengan membangkitkan matriks kovariansi sampel dari data *return*. Didefinisikan sebuah matriks, $\mathbf{R}$, yang memuat *return* terealisasi harian dari keempat saham anggota portofolio, sebagai berikut:

$$\mathbf{R}' = \begin{bmatrix} 0{,}080508475 & 0{,}026392962 & 0{,}015748031 & -0{,}041322314 \\ 0{,}035294118 & -0{,}002857143 & -0{,}003875969 & -0{,}025862069 \\ \vdots & \vdots & \vdots & \vdots \\ -0{,}027027027 & 0{,}007042254 & -0{,}003875969 & 0{,}019607843 \end{bmatrix}$$

dengan kolom pertama hingga keempat berturut-turut mewakili *return* terealisasi harian dari saham AMMN, ANTM, BBTN, dan MBMA. Keempat saham ini selanjutnya akan diwakili oleh indeks 1 sampai dengan 4. Ekspektasi *return* diestimasi oleh rata-rata *return* tahunan yang dirumuskan pada Persamaan (2.27). Dengan bantuan komputasi, diperoleh rata-rata *return* tahunan yang dikelompokkan dalam vektor mean berikut:

$$\boldsymbol{\mu} = \begin{bmatrix} \bar{R}_1 \\ \bar{R}_2 \\ \bar{R}_3 \\ \bar{R}_4 \end{bmatrix}$$

$$= \begin{bmatrix} 0{,}002186107 \\ -0{,}0004830982 \\ 0{,}0002767127 \\ -0.0002213262 \end{bmatrix}. \tag{4.1}$$

Lebih lanjut, estimasi variansi dan kovariansi *return* dirumuskan pada Persamaan (2.28) dan Persamaan (2.29) dan dikomputasikan sebagai matriks kovariansi berikut:

$$\begin{aligned} \boldsymbol{\Sigma} &= \begin{bmatrix} \mathrm{Var}(R_1) & \mathrm{Cov}(R_1, R_2) & \mathrm{Cov}(R_1, R_3) & \mathrm{Cov}(R_1, R_4) \\ \mathrm{Cov}(R_2, R_1) & \mathrm{Var}(R_2) & \mathrm{Cov}(R_2, R_3) & \mathrm{Cov}(R_2, R_4) \\ \mathrm{Cov}(R_3, R_1) & \mathrm{Cov}(R_3, R_2) & \mathrm{Var}(R_3) & \mathrm{Cov}(R_3, R_4) \\ \mathrm{Cov}(R_4, R_1) & \mathrm{Cov}(R_4, R_2) & \mathrm{Cov}(R_4, R_3) & \mathrm{Var}(R_4) \end{bmatrix} \\ &= \begin{bmatrix} 0{,}0008134398 & -0{,}00004392384 & -0{,}00000652270 & -0{,}000043720495 \\ -0{,}00004392384 & 0{,}0005257176 & 0{,}00008836710 & 0{,}0001934192 \\ -0{,}00000652270 & 0{,}00008836710 & 0{,}0004602968 & 0{,}0001780035 \\ -0{,}000043720495 & 0{,}0001934192 & 0{,}0001780035 & 0{,}001185855 \end{bmatrix}. \end{aligned} \tag{4.2}$$

Selanjutnya, matriks kovariansi invers dikomputasikan dan diperoleh hasil sebagai berikut:

$$\boldsymbol{\Sigma}^{-1} = \begin{bmatrix} 1.236{,}32510 & 92{,}33711 & -14{,}24148 & 36{,}29104 \\ 92{,}33711 & 2.064{,}29666 & -282{,}61282 & -290{,}60007 \\ -14{,}24148 & -282{,}61282 & 2.345{,}08624 & -306{,}48186 \\ 36{,}29104 & -290{,}60007 & -306{,}48186 & 938{,}12071 \end{bmatrix}.$$

Bobot yang meminimumkan model CMVP pada Persamaan (3.2) diberikan oleh Persamaan (3.15) dan dilambangkan $\mathbf{w}_{\min}$. Pembilang dari $\mathbf{w}_{\min}$ ialah:

$$\boldsymbol{\Sigma}^{-1}\mathbf{1}_4 = \begin{bmatrix} 1.236{,}32510 & \cdots & 36{,}29104 \\ \vdots & \ddots & \vdots \\ 36{,}29104 & \cdots & 938{,}12071 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$$

$$= \begin{bmatrix} 1.350{,}7118 \\ 1.583{,}4209 \\ 1.741{,}7501 \\ 377{,}3298 \end{bmatrix},$$

sedangkan penyebutnya ialah:

$$\mathbf{1}_4'\boldsymbol{\Sigma}^{-1}\mathbf{1}_4 = \begin{bmatrix} 1 & 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1.236{,}32510 & \cdots & 36{,}29104 \\ \vdots & \ddots & \vdots \\ 36{,}29104 & \cdots & 938{,}12071 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$$

$$= 5.053{,}213. \tag{4.3}$$

Dengan demikian, diperoleh bobot portofolio *minimum variance*:

$$\begin{aligned} \mathbf{w}_{\min} &= \frac{\boldsymbol{\Sigma}^{-1}\mathbf{1}_4}{\mathbf{1}_4'\boldsymbol{\Sigma}^{-1}\mathbf{1}_4} \\ &= \frac{\begin{bmatrix} 1.350{,}7118 \\ 1.583{,}4209 \\ 1.741{,}7501 \\ 377{,}3298 \end{bmatrix}}{5.053{,}213} \\ &= \frac{1}{5.053{,}213} \begin{bmatrix} 1.350{,}7118 \\ 1.583{,}4209 \\ 1.741{,}7501 \\ 377{,}3298 \end{bmatrix} \\ &= \begin{bmatrix} 0{,}26729764 \\ 0{,}31334935 \\ 0{,}34468174 \\ 0{,}07467127 \end{bmatrix} \end{aligned}$$

dengan:

$$f(\mathbf{w}_{\min}) = 0{,}00009894696.$$

Oleh karena itu, pada kasus ini, metode pengali Lagrange dengan fungsi Lagrange termodifikasi terbukti menghasilkan bobot-bobot portofolio yang nonnegatif, sebagaimana kendala pertidaksamaan pada model CMVP.

Di sisi lain, pendekatan pemrograman kuadratik diperantarai oleh fungsi *solve.QP* dalam bahasa pemrograman R. Fungsi ini terdiri atas empat argumen wajib, yaitu *Dmat*, *dvec*, *Amat*, dan *bvec*. Keempat argumen ini merupakan masukan berbentuk vektor dan matriks yang secara berturut-turut berkorespondensi dengan $\mathbf{D}$, $\mathbf{d}$,

$$\mathbf{A}' = \begin{bmatrix} \mathbf{P} \\ \mathbf{R} \end{bmatrix},$$

dan

$$\mathbf{b} = \begin{bmatrix} \mathbf{q} \\ \mathbf{s} \end{bmatrix}$$

yang terdapat pada Persamaan (2.62), Persamaan (2.63), dan Persamaan (2.64). Dengan menyesuaikan model CMVP pada Persamaan 3.2, masukan untuk keempat argumen fungsi *solve.QP* secara berturut-turut ialah:

$$\mathbf{D} = \mathbf{\Sigma},$$
$$\mathbf{d} = \mathbf{0}_4,$$
$$\mathbf{A}' = \begin{bmatrix} \mathbf{1}_4' \\ \mathbf{I}_4 \end{bmatrix}, \text{ dan}$$
$$\mathbf{b} = \begin{bmatrix} 1 \\ \mathbf{0}_4 \end{bmatrix}.$$

Dalam komputasi, didefinisikan pula argumen *meq*, yaitu banyaknya kendala berbentuk persamaan dari model pemrograman kuadratik yang hendak diselesaikan. Pada kasus ini, hanya terdapat satu kendala persamaan sehingga *meq* bernilai 1.

Komputasi dan hasil komputasi untuk portofolio *minimum variance* terlampir pada Lampiran 11. Pendekatan metode pengali Lagrange dan pemrograman kuadratik terbukti mengembalikan nilai pengali Lagrange dan bobot-bobot portofolio yang sama.

4.6. Pembobotan Portofolio Menggunakan *Genetic Algorithm*

Komputasi *Genetic Algorithm* (GA) menggunakan bahasa pemrograman R diperantarai oleh fungsi *ga* dalam *library GA*. Ditemukan oleh Luca Scrucca, seorang peneliti dalam bidang Statistika Terapan asal Italia, fungsi *ga* memuat argumen-argumen berikut:

```
ga(type = c("binary", "real-valued", "permutation"),
   fitness = ...,
   lower, upper, nBits,
   population = gaControl(type)$population,
   selection = gaControl(type)$selection,
   crossover = gaControl(type)$crossover,
   mutation = gaControl(type)$mutation,
   popSize = 50,
   pcrossover = 0.8,
   pmutation = 0.1,
   elitism = base::max(1, round(popSize*0.05)),
   updatePop = FALSE,
   postFitness = NULL,
   maxiter = 100,
   run = maxiter,
   maxFitness = Inf,
   names = NULL,
   suggestions = NULL,
   optim = FALSE,
   optimArgs = list(method = "L-BFGS-B",
                    poptim = 0.05,
                    pressel = 0.5,
                    control = list(fnscale = -1,
                                   maxit = 100)),
   keepBest = FALSE,
   parallel = FALSE,
   monitor = if(interactive()) gaMonitor else FALSE,
```

```
seed = NULL)
```

Fungsi *ga* dapat digunakan untuk melangsungkan tiga jenis kasus GA, yaitu biner (*binary*), bernilai real (*real-valued*), dan permutasi (*permutation*). Jenis kasus menjadi argumen utama yang wajib dinyatakan oleh pengguna fungsi karena masukan dari argumen ini terhubung secara otomatis dengan metode pemilihan populasi mula-mula, seleksi, persilangan, dan mutasi yang sesuai. Metode-metode bawaan dari tahap-tahap ini diaktifkan melalui subfungsi *gaControl*. Akan tetapi, pengguna juga dapat mendefinisikan metode-metode yang diinginkan secara spesifik.

Fungsi *ga* dirancang untuk menyelesaikan permasalahan maksimisasi. Fungsi objektif yang akan dioptimisasi menjadi masukan bagi argumen *fitness*. Jika permasalahan yang hendak diselesaikan adalah minimisasi, pengguna dapat menegasikan fungsi objektif sehingga fungsi *ga* memaksimisasi negatif dari fungsi objektif yang dikehendaki.

Kendala-kendala yang didefinisikan secara matematis juga dapat dilibatkan dalam fungsi *ga*. Secara komputasional, batasan-batasan nilai (*boundaries*) dapat dinyatakan untuk tiap variabel dalam fungsi objektif pada argumen *lower* dan *upper*, sedangkan kendala-kendala persamaan dan/atau pertidaksamaan didefinisikan secara bersamaan dengan fungsi objektif untuk argumen *fitness*.

Argumen-argumen lain dalam fungsi *ga* bersifat opsional. Argumen-argumen ini telah mempunyai definisi nilai bawaan, tetapi pengguna juga dapat mendefinisikan nilai-nilai argumen ini secara mandiri. Argumen-argumen ini antara lain ukuran populasi (*popSize*), taraf persilangan (*pcrossover*), taraf mutasi (*pmutation*), taraf elitisme untuk pemilihan populasi baru (*elitism*), pembaharuan populasi (*updatePop*), dan jumlah iterasi maksimum (*maxiter*).

Sebagai contoh, diperhatikan fungsi Sphere dalam Rao (2020) yang didefinisikan sebagai berikut:

$$f(x) = \sum_{i=1}^{n} x_i^2. \tag{4.4}$$

Fungsi tersebut mempunyai nilai minimum global sebesar nol yang dicapai melalui

solusi $(0, 0, \ldots, 0)$. Menggunakan fungsi *ga*, fungsi Sphere berdimensi $n = 30$ diminimisasi dalam ruang pencarian berupa interval $[-100, 100]$ untuk tiap x_i. Mengacu pada eksperimen Suyanto dkk. (2022), ditentukan ukuran populasi sebanyak seratus, taraf persilangan sebesar 0,8, dan taraf mutasi sebesar 0,05. Dengan iterasi sebanyak seribu kali, sintaksis dijalankan sebagaimana termuat pada Lampiran 12. Nilai minimum fungsi Sphere yang diperoleh ialah sebesar 0,3148834.

Untuk menciptakan kesebandingan antara GA dan model portofolio *minimum variance*, GA juga akan diuji pada model CMVP yang termuat pada Persamaan (3.2). Guna memuat fungsi objektif dan kendala secara bersamaan dalam argumen *fitness* dari fungsi *GA*, fungsi Lagrange pada Persamaan (3.10) akan digunakan. Diperhatikan bahwa fungsi objektif dari model CMVP dapat dijabarkan sebagai jumlahan ganda berikut:

$$\begin{aligned}
\frac{1}{2}\mathbf{w}'\boldsymbol{\Sigma}\mathbf{w} &= \frac{1}{2}\sum_{i=1}^{4}\sum_{j=1}^{4} w_i w_j \sigma_{ij} \\
&= \frac{1}{2}\sum_{i=1}^{4}(w_i w_1 \sigma_{i1} + w_i w_2 \sigma_{i2} + w_i w_3 \sigma_{i3} + w_i w_4 \sigma_{i4}) \\
&= \frac{1}{2}(w_1^2\sigma_1^2 + w_1 w_2 \sigma_{12} + w_1 w_3 \sigma_{13} + w_1 w_4 \sigma_{14} \\
&\qquad + w_2 w_1 \sigma_{21} + w_2^2\sigma_2^2 + w_2 w_3 \sigma_{23} + w_2 w_4 \sigma_{24} \\
&\qquad + w_3 w_1 \sigma_{31} + w_3 w_2 \sigma_{32} + w_3^2\sigma_3^2 + w_3 w_4 \sigma_{34} \\
&\qquad + w_4 w_1 \sigma_{41} + w_4 w_2 \sigma_{42} + w_4 w_3 \sigma_{43} + w_4^2\sigma_4^2) \\
&= \frac{1}{2}\big(w_1^2\sigma_1^2 + w_2^2\sigma_2^2 + w_3^2\sigma_3^2 + w_4^2\sigma_4^2 \\
&\qquad + 2(w_1 w_2 \sigma_{12} + w_1 w_3 \sigma_{13} + w_1 w_4 \sigma_{14} \\
&\qquad\quad + w_2 w_3 \sigma_{23} + w_2 w_4 \sigma_{24} + w_3 w_4 \sigma_{34})\big) \\
&= \frac{1}{2}(w_1^2\sigma_1^2 + w_2^2\sigma_2^2 + w_3^2\sigma_3^2 + w_4^2\sigma_4^2) \\
&\quad + (w_1 w_2 \sigma_{12} + w_1 w_3 \sigma_{13} + w_1 w_4 \sigma_{14} \\
&\qquad + w_2 w_3 \sigma_{23} + w_2 w_4 \sigma_{24} + w_3 w_4 \sigma_{34}).
\end{aligned} \tag{4.5}$$

dengan w_i melambangkan bobot saham ke-i dalam portofolio dan σ_{ij} melambangkan kovariansi antara saham ke-i dan ke-j. Dengan menyubstitusikan nilai-nilai va-

riansi dan kovariansi dari Persamaan (4.2), fungsi objektif berupa jumlahan ganda pada Persamaan (4.5) dapat dituliskan kembali sebagai:

$$\begin{aligned}\frac{1}{2}\mathbf{w}'\boldsymbol{\Sigma}\mathbf{w} = \frac{1}{2}(&0{,}0008134398w_1^2 + 0{,}0005257176w_2^2 \\ &+ 0{,}0004602968w_3^2 + 0{,}001185855w_4^2) \\ &+ (-0{,}00004392384w_1w_2 - 0{,}00000652270w_1w_3 \\ &- 0{,}000043720495w_1w_4 + 0{,}00008836710w_2w_3 \\ &+ 0{,}0001934192w_2w_4 + 0{,}0001780035w_3w_4) \\ = &\ 0{,}0004067199w_1^2 + 0{,}0002628588w_2^2 \\ &+ 0{,}0002301484w_3^2 + 0{,}0005929275w_4^2 \\ &- 0{,}00004392384w_1w_2 - 0{,}00000652270w_1w_3 \\ &- 0{,}000043720495w_1w_4 + 0{,}00008836710w_2w_3 \\ &+ 0{,}0001934192w_2w_4 + 0{,}0001780035w_3w_4. \end{aligned} \tag{4.6}$$

Lebih lanjut, pengali Lagrange dari fungsi Lagrange pada Persamaan (3.10) telah diberikan pada Persamaan (3.14) serta dikomputasikan pada Persamaan (4.3) dan kendala persamaan pada model CMVP dapat dijabarkan sebagai berikut:

$$\begin{aligned} \mathbf{w}'\mathbf{1}_4 &= 1 \\ \iff w_1 + w_2 + w_3 + w_4 &= 1 \\ \iff w_1 + w_2 + w_3 + w_4 - 1 &= 0. \end{aligned} \tag{4.7}$$

Dengan demikian, fungsi Lagrange yang ekuivalen dengan fungsi *fitness* diberikan sebagai berikut:

$$\begin{aligned}\mathcal{L}(\mathbf{w}, \lambda) = &\ 0{,}0004067199w_1^2 + 0{,}0002628588w_2^2 \\ &+ 0{,}0002301484w_3^2 + 0{,}0005929275w_4^2 \\ &- 0{,}00004392384w_1w_2 - 0{,}00000652270w_1w_3 \\ &- 0{,}000043720495w_1w_4 + 0{,}00008836710w_2w_3 \\ &+ 0{,}0001934192w_2w_4 + 0{,}0001780035w_3w_4 \\ &- 0{,}0001978939(w_1 + w_2 + w_3 + w_4 - 1).\end{aligned}$$

Adapun kendala nilai dari CMVP dapat dipenuhi dengan membatasi ruang pencarian $\mathcal{W}$ dalam interval:

$$\left\{ \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} \right\}. \tag{4.8}$$

Studi kasus optimisasi portofolio saham dalam penelitian ini ditujukan untuk menemukan bobot-bobot portofolio bernilai real yang meminimalisasi risiko. Oleh karenanya, studi kasus ini termasuk dalam jenis kasus bernilai real. Penulis menggunakan metode-metode bawaan untuk tahap inisiasi populasi, persilangan, dan mutasi, sedangkan metode pemeringkatan linear (*linear ranking*) akan didefinisikan secara spesifik untuk tahap seleksi. Batas bawah dan atas ruang pencarian $\mathcal{W}$ pada Persamaan (4.8) menjadi masukan untuk argumen *lower* dan *upper*.

Komputasi GA dijalankan menurut sintaksis yang termuat pada Lampiran 13. Berdasarkan hasil komputasi tersebut, diperoleh bahwa bobot yang meminimalisasi fungsi objektif adalah:

$$\mathbf{w}_{\text{GA}} = \begin{bmatrix} 0{,}2673440 \\ 0{,}3133429 \\ 0{,}3446411 \\ 0{,}07478484 \end{bmatrix}$$

dengan

$$f(\mathbf{w}_{\text{GA}}) = 0{,}00009896927.$$

4.7. Penyesuaian Konsep Matematis *Komodo Mlipir Algorithm*

Pada pemaparan konsep *Komodo Mlipir Algorithm* oleh Suyanto dkk. (2022), rumusan pergerakan komodo muda diberikan sebagai berikut:

$$w_{ij} = \begin{cases} \sum_{l=1}^{m} r_1(k_{jl} - k_{il}), & \text{jika } r_2 < d; \\ 0, & \text{lainnya} \end{cases}$$

$$\mathbf{k}'_i = \mathbf{k}_i + \sum_{j=1}^{q} w_{ij}, \quad i \neq j.$$

Rumusan di atas kurang tepat karena vektor $\mathbf{k}_i$ tidak dapat dijumlahkan dengan skalar w_{ij}. Selain itu, keterangan "$i \neq j$" tidak relevan karena keduanya berturut-turut melambangkan indeks dari komodo muda dan komodo jantan, yakni dua golongan komodo yang berbeda. Oleh karena itu, dengan menyesuaikan narasi deskriptif pada Suyanto dkk. (2022), rumusan di atas disesuaikan menjadi Persamaan (3.22).

Selain itu, distribusi probabilitas acuan untuk memilih l secara random turut dialihkan dari distribusi normal menjadi distribusi uniform. Penyesuaian ini dilakukan karena tidak terdapat penjelasan lebih lanjut akan pemetaan probabilitas dari distribusi normal terhadap tiap nilai l yang memungkinkan, yaitu $1, 2, \ldots, m$.

4.8. Pembahasan Percobaan *Komodo Mlipir Algorithm*

Penulis mendapati bahwa percobaan pengujian performa *Komodo Mlipir Algorithm* (KMA) oleh Suyanto dkk. (2022) memuat beberapa inkonsistensi dan kejanggalan. Pada evolusi fase pertama, ukuran populasi sebanyak lima individu komodo tidak sejalan dengan ketentuan ukuran populasi optimal, yaitu sebanyak dua puluh hingga dua ratus. Pada fase ini pula, tidak terdapat penjelasan mengapa $d = (m-1)/m$ dirujuk sebagai "taraf *mlipir* maksimum", mengingat d merupakan suatu nilai probabilitas yang bernilai maksimum satu. Syarat terminasi tidak lagi didasarkan pada ukuran populasi yang telah mengalami adaptasi (n'), tetapi batasan jumlah iterasi. Di sisi lain, pada evolusi fase kedua, konsep maupun prosedur penyetelan mandiri ukuran populasi tidak dijabarkan sehingga tidak dapat dipraktikkan kembali pada penelitian-penelitian berikutnya.

Secara umum, pemisahan percobaan menjadi dua fase berdasarkan golongan fungsi merupakan keunikan yang terdapat pada penelitian Suyanto dkk. (2022). Pada penelitian ini, algoritma hanya akan dijalankan sebanyak satu fase menurut alur yang telah digambarkan melalui *pseudocode* pada Lampiran 3. Perbandingan antara percobaan pada penelitian Suyanto dkk. (2022) dan penelitian ini diberikan pada Tabel 4.2 berikut.

Tabel 4.2 Perbandingan penelitian Suyanto dkk. (2022) dengan penelitian ini.

Aspek	**Penelitian Suyanto dkk. (2022)**	**Penelitian ini**
Banyak fase	Dua	Satu
Ukuran populasi mula-mula	Lima	Dua ratus
Taraf *mlipir* (d)	$(m-1)/m$	0,5
Syarat terminasi	Jumlah iterasi	Ukuran populasi baru (n')
Penyetelan mandiri ukuran populasi	Ada	Tidak ada

4.9. Pembobotan Portofolio Menggunakan *Komodo Mlipir Algorithm*

Sebagai algoritma optimisasi baru, fungsi bawaan *Komodo Mlipir Algorithm* (KMA) saat ini hanya tersedia dalam bahasa pemrograman MATLAB. Agar dapat diimplementasikan menggunakan bahasa pemrograman R, Penulis menyusun fungsi *KMA* menurut kerangka algoritma pada Lampiran 3. Susunan lengkap fungsi *KMA* tersebut terdapat pada Lampiran 14.

Dalam KMA, terdapat beberapa operasi yang dijalankan secara berulang pada tiap iterasi, yaitu pengukuran kualitas komodo, penggerakan komodo menurut golongannya (jantan, betina, atau muda), dan pembandingan kualitas komodo terbaik dari tiga iterasi terakhir sebagai dasar untuk memperbarui ukuran populasi. Agar algoritma berjalan secara efisien, operasi-operasi ini dimuat dalam fungsi-fungsi buatan secara terpisah. Fungsi *vektor_kualitas* mengukur kualitas seekor komodo, yang ekuivalen dengan nilai sebuah fungsi objektif atas komodo tersebut. Fungsi *gerak_jantan*, *gerak_betina*, dan *gerak_muda* secara berturut-turut memperbarui posisi komodo jantan, betina, dan muda menurut Persamaan (3.18), Persamaan (3.19), dan Persamaan (3.22). Terdapat beberapa fungsi bawaan dari bahasa pemrograman R yang sama-sama digunakan dalam ketiga fungsi ini, yakni antara lain *set.seed*, *qnorm*, *runif*, *pnorm*, dan *mapply*. Fungsi *set.seed* diaktifkan agar

fungsi pembangkit bilangan random menghasilkan bilangan random yang sama setiap kali pembangkitan dilakukan. *qnorm*, *runif*, dan *pnorm* digunakan secara bersamaan untuk membangkitkan bilangan random berdistribusi normal dalam interval nilai $(0, 1)$. *runif* membangkitkan bilangan random berdistribusi uniform. Dengan argumen *min = pnorm(0)* dan *max = pnorm(1)*, ditentukan bahwa batas minimum dan maksimum dari bilangan random uniform yang akan dibangkitkan ialah $\phi(0) = 0{,}5$ dan $\phi(1) = 1$, dengan $\phi(x)$ merupakan PDF normal standar yang diberikan oleh Persamaan (2.23). Bilangan random uniform menjadi masukan bagi fungsi *qnorm* yang ekuivalen dengan invers CDF normal standar, yaitu invers dari Persamaan (2.24), mentransformasi bilangan random uniform menjadi suatu bilangan random dari distribusi normal standar. Terakhir, fungsi *df1* dan *df2* secara berturut-turut ekuivalen dengan Persamaan (3.24) dan Persamaan (3.25).

Fungsi *KMA* memerlukan tiga argumen wajib, yaitu ukuran populasi komodo, dimensi tiap komodo, dan fungsi objektif. Ketiga argumen ini secara berturut-turut dinyatakan sebagai *N*, *m*, dan *func*. Selain itu, terdapat tujuh argumen pilihan, yaitu *p*, *d*, *a*, *max_iter*, *lower*, *upper*, dan *normalize*. *p*, *d*, dan *a* secara berturut-turut melambangkan porsi komodo dewasa, tingkat *mlipir*, dan banyak pertambahan atau pengurangan ukuran populasi. Sebagai bawaan, ketiga argumen ini bernilai 0,5, 0,5, dan 5. *max_iter* merupakan banyak iterasi maksimum dengan nilai bawaan sebesar seratus, sedangkan *lower* dan *upper* ialah batas minimum dan maksimum untuk tiap elemen komodo dengan nilai bawaan sebesar nol dan satu, sebagaimana interval nilai bobot portofolio CMVP. *normalize* merupakan variabel biner, dengan nilai *True* atau *T* berarti bahwa normalisasi akan dilakukan pada saat algoritma berlangsung.

Pada tiap iterasinya, fungsi *KMA* terlebih dahulu mengukur kualitas komodo mula-mula dan mengurutkannya dari kualitas tertinggi hingga terendah. Fungsi kemudian menghitung banyaknya komodo jantan dan muda, lalu melakukan segmentasi terhadap komodo-komodo dalam populasi berdasarkan strata kualitasnya. Setelah itu, fungsi memanggil fungsi-fungsi penggerak yang telah disusun sebelumnya untuk menggerakan tiap komodo menurut golongannya. Komodo-komodo yang telah digerakkan kemudian disatukan dalam sebuah vektor dan dinormalisasi.

Normalisasi merupakan tahap yang Penulis tambahkan terhadap algoritma Suyanto dkk. (2022) yang bertujuan agar jumlah elemen dari seluruh dimensi komodo bernilai sama dengan satu. Modifikasi lainnya ialah *clipping*, yaitu mengembalikan nilai satu dimensi komodo atau lebih ke dalam interval $(0, 1)$. *Clipping* melibatkan fungsi *pmin* dan *pmax*. Fungsi *pmax* mengembalikan maksimum antara elemen tiap dimensi dan nol guna mencegah elemen bernilai negatif, sedangkan fungsi *pmin* mengembalikan minimum antara luaran fungsi *pmax* dan satu untuk menghindari elemen bernilai lebih dari satu. Setelah melalui proses *clipping*, tiap komodo dinormalisasi kembali untuk memastikan jumlah elemen dari seluruh dimensinya bernilai sama dengan satu.

Terakhir, kualitas tiap komodo diukur kembali dan seluruh komodo diurutkan secara menurun berdasarkan nilai kualitas barunya. Komodo terbaik ialah komodo dengan kualitas paling kecil, yaitu komodo yang meminimisasi fungsi objektif. Memasuki iterasi ketiga, komodo terbaik dari tiga iterasi terakhir akan ditinjau untuk memperbarui ukuran populasi komodo. Algoritma memasuki terminasi jika pembaruan ukuran populasi komodo bernilai nonpositif. Fungsi *KMA* diakhiri dengan visualisasi evolusi komodo terbaik dari iterasi pertama hingga terakhir.

KMA terlebih dahulu diaplikasikan pada fungsi Sphere yang telah diberikan pada Persamaan (4.4). Ukuran populasi mula-mula dan dimensi tiap komodo secara berturut-turut ditentukan sebesar dua ratus dan tiga puluh, sama dengan aplikasi *Genetic Algorithm* (GA) untuk mengoptimisasi fungsi tersebut. Setelah melalui 42 iterasi, diperoleh solusi terbaik akhir dengan kualitas sebesar 133.796,9. Nilai ini sangat jauh dari minimum global fungsi tersebut yang bernilai nol. Visualisasi menunjukkan adanya peningkatan nilai optimum yang sangat ekstrem dari iterasi kedua ke iterasi ketiga, diikuti tren penurunan yang landai dan fluktuatif hingga iterasi terakhir. Hal ini menunjukkan bahwa KMA yang dibangun berdasarkan konsep matematisnya tidak stabil dalam mencari solusi optimum untuk fungsi Sphere. Akan tetapi, jika ukuran populasi mula-mula ditambah guna memperbanyak iterasi, solusi optimum global memungkinkan untuk dicapai. Sintaksis dan luaran untuk aplikasi ini dapat diamati pada Lampiran 15.

Selanjutnya, KMA diaplikasikan untuk mencari solusi optimum CMVP yang telah dirancang untuk penelitian ini. Diperoleh bahwa bobot yang meminimisasi fungsi objektif ialah:

$$\mathbf{w}_{\text{KMA}} = \begin{bmatrix} 0{,}3122141 \\ 0{,}2713546 \\ 0{,}4036373 \\ 0{,}01279399 \end{bmatrix}$$

dengan:

$$f(\mathbf{w}_{\text{KMA}}) = 0{,}0001031325.$$

Kualitas solusi terbaik akhir dari KMA tidak lebih baik daripada kualitas solusi terbaik akhir yang diperoleh dari GA. Lebih lanjut, visualisasi juga menunjukkan ketidakstabilan KMA dalam mencari solusi terbaik untuk permasalahan ini.

Penulis mendapati dua buah faktor yang diduga menyebabkan masalah fluktuasi solusi terbaik pada kelangsungan KMA. Pertama, ruang pencarian solusi optimal untuk permasalahan ini cukup sempit dengan adanya kendala persamaan dan kendala nilai (berbentuk pertidaksamaan). Jika diilustrasikan, irisan antara kedua kendala ini terdapat pada kurva $w_1 + w_2 + w_3 + w_4 = 1$ berbentuk garis yang dibatasi oleh batas-batas luar kurva kendala nilai. Hal ini mengakibatkan solusi optimal yang berlaku hanya terdapat di sepanjang garis tersebut. Kedua, pembaruan posisi suatu komodo dilakukan melalui randomisasi dan operasi penjumlahan. Maka, tidak dapat dipungkiri bahwa jumlahan tersebut menghasilkan posisi baru di luar kendala permasalahan, yaitu dimensi yang bernilai negatif atau lebih dari satu. Peristiwa ini belum pernah disebutkan atau dicantumkan pada penelitian-penelitian terdahulu, termasuk oleh Suyanto dkk. (2022) selaku pionir KMA, sehingga tidak terdapat solusi eksak untuk menyelesaikannya.

Sintaksis dan luaran untuk aplikasi KMA terhadap CMVP dapat dilihat pada Lampiran 16.

4.10. Pembobotan Portofolio Menggunakan *Particle Swarm Optimization*

Serupa dengan *Komodo Mlipir Algorithm* (KMA), *Particle Swarm Optimization* (PSO) merupakan salah satu algoritma metaheuristik lain yang berbasis kecerdasan kawanan. Secara khusus, PSO terinspirasi dari pergerakan serangga atau hewan bersayap lainnya dalam terbang menyusuri suatu wilayah dan mencari titik-titik terbaik untuk mendarat. Fenomena ini melandasi konsep pencarian solusi terbaik dari suatu ruang pencarian.

PSO dijalankan pada bahasa pemrograman R menggunakan bantuan fungsi *psoptim* yang termuat dalam *library pso*. Fungsi ini memuat dua argumen wajib, yaitu *par* dan *fn*. *par* diisi dengan dimensi permasalahan optimisasi, sedangkan *fn* diisi dengan fungsi objektif. Secara bawaan, jenis optimisasi yang dilakukan melalui fungsi *pso* adalah minimisasi. Oleh karena itu, pada penelitian ini, fungsi yang akan dimasukkan ke dalam argumen *fn* tidak perlu dinegasikan. Selain itu, beberapa argumen lain yang dapat didefinisikan secara opsional ialah *lower* dan *upper* yang secara berturut-turut diisi oleh batas bawah dan batas atas dari tiap dimensi.

Sintaksis dan luaran untuk pembobotan portofolio menggunakan PSO terdapat pada Lampiran 17. Berdasarkan luaran yang ada, diperoleh bahwa bobot portofolio yang meminimisasi fungsi objektif yang tertuang pada Persamaan (3.2) ialah:

$$\begin{bmatrix} 0{,}26729764 \\ 0{,}31334935 \\ 0{,}34468174 \\ 0{,}07467127 \end{bmatrix}$$

dengan:

$$f(\mathbf{w}_{\min}) = 0{,}00009894696.$$

Luaran ini diperoleh setelah seribu iterasi dan bernilai sama dengan portofolio yang dibobotkan melalui metode *minimum variance*.

4.11. Perhitungan Beta Portofolio

Treynor ratio dan *Jensen's alpha* melibatkan beta portofolio dalam perhitungannya. Sebagaimana tertuang pada subbab mengenai *Capital Asset Pricing Model* (CAPM), beta portofolio bersifat relatif terhadap portofolio pasar. Pada kasus ini, asumsi-asumsi CAPM dianggap berlaku sehingga Indeks Harga Pasar Gabungan (IHSG) ditentukan sebagai portofolio pasar.

Menyesuaikan Persamaan (2.38), beta tiap sekuritas di dalam suatu portofolio terhadap portofolio pasar dirumuskan sebagai:

$$\beta_i^M = \frac{\sigma_{iM}}{\sigma_M^2},$$

dengan σ_{iM} adalah kovariansi antara *return* sekuritas dan *return* portofolio pasar serta σ_M^2 adalah variansi portofolio pasar. Dengan menggabungkan beta seluruh sekuritas menjadi suatu vektor, $\boldsymbol{\beta}_M$, beta portofolio kemudian diperoleh melalui rumus berikut:

$$\beta_P = \mathbf{w}'\boldsymbol{\beta}_M.$$

Data riwayat harga harian IHSG termuat pada Lampiran 18. Komputasi *return* dari data harga harian termuat pada Lampiran 19. Data *return* IHSG selanjutnya digabungkan dengan *return* harian keempat saham yang tergabung dalam portofolio yang diteliti untuk menghitung beta tiap saham relatif terhadap portofolio pasar. Diperoleh vektor atas beta-beta saham sebagai berikut:

$$\boldsymbol{\beta}_M = \begin{bmatrix} 0{,}5538391 \\ 0{,}7996983 \\ 1{,}3914885 \\ 1{,}1772685 \end{bmatrix},$$

berdasarkan komputasi yang termuat pada Lampiran 20.

Komputasi beta dari ketiga portofolio terdapat pada Lampiran 21. Hasil komputasi menunjukkan bahwa beta portofolio yang dibangun menggunakan metode *minimum variance*, *Genetic Algorithm* (GA), *Komodo Mlipir Algorithm* (KMA), dan *Particle Swarm Optimization* (PSO) bernilai 0,9661536, 0,9662512, 0,9666368,

dan 0,9661536 secara berturut-turut. Nilai-nilai ini bermakna bahwa portofolio KMA menghasilkan ekspektasi perubahan *return* yang paling tinggi untuk tiap persen perubahan *return* IHSG, yakni sebesar 96,66 persen. Meski demikian, keempat portofolio tidak lebih volatil daripada portofolio pasar.

4.12. Perbandingan Performa Portofolio

Sejauh komputasi yang telah dilakukan hingga subbab sebelumnya, portofolio *minimum variance* merupakan portofolio yang paling meminimisasi risiko dalam model CMVP. Meski demikian, dalam penelitian ini, kualitas portofolio juga akan dibandingkan melalui tiga ukuran performa portofolio yang telah Penulis tentukan, yaitu *Sharpe ratio*, *Treynor ratio*, dan *Jensen's alpha*. Rumusan tiap ukuran yang secara berturut-turut termuat pada Persamaan (2.39), Persamaan (2.44), dan Persamaan (2.43) diimplementasikan menjadi fungsi-fungsi buatan, lalu diterapkan pada portofolio *minimum variance*, *Genetic Algorithm* (GA), *Komodo Mlipir Algorithm* (KMA), dan *Particle Swarm Optimization* (PSO).

Hasil komputasi untuk ketiga ukuran diberikan pada Tabel 4.3 di bawah ini.

Tabel 4.3 Perbandingan ukuran performa portofolio *minimum variance*, GA, KMA, dan PSO.

Portofolio	***Sharpe ratio***	***Treynor ratio***	***Jensen's alpha***
Minimum variance	0,2830541	0,06344737	0,1192077
GA	0,2830966	0,06345765	0,1192297
KMA	0,4364185	0,0998221	0,1544285
PSO	0,2830541	0,06344737	0,1192077

Tabel di atas menunjukkan bahwa ukuran performa seluruh portofolio bernilai kurang dari satu. Untuk ukuran-ukuran berbasis rasio, hal ini berarti bahwa portofolio-portofolio yang dibentuk tidak mampu mengembalikan *return* yang sebanding atau lebih besar daripada risiko keseluruhan maupun risiko sistematis semata. Secara statistik, peristiwa ini mungkin terjadi karena pemilihan kombinasi saham yang kurang maksimal atau metode analisis klaster yang kurang baik karena sensitif terhadap pencilan. Di sisi lain, pada realitasnya, nilai *Treynor ratio* yang lebih rendah

daripada *Sharpe ratio* dapat mengindikasikan bahwa risiko sistematis pada periode observasi saham, yaitu Desember 2023 sampai dengan November 2024, berkontribusi lebih banyak daripada risiko *firm-specific* pada perhitungan nilai risiko keseluruhan. Peristiwa ini menandakan bahwa dalam satu hingga dua tahun terakhir, guncangan pada perekonomian Indonesia menimpa seluruh sektor ekonomi sehingga berdampak lebih besar daripada perubahan-perubahan yang berasal dari badan-badan usaha. Meski demikian, *Jensen's alpha* yang bernilai positif mencirikan bahwa ekspektasi *return* dari ketiga portofolio mampu melebihi *required return* yang diperlukan. Artinya, meskipun ekspektasi *return* tidak sebanding dengan risiko investasi, nilai yang diharapkan masih melebihi minimum yang dikompensasikan terhadap risiko tersebut.

Untuk masing-masing ukuran, portofolio yang dibobotkan melalui KMA terasosiasi dengan nilai yang tertinggi, sedangkan portofolio yang dibobotkan melalui metode *minimum variance* dan PSO terasosiasi dengan nilai yang terendah. Hal ini menunjukkan bahwa KMA merupakan alternatif algoritma yang baik terhadap metode-metode optimisasi yang telah diuji dan digunakan pada masa lampau, khususnya untuk permasalahan optimisasi portofolio.

BAB V

PENUTUP

5.1. Kesimpulan

Penelitian ini dapat disimpulkan sebagai berikut:

1. Normalitas *return* harian dan analisis klaster *K-Means* ditentukan sebagai dasar pemilihan saham dari indeks saham LQ45 untuk pembentukan portofolio. Dari 45 saham, terdapat sembilan belas saham dengan *return* harian berdistribusi normal. Dua klaster terbentuk dari sembilan belas saham tersebut. Dua saham dari tiap klaster dilibatkan dalam portofolio berdasarkan nilai *Sharpe ratio* tertinggi.
2. Dengan adanya kendala persamaan dan kendala batas dalam model *no-short-sale-constrained minimum variance portfolio* (CMVP), metode *minimum variance* dan *Genetic Algorithm* (GA) mampu membangun portofolio dengan bobot-bobot positif, sedangkan metode *Komodo Mlipir Algorithm* (KMA) masih memunculkan bobot-bobot negatif dalam iterasi-iterasinya. Dengan kata lain, investor yang menggunakan metode KMA perlu mempraktikkan *shortselling* atau melanggar kendala batas yang ditentukan.
3. Berdasarkan tiga ukuran performa portofolio, yaitu *Sharpe ratio*, *Treynor ratio*, dan *Jensen's alpha*, portofolio yang dihasilkan melalui KMA mempunyai performa terbaik, sedangkan portofolio yang dihasilkan melalui metode *minimum variance* dan *Particle Swarm Optimization* (PSO) menunjukkan performa terburuk.

5.2. Saran

Guna menunjang perkembangan penelitian di masa yang akan datang, Penulis memberikan saran-saran berikut:

1. Analisis klaster untuk pemilihan saham dapat divariasikan dengan metode-metode analisis klaster dengan basis yang berbeda, seperti hierarki, kepadatan, dan *grid*.

2. Algoritma-algoritma yang diturunkan atau dileburkan dengan KMA, seperti *Stochastic Komodo Algorithm* (SKA), *Improved Adaptive Komodo Mlipir Algorithm* (IKMA), dan *Hybrid Pelican Komodo Algorithm* (HPKA), dapat digunakan dalam eksperimen penyelesaian permasalahan optimisasi, khususnya optimisasi portofolio.
3. Sintaksis KMA pada penelitian ini masih dapat disempurnakan dan disusun menjadi *library* yang terintegrasi pada berbagai bahasa pemrograman yang dipakai secara lebih meluas, seperti R dan Python.
4. Performa KMA dapat diteliti lebih jauh untuk permasalahan optimisasi portofolio, misalnya dengan:
    a. menambah keragaman jenis instrumen investasi dalam portofolio, seperti logam mulia dan mata uang kripto, atau
    b. menggunakan jenis portofolio yang lebih kompleks, seperti L_1-*norm-constrained minimum variance portfolio* (L_1-NCMVP) dan L_1-*regularization minimum variance portfolio* (L_1-RMVP).

DAFTAR PUSTAKA

Aditya, I. A., Simaremare, A. A., Raharjo, J., Suyanto, dan Wijayanto, I. (2022). "Komodo Mlipir Algorithm to Solve Generator Scheduling Problems". *2nd International Conference on Electronic and Electrical Engineering and Intelligent System (ICE3IS)*, Indonesia, 84—88.

Bain, L. J. dan Engelhardt, M. (1992). *Introduction to Probability and Mathematical Statistics* (Edisi 2). Duxbury.

Bank Indonesia. (t.t.) *BI-Rate*. Bank Indonesia. https://www.bi.go.id/id/fungsi-utama/moneter/bi-rate/default.aspx.

Berk, J. dan DeMarzo, P. (2016). *Corporate Finance* (Edisi 4). Pearson.

Bitar, A. W., de Curvalho, N., dan Gatignol, V. (2023). *Covariance matrix estimation for robust portfolio allocation*. HAL Open Science.

Bodie, Z., Kane, A., dan Marcus, A. J. (2014). *Investments* (Edisi 10). McGraw-Hill Education.

Bulani, V., Bezbradica, M., dan Crane, M. (2025). *Improving Portfolio Management Using Clustering and Particle Swarm Optimization*. *Mathematics*, 13, 1623—1650.

Chen, J. (2021, 28 Januari). *Risk-Free Asset: Definition and Examples of Asset Types*. Investopedia. https://www.investopedia.com/terms/r/riskfreeasset.asp#:∼:text=A%20risk%2Dfree%20asset%20is,the%20U.S.%20government%20backs%20them.

Chen, J. (2022, 29 September). *Risk Asset: Definition and Examples From Stocks to Crypto*. Investopedia. https://www.investopedia.com/terms/r/risk-asset.asp#:∼:text=A%20risk%20asset%20is%20any,%2C%20real%20estate%2C%20and%20currencies.

Cheong, D., Kim, Y. M., Byun, H. B., Oh, K. J., dan Kim, T. Y. (2017). ”Using genetic algorithm to support clustering-based portfolio optimization by investor information”. *Applied Soft Computing*, 61, 593—602.

Cogneau, P. dan Hübner, G. (2009). ”The 101 ways to measure portfolio performance”. [Naskah tidak terpublikasi]. University of Liège. https://dx.doi.org/10.2139/ssrn.1326076.

Dai, Z. (2019). ”A Closer Look at the Minimum-Variance Portfolio Optimization Model”. *Mathematical Problems in Engineering*, 2019, 1—8.

Data Services Division Bursa Efek Indonesia. (2024). *IDX Company Fact Sheet: LQ45, August 2024 - January 2025*.

Dharmapuri, C. M. dan Reddy, B. V. R. (2024). ”Spectrum and Energy Efficiency in CRNs Using Dynamic Channel Reservation and Komodo Mlipir Optimization”. *IETE Journal of Research*, 70, 11, 8291—8299.

Dubinskas, P. dan Urbšienė. (2017). ”Investment Portfolio Optimization by Applying a Genetic Algorithm-based Approach”. *Ekonomika*, 96(2), 66—78.

Eltibi, M. F. dan Ashour, W. M. (2011). ”Initializing K-Means Clustering Algorithm using Statistical Information”. *International Journal of Computer Applications*, 29(7), 51—55.

Faia, R., Pinto, T., Vale, Z., Corchado, J. M., Soares, J., dan Lezama, F. (2018). ”Genetic Algorithms for Portfolio Optimization with Weighted Sum Approach”. *2018 IEEE Symposium Series on Computational Intelligence (SSCI)*, India, 1823—1829. https://doi.org/10.1109/SSCI.2018.8628773.

Fauzia, A. M., Kusrini, M. D., Mulyani, Y. A., Nusantara, M. G. G., Sari, F. E., Setiawan, R. A., dan Ariefiandy, A. (2024). ”Community Perspectives in Ethogram for Komodo Dragon (*Varanus komodoensis*) in the Wild”. *Media Konservasi*, 29 (2), 91—100.

Finaka, A. W. (2021). *Peleburan dan Pembentukan Kementerian Baru*. Indonesiabaik.id. https://indonesiabaik.id/videografis/peleburan-dan-pembentukan-kementerian-baru.

Fitri, A. N. (2024). *Tren Investasi Digital Naik, 67% Masyarakat Indonesia Berencana Investasi Tahun Depan*. Kontan.co.id. https://investasi.kontan.co.id/news/tren-investasi-digital-naik-67-masyarakat-indonesia-berencana-investasi-tahun-depan.

Flores-Fernandez, G. A., Jimenez-Carrion, M., Gutierrez, F., dan Sanchez-Ancajima, R. A. (2024). ”Genetic Algorithm and LSTM Artificial Neural Network for Investment Portfolio Optimization”. *Journal of Wireless Mobile Networks, Ubiquitous Computing, and Dependable Applications*, 15(2), 27—46.

Han, J., Kamber, M., dan Pei, J. (2012). *Data Mining Concepts and Techniques* (Edisi 3). Morgan Kaufmann Publishers.

Hogg, R. V., McKean, J. W., dan Craig, A. T. (2005). *Introduction to Mathematical Statistics* (Edisi 6). Pearson Prentice Hall.

Jagannathan, R. dan Ma, T. (2003). ”Risk Reduction in Large Portfolios: Why Imposing the Wrong Constraints Helps”. *NBER Working Paper Series*.

Jati, G. K., Kuwanto, G., Hashmi, T., dan Widjaja, H. (2023). ”Discrete komodo algorithm for traveling salesman problem”. *Applied Soft Computing*, 139, 1—21.

Johnson, R. A. dan Winchern, D. W. (2007). *Applied Multivariate Statistical Analysis* (Edisi 6). Pearson Prentice Hall.

Kraska-Miller, M. (2013). *Nonparametric Statistics for Social and Behavioral Sciences*. CRC Press.

Kuhn, H. W. dan Tucker, A. W. (1951). ”Nonlinear Programming”. *Proceedings of the 2nd Berkeley Symposium on Mathematics, Statistics and Probability*, 2, 481—492.

Kusuma, P. D. dan Dinimaharawati, A. (2022). ”Hybrid Pelican Komodo Algorithm”. *International Journal of Advanced Computer Science and Applications*, 13, 6, 46—55.

Kusuma, P. D. dan Kallista, M. (2022). ”Stochastic Komodo Algorithm”. *International Journal of Intelligent Engineering and Systems*, 15, 4, 156—166.

Li, H. dan Shi, N. (2022). ”Application of Genetic Optimization Algorithm in Financial Portfolio Problem”. *Computational Intelligence and Neuroscience*, 2022(1), 1—9.

Li, L. dan Zhao, M. (2022). ”A Novel Komodo Mlipir Algorithm and Its Application in PM2.5 Detection”. *Atmosphere* 2022, 13(12), 2051, 1—17.

Lim, S., Kim, M., dan Ahn, C. J. (2020). ”A Genetic Algorithm (GA) Approach to the Portfolio Design Based on Market Movements and Asset Valuations”. *IEEE Access*, 8, 140234—140249.

Liu, Q. dan Zhang, X. (2022). ”Improved Adaptive Komodo Mlipir Algorithm”. *IEEE Access*, 10, 67883—67897.

Luptáčik, M. (2010). *Mathematical Optimization and Economic Analysis*. Springer.

Mahner, M. dan Kary, M. (1997). ”What Exactly Are Genomes, Genotypes and Phenotypes? And What About Phenomes?”. *Journal of Theoretical Biology*, 186 (1), 55—63.

Marhfor, A. (2016). ”Portfolio Performance Measurement: Review of Literature and Avenues of Future Research”. *American Journal of Industrial and Business Management*, 6, 432—438.

Nocedal, J. dan Wright, S. J. (2006). *Numerical Optimization* (Edisi 2). Springer.

Nurawan, M. R. dan Mahendra, R. (2023) *Apa itu Indeks LQ45? Ini Kriteria Dan Daftar Sahamnya*. Bisnis.com. https://market.bisnis.com/read/20231110/7/1712648/apa-itu-indeks-lq45-ini-kriteria-dan-daftar-sahamnya.

Pramuji, S. (2024). *Gen Z Serbu Bursa Saham*. Datanesia. https://datanesia.id/gen-z-dominasi-investor-individu/.

Putri, B. U. (2021). *Pembentukan Kementerian Investasi Disebut Demi Naikkan Wibawa BKPM*. Tempo. https://www.tempo.co/politik/pembentukan-kementerian-investasi-disebut-demi-naikkan-wibawa-bkpm-522693.

Rajwar, K., Deep, K., dan Das, S. (2023). "An exhaustive review of the metaheuristic algorithms for search and optimization: taxonomy, applications, and open challenges". *Artificial Intelligence Review*, 56, 13187—13257.

Rao, R. V. (2020). "Rao algorithms: Three metaphor-less simple algorithms for solving optimization problems". *International Journal of Industrial Engineering Computations*, 11, 107—130.

Reeves, C. R. (2010). "Genetic algorithms". Dalam Gendreau, M. dan Potvin, J. (Eds.), *Handbook of Metaheuristics* (Edisi 2, hlm. 109—139). Springer.

Ripley, B. D. (1987). *Stochastic Simulation*. John Wiley & Sons.

Ross, S. M. (2010). *Introduction to Probability Models* (Edisi 10). Academic Press.

Schott, J. R. (2017). *Matrix Analysis for Statistics* (Edisi 3). John Wiley & Sons, Inc.

Soundarayaa, R. K. dan Balasubramanian, C. (2024). "Komodo Mlipir Algorithm-based optimal route determination mechanism for improving Quality of Service in Vehicular ad hoc network". *Sustainable Computing: Informatics and Systems*, 42, 1—19.

Stewart, J. (2015). *Calculus: Early Transcendentals* (Edisi 8). Cengage Learning.

Stoddard, A. M. (1979). "Standardization of Measures Prior to Cluster Analysis". *Biometrics*, 35(4), 765—773.

Sukono, Hidayat, Y., Lesmana, E., Putra, A. S., Napitupulu, H., dan Supian, S. (2018). ”Portfolio optimization by using linear programing models based on genetic algorithm”. *IOP Conference Series: Materials Science and Engineering*, Indonesia, 300, 1—9.

Sun, R., Ma, T., Liu, S., dan Sathye, M. (2019). ”Improved Covariance Matrix Estimation for Portfolio Risk Measurement: A Review”. *Journal of Risk and Financial Management*, 12(1), 48.

Sutomo. (2020). ”Vegetation Composition of Savanna Ecosystem as a Habitat For The Komodo Dragon (Varanus komodoensis) on Padar and Komodo Islands, Flores East Nusa Tenggara Indonesia”. *Journal of Tropical Biodiversity and Biotechnology*, 5(1), 10—15.

Suyanto, Ariyanto, A. A., dan Ariyanto, A. F. (2022). ”Komodo Mlipir Algorithm”. *Applied Soft Computing*, 114, 1—17.

Taha, H. A. (2007). *Operations Research: An Introduction* (Edisi 8). Pearson Prentice Hall.

The Editors of Encyclopaedia Britannica. (2024, 22 Oktober). *Komodo dragon*. https://www.britannica.com/animal/Komodo-dragon.

Vasiani, V. D., Handari, B. D., dan Hertono, G. F. (2020). ”Stock portfolio optimization using priority index and genetic algorithm”. *Journal of Physics: Conference Series*, 1442, 1—5.

Virlics, A. (2013). ”Investment Decision Making and Risk”. *Procedia Economics and Finance*, 6, 169—177.

Watts, P., Buley, K., Sanderson, S., Boardman, W. S. J., Ciofi, C., dan Gibson, R. (2007). ”Parthenogenesis in Komodo dragons”. *Nature*, 444, 1021—1022.

Wiranto, A. A. (2022). *Tren Investasi Meningkat, 71% Orang Indonesia Berinvestasi Lewat Aplikasi*. SWA. https://swa.co.id/read/377717/tren-investasi-meningkat-71-orang-indonesia-berinvestasi-lewat-aplikasi.

Zaimovic, A., Omanovic, A., dan Arnaut-Berilo, A. (2021). ”How Many Stocks Are Sufficient for Equity Portfolio Diversification? A Review of the Literature”. *Journal of Risk and Financial Management*, 14, 551—580.

Zhou, Q. (2020). *Portfolio Optimization with Robust Covariance and Conditional Value-at-Risk Constraints*. Cornell University.

Zhu, S. (2016). ”Research on the Portfolio Optimization Model under Quantitative Constraint Based on Genetic Algorithm”. *Journal of Mathematical Finance*, 6, 465—470.

LAMPIRAN

Lampiran 1. Daftar Saham dalam Indeks LQ45

No.	Nama perusahaan	Kode saham
1.	Aspirasi Hidup Indonesia Tbk	ACES
2.	Adaro Energy Indonesia Tbk	ADRO
3.	AKR Corporindo Tbk	AKRA
4.	Amman Mineral Internasional Tbk	AMMN
5.	Sumber Alfaria Trijaya Tbk	AMRT
6.	Aneka Tambang Tbk	ANTM
7.	Bank Jago Tbk	ARTO
8.	Astra International Tbk	ASII
9.	Bank Central Asia Tbk	BBCA
10.	Bank Negara Indonesia (Persero) Tbk	BBNI
11.	Bank Rakyat Indonesia (Persero) Tbk	BBRI
12.	Bank Tabungan Negara (Persero) Tbk	BBTN
13.	Bank Mandiri (Persero) Tbk	BMRI
14.	Bank Syariah Indonesia Tbk	BRIS
15.	Barito Pacific Tbk	BRPT
16.	Bukalapakcom Tbk	BUKA
17.	Charoen Pokphand Indonesia Tbk	CPIN
18.	ESSA Industries Indonesia Tbk	ESSA
19.	xL Axiata Tbk	EXCL
20.	Gudang Garam Tbk	GGRM
21.	GoTo Gojek Tokopedia Tbk	GOTO
22.	Harum Energy Tbk	HRUM
23.	Indofood CBP Sukses Makmur Tbk	ICBP

No.	Nama perusahaan	Kode saham
24.	Vale Indonesia Tbk	INCO
25.	Indofood Sukses Makmur Tbk	INDF
26.	Indah Kiat Pulp & Paper Tbk	INKP
27.	Indocement Tunggal Prakarsa Tbk	INTP
28.	Indosat Tbk	ISAT
29.	Indo Tambangraya Megah Tbk	ITMG
30.	Jasa Marga (Persero) Tbk	JSMR
31.	Kalbe Farma Tbk	KLBF
32.	Mitra Adiperkasa Tbk	MAPI
33.	Merdeka Battery Materials Tbk	MBMA
34.	Merdeka Copper Gold Tbk	MDKA
35.	Medco Energi Internasional Tbk	MEDC
36.	Dayamitra Telekomunikasi Tbk	MTEL
37.	Perusahaan Gas Negara Tbk	PGAS
38.	Pertamina Geothermal Energy Tbk	PGEO
39.	Bukit Asam Tbk	PTBA
40.	Industri Jamu dan Farmasi Sido Muncul Tbk	SIDO
41.	Semen Indonesia (Persero) Tbk	SMGR
42.	Telkom Indonesia (Persero) Tbk	TLKM
43.	Sarana Menara Nusantara Tbk	TOWR
44.	United Tractors Tbk	UNTR
45.	Unilever Indonesia Tbk	UNVR

(Bursa Efek Indonesia, 2024)

Lampiran 2. ***Pseudocode Genetic Algorithm*** **(GA)**

Tentukan populasi kromosom mula-mula;

WHILE Kondisi terminasi tidak terpenuhi ***DO***:

REPEAT

IF kondisi persilangan terpenuhi ***THEN***

{Pilih kromosom induk;

Pilih parameter-parameter persilangan;

Lakukan persilangan};

IF kondisi mutasi terpenuhi ***THEN***

{Pilih titik-titik mutasi;

Lakukan persilangan};

Evaluasi *fitness* kromosom anakan

UNTIL kromosom anakan yang dihasilkan berjumlah cukup;

Pilih populasi baru;

END WHILE

(Reeves, 2010)

Lampiran 3. ***Pseudocode Komodo Mlipir Algorithm*** **(KMA)**

Tentukan n, p, dan d;

Inisiasikan n individu yang masing-masing terdiri atas m dimensi;

WHILE Kondisi terminasi tidak terpenuhi ***DO***:

FOR tiap komodo:

Hitung kualitasnya, lalu urutkan sesuai peringkat;

END FOR

Berdasarkan peringkat dan porsi p, pisahkan populasi menjadi q komodo dewasa, satu komodo betina, dan s komodo muda;

FOR tiap komodo dewasa:

Lakukan pergerakan dan perbarui posisi;

END FOR

Perbarui posisi komodo betina dengan mengawini komodo dewasa terbaik atau melakukan partenogenesis;

FOR tiap komodo muda:

Lakukan pergerakan dan perbarui posisi;

END FOR

Pilih satu komodo dengan kualitas terbaik dari antara ketiga kelompok sebagai solusi terbaik, $\mathbf{k}_{\text{best}}$;

Mulai iterasi ketiga, perbarui ukuran populasi;

END WHILE

(Suyanto dkk., 2022)

Lampiran 4. Data Riwayat Harga Saham

Sintaksis:

```
#Library
library(cluster)
library(ClusterR)
library(dplyr)
library(factoextra)
library(GA)
library(ggplot2)
library(openxlsx)
library(pso)
library(quadprog)
library(tidyr)
library(tidyverse)


#Impor data
dt = read.xlsx('Data␣LQ45.xlsx')
dt = dt[, -1]
View(dt)
```

Luaran:

Tanggal	ACES	ADRO	AKRA	⋯	UNTR	UNVR
01-12-2023	735	2,560	1,435	⋯	22,150	3,630
04-12-2023	720	2,560	1,405	⋯	22,425	3,630
05-12-2023	710	2,510	1,405	⋯	22,050	3,620
06-12-2023	730	2,530	1,400	⋯	21,625	3,510
07-12-2023	695	2,530	1,335	⋯	21,700	3,570
⋮	⋮	⋮	⋮	⋱	⋮	⋮
22-11-2024	790	3,750	1,305	⋯	27,000	1,795
25-11-2024	785	3,770	1,265	⋯	27,600	1,915
26-11-2024	780	3,670	1,230	⋯	27,500	1,870

28-11-2024	775	2,760	1,225	$\cdots$	27,375	1,885
29-11-2024	770	2,080	1,230	$\cdots$	26,775	1,865

Luaran selengkapnya dapat diakses pada tautan bit.ly/DataTA_473767 pada *sheet* ”Saham”.

Lampiran 5. Komputasi *Return* Saham

Sintaksis:

```
#Returns
late_dt = rbind(dt, 0)
late_dt = late_dt[-1,]
View(late_dt)

returns = (late_dt - dt)/dt
returns = returns[-nrow(returns),]
View(returns)
```

Luaran:

ACES	ADRO	AKRA	⋯	TOWR	UNTR	UNVR
-0.02041	0	-0.02091	⋯	0.026596	0.012415	0
-0.01389	-0.01953	0	⋯	0.015544	-0.01672	-0.00275
0.028169	0.007968	-0.00356	⋯	-0.03061	-0.01927	-0.03039
-0.04795	0	-0.04643	⋯	-0.04737	0.003468	0.017094
0	0.011858	0.044944	⋯	0	0.02765	-0.01681
⋮	⋮	⋮	⋱	⋮	⋮	⋮
-0.0125	0.019022	0	⋯	0	0.012184	0.031609
-0.00633	0.005333	-0.03065	⋯	-0.02083	0.022222	0.066852
-0.00637	-0.02653	-0.02767	⋯	0	-0.00362	-0.0235
-0.00641	-0.24796	-0.00407	⋯	0	-0.00455	0.008021
-0.00645	-0.24638	0.004082	⋯	0	-0.02192	-0.01061

Luaran selengkapnya dapat diakses pada tautan bit.ly/DataTA_473767 pada *sheet* ”Return”.

Lampiran 6. Uji Kolmogorov-Smirnov terhadap Normalitas *Return* Harian Saham

Sintaksis:

```
#Uji normalitas Kolmogorov-Smirnov
kstest = function(data){
  ks.test(data, "pnorm", mean = mean(data),
                         sd = sd(data))$p.value
}

normality = data.frame(sapply(returns, kstest))
names(normalitas)[1] = "p-value"
normalitas$Kesimpulan = with(normalitas,
                             ifelse(`p-value` < 0.05,
                                    'Tidak normal',
                                    'Normal'))
normalitas = rownames_to_column(normalitas)
names(normalitas)[names(normalitas) == "rowname"] = "Saham"

View(normalitas)
```

Luaran:

Saham	*p-value*	Kesimpulan
ACES	0.01593687	Tidak normal
ADRO	6.0089E-07	Tidak normal
AKRA	0.02719894	Tidak normal
AMMN	0.05312296	Normal
AMRT	0.05907301	Normal
ANTM	0.17005662	Normal
ARTO	0.04517903	Tidak normal
ASII	0.20873054	Normal
BBCA	0.24127884	Normal

BBNI	0.165671	Normal
BBRI	0.60607667	Normal
BBTN	0.08754043	Normal
BMRI	0.06227151	Normal
BRIS	0.01929534	Tidak normal
BRPT	0.00011725	Tidak normal
BUKA	0.00026998	Tidak normal
CPIN	0.04420635	Tidak normal
ESSA	0.02028507	Tidak normal
EXCL	0.04231043	Tidak normal
GGRM	0.00029227	Tidak normal
GOTO	2.718E-05	Tidak normal
HRUM	0.08640976	Normal
ICBP	0.10030574	Normal
INCO	0.00871974	Tidak normal
INDF	0.09751483	Normal
INKP	0.17763771	Normal
INTP	0.00338442	Tidak normal
ISAT	7.3011E-12	Tidak normal
ITMG	0.19979133	Normal
JSMR	0.01195846	Tidak normal
KLBF	0.01481037	Tidak normal
MAPI	0.0076848	Tidak normal
MBMA	0.0805751	Normal
MDKA	0.03384926	Tidak normal
MEDC	0.04398079	Tidak normal
MTEL	2.4624E-05	Tidak normal
PGAS	0.06054331	Normal
PGEO	0.00013651	Tidak normal
PTBA	0.0164985	Tidak normal

SIDO	6.4403E-05	Tidak normal
SMGR	0.06393687	Normal
TLKM	0.06085432	Normal
TOWR	0.00018635	Tidak normal
UNTR	0.22113616	Normal
UNVR	0.03585209	Tidak normal

Lampiran 7. Vektor Mean *Return*, Deviasi Standar, dan *Sharpe Ratio* dari Saham dengan *Return* Harian Berdistribusi Normal

Sintaksis:

```
#Fungsi Sharpe ratio
sharpe_ratio = function(data){
  (mean(data) - 0.06) / sd(data)
}

returns = returns[c('AMMN', 'AMRT', 'ANTM', 'ASII',
                    'BBCA', 'BBNI', 'BBRI', 'BBTN',
                    'BMRI', 'HRUM', 'ICBP', 'INDF',
                    'INKP', 'ITMG', 'MBMA', 'PGAS',
                    'SMGR', 'TLKM', 'UNTR')]

stock_stats = gather(returns, factor_key = TRUE)
stock_stats = stock_stats %>% group_by(key) %>%
  summarise(Mean = mean(value),
            `Deviasi Standar` = sd(value),
            `Sharpe ratio` = sharpe_ratio(value))
stock_stats = stock_stats %>% remove_rownames %>%
  column_to_rownames(var = 'key')
View(stock_stats)
```

Luaran:

Saham	*Mean*	Deviasi Standar	*Sharpe Ratio*
AMMN	0.00218611	0.028520866	-2.0270735
AMRT	6.9472E-05	0.016924599	-3.5410308
ANTM	-0.0004831	0.022928533	-2.6378966
ASII	-0.0003626	0.017044122	-3.5415508
BBCA	0.000561	0.013524238	-4.3949978
BBNI	-5.582E-05	0.018308605	-3.2801964

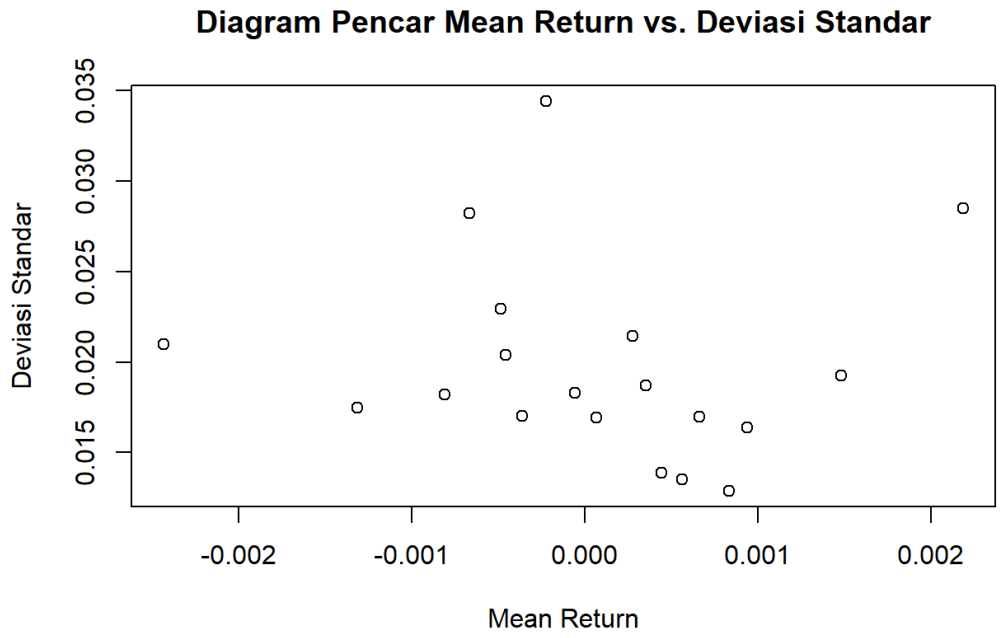
BBRI	-0.0008092	0.018213773	-3.3386396
BBTN	0.00027671	0.021454528	-2.7837148
BMRI	0.0003515	0.018730919	-3.1844938
HRUM	-0.0006645	0.028252371	-2.1472352
ICBP	0.00066382	0.016955066	-3.4996137
INDF	0.00083313	0.01288752	-4.5910205
INKP	-0.0004549	0.020392259	-2.9645984
ITMG	0.00044423	0.013870487	-4.2937041
MBMA	-0.0002213	0.034436253	-1.748777
PGAS	0.00147921	0.019268461	-3.0371286
SMGR	-0.0024328	0.020979092	-2.9759521
TLKM	-0.0013123	0.017473873	-3.5087969
UNTR	0.00093788	0.016400037	-3.6013406

Lampiran 8. Diagram Pencar Mean *Return* dan Risiko dari Saham dengan *Return* Harian Berdistribusi Normal

Sintaksis:

```
#Diagram pencar
plot(stock_stats$Mean, stock_stats$`Deviasi Standar`,
     main = "Diagram␣Pencar␣Mean␣Return␣vs.␣Deviasi
␣␣␣␣␣Standar",
     xlab = "Mean␣Return",
     ylab = "Deviasi␣Standar")
```

Luaran:



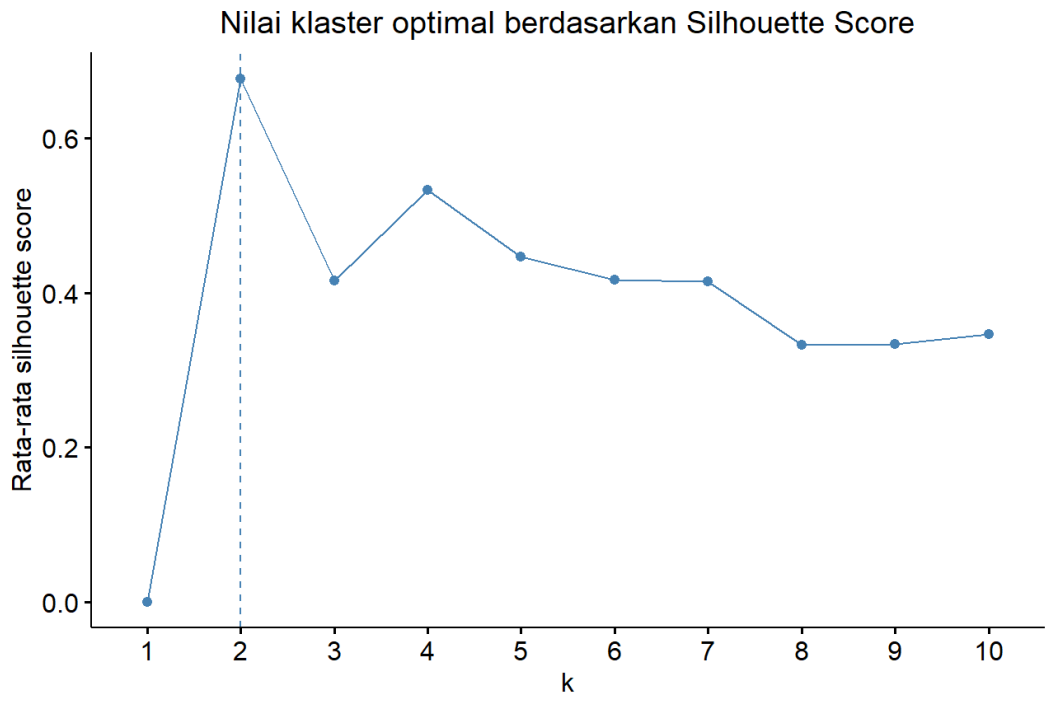
Lampiran 9. Visualisasi *Silhouette Score*

Sintaksis:

```
#Silhouette score
set.seed(20429)

fviz_nbclust(stock_stats[. 1:2], kmeans,
             method = 'silhouette') +
  ggtitle("Nilai klaster optimal berdasarkan Silhouette
  Score") +
  theme(plot.title = element_text(hjust = 0.5)) +
  xlab("k") +
  ylab("Rata-rata silhouette score")
```

Luaran:



Lampiran 10. Analisis Klaster *K-Means*

Sintaksis:

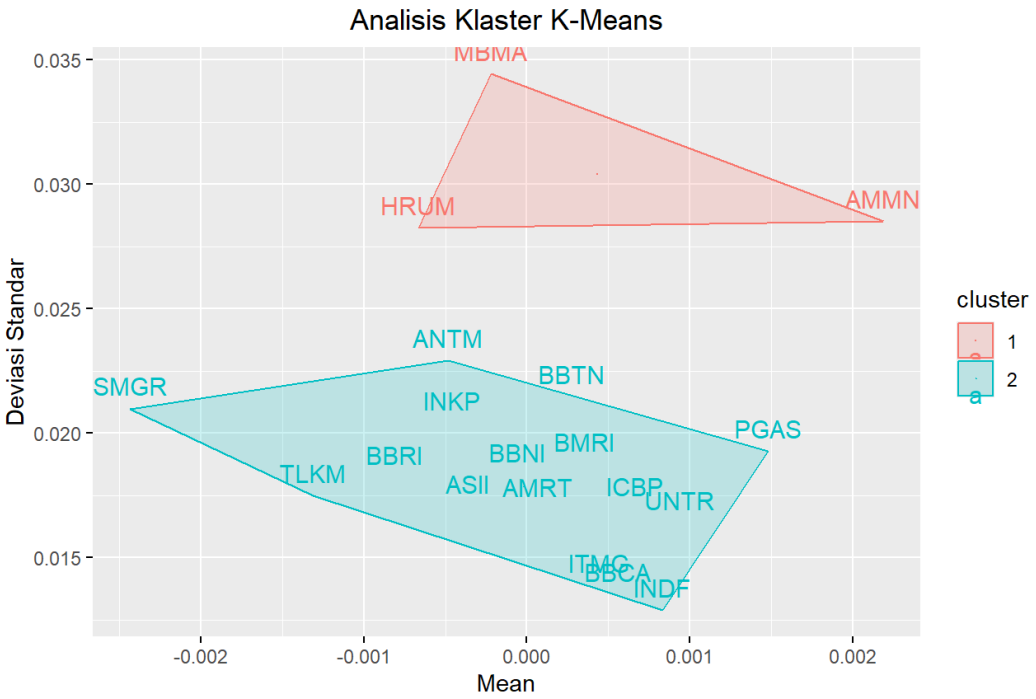
```
#Analisis Klaster K-Means
set.seed(20429)

km.final = kmeans(stock_stats[, 1:2], 2)
stock_stats$Klaster = km.final$cluster

mean(silhouette(km.final$cluster,
                dist(stock_stats[, 1:2]))[,3])

fviz_cluster(km.final, data = stock_stats[, 1:2],
             geom = 'text', stand = FALSE) +
  ggtitle('Analisis Klaster K-Means') +
  theme(plot.title = element_text(hjust = 0.5))
```

Luaran:



Lampiran 11. Pembobotan Portofolio *Minimum Variance*

Sintaksis:

```
#### Pembobotan portofolio minimum variance ####
returns = returns[c('AMMN', 'ANTM', 'BBTN', 'MBMA')]

#Vektor mean
mean_vector = list()
for (i in 1:4){
  mean_vector[i] = mean(returns[, i])
}

#Matriks kovariansi
cov_matrix = cov(returns)

#Invers matriks kovariansi
inv_cov_matrix = solve(cov_matrix)

#Pembilang
voo_4 = c(1, 1, 1, 1)
dim(voo_4) = c(4, 1)
pembilang = inv_cov_matrix %*% voo_4

#Penyebut
penyebut = t(voo_4) %*% inv_cov_matrix %*% voo_4
lambda = 1 / penyebut
lambda

#Bobot
w_min = matrix(pembilang %*% (1 / penyebut))
w_min

#Pemrograman kuadrat
```

```
qp.out = solve.QP(Dmat = cov_matrix, dvec = rep(0, 4),
                  Amat = cbind(rep(1, 4), diag(4)),
                  bvec = c(1, rep(0, 4)), meq = 1)
qp.out
```

Luaran:

```
> lambda
             [,1]
[1,] 0.0001978939

> w_min
           [,1]
[1,] 0.26729764
[2,] 0.31334935
[3,] 0.34468174
[4,] 0.07467127

> qp.out
$solution
[1] 0.26729764 0.31334935 0.34468174 0.07467127

$value
[1] 9.894696e-05

$unconstrained.solution
[1] 0 0 0 0

$iterations
[1] 2 0

$Lagrangian
[1] 0.0001978939 0.0000000000
[3] 0.0000000000 0.0000000000
```

```
[5] 0.0000000000

$iact
[1] 1
```

Lampiran 12. Aplikasi *Genetic Algorithm* untuk Menyelesaikan Fungsi Sphere

Sintaksis:

```
#GA untuk Fungsi Sphere
sphere = function(x){
  sum(x^2)
}

GA = ga(type = "real-valued",
        fitness = function(x) -sphere(x),
        lower = rep(-100, 30), upper = rep(100, 30),
        popSize = 100, pcrossover = 0.8,
        pmutation = 0.05,
        selection = "gareal_lrSelection",
        maxiter = 1000,
        elitism = 10, seed = 20429)
GA@solution
sphere(GA@solution)
```

Luaran:

```
> GA@solution
            x1        x2          x3          x4
[1,] 0.1214132 0.1133256 -0.09313949 -0.02602403
              x5         x6        x7        x8
[1,] -0.07227723 0.01455089 0.0206798 0.1020251
             x9         x10        x11         x12
[1,] 0.09103018 -0.04956427 -0.1292126 -0.03447824
           x13          x14         x15        x16
[1,] -0.095729 -0.009619393 -0.05007007 0.03640013
           x17       x18        x19        x20
[1,] 0.2044053 0.1053586 -0.1115318 -0.1096968
            x21        x22         x23         x24
[1,] -0.1253595 -0.1557265 -0.08741097 -0.01377968
```

```
             x25         x26         x27        x28
[1,] -0.09794862 0.05134507 0.05969794 0.2596163
             x29        x30
[1,] 0.03662251 0.1013489

> sphere(GA@solution)
[1] 0.3148834
```

Lampiran 13. Pembobotan Portofolio Menggunakan *Genetic Algorithm*

Sintaksis:

```
#### Pembobotan portofolio Genetic Algorithm ####
f0 = function(w){
  0.5 * (cov_matrix[1, 1] * w[1]^2 +
         cov_matrix[2, 2] * w[2]^2 +
         cov_matrix[3, 3] * w[3]^2 +
         cov_matrix[4, 4] * w[4]^2) +
    (cov_matrix[1, 2] * w[1] * w[2] +
     cov_matrix[1, 3] * w[1] * w[3] +
     cov_matrix[1, 4] * w[1] * w[4] +
     cov_matrix[2, 3] * w[2] * w[3] +
     cov_matrix[2, 4] * w[2] * w[4] +
     cov_matrix[3, 4] * w[3] * w[4])
}

lambda = 1 / penyebut
g = function(w){
  f0 = 0.5 * (cov_matrix[1, 1] * w[1]^2 +
         cov_matrix[2, 2] * w[2]^2 +
         cov_matrix[3, 3] * w[3]^2 +
         cov_matrix[4, 4] * w[4]^2) +
         (cov_matrix[1, 2] * w[1] * w[2] +
         cov_matrix[1, 3] * w[1] * w[3] +
         cov_matrix[1, 4] * w[1] * w[4] +
         cov_matrix[2, 3] * w[2] * w[3] +
         cov_matrix[2, 4] * w[2] * w[4] +
         cov_matrix[3, 4] * w[3] * w[4])
  f1 = w[1] + w[2] + w[3] + w[4] - 1

  f = f0 - lambda * f1
  return(f)
```

```
}

GA = ga(type = "real-valued",
        fitness = function(w) -g(w),
        lower = c(0, 0, 0, 0), upper = c(1, 1, 1, 1),
        popSize = 100, pcrossover = 0.8,
        pmutation = 0.05,
        selection = "gareal_lrSelection",
        maxiter = 1000, elitism = 10,
        names = c("w1", "w2", "w3", "w4"),
        seed = 20429)

w_GA = matrix(GA@solution)
w_GA

f0(w_GA)
```

Luaran:

```
> w_GA
           [,1]
[1,] 0.26734397
[2,] 0.31334285
[3,] 0.34464106
[4,] 0.07478484
> f0(w_GA)
[1] 9.896927e-05
```

Lampiran 14. Fungsi *Komodo Mlipir Algorithm*

Sintaksis:

```
#### Pembobotan portofolio Komodo Mlipir Algorithm ####
## Vektor kualitas
vektor_kualitas = function(K, func){
  f = list()

  for(n in 1:length(K)){
    f[[n]] = func(K[[n]])
  }

  return(f)
}

## Vektor penggerak komodo jantan
gerak_jantan = function(K, f){
  q = length(K)
  K_new = list()

  for(i in 1:q){
    sum_w = 0

    for(j in 1:q){
      if(j == i){
        next
      }

      set.seed(1000 + j + i)
      r1 = qnorm(runif(1, min = pnorm(0), max = pnorm(1)))

      if(f[[j]] < f[[i]]){
        w_ij = r1 * (K[[j]] - K[[i]])
```

```
      }
      else{
        w_ij = r1 * (K[[i]] - K[[j]])
      }

      sum_w = mapply("+", sum_w, w_ij)
    }

    K_new[[i]] = mapply("+", K[[i]], sum_w)
  }

  return(K_new)
}

gerak_betina = function(iter, K, f, m, k_jantan_best, func){
  K1 = list()
  K2 = list()
  K_new = list()
  alpha = 0.1
  b = 0
  a = 1

  kual_K = vektor_kualitas(K, func)

  #Bangkitkan satu bilangan random
  set.seed(2000 + iter)
  r = runif(1)

  if(r >= 0.5){
    #Berkawin
    for(l in 1:m){
      set.seed(3000 + l)
      r1 = qnorm(runif(1, min = pnorm(0), max = pnorm(1)))
```

```
    K1[[l]] = rl * k_jantan_best[[l]] +
      (1 - rl) * K[[1]][[l]]
    K2[[l]] = rl * K[[1]][[l]] +
      (1 - rl) * k_jantan_best[[l]]
  }

  kual_K1 = unlist(vektor_kualitas(list(unlist(K1)),
                                   func))
  kual_K2 = unlist(vektor_kualitas(list(unlist(K2)),
                                   func))


  if(kual_K1 >= kual_K2){
    if(kual_K1 >= kual_K){
      K_new = unlist(K1)
    }
    else{
      K_new = unlist(K)
    }
  }
  else{
    if(kual_K2 >= kual_K){
      K_new = unlist(K2)
    }
    else{
      K_new = unlist(K)
    }
  }
}

else{
  #Partenogenesis
```

```
    set.seed(4000 + iter)
    rl = rnorm(1)

    for(l in 1:m){
      K1[[l]] = K[[1]][[l]] +
        (2 * rl - 1) * alpha * abs(a - b)
    }

    kual_K1 = unlist(vektor_kualitas(list(unlist(K1)),
                                     func))

    if(kual_K1 >= kual_K){
      K_new = unlist(K1)
    }
    else{
      K_new = unlist(K)
    }
  }

  return(K_new)
}

##Vektor penggerak komodo muda
gerak_muda = function(iter, K_muda, f_muda, K_jantan, m, d){
  s = length(K_muda)
  q = length(K_jantan)
  K_new = list()

  for(i in 1:s){
    sum_w = 0

    for(j in 1:q){
      w_ij = list()
```

```
    for(l in 1:m){
      #Bangkitkan bilangan random
      set.seed(5000 + iter + i + j + l)
      r2 = qnorm(runif(1, min = pnorm(0), max = pnorm(1)))
      set.seed(6000 + iter + i + j + l)
      r1 = qnorm(runif(1, min = pnorm(0), max = pnorm(1)))

      set.seed(7000 + iter + i + j + l)
      l_select = sample(c(1:m), size = 1)

      if(l == l_select){
        if(r2 < d){
          w_ij[[l]] = r1 * (K_jantan[[j]][[l]] -
                              K_muda[[i]][[l]])
        }
        else{
          w_ij[[l]] = 0
        }
      }
      else{
        w_ij[[l]] = 0
      }
    }

    w_ij = unlist(w_ij)
    sum_w = mapply("+", sum_w, w_ij)
  }

  K_new[[i]] = mapply("+", K_muda[[i]], sum_w)
}

return(K_new)
```

```
}

##Selisih kualitas solusi optimum
df1 = function(f, iter){
  diff = abs(f[[iter - 2]] - f[[iter - 1]]) /
    f[[iter - 2]]
  return(diff)
}

df2 = function(f, iter){
  diff = abs(f[[iter - 1]] - f[[iter]]) /
    f[[iter - 1]]
  return(diff)
}

##KMA
KMA = function(N, m, func, p = 0.5, d = 0.5,
               a = 5, max_iter = 100,
               lower = 0, upper = 1, normalize = F){
  K = list()
  for(n in 1:N){
    set.seed(n)
    K[[n]] = runif(m)
  }

  K_best = list()
  f_best = list()
  iter = 1

  while(iter <= max_iter){
    ##Mengurutkan
    f = vektor_kualitas(K, func)
    f = sort(unlist(f), index.return = T)
```

```
K_sorted = list()
for(n in f$ix){
  K_sorted[[n]] = K[[f$ix[n]]]
}
K = K_sorted

#Definisi
q = floor((1 - p) * N)
s = N - q - 1

K_jantan = head(K, q)
f_jantan = head(f$x, q)
K_betina = K[q + 1]
f_betina = f$x[q + 1]
K_muda = tail(K, s)
f_muda = tail(f$x, s)

##Gerakan komodo jantan
K_jantan_baru = gerak_jantan(K_jantan, f_jantan)
f_jantan_baru = vektor_kualitas(K_jantan_baru, func)

#Komodo jantan terbaik
f_jantan_baru_sorted = sort(unlist(f_jantan_baru),
                            index.return = T)
k_jantan_best = K_jantan_baru[[f_jantan_baru_sorted$ix[1]]]

##Gerakan komodo betina
K_betina_baru = gerak_betina(iter, K_betina, f_betina,
                             m, k_jantan_best, func)
f_betina_baru = vektor_kualitas(list(K_betina_baru),
                                func)

##Gerakan komodo muda
```

```
K_muda_baru = gerak_muda(iter, K_muda, f_muda, \
                         K_jantan_baru, m, d)
f_muda_baru = vektor_kualitas(K_muda_baru, func)

##Gabungan
K_baru = c(K_jantan_baru, list(K_betina_baru),
           K_muda_baru)
f_baru = c(f_jantan_baru, f_betina_baru, f_muda_baru)
for(n in 1:N){
  if(normalize == T){
    K_baru[[n]] = K_baru[[n]] / sum(K_baru[[n]])
  }

  K_baru[[n]] = pmin(pmax(K_baru[[n]], lower), upper)

  if(normalize == T){
    K_baru[[n]] = K_baru[[n]] / sum(K_baru[[n]])
  }
}
f_baru = vektor_kualitas(K_baru, func)

##Mengurutkan
f_baru = sort(unlist(f_baru), index.return = T)
K_baru_sorted = list()
for(n in f_baru$ix){
  K_baru_sorted[[n]] = K_baru[[f_baru$ix[n]]]
}
K_baru = K_baru_sorted
f_baru = f_baru$x

K_best[[iter]] = list(K_baru[[1]])
f_best[[iter]] = f_baru[[1]]
```

```
  cat("Iterasi:␣", iter, "\nK␣best:\n",
      K_best[[iter]][[1]],
      "\nf_best:␣", f_best[[iter]][[1]],
      "\nPopulasi:␣", N, "\n==========\n")

  if(iter >= 3){
    df_1 = df1(f_best, iter)
    df_2 = df2(f_best, iter)

    if((df_1 > 0) && (df_2 > 0)){
      N = N - a
      if(N <= 0){
        break
      }
      else{
        K = head(K_baru, N)
        f = head(f_baru, N)
      }
    }
    else{
      for(n in (N + 1):(N + a)){
        set.seed(n)
        K_baru[[n]] = runif(m)
      }

      N = N + a
    }
  }

  K = K_baru
  iter = iter + 1
}
```

```
  cat("\nKomodo terbaik:\n", K_best[[iter]][[1]], "\n")
  cat("Kualitas: ", f_best[[iter]][[1]], "\n")
  cat("Iterasi: ", iter)

  #Grafik
  data_plot = data.frame(c(1:length(unlist(f_best))),
                         unlist(f_best))
  colnames(data_plot) = c('Iterasi', 'f_best')
  ggplot(data_plot, aes(x = Iterasi, y = f_best)) +
    geom_line(color = 'black', size = 1.5) +
    geom_point(shape = 19 , color = 'chartreuse3',
               size = 2.5) +
    ggtitle("Evolusi nilai optimum global") +
    xlab('Iterasi') + ylab('f_best')
}
```

Lampiran 15. Aplikasi *Komodo Mlipir Algorithm* untuk Menyelesaikan Fungsi Sphere

Sintaksis:

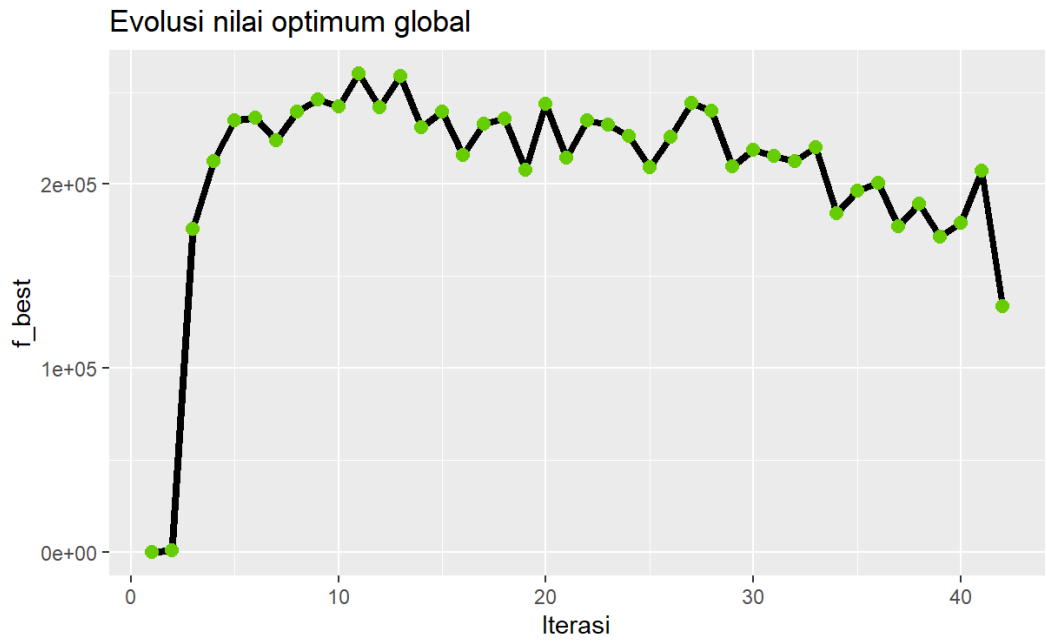
```
KMA(200, 30, func = sphere,
    lower = -100, upper = 100)
```

Luaran:

```
Iterasi:  1
K best:
 0.1075015 0.4877447 -0.8911181 -1.599486
 -0.1505463 0.3040065 -0.7689105 0.2373138
 -1.332546 -2.077841 0.5462063 -0.8351033
 2.865099 0.6534056 0.4767018 -0.3828899
 -0.8728847 -0.8638896 -0.2833719 -0.3499226
 0.3000031 1.263627 -1.105993 0.6055739
 -1.076051 -1.485405 0.2256191 1.666111
 0.2943031 -0.7564637
f_best:  32.30061
Populasi:  200
==========
...
==========

Komodo terbaik:
 -60.81865 -100 100 -100
 -100 62.10844 31.41833 37.04374
 25.69892 31.41833 -72.91459 68.82071
 -77.09571 100 16.88959 -100
 -100 -31.41833 -54.7052 27.10437
 -41.81451 29.7871 23.12563 16.88959
 4.340415 -100 -100 -56.00618
 65.88495 16.88959
Kualitas:  133796.9
```

```
Iterasi:  42
```


Evolusi nilai optimum global
f_best
2e+05
1e+05
0e+00
0
10
20
30
40
Iterasi

Lampiran 16. Pembobotan Portofolio Menggunakan *Komodo Mlipir Algorithm*

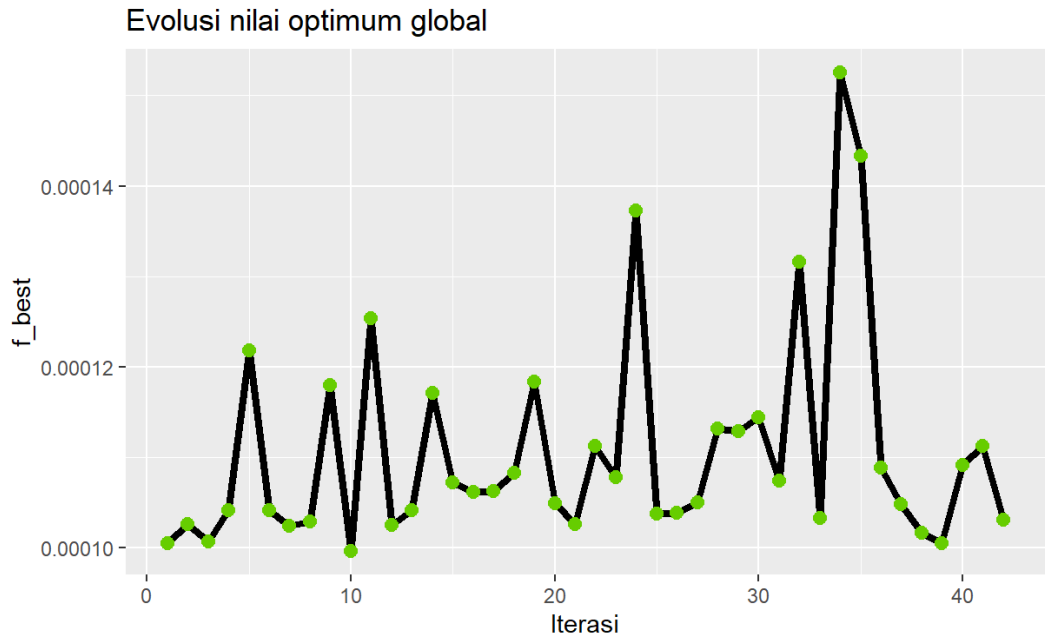
Sintaksis:

```
KMA(200, 4, func = g, normalize = T)
```

Luaran:

```
Iterasi:  1
K best:
 0.3021235 0.3478262 0.2838541 0.06619618
f_best:  0.0001004718
Populasi:  200
==========
Iterasi:  2
K best:
 0.2481816 0.3312667 0.4205517 0
f_best:  0.0001026208
Populasi:  200
==========
...
==========

Komodo terbaik:
 0.3122141 0.2713546 0.4036373 0.01279399
Kualitas:  0.0001031325
Iterasi:  42
```



Lampiran 17. Pembobotan Portofolio Menggunakan *Particle Swarm Optimization*

Sintaksis:

```
psoptim(par = rep(NA, 4), fn = g,
        lower = rep(0, 4), upper = rep(1, 4))
```

Luaran:

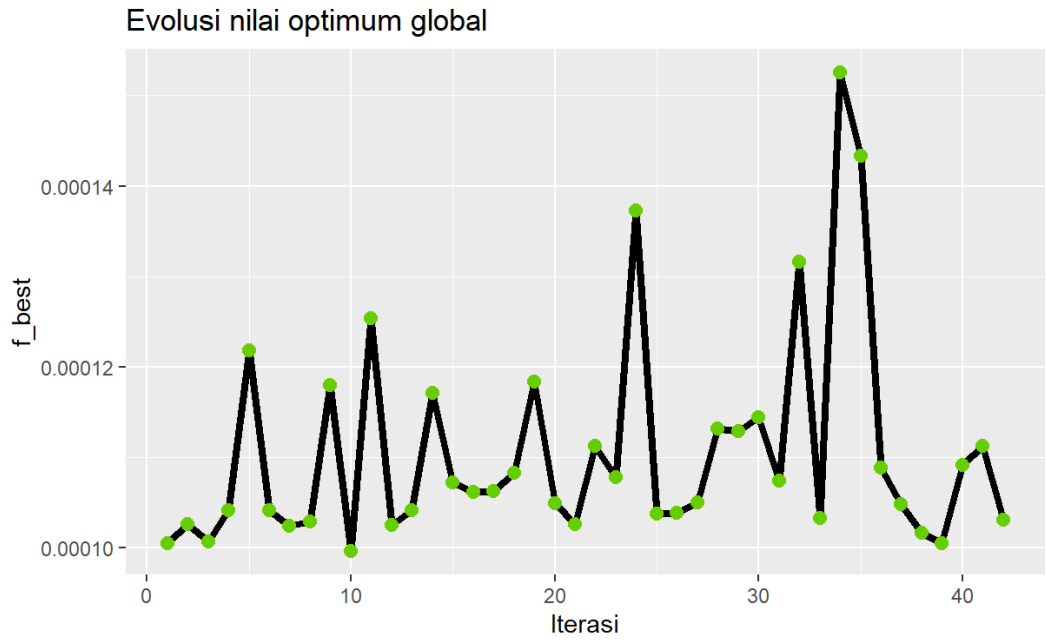
```
$par
[1] 0.26729762 0.31334934 0.34468171 0.07467127

$value
[1] 9.894696e-05

$counts
 function iteration  restarts
    14000      1000         0

$convergence
[1] 2
```

```
$message
[1] "Maximal number of iterations reached"
```



Lampiran 18. Data Riwayat Harga IHSG

Sintaksis:

```
#Data IHSG
IHSG = read.xlsx('Data IHSG.xlsx')
IHSG = IHSG[, -1]
```

Luaran:

Tanggal	Harga
01-12-2023	7.059,91
04-12-2023	7.093,60
05-12-2023	7.100,85
06-12-2023	7.087,40
07-12-2023	7.134,62
⋮	⋮
22-11-2024	7.195,56
25-11-2024	7.314,11
26-11-2024	7.245,89
28-11-2024	7.200,16
29-11-2024	7.114,27

Lampiran 19. Komputasi *Return* IHSG

Sintaksis:

```
#Return IHSG
late_IHSG = IHSG[-1]
return_IHSG = (late_IHSG - IHSG) / IHSG
return_IHSG = return_IHSG[-length(return_IHSG)]
```

Luaran:

Harga
0,00477202
0,00102205
-0,0018941
0,00666253
0,00350124
⋮
-0,00549
0,00765309
0,01647544
-0,0093272
-0,0063112

Lampiran 20. Komputasi Portofolio Saham Relatif Terhadap Portofolio Pasar

Sintaksis:

```
#Beta saham terhadap pasar
BM = apply(returns, 2, function(saham){
  cov(saham, return_IHSG) / var(return_IHSG)
})
BM = matrix(BM)
BM
```

Luaran:

```
> BM
          [,1]
[1,] 0.5538391
[2,] 0.7996983
[3,] 1.3914885
[4,] 1.1772685
```

Lampiran 21. Komputasi Beta Portofolio

Sintaksis:

```
w_KMA = matrix(c(0.3122141, 0.2713546, 0.4036373, 0.01279399))
w_PSO = matrix(c(0.26729762, 0.31334934, 0.34468171, 0.07467127))

#Beta portofolio
B_MV = t(w_min) %*% BM
B_MV

B_GA = t(w_GA) %*% BM
B_GA

B_KMA = t(w_KMA) %*% BM
B_KMA

B_PSO = t(w_PSO) %*% BM
B_PSO
```

Luaran:

```
> B_MV
          [,1]
[1,] 0.9661536

> B_GA
          [,1]
[1,] 0.9662512

> B_KMA
         [,1]
[1,] 0.9666368

> B_PSO
          [,1]
```

```
[1,] 0.9661536
```

Lampiran 22. Komputasi *Sharpe Ratio*

Sintaksis:

```
#Sharpe ratio
sharpe_ratio = function(w, mean_vec, cov_mat){
  Mean = t(w) %*% unlist(mean_vec)
  Var = t(w) %*% cov_mat %*% w

  Mean = Mean * 237
  SD = sqrt(Var) * sqrt(237)
  r_f = 0.06

  SR = (Mean - r_f) / SD
  return(SR)
}

sharpe_ratio(w_min, mean_vector, cov_matrix)
sharpe_ratio(w_GA, mean_vector, cov_matrix)
sharpe_ratio(w_KMA, mean_vector, cov_matrix)
sharpe_ratio(w_PSO, mean_vector, cov_matrix)
```

Luaran:

```
> sharpe_ratio(w_min, mean_vector, cov_matrix)
          [,1]
[1,] 0.2830541
> sharpe_ratio(w_GA, mean_vector, cov_matrix)
          [,1]
[1,] 0.2830966
> sharpe_ratio(w_KMA, mean_vector, cov_matrix)
          [,1]
[1,] 0.4364185
> sharpe_ratio(w_PSO, mean_vector, cov_matrix)
          [,1]
[1,] 0.2830541
```

Lampiran 23. Komputasi *Treynor Ratio*

Sintaksis:

```
#Treynor ratio
treynor_ratio = function(w, mean_vec){
  Mean = t(w) %*% unlist(mean_vec)
  Mean = Mean * 237

  Beta = t(w) %*% BM
  r_f = 0.06

  TR = (Mean - r_f) / Beta
  return(TR)
}

treynor_ratio(w_min, mean_vector)
treynor_ratio(w_GA, mean_vector)
treynor_ratio(w_KMA, mean_vector)
treynor_ratio(w_PSO, mean_vector)
```

Luaran:

```
> treynor_ratio(w_min, mean_vector)
           [,1]
[1,] 0.06344737
> treynor_ratio(w_GA, mean_vector)
           [,1]
[1,] 0.06345765
> treynor_ratio(w_KMA, mean_vector)
           [,1]
[1,] 0.0998221
> treynor_ratio(w_PSO, mean_vector)
           [,1]
[1,] 0.06344737
```

Lampiran 24. Komputasi *Jensen's Alpha*

Sintaksis:

```
#Ekspektasi return pasar
mean_M = mean(return_IHSG)
mean_M

#Jensen's alpha
jensen_alpha = function(w, mean_vec){
  Mean = t(w) %*% unlist(mean_vec)
  Mean = Mean * 237
  Mean_M = mean_M * 237

  Beta = t(w) %*% BM
  r_f = 0.06

  JA = Mean - (0.06 + Beta * (mean_M - r_f))
  return(JA)
}

jensen_alpha(w_min, mean_vector)
jensen_alpha(w_GA, mean_vector)
jensen_alpha(w_KMA, mean_vector)
jensen_alpha(w_PSO, mean_vector)
```

Luaran:

```
> mean_M
[1] 6.353708e-05

> jensen_alpha(w_min, mean_vector)
          [,1]
[1,] 0.1192077
> jensen_alpha(w_GA, mean_vector)
          [,1]
```

```
[1,] 0.1192297
> jensen_alpha(w_KMA, mean_vector)
          [,1]
[1,] 0.1544285
> jensen_alpha(w_PSO, mean_vector)
          [,1]
[1,] 0.1192077
```