PROPOSAL TUGAS AKHIR - SM234801

OPTIMASI PORTOFOLIO UTANG VALAS PEMERINTAH INDONESIA MENGGUNAKAN METODE CVAR BERDASARKAN HASIL PERAMALAN MODEL ARIMA-GARCH

BAGUS RICO PAMBUDI

NRP 5002221144

Dosen Pembimbing

Sena Safarina, S.Si., M.Sc., D.Sc.

NIP 1990202012052

Dra. Laksmi Prita Wardhani, M.Si

NIP 19611208 198803 2 001

Program Studi Sarjana

Departemen Matematika

Fakultas Sains dan Analitika Data

Institut Teknologi Sepuluh Nopember

Surabaya

2025

FINAL PROJECT PROPOSAL - SM234801

OPTIMIZATION OF INDONESIA'S SOVEREIGN FOREIGN CURRENCY DEBT PORTFOLIO USING THE CVAR METHOD BASED ON ARIMA-GARCH FORECASTING RESULTS

BAGUS RICO PAMBUDI

NRP 5002221144

Supervisors

Sena Safarina, S.Si., M.Sc., D.Sc.

NIP 1990202012052

Dra. Laksmi Prita Wardhani, M.Si

NIP 19611208 198803 2 001

Bachelor Program

Departement of Mathematics

Faculty of Scientics

Institut Teknologi Sepuluh Nopember

Surabaya

2025

LEMBAR PENGESAHAN

Optimasi Portofolio Utang Valas Pemerintah Indonesia Menggunakan Metode CVaR Berdasarkan Hasil Peramalan Model ARIMA-GARCH

Optimization of Indonesia's Sovereign Foreign Currency Debt Portfolio Using the CVaR Method Based on ARIMA-GARCH Forecasting Results

PROPOSAL TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat
memperoleh gelar Sarjana Matematika pada
Program Studi S-1 Matematika
Departemen Matematika
Fakultas Sains dan Analitika Data
Institut Teknologi Sepuluh Nopember

Oleh: **BAGUS RICO PAMBUDI**
NRP. 5002221144

Menyetujui,

Dosen Pembimbing I	Dosen Pembimbing II
Sena Safarina, S.Si., M.Sc., D.Sc.	Dra. Laksmi Prita Wardhani, M.Si
NIP. 1990202012052	NIP. 19611208 198803 2 001

Mengetahui,
Kepala Program Studi Sarjana
Departemen Matematika FSAD-ITS

Dr. Tahiyatul Asfihani, S.Si, M.Si
NIP. 19870728 201404 2 001

Surabaya
Desember, 2025

ABSTRAK

Optimasi Portofolio Utang Valas Pemerintah Indonesia Menggunakan Metode CVaR Berdasarkan Hasil Peramalan Model ARIMA-GARCH

Nama Mahasiswa / NRP	:	Bagus Rico Pambudi / 5002221144
Departemen	:	Matematika FSAD -ITS
Dosen Pembimbing	:	1. Sena Safarina, S.Si., M.Sc., D.Sc. 2. Dra. Laksmi Prita Wardhani, M.Si

Abstrak

Utang pemerintah berdenominasi valuta asing memiliki peranan penting dalam pembiayaan anggaran negara, namun risikonya terhadap volatilitas nilai tukar dan suku bunga global menuntut strategi pengelolaan risiko yang presisi. Penelitian ini diawali dengan penerapan model hibrida ARIMA-GARCH untuk meramalkan pergerakan dan volatilitas nilai tukar serta suku bunga guna menangkap karakteristik heteroskedastisitas data keuangan. Hasil peramalan tersebut selanjutnya digabungkan sebagai input dinamis dalam formulasi model optimasi portofolio utang valas pemerintah Indonesia (pada mata uang USD, EUR, dan JPY) menggunakan pendekatan *Mean-Variance Optimization* (MVO) dan *Conditional Value-at-Risk* (CVaR). Kinerja kedua metode optimasi dianalisis hasil optimasinya berdasarkan skenario penggunaan data historis dan data hasil peramalan untuk menentukan komposisi bobot utang yang paling efisien dari segi biaya dan mitigasi risiko. Melalui penelitian ini, model CVaR diharapkan mampu menghasilkan struktur utang yang lebih tangguh terhadap risiko ekstrem (*tail risk*) dan memberikan efisiensi biaya yang lebih baik dibandingkan model MVO di tengah ketidakpastian ekonomi global.

Kata kunci: *ARIMA-GARCH, CVaR, MVO, optimasi portofolio, utang valas.*

ABSTRACT

Optimization of Indonesia's Sovereign Foreign Currency Debt Portfolio Using the CVaR Method Based on ARIMA-GARCH Forecasting Results

Student Name / NRP	:	Bagus Rico Pambudi / 5002221144
Departement	:	Mathematics SCIENTICS - ITS
Advisor	:	1. Sena Safarina, S.Si., M.Sc., D.Sc. 2. Dra. Laksmi Prita Wardhani, M.Si

Abstract

Foreign currency-denominated government debt plays a pivotal role in state budget financing; however, its exposure to global exchange rate and interest rate volatility demands precise risk management strategies. This study commences with the application of a hybrid ARIMA-GARCH model to forecast the movements and volatility of exchange rates and interest rates, aiming to capture the heteroscedastic characteristics of financial data. These forecasts are subsequently integrated as dynamic inputs into the formulation of the Indonesian government's foreign debt portfolio optimization model (covering USD, EUR, and JPY) using *Mean-Variance Optimization* (MVO) and *Conditional Value-at-Risk* (CVaR) approaches. The optimization results of both methods are analyzed based on scenarios using historical data and forecasted data to determine the most efficient debt weight composition in terms of cost and risk mitigation. Through this study, the CVaR model is expected to yield a debt structure that is more resilient to tail risk and provides superior cost efficiency compared to the MVO model amidst global economic uncertainty.

Keywords: *ARIMA-GARCH, CVaR, foreign currency debt, MVO, portfolio optimization.*

DAFTAR ISI

LEMBAR PENGESAHAN i

ABSTRAK ii

ABSTRACT iii

DAFTAR ISI iv

DAFTAR GAMBAR vi

DAFTAR TABEL vii

DAFTAR SIMBOL viii

BAB I PENDAHULUAN 1
- 1.1 Latar Belakang . . . 1
- 1.2 Rumusan Masalah . . . 3
- 1.3 Batasan Masalah . . . 4
- 1.4 Tujuan Penelitian . . . 4
- 1.5 Manfaat Penelitian . . . 4

BAB II TINJAUAN PUSTAKA 5
- 2.1 Hasil Penelitian Terdahulu . . . 5
- 2.2 Utang Valas . . . 7
- 2.3 *Autoregressive Integrated Moving Average* (ARIMA) . . . 8
- 2.4 Identifikasi Model ARIMA . . . 9
  - 2.4.1 Stasioneritas Data . . . 9
  - 2.4.2 Plot ACF & PACF . . . 11
  - 2.4.3 Identifikasi Orde Model ARIMA . . . 12
- 2.5 Estimasi Parameter . . . 12
- 2.6 Uji Diagnostik Model . . . 13
  - 2.6.1 Uji Normalitas Residual . . . 14
  - 2.6.2 Uji Residual *White Noise* . . . 14
- 2.7 Uji Heteroskedastisitas . . . 15
- 2.8 *Generalized Autoregressive Conditional Heteroscedasticity* (GARCH) . . . 16
- 2.9 *Akaike Information Criterion* (AIC) . . . 17
- 2.10 *Root Mean Square Error* (RMSE) . . . 17
- 2.11 *Mean-Variance Optimization* (MVO) . . . 18
- 2.12 Ukuran Risiko . . . 19
- 2.13 *Conditional Value-at-Risk* (CVaR) . . . 21
- 2.14 *Quadratic Programming* . . . 23

BAB III METODOLOGI 24
- 3.1 Sumber Data . . . 24
- 3.2 Variabel Penelitian . . . 24
- 3.3 Tahapan Penelitian . . . 25
  - 3.3.1 Studi Literatur . . . 25

3.3.2 Pembentukan Model Biaya Utang 25
3.3.3 Preprocessing Data 25
3.3.4 Pembentukan Model ARIMA-GARCH 25
3.3.5 Input Optimasi 26
3.3.6 Proses Optimasi 27
3.3.7 Portofolio Optimal 27
3.3.8 Analisis Hasil dan Pembahasan 27
3.3.9 Penyusunan Tugas Akhir 28
3.4 Diagram Alir Penelitian 28
3.5 Jadwal Kegiatan 29
DAFTAR PUSTAKA 30

DAFTAR GAMBAR

Gambar 3.1 Diagram alir penelitian 28

DAFTAR TABEL

Tabel 2.1 Pola Teoretis ACF dan PACF 12

Tabel 3.1 Variabel Penelitian 24
Tabel 3.2 Jadwal kegiatan Tugas Akhir 29

DAFTAR SIMBOL

Y	:	Nilai asli deret waktu sebelum transformasi
Y_t	:	Nilai deret waktu pada periode ke-t
$Y^{(\lambda)}$	:	Nilai deret waktu setelah transformasi Box–Cox
$\nabla^d Y_t$	:	Hasil *differencing* orde-d
B	:	Operator *backshift* ($BY_t = Y_{t-1}$)
$\Phi_p(B)$	:	Polinomial AR (operator)
$\Theta_q(B)$	:	Polinomial MA (operator)
p, d, q	:	Orde ARIMA (AR, differencing, MA)
ε_t	:	Residual (galat) pada waktu ke-t
$\tilde{\varepsilon}_t$	:	Residual terstandarisasi
σ_t^2	:	Varians bersyarat pada waktu ke-t
ϕ_i, θ_j	:	Parameter AR/MA
$\alpha_0, \alpha_i, \beta_j$	:	Parameter GARCH
P, Q	:	Orde GARCH (ARCH, GARCH)
$\mathbf{x}$	:	Vektor bobot portofolio
$\boldsymbol{\mu}$	:	Vektor *Expected return*
$\boldsymbol{\Sigma}$	:	Matriks varians-kovarians
$f(\mathbf{x}, \mathbf{y})$	:	Fungsi kerugian portofolio
$\Psi(\mathbf{x}, \alpha)$	:	Probabilitas kumulatif kerugian
$\alpha_\beta(\mathbf{x})$	:	β-Value-at-Risk (VaR)
$\phi_\beta(\mathbf{x})$	:	β-Conditional Value-at-Risk (CVaR)

BAB I
PENDAHULUAN

1.1 Latar Belakang

Indonesia merupakan kekuatan ekonomi di kawasan pasar berkembang, sebagaimana ditunjukkan oleh World Bank (2025) dalam laporannya mengenai prospek ekonomi Indonesia.Hal tersebut juga diperkuat oleh data Badan Pusat Statistik (2025) yang mencatat pertumbuhan ekonomi sebesar 5,04% *year-on-year* pada Triwulan III-2025, dengan nilai Produk Domestik Bruto (PDB) atas dasar harga berlaku mencapai Rp6.060,0 triliun, meningkat dari Rp5.947,0 triliun pada triwulan sebelumnya. Meskipun fundamental perekonomian menunjukkan kinerja yang baik, pemerintah tetap menghadapi tantangan yang berat dalam mengelola Anggaran Pendapatan dan Belanja Negara (APBN). Kebutuhan belanja yang terus meningkat untuk mendukung pembangunan nasional sering kali melampaui kapasitas penerimaan negara sehingga menciptakan defisit anggaran. Tekanan pada neraca pembayaran akibat pertumbuhan impor yang tinggi semakin menambah beban tersebut dan menuntut pengelolaan fiskal yang baik (Badan Pusat Statistik, 2025). Fiskal adalah segala aspek yang berkaitan dengan urusan keuangan negara, khususnya yang mencakup pengelolaan pendapatan melalui perpajakan dan alokasi belanja pemerintah dalam kerangka Anggaran Pendapatan dan Belanja Negara (APBN) untuk memengaruhi stabilitas ekonomi makro. Merespon situasi tersebut, sejumlah kajian dari *International Monetary Fund* (2025) dan Bank Indonesia (2025) menekankan pentingnya menjaga keseimbangan ekonomi Indonesia terhadap gejolak eksternal. Langkah yang diambil oleh pemerintah Indonesia adalah mempertimbangkan instrumen utang untuk menutup defisit tersebut, namun penggunaannya harus tetap dikelola dengan strategi yang tepat agar tidak membebani keuangan negara.

Utang pemerintah memegang peranan yang sangat penting dalam pendanaan APBN, sebagaimanaditunjukkan oleh kontribusinya yang pernah mencapai 100,1% selama periode 2004 hingga 2011 (Nasir, 2013). Seiring berjalannya waktu, komposisi utang pemerintah mengalami perubahan strategi yang signifikan, terutama dalam porsi utang berdenominasi valuta asing atau valas (CNBC Indonesia, 2025). Utang valuta asing (valas) merupakan utang yang dicatat dan dibayarkan dalam mata uang selain rupiah, dan dalam beberapa tahun terakhir tren penurunannya terlihat dari porsinya yang turun dari 33,5% pada 2020 menjadi 28,7% pada 2024 dan 28,3% pada 2025. Sebaliknya, utang pemerintah saat ini didominasi oleh denominasi rupiah yang porsinya meningkat dari 71,39% pada tahun 2024 menjadi 71,73% pada tahun 2025. Meskipun demikian, pemerintah menilai struktur utang valas saat ini tetap stabil karena tingkat keterpaparannya terhadap perubahan kurs hanya berada di kisaran 28%. Utang valas ini tetap dipertahankan karena perannya sebagai pelengkap ketika kapasitas pendanaan domestik belum sepenuhnya mencukupi kebutuhan pembiayaan negara. Pengelolaan komposisi antara utang domestik dan valas ini menjadi kunci utama dalam menjaga keberlanjutan fiskal jangka panjang.

Menurut Avdjiev et al. (2021), utang valas memiliki peran penting bagi negara berkembang karena dapat memenuhi kebutuhan pendanaan yang tidak sepenuhnya dapat dipenuhi oleh pasar domestik serta memberikan akses terhadap sumber dana yang lebih beragam dan berbiaya relatif lebih murah dibandingkan dengan utang berdenominasi

rupiah. Selain itu, utang valas memungkinkan pemerintah memperoleh fleksibilitas dalam mengatur pembiayaan dan dapat menjaga kestabilan pasar lokal ketika kapasitas pendanaan lokal masih terbatas. Namun, komposisi utang valas yang tidak optimal menghadirkan risiko pasar yang signifikan bagi ketahanan fiskal negara. Volatilitas suku bunga global yang berubah setiap hari berpotensi memengaruhi biaya utang pemerintah secara langsung dan tidak terduga. Risiko lainnya muncul dari fluktuasi nilai tukar mata uang asing yang dapat meningkatkan beban pembayaran pokok dan bunga ketika terjadi pelemahan nilai tukar rupiah (Direktorat Jenderal Pengelolaan Pembiayaan dan Risiko, 2025a). Oleh karena itu, pemerintah perlu melakukan optimasi portofolio instrumen utang untuk menyeimbangkan biaya pembayaran dan risiko (Zenios et al., 2019).

Ditengah dinamika ekonomi global yang penuh ketidakpastian, pemahaman mengenai proyeksi kondisi pasar ke depan menjadi hal yang penting dalam merumuskan kebijakan pembiayaan yang berkelanjutan. Dalam upaya menghasilkan proyeksi yang akurat, tantangannya terletak pada penentuan metodologi yang paling cocok digunakan. Literatur peramalan data keuangan masih memperdebatkan efektivitas antara metode statistika klasik dan metode komputasi kompleks seperti kecerdasan buatan. Sk (2015) menemukan bahwa model linier sederhana seperti ARIMA mampu menghasilkan akurasi yang lebih baik dibandingkan *Neural Network* pada data dengan pola linear. Namun, pendekatan linear klasik ini memiliki keterbatasan mendasar karena mengasumsikan varians yang konstan, sehingga sering kali gagal menangkap fenomena *volatility clustering* (Hassani et al., 2020). Untuk mengatasi kelemahan tersebut, Kim et al. (2021) membuktikan bahwa pendekatan keluarga GARCH sangat efektif dalam menangkap volatilitas dinamis dan efek asimetris pada data pasar obligasi serta suku bunga. Efektivitas ini diperkuat oleh temuan Zhu (2025) pada data nilai tukar, yang menunjukkan bahwa penggabungan ARIMA untuk menangkap tren rata-rata dan GARCH untuk memodelkan fluktuasi risiko menghasilkan estimasi yang jauh lebih akurat. Penggabungan kedua model ini terbukti mampu mengatasi masalah heteroskedastisitas yang sering diabaikan oleh model peramalan tunggal. Oleh karena itu, penelitian ini menggunakan metode gabungan *ARIMA-GARCH* untuk memodelkan volatilitas suku bunga dan nilai tukar secara akurat.

Akurasi hasil peramalan volatilitas yang diperoleh menjadi landasan dalam menentukan alokasi aset utang yang optimal. Model klasik *Mean-Variance* (MVO) dari Markowitz sering digunakan sebagai acuan dasar dalam pembentukan portofolio investasi maupun utang. Namun demikian, model MVO memiliki kelemahan fundamental karena mengandalkan variansi sebagai ukuran risiko dan mengasumsikan distribusi *return* bersifat normal. Padahal, Alexander & Baptista (2004) menunjukkan bahwa data pasar keuangan sering kali memiliki probabilitas kejadian ekstrem yang jauh lebih tinggi dibandingkan asumsi distribusi normal. Sebagai alternatif yang lebih tangguh terhadap karakteristik data tersebut, penelitian ini menggunakan metode *Conditional Value-at-Risk* (CVaR) sebagai fungsi tujuan optimasi. Berbeda dengan MVO dan VaR, CVaR mampu mengukur rata-rata kerugian di luar tingkat kepercayaan tertentu secara koheren. Kemampuan ini membuat CVaR lebih efektif dalam menangkap risiko kejadian ekstrem dan menghasilkan portofolio yang tangguh terhadap guncangan ekstrem (Quaranta & Zaffaroni, 2008). Penggunaan CVaR dalam optimasi utang pemerintah telah dilakukan pada penelitian sebelumnya yang membuktikan efektivitas metode ini dalam meningkatkan kinerja portofolio fiskal. Yavuz & Gölbaşı (2019) membuktikan hal ini pada kasus utang negara Turki, di mana strategi optimasi stokastik mampu menurunkan risiko sebesar 13% dan biaya 9% dibandingkan portofolio berbobot merata. Temuan serupa divalidasi oleh Yang et al. (2022) pada

konteks pemerintah daerah di Tiongkok, yang menunjukkan secara grafis bahwa seluruh portofolio aktual yang diterbitkan pemerintah berada di posisi inefisien (di atas *efficient frontier*). Kedua hasil penelitian tersebut menyimpulkan bahwa metode optimasi CVaR dapat membuka ruang efisiensi fiskal yang signifikan.

Penelitian ini menawarkan kebaruan dari penelitian-penelitian sebelumnya sebagai berikut. Pertama, berbeda dengan Sk (2015) dan Zhu (2025) yang tujuan akhirnya mendapatkan hasil peramalan nilai tukar mata uang, penelitian ini tidak berhenti pada hasil peramalan nilai tukar mata uang saja, melainkan memanfaatkannya sebagai *input* untuk mendapatkan portofolio utang optimal. Kedua, berbeda dengan Hassani et al. (2020) dan Kim et al. (2021) yang berfokus pada pemodelan volatilitas instrumen keuangan varian model GARCH, penelitian ini berfokus untuk mendapatkan hasil peramalan suku bunga utang menggunakan model ARIMA-GARCH. Ketiga, berbeda dengan Yavuz & Gölbaşı (2019) dan Yang et al. (2022) yang metode simulasi stokastik dan model suku bunga (seperti CIR) untuk membangkitkan skenario risiko secara luas, penelitian ini menggunakan model ARIMA-GARCH untuk mendapatkan hasil permalannya. Kebaruan utama penelitian ini terletak pada penggabungan metode peramalan ARIMA-GARCH dengan optimasi portofolio berbasis CVaR. Penelitian ini bertujuan untuk membandingkan kinerja optimasi portofolio antara metode *Mean-Variance Optimization* (MVO) dan *Conditional Value-at-Risk* (CVaR), baik menggunakan data historis maupun data hasil peramalan model ARIMA-GARCH. Penelitian ini diharapkan mampu untuk memberikan rekomendasi strategi pengelolaan komposisi utang valas yang optimal dan tangguh dalam menghadapi ketidakpastian pasar global, serta menyediakan acuan berbasis data untuk mendukung perencanaan fiskal dan manajemen risiko utang di masa depan.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, permasalahan yang akan dibahas dalam penelitian ini dirumuskan sebagai berikut:

1. Bagaimana hasil peramalan tingkat suku bunga dan nilai tukar mata uang asing menggunakan model gabungan ARIMA-GARCH?

2. Bagaimana pembentukan model optimasi untuk utang valas?

3. Bagaimana implementasi CVaR dalam optimasi portofolio utang valas pemerintah Indonesia?

4. Bagaimana hasil komposisi portofolio utang valas pemerintah Indonesia yang optimal menggunakan metode optimisasi MVO dan ukuran risiko CVaR, baik berdasarkan data historis maupun hasil peramalan?

5. Bagaimana perbandingan kinerja portofolio yang dihasilkan oleh model optimisasi MVO dengan ukuran risiko CVaR dalam hal efisiensi biaya dan mitigasi risiko, baik berdasarkan data historis maupun hasil peramalan?

1.3 Batasan Masalah

Agar penelitian ini lebih terarah dan fokus pada permasalahan yang telah dirumuskan, penulis menetapkan batasan-batasan masalah sebagai berikut:

1. Data yang digunakan adalah data sekunder harian pada periode 03 Juli 2017 hingga 24 November 2025, yang mencakup tingkat suku bunga utang untuk mata uang USD (jangka waktu 5, 10, 15 tahun), EUR (jangka waktu 7, 10 tahun), dan JPY (jangka waktu 5, 10 tahun), serta nilai tukar mata uang USD ke EUR dan USD ke JPY.

2. Objek analisis dibatasi pada portofolio utang pemerintah yang berdenominasi mata uang asing (Valas), yaitu Dolar Amerika Serikat (USD), Euro (EUR), dan Yen Jepang (JPY).

3. Peramalan dilakukan dalam rata-rata bulanan untuk proyeksi jangka menengah.

4. Faktor-faktor eksternal lain yang dapat memengaruhi tingkat suku bunga dan nilai tukar diabaikan.

1.4 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah ditetapkan, tujuan dari penelitian ini adalah:

1. Menghasilkan peramalan tingkat suku bunga dan nilai tukar mata uang asing menggunakan model gabungan ARIMA-GARCH.

2. Memformulasikan bentuk model optimasi untuk utang valas pemerintah Indonesia.

3. Mendapatkan hasil implementasi CVaR dalam optimasi portofolio utang valas pemerintah Indonesia.

4. Menentukan komposisi portofolio utang valas pemerintah Indonesia yang optimal menggunakan metode optimisasi MVO dan ukuran risiko CVaR, baik berdasarkan data historis maupun hasil peramalan.

5. Memperoleh hasil analisis perbandingan kinerja portofolio yang dihasilkan oleh model optimisasi MVO dengan ukuran risiko CVaR dalam hal efisiensi biaya dan mitigasi risiko baik berdasarkan data historis maupun hasil peramalan.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat bagi pengelola utang negara sebagai berikut:

1. Memberikan rekomendasi strategi pengelolaan komposisi utang valas pemerintah yang optimal dan tangguh dalam menghadapai ketidakpastian pasar global.

2. Menyediakan hasil peramalan tingkat suku bunga dan nilai tukar menggunakan model gabungan ARIMA-GARCH sebagai acuan berbasis data untuk mendukung perencanaan fiskal dan manajemen risiko utang di masa depan.

BAB II
TINJAUAN PUSTAKA

2.1 Hasil Penelitian Terdahulu

Perdebatan mengenai efektivitas antara metode statistik klasik dan metode komputasi modern masih menjadi topik hangat dalam literatur peramalan keuangan. Meskipun tren penggunaan metode komputasi kompleks seperti kecerdasan buatan (*Artificial Intelligence*) semakin meningkat, metode peramalan klasik seperti ARIMA terbukti tetap memiliki relevansi yang tinggi tergantung pada karakteristik data. Hal tersebut dibuktikan oleh penelitian Sk (2015) yang bertujuan untuk mengidentifikasi model peramalan nilai tukar yang paling akurat. Penelitian tersebut menggunakan nilai tukar Rupee India terhadap Dolar AS (USD), Poundsterling Inggris (GBP), Euro (EUR), dan Yen Jepang (JPY) sebagai objek penelitian. Penelitian tersebut berfokus pada perbandingan kinerja model linier ARIMA dengan model nonlinier seperti *Neural Network* dan *Fuzzy Neuron* (ANFIS). Berbeda dengan asumsi umum bahwa model yang lebih kompleks selalu lebih akurat, penelitian tersebut justru menemukan bahwa model ARIMA menghasilkan kinerja peramalan terbaik berdasarkan kriteria Akaike Information Criterion (AIC) dan *Bayesian Information Criterion* (BIC). Temuan tersebut menegaskan pentingnya prinsip parsimoni, dimana pada kondisi tertentu model linier ARIMA sederhana dapat memberikan kinerja yang lebih baik dibandingkan dengan model nonlinier yang lebih kompleks, seperti *Neural Network* dan *Fuzzy Neural Network*. Hal tersebut terjadi karena data yang digunakan bersifat linear, sehingga penggunaan Machine Learning menjadi berlebihan dan justru bisa menyebabkan *overfitting* (model terlalu berusaha mencocokkan noise/gangguan kecil pada data, bukan tren utamanya).

Penelitian selanjutnya mengenai peramalan data keuangan dilakukan oleh Hassani et al. (2020). Objek yang diteliti adalah volatilitas suku bunga jangka pendek, menengah dan panjang di *United Kingdom of Great Britain and Northern Ireland* (UK) dengan menggunakan data bulanan historis jangka panjang dari Mei 1836 hingga Juni 2018 (2.186 bulan). Fokus penelitian tersebut adalah menganalisis kemampuan peramalan jangka sangat pendek, pendek, menengah, dan panjang dari berbagai model GARCH univariat dengan mempertimbangkan berbagai jenis distribusi residualnya. Tujuan dari penelitian tersebut adalah untuk menentukan model mana yang paling akurat dalam meramalkan volatilitas suku bunga Inggris pada berbagai horizon waktu dan membuktikan pentingnya mempertimbangkan distribusi alternatif selain distribusi normal . Penelitian tersebut menggunakan berbagai varian model volatilitas, meliputi GARCH, EGARCH, GJR-GARCH, TGARCH, CGARCH, A-PARCH, ARMA-GASGARCH, serta Mixture Autoregressive (MAR), dengan penerapan beragam distribusi error untuk menangkap karakteristik *heavy-tailed*, seperti Normal, Student's *t*, GED, Skew Normal, Skew Student's *t*, SGED, Inverse Gaussian, Generalized Hyperbolic, dan Johnson's SU. Kinerja model dievaluasi menggunakan Root Mean Square Error (RMSE) dan uji Kolmogorov–Smirnov Predictive Accuracy (KSPA). Hasil penelitian menunjukkan bahwa model A-PARCH dengan distribusi error Skew Generalized Error Distribution (SGED) merupakan model paling akurat untuk peramalan jangka sangat pendek ($h = 1$). Untuk horizon jangka pendek, menengah, dan panjang ($h = 3, 6, 12$), model GARCH standar dengan distribusi

Generalized Error Distribution (GED) terbukti memberikan tingkat akurasi terbaik. Selain itu, asimetri volatilitas yang merepresentasikan respons berbeda terhadap guncangan positif dan negatif hanya signifikan pada peramalan jangka sangat pendek dan tidak meningkatkan akurasi pada horizon yang lebih panjang.

Penelitian selanjutnya dilakukan oleh Kim et al. (2021) yang meneliti perilaku *yield spreads* pada obligasi korporasi. Dalam penelitian tersebut, *yield spread* atau *credit spread* didefinisikan sebagai selisih antara imbal hasil obligasi korporasi dan imbal hasil obligasi pemerintah (*Treasury bond*) dengan jangka waktu jatuh tempo sama. Selisih tersebut menggambarkan premi risiko yang diterima investor sebagai kompensasi atas kemungkinan terjadinya gagal bayar oleh penerbit obligasi korporasi. Penelitian tersebut menganalisis hubungan antara volatilitas extityield spreads dengan beberapa variabel lain, seperti volatilitas suku bunga, volatilitas pasar saham, dan tingkat risiko gagal bayar. Tujuan utama dari penelitian tersebut adalah untuk mengestimasi volatilitas *yield spreads* tersebut dengan lebih akurat. Untuk mencapai tujuan tersebut, penelitian tersebut memanfaatkan berbagai varian model GARCH seperti GARCH standar, E-GARCH, T-GARCH, P-GARCH, Q-GARCH dan I-GARCH. Hasil penelitian menunjukkan bahwa model-model tersebut mampu menangkap perubahan volatilitas extityield spreads dengan baik. Temuan penting lainnya adalah adanya hubungan kuat antara volatilitas *yield spreads* dan volatilitas suku bunga serta munculnya efek asimetris, dimana informasi negatif meningkatkan volatilitas lebih besar dibandingkan informasi positif.

Penelitian berikutnya mengenai peramalan nilai tukar dilakukan oleh Zhu (2025) dengan menggunakan data nilai tukar USD/JPY. Tujuan utama penelitian tersebut adalah menangkap tren linear sekaligus perubahan volatilitas dari waktu ke waktu (*time-varying volatility*) pada data nilai tukar yang bersifat dinamis. Model yang digunakan adalah model gabungan ARIMA(p, d, q)-GARCH(P, Q). Pada model tersebut, ARIMA berperan untuk memodelkan dan meramalkan nilai tengah atau arah pergerakan data dari waktu ke waktu (*conditional mean*). Sementara itu, GARCH digunakan untuk menggambarkan seberapa besar fluktuasi yang mungkin terjadi di sekitar nilai tersebut. Dengan kata lain, ARIMA memprediksi nilai utamanya, sedangkan GARCH memprediksi tingkat ketidakstabilannya melalui pola pengelompokan volatilitas (*volatility clustering*) pada residualnya (R. Engle, 2001). Hasil penelitian menunjukkan bahwa ARIMA(p, d, q)-GARCH(P, Q) mampu menghasilkan residual yang bersifat *white noise* dan stasioner meskipun tidak mengikuti distribusi normal, serta cukup efektif dalam menggambarkan dinamika nilai tukar secara keseluruhan sehingga dapat dimanfaatkan dalam analisis risiko keuangan.

Penelitian lain yang berkaitan dengan manajemen utang dilakukan oleh Yavuz & Gölbaşı (2019) yang meneliti optimasi komposisi utang negara Turki. Fokus pada penelitian tersebut Menemukan komposisi utang dan strategi peminjaman yang optimal, khususnya bagi negara yang memiliki kendala atau batasan dalam instrumen peminjaman. Penelitian tersebut bertujuan untuk menentukan komposisi utang yang optimal tanpa memerlukan program optimasi yang rumit, cukup dengan memanfaatkan modul simulasi yang sudah ada. Penelitian tersebut menggunakan metode simluasi stokastik berbasis *Turkish Treasury Debt Simulation Model* (TTDSM) dengan batasan instrumen tertentu untuk memproyeksikan variabel makroekonomi serta menghitung biaya dan risiko strategi selama periode lima tahun. Selanjutnya, ratusan strategi tersebut dievaluasi untuk membentuk kurva efficient frontier, di mana portofolio optimal ditentukan melalui analisis marginal rasio *Marginal Conditional Cost-at-Risk* (MCCaR) terhadap biaya marginal. Penelitian tersebut berhasil

mengidentifikasi strategi optimal yang mampu menurunkan risiko sebesar 13% dan biaya sebesar 9% dibandingkan dengan portofolio berbobot merata. Komposisi terbaik yang ditemukan didominasi oleh 60% obligasi tanpa kupon (*zero-coupon*) dan 25% kupon tetap (*fixed-rate*), dengan alokasi masing-masing 5% untuk kupon mengambang, indeks inflasi, dan valuta asing. Hasil analisis juga menunjukkan bahwa kombinasi instrumen valuta asing dan mata uang lokal memberikan *trade-off* biaya-risiko yang paling signifikan karena rendahnya korelasi antar-instrumen tersebut. Mengingat asumsi makroekonomi memegang peran krusial yang dapat mengubah hasil secara signifikan, penyesuaian dan analisis ulang model tetap perlu dilakukan secara berkala. Terlepas dari hal tersebut, penerapan metode tersebut sangat disarankan oleh Yavuz & Gölbaşı bagi para pengelola utang di negara berkembang yang menghadapi keterbatasan pasar, karena kemampuannya memberikan solusi perbaikan struktur utang secara cepat dan tepat.

Penelitian selanjutnya yang berkaitan dengan manajemen utang negara adalah penelitian yang dilakukan oleh Yang et al. (2022) yang mengambil objek pada pemerintah daerah di Tiongkok. Penelitian tersebut berfokus pada penentuan komposisi portofolio obligasi yang optimal untuk mengatasi masalah pengalihan risiko likuiditas ke masa depan akibat penerbitan utang jangka panjang guna menutup utang jangka pendek. Tujuan utama dari penelitian tersebut adalah meminimalkan ekspektasi biaya utang dengan tetap mematuhi batasan risiko likuiditas dan risiko penyimpangan biaya demi meningkatkan keberlanjutan utang. Metode yang diterapkan adalah pendekatan *multi-period stochastic programming* dengan simulasi suku bunga *Cox-Ingersoll-Ross* (CIR), serta penggunaan *Conditional Payment-at-Risk* (CPaR) untuk mengukur risiko likuiditas dan *Conditional Value-at-Risk* (CVaR) untuk risiko penyimpangan biaya. Hasil penelitian berhasil memetakan *efficient frontier* yang merepresentasikan *trade-off* optimal antara ekspektasi biaya, risiko likuiditas (CPaR), dan risiko penyimpangan biaya (CVaR). Hasil penelitian tersebut juga menunjukkan bahwa di bawah batasan risiko likuiditas yang terkendali, pengambil keputusan memiliki fleksibilitas untuk meminimalkan biaya dengan menyesuaikan proporsi obligasi yang jatuh tempo setelah periode perencanaan. Sebaliknya, pada tingkat risiko biaya yang tetap, manajemen arus kas pembayaran kembali dapat dioptimalkan melalui penyesuaian komposisi antara obligasi jangka pendek dan panjang. Hal tersebut menunjukkan bahwa pemerintah daerah memiliki ruang efisiensi yang bisa dimanfaatkan untuk hal lain, karena pemerintah daerah di Tiongkok membayar biaya lebih mahal dari yang seharusnya untuk menanggung tingkat risiko likuiditas yang mereka hadapi.

2.2 Utang Valas

Menurut Fadillah et al. (2025), valuta asing (valas) adalah mata uang negara lain yang diterima dan digunakan sebagai alat pembayaran yang sah dalam transaksi lintas batas. Dalam konteks pembiayaan negara, utang valas merujuk pada kewajiban pembayaran kepada pihak luar negeri dimana pelunasannya harus dilakukan menggunakan mata uang asing yang telah disepakati (Nasir, 2013). Penggunaan instrumen ini memiliki konsekuensi risiko yang signifikan terhadap stabilitas ekonomi. Fadillah et al. (2025) menjelaskan bahwa fluktuasi nilai tukar memegang peranan krusial karena depresiasi atau penurunan tajam nilai tukar mata uang domestik dapat menyebabkan lonjakan beban utang luar negeri secara tiba-tiba yang pada akhirnya mengancam stabilitas keuangan nasional. Selain risiko nilai tukar, pergerakan suku bunga global juga menjadi faktor penentu krusial dalam penilaian risiko utang valas, dimana kenaikan suku bunga akan meningkatkan biaya utang valas sehingga berdampak langsung pada pembengkakan beban bunga utang (Direktorat

Jenderal Pengelolaan Pembiayaan dan Risiko, 2025b).

Pengaruh perubahan nilai tukar dan suku bunga terhadap beban utang pemerintah Indonesia tampak nyata dalam hasil pengamatan empiris yang dilakukan oleh Direktorat Jenderal Pengelolaan Utang (2019). Pada periode Maret 2005–September 2014, guncangan penurunan nilai tukar rupiah terbukti mendorong kenaikan rasio utang pemerintah sehingga menunjukkan adanya pembengkakan beban utang. Namun, pada periode Oktober 2014–Maret 2019 terlihat pola yang berbeda karena pelemahan rupiah justru diikuti oleh penurunan rasio utang. Kondisi ini terjadi karena pemerintah berhasil menekan porsi utang valuta asing terhadap total utang dari 54,3% pada tahun 2005 menjadi 41,6% pada tahun 2018 (Direktorat Jenderal Pengelolaan Utang, 2019). Meskipun porsi utang valas menurun, perubahan komposisi instrumen dari pinjaman ke Surat Berharga Negara (SBN) valas membuat portofolio utang menjadi lebih sensitif terhadap perubahan kondisi pasar. Oleh karena itu, penyusunan komposisi utang valas yang optimal menjadi langkah penting untuk mengurangi dampak perubahan nilai tukar dan suku bunga terhadap beban pembayaran utang (Direktorat Jenderal Pengelolaan Utang, 2019; Fadillah et al., 2025).

2.3 *Autoregressive Integrated Moving Average* (ARIMA)

Autoregressive Integrated Moving Average (ARIMA) pertama kali diperkenalkan oleh Box dan Jenkins pada tahun 1970, dan model ini kemudian dikenal luas sebagai model Box–Jenkins. Model ARIMA merupakan gabungan komponen *autoregressive* (AR), *differencing* (I), dan *moving average* (MA) yang dinotasikan secara umum sebagai ARIMA(p, d, q) (Box et al., 2015). Notasi tersebut merepresentasikan orde spesifik dari masing-masing bagian, dimana p adalah orde untuk bagian *autoregressive*, d menunjukkan tingkat *differencing* yang diperlukan, dan q adalah orde untuk *moving average*. Berdasarkan susunan komponen tersebut, berikut beberapa bentuk khusus dari model ARIMA.

1. Model ARIMA$(p, 0, 0)$

   Model ini lebih sering dikenal sebagai model AR(p) yang mengasumsikan bahwa nilai saat ini bergantung secara linear pada beberapa nilai masa lalu. Model ini dirumuskan sebagai berikut.

   $$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \varepsilon_t. \tag{2.1}$$

   Dimana Y_t adalah nilai observasi deret waktu pada periode ke-t, ϕ_i adalah parameter *autoregressive* ke-i yang menunjukkan bobot pengaruh data masa lalu, dan ε_t adalah nilai residual atau galat acak pada periode ke-t yang diasumsikan bersifat *white noise*. Menggunakan operator *lag* atau *backshift* (B) yang didefinisikan sebagai $BY_t = Y_{t-1}$, Persamaan (2.1) dapat dituliskan sebagai berikut.

   $$\Phi_p(B) Y_t = \varepsilon_t, \quad \text{dimana} \quad \Phi_p(B) = 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p. \tag{2.2}$$

   Dimana $\Phi_p(B)$ merupakan notasi polinomial operator untuk komponen AR dengan orde p.

2. Model ARIMA$(0, 0, q)$

   Model ini disebut sebagai MA(q) yang hanya memperhitungkan pengaruh *error* dari beberapa periode sebelumnya. Bentuk model ini dirumuskan sebagai berikut.

   $$Y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}. \tag{2.3}$$

Pada Persamaan (2.3), μ merepresentasikan konstanta yang menunjukkan rata-rata proses data, sedangkan θ_j adalah parameter *moving average* ke-j yang mengukur bobot pengaruh residual masa lalu. Dalam bentuk operator *backshift* B, model ini dapat dituliskan sebagai berikut.

$$Y_t = \mu + \Theta_q(B)\varepsilon_t, \quad \text{dimana} \quad \Theta_q(B) = 1 + \theta_1 B + \theta_2 B^2 + \cdots + \theta_q B^q. \tag{2.4}$$

Dimana $\Theta_q(B)$ adalah polinomial operator untuk komponen MA dengan orde q.

3. Model ARIMA$(p, 0, q)$

   Model ini umumnya dikenal sebagai ARMA(p, q). Model ini dibentuk dengan menggabungkan komponen AR pada Persamaan (2.1) dan komponen MA pada Persamaan (2.3), sehingga memperhitungkan pengaruh nilai masa lalu serta residual dari periode sebelumnya pada data yang sudah stasioner. Bentuk model ini dirumuskan sebagai berikut.

$$Y_t = \mu + \phi_1 Y_{t-1} + \cdots + \phi_p Y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}. \tag{2.5}$$

   Dengan menggunakan operator polinomial $\Phi_p(B)$ dan $\Theta_q(B)$ yang telah didefinisikan sebelumnya, Persamaan (2.5) dapat ditulis secara ringkas sebagai berikut.

$$\Phi_p(B)Y_t = \Theta_q(B)\varepsilon_t. \tag{2.6}$$

4. Model ARIMA(p, d, q)

   Model ini digunakan untuk data yang tidak stasioner, sehingga perlu didiferensiasi sebanyak d kali agar menjadi stasioner. Proses diferensiasi ini melibatkan operator Δ, dimana $\Delta Y_t = Y_t - Y_{t-1}$. Bentuk model ini dirumuskan sebagai berikut.

$$\Delta^d Y_t = \phi_1 \Delta^d Y_{t-1} + \cdots + \phi_p \Delta^d Y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}. \tag{2.7}$$

   Dalam bentuk operator *backshift* B, Persamaan (2.7) dapat dituliskan sebagai berikut.

$$\Phi_p(B)(1 - B)^d Y_t = \Theta_q(B)\varepsilon_t. \tag{2.8}$$

   Pada Persamaan (2.8), $(1 - B)^d$ merepresentasikan operasi *differencing* dengan orde d yang diterapkan pada data Y_t untuk mencapai stasioneritas sebelum dilakukan pemodelan AR dan MA.

2.4 Identifikasi Model ARIMA

Proses pembentukan model ARIMA dilakukan melalui beberapa tahapan. Tahapan pertama diawali dengan pemeriksaan kestasioneran data, kemudian dilanjutkan dengan penentuan calon model melalui analisis plot *Autocorrelation Function* (ACF) dan *Partial Autocorrelation Function* (PACF). Setelah calon model diperoleh, selanjutnya dilakukanestimasi parameter serta serta uji diagnostik untuk memvalidasi kelayakan model.

2.4.1 Stasioneritas Data

Stasioneritas adalah kondisi ketika sifat statistik data tidak berubah seiring waktu (Wei, 2006). Stasioneritas terhadap mean berarti rata-rata data konstan, sedangkan stasioneritas

terhadap varians berarti sebaran data konstan. Model ARIMA memerlukan asumsi bahwa data stasioner terhadap keduanya. Data yang tidak stasioner dapat menyebabkan kesulitan peramalan (Thakkar & Chaudhari, 2021) dan regresi palsu (*spurious regression*), yaitu hasil uji tampak signifikan padahal tidak ada hubungan nyata antarvariabelnya (Gujarati & Porter, 2009). Salah satu metode statistik yang umum digunakan untuk menguji stasioneritas data deret waktu adalah uji *Augmented Dickey-Fuller* (ADF), yang bertujuan untuk mendeteksi keberadaan akar unit (*unit root*) sebagai indikasi ketidakstasioneran data. Menurut Gujarati & Porter (2009), prosedur pengujian ini didasarkan pada model regresi yang dirumuskan sebagai berikut.

$$\Delta Y_t = \beta_1 + \beta_2 t + \delta Y_{t-1} + \sum_{i=1}^{m} \alpha_i \Delta Y_{t-i} + \varepsilon_t. \tag{2.9}$$

Dalam Persamaan (2.9), ΔY_t merupakan selisih pertama data pada waktu ke-t, β_1 adalah konstanta atau intersep, β_2 adalah koefisien tren waktu, dan δ adalah koefisien uji akar unit yang menjadi fokus pengujian. Selain itu, α_i merupakan koefisien untuk komponen *augmented* yang menangkap autokorelasi, dan ε_t adalah komponen galat pada waktu ke-t. Langkah-langkah uji *Augmented Dickey–Fuller* (ADF) adalah sebagai berikut.

(1) **Hipotesis:**

$H_0 : \delta = 0,$ sehingga data tidak stasioner (terdapat akar unit),
$H_1 : \delta < 0,$ sehingga data stasioner (tidak terdapat akar unit).

(2) **Statistik Uji:**
Statistik uji ADF dirumuskan sebagai rasio antara estimasi koefisien δ terhadap galat bakunya, yang dinyatakan pada Persamaan (2.10).

$$ADF_{hitung} = \frac{\hat{\delta}}{SE(\hat{\delta})}. \tag{2.10}$$

Pada Persamaan (2.10), $\hat{\delta}$ adalah nilai estimasi koefisien uji akar unit yang diperoleh dari regresi, dan $SE(\hat{\delta})$ adalah galat baku (*standard error*) dari estimasi tersebut.

(3) **Daerah Kritis:**
Nilai kritis uji (ADF_{tabel}) ditentukan berdasarkan tabel MacKinnon (MacKinnon, 2010) pada tingkat signifikansi α. Kriteria pengujian adalah sebagai berikut.

$ADF_{hitung} < ADF_{tabel}$ maka H_0 ditolak (data stasioner),
$ADF_{hitung} \geq ADF_{tabel}$ maka H_0 gagal ditolak (data tidak stasioner).

(4) **Keputusan:**
Keputusan pengujian ditentukan berdasarkan perbandingan antara nilai ADF_{hitung} dan ADF_{tabel} sesuai dengan daerah kritis yang telah ditetapkan.

Data yang tidak memenuhi asumsi stasioneritas memerlukan proses transformasi. Apabila data tersebut tidak stasioner terhadap varians, data dapat ditransformasikan

menggunakan transformasi Box–Cox seperti pada Persamaan (2.11).

$$Y^{(\lambda)} = \begin{cases} \dfrac{Y^{\lambda} - 1}{\lambda}, & \lambda \neq 0. \\ \ln(Y), & \lambda = 0. \end{cases} \tag{2.11}$$

Pada Persamaan (2.11), $Y^{(\lambda)}$ adalah nilai deret waktu setelah transformasi, Y adalah nilai asli deret waktu, dan λ adalah parameter transformasi Box–Cox yang menentukan jenis transformasi yang diterapkan. Sementara itu, jika data tidak stasioner terhadap nilai rata-rata atau *mean*, penanganan dilakukan melalui proses *differencing* yang dinyatakan dalam Persamaan (2.12).

$$\nabla^d Y_t = (1 - B)^d Y_t. \tag{2.12}$$

Dalam Persamaan (2.12), $\nabla^d Y_t$ menunjukkan hasil *differencing* orde-d, dan B adalah operator *backshift* yang didefinisikan sebagai $BY_t = Y_{t-1}$.

2.4.2 Plot ACF & PACF

Identifikasi struktur model deret waktu dilakukan dengan menganalisis pola visual pada plot *Autocorrelation Function* (ACF) dan *Partial Autocorrelation Function* (PACF). Berdasarkan Wei (2006), fungsi autokorelasi pada *lag* k (ρ_k) didefinisikan sebagai rasio antara autokovarians pada *lag* k terhadap varians data yang dirumuskan pada Persamaan (2.13).

$$\rho_k = \frac{\gamma_k}{\gamma_0}, \quad \text{dengan } \gamma_k = \mathrm{Cov}(Y_t, Y_{t+k}). \tag{2.13}$$

Dalam Persamaan (2.13), ρ_k merupakan koefisien autokorelasi pada *lag* k, γ_k adalah autokovarians pada *lag* k, dan γ_0 merepresentasikan varians data atau autokovarians pada *lag* 0. Adapun Y_t didefinisikan sebagai nilai observasi deret waktu pada periode ke-t. Sementara itu, PACF (ϕ_{kk}) didefinisikan sebagai korelasi antara pengamatan pada waktu ke-t dan waktu ke-$t-k$ setelah menghilangkan pengaruh linear dari data lain di antara kedua waktu tersebut. PACF dirumuskan sebagai berikut.

$$\phi_{kk} = \mathrm{Corr}(Y_t, Y_{t+k} \mid Y_{t+1}, \ldots, Y_{t+k-1}), \tag{2.14}$$

dengan operasi korelasi bersyarat secara umum didefinisikan sebagai berikut.

$$\mathrm{Corr}(A, B \mid C) = \frac{\mathrm{Cov}(A, B \mid C)}{\sqrt{\mathrm{Var}(A \mid C)\mathrm{Var}(B \mid C)}}, \tag{2.15}$$

Berdasarkan Persamaan (2.14) dan (2.15), ϕ_{kk} merupakan koefisien autokorelasi parsial pada *lag* k yang mengukur korelasi murni antara Y_t (sebagai A) dan Y_{t+k} (sebagai B). Pengukuran ini dilakukan dengan memperhitungkan kovarians (Cov) dan varians (Var) bersyarat setelah menghilangkan pengaruh linear dari sekumpulan variabel perantara $Y_{t+1}, \ldots, Y_{t+k-1}$ (sebagai C).

Pola visual yang dihasilkan dari plot ACF dan PACF berdasarkan Persamaan (2.13) dan (2.14) dicocokkan dengan pola teoretis yang dirangkum oleh Dani et al. (2025) sebagaimana disajikan pada Tabel 2.1.

Tabel 2.1 Pola Teoretis ACF dan PACF

Model	**Pola ACF**	**Pola PACF**
AR(p)	Menurun menuju nol (*tails off*)	Terputus setelah lag p (*cuts off*)
MA(q)	Terputus setelah lag q (*cuts off*)	Menurun menuju nol (*tails off*)
ARMA(p, q)	Menurun menuju nol (*tails off*)	Menurun menuju nol (*tails off*)

Berdasarkan Tabel 2.1, istilah *cuts off* merujuk pada kondisi dimana nilai autokorelasi signifikan hingga *lag* tertentu dan kemudian terputus atau mendekati nol secara tiba-tiba. Sebaliknya, pola *tails off* menggambarkan penurunan nilai koefisien secara perlahan menuju nol, baik berbentuk penurunan eksponensial maupun gelombang sinusoidal.

2.4.3 Identifikasi Orde Model ARIMA

Penentuan kandidat model ARIMA(p, d, q) dilakukan dengan mengamati pada *lag* ke berapa plot PACF dan ACF mengalami pemutusan atau *cuts off*, sesuai dengan karakteristik pola teoretis yang telah dirangkum pada Tabel 2.1. Mengingat proses identifikasi visual ini sering kali menghasilkan lebih dari satu kemungkinan kombinasi model yang layak, seleksi model terbaik harus berpedoman pada prinsip parsimoni. Menurut Sober (1981), prinsip ini menegaskan bahwa parameter yang tidak memberikan kontribusi nyata dalam menjelaskan pola data sebaiknya tidak dimasukkan ke dalam model. Pendekatan ini diperkuat oleh penjelasan Woodward et al. (2017), yang menyatakan bahwa penggunaan parameter yang terlalu banyak justru berisiko meningkatkan ketidakpastian serta membuat hasil peramalan menjadi tidak stabil akibat sensitivitas yang tinggi terhadap perubahan data, sehingga model dengan struktur paling sederhana namun tetap representatif adalah prioritas utama untuk dipilih.

2.5 Estimasi Parameter

Setelah calon model ARIMA (p, d, q) diperoleh melalui tahap identifikasi model, langkah berikutnya adalah mengestimasi nilai parameter dari komponen *autoregressive* (ϕ) dan *moving average* (θ). Metode yang paling umum digunakan adalah *Maximum Likelihood Estimation* (MLE). Menurut Cryer & Chan (2008), prinsip dasar metode ini adalah mencari nilai parameter yang memaksimumkan fungsi kemungkinan atau *likelihood*. Untuk mempermudah proses komputasi, fungsi tersebut diubah ke dalam bentuk logaritma natural atau disebut sebagai *log-likelihood function* yang dirumuskan pada Persamaan (2.16).

$$\ln L(\phi, \mu, \theta, \sigma^2) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma^2) - \frac{S(\phi, \mu, \theta)}{2\sigma^2}. \tag{2.16}$$

Dalam Persamaan (2.16), n menyatakan jumlah data observasi, σ^2 adalah varians dari galat, dan $S(\phi, \mu, \theta)$ merupakan fungsi jumlah kuadrat galat. Secara komputasi, memaksimumkan fungsi *log-likelihood* tersebut ekuivalen dengan meminimalkan komponen $S(\phi, \mu, \theta)$ yang didefinisikan pada Persamaan (2.17).

$$S(\phi, \mu, \theta) = \sum_{t=1}^{n} \varepsilon_t^2. \tag{2.17}$$

Dimana ε_t adalah nilai residual atau komponen galat pada waktu ke-t. Minimasi Persamaan (2.17) akan menghasilkan aproksimasi parameter $(\hat{\phi}, \hat{\theta})$ yang paling mendekati data aktual.

Selanjutnya, signifikansi parameter yang telah diestimasi diuji menggunakan uji-t untuk memastikan kelayakannya dalam model. Langkah-langkah uji-t adalah sebagai berikut.

(1) **Hipotesis:**
Dalam pengujian ini, β_i merepresentasikan parameter model ke-i yang akan diuji, baik itu parameter AR (ϕ) maupun parameter MA (θ).

$H_0 : \beta_i = 0,$ sehingga parameter tidak signifikan terhadap model,
$H_1 : \beta_i \neq 0,$ sehingga parameter signifikan terhadap model.

(2) **Statistik Uji:**
Statistik uji yang digunakan dihitung melalui rasio antara nilai estimasi parameter terhadap galat bakunya, yang dirumuskan pada Persamaan (2.18).

$$t_{\text{hitung}} = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)}, \tag{2.18}$$

dengan:

$$SE(\hat{\beta}_i) = \frac{SD(\hat{\beta}_i)}{\sqrt{n}}$$
$$SD(\hat{\beta}_i) = \sqrt{\text{Var}(\hat{\beta}_i)}$$
$$\text{Var}(\hat{\beta}_i) = \frac{\sum(\beta_i - \hat{\beta}_i)^2}{n-1}.$$

Dimana t_{hitung} adalah nilai statistik uji-t, $\hat{\beta}_i$ adalah estimasi parameter yang diuji ($\hat{\phi}$ atau $\hat{\theta}$), dan n adalah jumlah observasi. Nilai $SE(\hat{\beta}_i)$ merupakan galat baku yang diturunkan dari standar deviasi $SD(\hat{\beta}_i)$, sedangkan $\text{Var}(\hat{\beta}_i)$ merupakan varians parameter yang dihitung berdasarkan selisih kuadrat antara nilai parameter dengan estimasinya.

(3) **Daerah Kritis:**
Nilai kritis uji (t_{tabel}) ditentukan berdasarkan distribusi t-Student dengan derajat bebas $(n-k)$ pada tingkat signifikansi α, dimana k adalah jumlah parameter yang diestimasi. Kriteria pengujian adalah sebagai berikut.

$|t_{hitung}| > t_{tabel}$ maka H_0 ditolak,
$|t_{hitung}| \leq t_{tabel}$ maka H_0 gagal ditolak.

(4) **Keputusan:**
Keputusan pengujian ditentukan berdasarkan perbandingan antara nilai statistik uji dan nilai kritis, atau dengan membandingkan nilai *p-value* terhadap tingkat signifikansi α.

2.6 Uji Diagnostik Model

Dalam model ARIMA, residual ε_t diasumsikan mengikuti distribusi normal dengan rata-rata nol dan varians σ_t^2, dinotasikan sebagai $\varepsilon_t \sim N(0, \sigma_t^2)$. Asumsi ini menjadi dasar

bagi pengujian diagnostik yang akan dilakukan, meliputi uji normalitas residual dan uji residual *white noise*.

2.6.1 Uji Normalitas Residual

Pengujian normalitas residual dilakukan untuk memastikan bahwa residual yang dihasilkan oleh model bersifat acak dan mengikuti distribusi normal (Wei, 2006). Salah satu metode yang sering digunakan adalah uji *Kolmogorov-Smirnov*. Langkah-langkah uji *Kolmogorov-Smirnov* adalah sebagai berikut.

(1) **Hipotesis:**

H_0 : Residual berdistribusi normal,

H_1 : Residual tidak berdistribusi normal.

(2) **Statistik Uji:**
Statistik uji *Kolmogorov-Smirnov* dirumuskan oleh Massey Jr (1951) sebagai berikut.

$$D_{hitung} = \max |F_0(x) - S_N(x)|, \tag{2.19}$$

dimana D_{hitung} adalah nilai statistik uji, $F_0(x)$ adalah fungsi distribusi kumulatif teoretis populasi (normal), dan $S_N(x)$ adalah fungsi distribusi kumulatif empiris dari sampel residual dengan ukuran N.

(3) **Daerah Kritis:**
Nilai kritis (D_{tabel}) ditentukan berdasarkan tabel uji *Kolmogorov-Smirnov* untuk ukuran sampel N dan tingkat signifikansi α. Kriteria pengambilan keputusan adalah sebagai berikut.

$$\begin{aligned} D_{hitung} > D_{tabel} &\quad \text{maka } H_0 \text{ ditolak (residual tidak normal),} \\ D_{hitung} \leq D_{tabel} &\quad \text{maka } H_0 \text{ gagal ditolak (residual normal).} \end{aligned}$$

(4) **Keputusan:**
Keputusan pengujian ditentukan berdasarkan perbandingan antara nilai statistik D_{hitung} dan nilai kritis D_{tabel} sesuai dengan kriteria yang telah ditetapkan.

2.6.2 Uji Residual *White Noise*

Pemeriksaan independensi residual bertujuan untuk memastikan bahwa residual bersifat acak (*white noise*) dan tidak memiliki korelasi antarwaktu. Jika residual masih memuat pola autokorelasi yang signifikan, maka model belum mampu menangkap seluruh informasi data secara optimal (Wei, 2006). Metode yang digunakan untuk menguji asumsi ini adalah statistik *Ljung-Box*. Langkah-langkah pengujian *Ljung-Box* adalah sebagai berikut.

(1) **Hipotesis:**
Hipotesis pengujian dirumuskan sebagai berikut.

$H_0 : \rho_1 = \cdots = \rho_K = 0,$ (residual bersifat acak/*white noise*),

$H_1 : \exists \rho_k \neq 0,$ (residual tidak acak/mengandung autokorelasi).

Dimana K adalah jumlah *lag* maksimum yang diuji. Variabel $\hat{\rho}_k$ adalah autokorelasi sampel dari residual pada *lag* ke-k, yang mengukur hubungan linear antara residual pada waktu t dan $t-k$.

(2) **Statistik Uji:**
Nilai statistik *Ljung-Box* (Q) dihitung menggunakan rumus yang dinyatakan dalam Persamaan (2.20) (Box et al., 2015).

$$Q = n(n+2)\sum_{k=1}^{K}(n-k)^{-1}\hat{\rho}_k^2. \tag{2.20}$$

Dimana n merepresentasikan jumlah data observasi.

(3) **Daerah Kritis:**
Nilai kritis uji ($\chi^2_{\alpha,df}$) ditentukan berdasarkan distribusi *Chi-Square* pada tingkat signifikansi α dengan derajat bebas $df = K-(p+q)$, dimana p dan q adalah orde model ARIMA yang diestimasi. Kriteria pengujian adalah sebagai berikut.

$$\begin{aligned} Q > \chi^2_{\alpha,df} &\quad \text{maka } H_0 \text{ ditolak,} \\ Q \leq \chi^2_{\alpha,df} &\quad \text{maka } H_0 \text{ gagal ditolak.} \end{aligned}$$

(4) **Keputusan:**
Keputusan pengujian ditentukan dengan membandingkan nilai statistik hitung Q dengan nilai kritis dari tabel distribusi *Chi-Square* sesuai dengan daerah kritis yang telah ditetapkan.

2.7 Uji Heteroskedastisitas

Uji heteroskedastisitas bertujuan untuk memastikan apakah varians dari residual bersifat konstan (homoskedastis) atau mengalami perubahan seiring waktu. Mengacu pada Wei (2006), jika varians residual tidak stabil atau mengandung efek ARCH (*Autoregressive Conditional Heteroscedasticity*), hal ini menunjukkan bahwa model perlu dikembangkan lebih lanjut menggunakan model volatilitas seperti GARCH. Metode yang digunakan untuk menguji asumsi ini adalah uji *Lagrange Multiplier* (ARCH-LM). Berdasarkan R. F. Engle (1982), langkah-langkah pengujian ARCH-LM adalah sebagai berikut.

(1) **Hipotesis:**

H_0 : Tidak terdapat efek ARCH (homoskedastis),

H_1 : Terdapat efek ARCH (heteroskedastis).

(2) **Statistik Uji:**
Statistik uji ARCH-LM bekerja dengan memeriksa korelasi pada kuadrat residual melalui persamaan regresi bantuan. Statistik ini dirumuskan sebagai

$$LM_{hitung} = nR^2, \tag{2.21}$$

dimana LM_{hitung} adalah nilai statistik uji, n adalah jumlah data observasi, dan R^2 adalah koefisien determinasi yang diperoleh dari regresi linear kuadrat residual terhadap *lag*-nya.

(3) **Daerah Kritis:**
Nilai statistik LM mengikuti distribusi Chi-Square (χ^2) dengan derajat bebas q (jumlah *lag* yang diuji) dan tingkat signifikansi α. Nilai kritis (χ^2_{tabel}) ditentukan berdasarkan tabel distribusi Chi-Square. Kriteria pengambilan keputusan adalah sebagai berikut:

$$\begin{aligned} LM_{hitung} > \chi^2_{tabel} &\quad \text{maka } H_0 \text{ ditolak (terdapat efek ARCH),} \\ LM_{hitung} \leq \chi^2_{tabel} &\quad \text{maka } H_0 \text{ gagal ditolak (tidak terdapat efek ARCH).} \end{aligned}$$

(4) **Keputusan:**
Keputusan pengujian ditentukan berdasarkan perbandingan antara nilai statistik LM_{hitung} dan nilai kritis χ^2_{tabel} sesuai dengan kriteria yang telah ditetapkan.

2.8 *Generalized Autoregressive Conditional Heteroscedasticity* (GARCH)

Pada model ARIMA standar, varians σ_t^2 diasumsikan konstan, namun data keuangan umumnya menunjukkan fenomena *volatility clustering* (R. F. Engle, 1982). Kondisi ini menyebabkan varians residual berubah dari waktu ke waktu, sehingga diperlukan model yang dapat menangkap dinamika tersebut. Model *Autoregressive Conditional Heteroskedasticity* (ARCH) memodelkan varians bersyarat sebagai fungsi dari kuadrat residual masa lalu. Model ARCH dengan orde Q dinyatakan dalam Persamaan (2.22).

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^{Q} \alpha_i \varepsilon_{t-i}^2. \tag{2.22}$$

Pada Persamaan (2.22), σ_t^2 adalah varians bersyarat dari residual pada waktu ke-t, α_0 adalah konstanta awal yang bernilai positif, dan α_i adalah koefisien ARCH ke-i yang mengukur dampak guncangan masa lalu. Adapun ε_{t-i}^2 merepresentasikan kuadrat dari residual model ARIMA pada waktu ke-$t-i$.

Model ARCH sering membutuhkan orde tinggi untuk menangkap pola volatilitas dengan baik. Untuk mengatasinya, Bollerslev (1986) mengembangkan model *Generalized Autoregressive Conditional Heteroscedasticity* (GARCH). Pada model ini, varians bersyarat juga bergantung pada nilai varians bersyarat periode sebelumnya. Bentuk umum model GARCH(P, Q) dituliskan dalam Persamaan (2.23).

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^{Q} \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^{P} \beta_j \sigma_{t-j}^2. \tag{2.23}$$

Dalam Persamaan (2.23), β_j adalah koefisien GARCH ke-j yang menunjukkan persistensi volatilitas, dan σ_{t-j}^2 adalah varians bersyarat pada waktu ke-$t-j$.

Estimasi parameter $\boldsymbol{\theta}$ dilakukan menggunakan metode *Maximum Likelihood Estimation* (MLE). Proses ini didasarkan pada asumsi bahwa residual terdistribusi normal bersyarat, yaitu $\varepsilon_t \mid \mathcal{F}_{t-1} \sim N(0, \sigma_t^2)$, dimana $\mathcal{F}_{t-1}$ adalah himpunan informasi yang tersedia hingga waktu ke-$t-1$. Fungsi *log-likelihood* yang dimaksimalkan dirumuskan pada Persamaan (2.24).

$$\ln L(\boldsymbol{\theta}) = -\frac{T}{2}\ln(2\pi) - \frac{1}{2}\sum_{t=1}^{T}\left(\ln \sigma_t^2 + \tilde{\varepsilon}_t^2\right), \tag{2.24}$$

dengan definisi residual terstandarisasi sebagai berikut.

$$\tilde{\varepsilon}_t = \frac{\varepsilon_t}{\sigma_t}.$$

Pada Persamaan (2.24), $\ln L(\boldsymbol{\theta})$ adalah fungsi *log-likelihood* dengan vektor parameter $\boldsymbol{\theta} = (\alpha_0, \alpha_i, \beta_j)$, T adalah jumlah data observasi, dan $\tilde{\varepsilon}_t$ adalah residual terstandarisasi. Persamaan (2.24) memerlukan penyelesaian secara numerik (Bollerslev, 1986).

Tahap pemilihan model terbaik dilakukan dengan membandingkan nilai *Akaike Information Criterion* (AIC), dimana model dengan AIC terkecil dipilih sebagai model optimal. Bollerslev (1986) menyebutkan bahwa model GARCH(1,1) sering kali sudah memadai untuk menangkap dinamika data keuangan. Setelah model diperoleh, langkah evaluasi dilakukan dengan menghitung residual terstandarisasi untuk menghilangkan efek heteroskedastisitas. Selanjutnya, dilakukan uji diagnostik yang meliputi uji normalitas, uji *white noise*, serta uji *ARCH-LM* pada residual terstandarisasi tersebut.

2.9 *Akaike Information Criterion* (AIC)

Akaike Information Criterion (AIC) diperkenalkan oleh Hirotugu Akaike pada tahun 1974 sebagai cara untuk memilih model statistik yang paling sesuai dengan data. Nilai AIC dihitung dari fungsi *likelihood* dan jumlah parameter dalam model, sehingga memberikan penilaian yang seimbang antara tingkat kecocokan model terhadap data dan kompleksitas model tersebut. Semakin kecil nilai AIC, semakin baik model tersebut karena dianggap mampu menjelaskan data dengan efektif tanpa menggunakan terlalu banyak parameter. Dalam penelitian ini, AIC digunakan untuk membandingkan performa model ARIMA dan GARCH (Cryer & Chan, 2008). Pemilihan model dengan AIC bekerja berdasarkan prinsip parsimoni (Burnham & Anderson, 2004), yaitu memilih model yang paling sederhana namun tetap mampu menjelaskan data dengan baik. Secara umum, rumus AIC dituliskan sebagai berikut.

$$\text{AIC} = -2\ln(L) + 2k. \tag{2.19}$$

Keterangan:

L : Nilai maksimum fungsi *likelihood*
k : Jumlah parameter yang diestimasi

2.10 *Root Mean Square Error* (RMSE)

Root Mean Square Error (RMSE) merupakan ukuran statistik yang digunakan untuk mengevaluasi kinerja model peramalan dengan cara menghitung akar kuadrat dari rata-rata kuadrat selisih antara nilai prediksi dan nilai aktual. Tujuan utama penggunaan metode ini adalah untuk mengukur tingkat presisi model, dimana nilai RMSE yang semakin kecil mengindikasikan bahwa hasil dugaan semakin mendekati data sebenarnya (Wei, 2006). Rumus untuk menghitung nilai RMSE didefinisikan sebagai berikut.

$$RMSE = \sqrt{\frac{1}{n}\sum_{t=1}^{n}(Y_t - \hat{Y}_t)^2}. \tag{2.25}$$

Keterangan:

n : Jumlah data observasi.
Y_t : Nilai data aktual pada periode ke-t.
$\hat{Y}_t$: Nilai hasil prediksi pada periode ke-t.

2.11 *Mean-Variance Optimization* (MVO)

Optimisasi portofolio merupakan proses memilih susunan aset yang paling sesuai untuk mencapai tujuan investasi tertentu, seperti meningkatkan keuntungan atau mengurangi risiko. Salah satu model dasar yang banyak digunakan adalah *Mean-Variance Optimization* (MVO) yang diperkenalkan oleh Harry Markowitz pada tahun 1950-an. Model ini menjadi landasan teori portofolio modern karena menekankan pentingnya menyeimbangkan dua ukuran statistik, yaitu nilai rata-rata sebagai gambaran pengembalian yang diharapkan (*expected return*) dan varians sebagai ukuran risiko (Cornuéjols et al., 2018). Prinsip penting dalam model ini adalah menyebarkan investasi pada berbagai aset sehingga risiko tidak bertumpu hanya pada satu aset saja.

Dalam teori portfolio modern, pengembalian aset didefinisikan sebagai tingkat perubahan nilai investasi antarwaktu yang dihitung dari data harga historis. Terdapat dua pendekatan untuk menghitung nilai ini, yaitu *Linear Return* (r_t^{lin}) dan *Log Return* (r_t^{log}) yang masing-masing dirumuskan pada Persamaan (2.26) dan (2.27).

$$r_t^{lin} = \frac{Y_t - Y_{t-1}}{Y_{t-1}}. \tag{2.26}$$

$$r_t^{log} = \ln\left(\frac{Y_t}{Y_{t-1}}\right). \tag{2.27}$$

Di antara kedua metode tersebut, *Log Return* lebih umum digunakan dalam studi empiris karena memiliki sifat aditivitas antarwaktu dan karakteristik distribusinya lebih mendekati distribusi normal (Ruppert & Matteson, 2011). Berdasarkan perhitungan tersebut, harapan pengembalian (*expected return*) dalam model MVO didefinisikan sebagai estimasi keuntungan rata-rata di masa depan ($\boldsymbol{\mu}$), yang dihitung menggunakan rata-rata dari pengembalian aset. Sementara itu, risiko didefinisikan sebagai volatilitas atau ketidakpastian pengembalian yang diestimasi melalui matriks varians-kovarians sampel ($\boldsymbol{\Sigma}$) (Cornuéjols et al., 2018). Tujuan utama dari penggunaan parameter-parameter ini adalah untuk mengakomodasi preferensi investor rasional di dunia nyata, yaitu menginginkan tingkat pengembalian yang setinggi mungkin dengan tingkat risiko yang serendah mungkin (Markowitz, 2008).

Menurut Markowitz (2008), model MVO dapat diformulasikan melalui dua pendekatan utama. Model pertama merumuskan upaya untuk meminimalkan risiko portofolio ($\mathbf{x}^T \boldsymbol{\Sigma}\, \mathbf{x}$) dengan tetap memastikan bahwa tingkat pengembalian minimum tertentu dapat dicapai.

Bentuk umum dari model ini adalah sebagai berikut.

$$\begin{aligned} \min_{\mathbf{x}} \quad & \mathbf{x}^T \boldsymbol{\Sigma}\, \mathbf{x} \\ \text{dengan kendala} \quad & \boldsymbol{\mu}^T \mathbf{x} \geq R, \\ & \sum_{i=1}^{n} x_i = 1, \\ & x_i \geq 0, \quad \forall i = 1, \ldots, n. \end{aligned} \tag{2.28}$$

Pada Persamaan (2.28), R adalah target pengembalian minimum yang diinginkan investor. Model kedua adalah kebalikan dari pendekatan pertama, yaitu memaksimalkan pengembalian portofolio ($\boldsymbol{\mu}^T \mathbf{x}$) dengan tetap menjaga agar risiko tidak melampaui batas tertentu yang dapat diterima. Bentuk umum dari model ini dinyatakan dalam Persamaan (2.29).

$$\begin{aligned} \max_{\mathbf{x}} \quad & \boldsymbol{\mu}^T \mathbf{x} \\ \text{dengan kendala} \quad & \mathbf{x}^T \boldsymbol{\Sigma}\, \mathbf{x} \leq \gamma^2, \\ & \sum_{i=1}^{n} x_i = 1, \\ & x_i \geq 0, \quad \forall i = 1, \ldots, n. \end{aligned} \tag{2.29}$$

Pada Persamaan (2.29), γ^2 merepresentasikan batas maksimum risiko yang dapat ditoleransi. Kedua model di atas memuat batasan-batasan agar solusi yang dihasilkan relevan dengan kondisi nyata. Persamaan $\sum_{i=1}^{n} x_i = 1$ merupakan kendala anggaran yang mewajibkan seluruh modal dialokasikan sepenuhnya ke dalam portofolio sehingga total bobot aset bernilai satu. Sementara itu, kendala $x_i \geq 0$ diterapkan untuk memastikan tidak adanya penjualan kosong (*short selling*), yang berarti investor tidak dapat meminjam aset untuk dijual.

Model pada Persamaan (2.28) dan (2.29) akan menghasilkan kumpulan portofolio optimal yang dikenal sebagai *Efficient Frontier*, yaitu himpunan pilihan portofolio dengan kombinasi risiko dan pengembalian yang optimal. Model pada persamaan (2.28) dan (2.29) juga dikembangkan lebih lanjut dengan memasukkan batasan-batasan lain seperti biaya transaksi, serta penggunaan ukuran risiko alternatif untuk menangkap kejadian ekstrem (Rockafellar et al., 2000). Pada penelitian ini, optimisasi portofolio dilakukan dengan menggunakan model yang meminimalkan risiko sebagaimana dirumuskan pada Persamaan (2.28).

2.12 Ukuran Risiko

Dalam manajemen portofolio, pemilihan ukuran risiko yang tepat sangat penting agar estimasi risiko dapat mencerminkan kondisi pasar secara akurat dan sejalan dengan prinsip diversifikasi. Artzner et al. (1999) merumuskan dasar teoritis untuk menilai kualitas suatu ukuran risiko melalui konsep *Coherent Risk Measures*. Suatu pemetaan risiko $\rho : \mathcal{G} \to \mathbb{R}$ dikatakan koheren apabila memenuhi empat sifat berikut untuk setiap variabel acak kerugian X dan Y di dalam $\mathcal{G}$.

1. *Translation Invariance*
   Untuk setiap risiko X dan jumlah modal bebas risiko $c \in \mathbb{R}$, berlaku:

   $$\rho(X + c \cdot r) = \rho(X) - c. \tag{2.30}$$

   Sifat ini menyatakan bahwa penambahan aset bebas risiko sebesar c pada risiko X akan menurunkan nilai ukuran risiko sebesar c. Dengan kata lain, modal bebas risiko secara langsung mengimbangi potensi kerugian dalam portofolio.

2. *Subadditivity*
   Untuk setiap risiko X dan Y, berlaku:

   $$\rho(X + Y) \leq \rho(X) + \rho(Y). \tag{2.31}$$

   Sifat ini menyatakan bahwa ukuran risiko portofolio gabungan tidak akan lebih besar atau sama dengan jumlah ukuran risiko masing-masing portofolio secara terpisah.

3. *Positive Homogeneity*
   Untuk setiap risiko X dan konstanta $\lambda \geq 0$, berlaku:

   $$\rho(\lambda X) = \lambda \rho(X). \tag{2.32}$$

   Sifat ini menyatakan bahwa jika ukuran posisi diperbesar dengan faktor tertentu, maka risikonya juga meningkat mengikuti skala perbesarannya.

4. *Monotonicity*
   Untuk setiap risiko X dan Y dengan $X \leq Y$, berlaku:

   $$\rho(Y) \leq \rho(X). \tag{2.33}$$

   Sifat ini menyatakan bahwa jika satu variabel acak kerugian tidak pernah melebihi variabel kerugian lainnya dalam suatu portofolio, maka ukuran risikonya harus lebih kecil atau sama.

Dalam model optimasi *Mean-Variance Optimization* (MVO), ukuran risiko yang digunakan adalah variansnya. Ukuran risiko ini memenuhi sifat *subadditivity* dan *positive homogeneity*, yang berarti penggabungan aset mampu menurunkan risiko total portofolio. Namun, ukuran risiko ini tidak dikategorikan sebagai ukuran risiko yang koheren karena gagal memenuhi sifat *monotonicity* (Artzner et al., 1999). Kegagalan ini disebabkan oleh sifat simetris varians yang menganggap semua fluktuasi sebagai risiko tanpa membedakan arahnya. Dalam model ini, lonjakan keuntungan yang sangat tinggi diperlakukan sama buruknya dengan kerugian yang dalam. Akibatnya, aset yang sering memberikan keuntungan besar justru dinilai memiliki risiko tinggi hanya karena nilainya berfluktuasi. Hal ini bertentangan prinsip yang memandang potensi keuntungan besar tersebut sebagai nilai tambah, bukan sebagai ancaman. Ukuran risiko lain yang umum digunakan seperti *Value-at-Risk* (VaR) seringkali tidak memenuhi sifat *subadditivity*, terutama pada distribusi dengan ekor yang sangat tebal (Artzner et al., 1999). Kondisi ini dapat menghasilkan penilaian risiko yang tidak konsisten, misalnya ketika diversifikasi justru tampak meningkatkan risiko. Oleh karena itu, diperlukan ukuran risiko yang memenuhi seluruh sifat-sifat ukuran risiko yang koheren, agar model optimasi portofolio memiliki dasar yang lebih kuat.

2.13 *Conditional Value-at-Risk* (CVaR)

Conditional Value-at-Risk (CVaR) yang juga dikenal sebagai *mean excess loss*, *mean shortfall*, atau *tail VaR* merupakan ukuran risiko yang muncul sebagai penyempurnaan dari *Value-at-Risk* (VaR). Ukuran ini dikembangkan karena VaR memiliki keterbatasan dalam menjelaskan risiko pada bagian ekor distribusi, yaitu ketika kerugian yang terjadi melampaui batas yang telah ditetapkan. Sebagai ukuran risiko yang pertama kali diperkenalkan oleh Morgan et al. (1997), VaR memberikan perkiraan mengenai batas kerugian maksimum yang diperkirakan tidak akan terlampaui dalam suatu periode tertentu dan pada tingkat kepercayaan tertentu. Meskipun demikian, VaR hanya menetapkan ambang kerugian tanpa memberikan gambaran mengenai seberapa besar kerugian yang mungkin terjadi apabila batas tersebut dilewati (Rockafellar et al., 2000). Kekurangan inilah yang mendorong penggunaan CVaR, karena ukuran ini mampu menggambarkan rata-rata kerugian yang terjadi pada kondisi ketika kerugian sudah melampaui nilai VaR. Rockafellar et al. (2000) mendefinisikan kerugian portofolio sebagai fungsi $f(\mathbf{x}, \mathbf{y})$, dimana $\mathbf{x}$ menyatakan keputusan portofolio dan $\mathbf{y}$ merupakan variabel acak yang merepresentasikan ketidakpastian pasar dengan densitas probabilitas $p(\mathbf{y})$. Probabilitas bahwa kerugian $f(\mathbf{x}, \mathbf{y})$ tidak melebihi suatu nilai ambang batas α dinyatakan oleh fungsi berikut.

$$\Psi(\mathbf{x}, \alpha) = \int_{f(\mathbf{x},\mathbf{y})\leq\alpha} p(\mathbf{y})d\mathbf{y}. \tag{2.34}$$

Fungsi $\Psi(\mathbf{x}, \alpha)$ pada Persamaan (2.34) merepresentasikan probabilitas kumulatif bahwa kerugian portofolio tidak akan melampaui ambang batas α. Dengan kata lain, $\Psi(\mathbf{x}, \alpha)$ adalah proporsi skenario ketidakpastian pasar dimana kerugian tetap berada di bawah atau sama dengan nilai α. Berdasarkan definisi tersebut, ambang kerugian terkecil sehingga probabilitas bahwa kerugian tidak melebihi ambang tersebut mencapai tingkat kepercayaan β disebut sebagai β-*Value-at-Risk* dan dinotasikan dengan $\alpha_\beta(\mathbf{x})$, yang dirumuskan sebagai berikut.

$$\alpha_\beta(\mathbf{x}) = \min\{\alpha \in \mathbb{R} : \Psi(\mathbf{x}, \alpha) \geq \beta\}. \tag{2.35}$$

Nilai ekspektasi kerugian ketika realisasinya melampaui batas β-*VaR* disebut sebagai β-*Conditional Value-at-Risk*. Besaran ini, yang dinotasikan sebagai $\phi_\beta(\mathbf{x})$, menggambarkan rata-rata kerugian pada bagian terburuk sebesar $(1 - \beta)$ dari seluruh kemungkinan yang dapat terjadi yang dirumuskan sebagai berikut.

$$\phi_\beta(\mathbf{x}) = (1 - \beta)^{-1} \int_{f(\mathbf{x},\mathbf{y})\geq\alpha_\beta(\mathbf{x})} f(\mathbf{x}, \mathbf{y})p(\mathbf{y})d\mathbf{y}. \tag{2.36}$$

Secara matematis, nilai CVaR (ϕ_β) selalu lebih besar atau sama dengan VaR (α_β) karena CVaR didefinisikan sebagai ekspektasi kerugian yang melampaui ambang batas VaR. Karakteristik ini menjadikan CVaR lebih unggul dalam menangkap besaran risiko ekor (*tail risk*) yang tidak terukur oleh VaR. Keunggulan utama CVaR terletak pada sifat konveksitasnya, yang memungkinkan minimisasi risiko dapat dilakukan secara efisien melalui *linear programming* dan menghasilkan solusi global yang optimal, berbeda dengan VaR yang memiliki keterbatasan dalam hal konveksitas.

Untuk menerapkan CVaR secara praktis, tantangan utama adalah bahwa nilai CVaR secara definisi bergantung pada VaR yang harus dihitung terlebih dahulu. Untuk mengatasi ketergantungan ini, Rockafellar et al. (2000) memperkenalkan *performance*

function $F_\beta(\mathbf{x}, \alpha)$ yang memungkinkan VaR dan CVaR dihitung secara bersamaan tanpa memerlukan asumsi distribusi tertentu. *Performance function* ini didefinisikan sebagai berikut.

$$F_\beta(\mathbf{x}, \alpha) = \alpha + (1-\beta)^{-1} \int_{\mathbf{y} \in \mathbb{R}^m} [f(\mathbf{x}, \mathbf{y}) - \alpha]^+ p(\mathbf{y})\, d\mathbf{y}, \tag{2.37}$$

dengan:

$$[f(\mathbf{x}, \mathbf{y}) - \alpha]^+ = \max(f(\mathbf{x}, \mathbf{y}) - \alpha, 0).$$

Pada Persamaan (2.37), suku $[f(\mathbf{x}, \mathbf{y}) - \alpha]^+$ merepresentasikan besaran kerugian yang melebihi nilai ambang batas α, yang dikenal sebagai *excess loss*. *Performance function* F_β membentuk ukuran risiko melalui penjumlahan antara nilai ambang batas α dan nilai harapan dari kerugian yang melampaui batas tersebut, yang dinormalisasi dengan faktor $(1-\beta)^{-1}$ (Rockafellar et al., 2000).

Menurut Teorema 1 dalam Rockafellar et al. (2000), fungsi $F_\beta(\mathbf{x}, \alpha)$ bersifat konveks dan terdiferensiasi secara kontinu terhadap α. Teorema tersebut menunjukkan bahwa nilai β-CVaR dapat diperoleh dengan meminimalkan F_β terhadap α sebagai berikut.

$$\phi_\beta(\mathbf{x}) = \min_{\alpha \in \mathbb{R}} F_\beta(\mathbf{x}, \alpha). \tag{2.38}$$

Dalam Persamaan (2.38), himpunan nilai α yang menghasilkan minimum tersebut dinyatakan sebagai Persamaan berikut.

$$A_\beta(\mathbf{x}) = \operatorname*{argmin}_{\alpha \in \mathbb{R}} F_\beta(\mathbf{x}, \alpha). \tag{2.39}$$

Dimana $A_\beta(\mathbf{x})$ merupakan interval tertutup dan terbatas yang tidak kosong (mungkin hanya terdiri dari satu titik). Adapun nilai β-VaR dari kerugian tersebut diberikan sebagai berikut.

$$\alpha_\beta(\mathbf{x}) = \text{titik ujung kiri dari } A_\beta(\mathbf{x}). \tag{2.40}$$

Dengan demikian, proses penentuan VaR dan CVaR dapat dilakukan secara bersamaan. Teorema 2 pada Rockafellar et al. (2000) menegaskan bahwa meminimalkan β-CVaR terhadap keputusan portofolio $\mathbf{x} \in X$ adalah setara dengan meminimalkan fungsi $F_\beta(\mathbf{x}, \alpha)$ secara simultan terhadap pasangan variabel $(\mathbf{x}, \alpha) \in X \times \mathbb{R}$. Ekuivalensi optimasi ini dirumuskan sebagai berikut.

$$\min_{\mathbf{x} \in X} \phi_\beta(\mathbf{x}) = \min_{(\mathbf{x}, \alpha) \in X \times \mathbb{R}} F_\beta(\mathbf{x}, \alpha). \tag{2.41}$$

Berdasarkan persamaan (2.41), pasangan $(\mathbf{x}^*, \alpha^*)$ mencapai nilai minimum pada ruas kanan jika dan hanya jika $\mathbf{x}^*$ meminimalkan β-CVaR dan α^* merupakan elemen dari $A_\beta(\mathbf{x}^*)$, yang berarti α^* merepresentasikan nilai β-VaR yang berkorespondensi. Teorema ini juga menjamin bahwa apabila fungsi kerugian $f(\mathbf{x}, \mathbf{y})$ bersifat konveks terhadap $\mathbf{x}$, maka fungsi $F_\beta(\mathbf{x}, \alpha)$ juga bersifat konveks terhadap $(\mathbf{x}, \alpha)$, sehingga memungkinkan penggunaan metode optimasi konveks untuk menemukan solusi optimal global tanpa perlu menghitung VaR secara terpisah terlebih dahulu.

Pada penerapannya di dunia nyata, distribusi $\mathbf{y}$ sering tidak diketahui secara eksplisit sehingga biasanya digantikan oleh q skenario sampel $\mathbf{y}_1, \ldots, \mathbf{y}_q$. Dengan cara ini, integral

pada *performance function* F_β dapat didekati menggunakan bentuk diskrit sebagai berikut.

$$\tilde{F}_\beta(\mathbf{x}, \alpha) = \alpha + \frac{1}{q(1-\beta)} \sum_{k=1}^{q} [f(\mathbf{x}, \mathbf{y}_k) - \alpha]^+. \tag{2.42}$$

Persamaan (2.42) menghasilkan fungsi yang tetap konveks. Untuk menyederhanakan perhitungan, Rockafellar memperkenalkan variabel bantu u_k yang menggantikan suku $[f(\mathbf{x}, \mathbf{y}_k) - \alpha]^+$ (Rockafellar & Uryasev, 2002). Dengan cara ini, permasalahan optimasi dapat diubah menjadi bentuk pemrograman linear seperti yang ditunjukkan pada Persamaan (2.43) berikut.

$$\begin{aligned} \min_{\mathbf{x},\alpha,u_k} \quad & \alpha + \frac{1}{q(1-\beta)} \sum_{k=1}^{q} u_k \\ \text{dengan kendala} \quad & u_k \geq f(\mathbf{x}, \mathbf{y}_k) - \alpha, \quad k = 1, \ldots, q, \\ & u_k \geq 0, \quad k = 1, \ldots, q. \end{aligned} \tag{2.43}$$

Model pada Persamaan (2.43) merupakan formulasi pemrograman linear yang dirancang untuk meminimalkan risiko CVaR melalui optimasi bersama terhadap tiga komponen utama, yaitu keputusan portofolio $\mathbf{x}$, ambang batas VaR α, dan variabel bantu kerugian u_k untuk setiap skenario. Fungsi objektif pada Persamaan (2.43) merepresentasikan aproksimasi diskrit dari *performance function* pada Persamaan (2.42), dimana α menangkap komponen ambang batas kerugian dan suku $\frac{1}{q(1-\beta)} \sum_{k=1}^{q} u_k$ mewakili rata-rata kerugian yang melampaui ambang pada bagian ekor distribusi. Kendala pada model Persamaan (2.43) merepresentasikan nilai $u_k = \max(f(\mathbf{x}, \mathbf{y}_k) - \alpha, 0)$. Sehingga hanya kerugian yang melampaui ambang batas α yang dievaluasi pada fungsi objektif, yang mengaproksimasi integral pada Persamaan (2.37).

2.14 *Quadratic Programming*

Quadratic Programming merupakan metode optimisasi yang digunakan untuk menyelesaikan masalah dengan fungsi tujuan berbentuk kuadratik dan kendala yang bersifat linier (Cornuéjols et al., 2018). Menurut Cornuéjols et al. (2018), bentuk umum dari masalah ini dapat dituliskan sebagai berikut.

$$\begin{aligned} \min_{\mathbf{x}} \quad & \frac{1}{2}\mathbf{x}^T\mathbf{Q}\mathbf{x} + \mathbf{c}^T\mathbf{x} \\ \text{dengan kendala} \quad & \mathbf{A}\mathbf{x} = \mathbf{b}, \\ & \mathbf{x} \geq 0. \end{aligned} \tag{2.44}$$

Agar fungsi objektif bersifat konveks, matriks $\mathbf{Q} \in \mathbb{R}^{n \times n}$ harus simetris dan memenuhi syarat sebagai matriks positif semidefinit. Jika syarat ini tidak terpenuhi, bentuk fungsi tujuan dapat menjadi tidak konveks sehingga solusi global menjadi lebih sulit untuk ditemukan (Cornuéjols et al., 2018). Kendala $\mathbf{A}\mathbf{x} = \mathbf{b}$ merepresentasikan sekumpulan batasan linier. Pertidaksamaan $\mathbf{x} \geq 0$ merupakan kendala non-negatif yang merepresentasikan larangan penjualan kosong (*short selling*), sehingga investor hanya diperbolehkan membeli aset. Sehingga bobot alokasi dana tidak boleh bernilai negatif.

BAB III
METODOLOGI

Bab ini menjelaskan tahapan pelaksanaan Tugas Akhir secara runtut dan sistematis, mulai dari pengumpulan data, peramalan, optimasi, hingga penyusunan laporan.

3.1 Sumber Data

Penelitian ini menggunakan data sekunder berupa deret waktu harian pada periode 03 Juli 2017 hingga 24 November 2025. Data yang digunakan mencakup tingkat suku bunga utang untuk mata uang USD (jangka waktu 5, 10, 30 tahun), EUR (jangka waktu 7, 10 tahun), dan JPY (jangka waktu 5, 10 tahun), serta nilai tukar USD terhadap EUR dan USD terhadap JPY. Data diperoleh dari pengelola utang negara Republik Indonesia.

3.2 Variabel Penelitian

Variabel pada penelitian ini terdiri atas biaya utang (C) sebagai variabel dependen, serta tingkat suku bunga (IR) dan nilai tukar (FX) sebagai variabel independen. Rincian variabel disajikan pada Tabel Tabel 3.1. Untuk keperluan peramalan, data bulanan dibagi menjadi dua bagian, yaitu 80% sebagai data *training* dan 20% sebagai data *testing*.

Tabel 3.1 Variabel Penelitian

Variabel	**Keterangan**
C_1	Biaya utang untuk mata uang USD dengan jangka waktu pelunasan 5 tahun
C_2	Biaya utang untuk mata uang USD dengan jangka waktu pelunasan 10 tahun
C_3	Biaya utang untuk mata uang USD dengan jangka waktu pelunasan 30 tahun
C_4	Biaya utang untuk mata uang EUR dengan jangka waktu pelunasan 7 tahun
C_5	Biaya utang untuk mata uang EUR dengan jangka waktu pelunasan 10 tahun
C_6	Biaya utang untuk mata uang JPY dengan jangka waktu pelunasan 5 tahun
C_7	Biaya utang untuk mata uang JPY dengan jangka waktu pelunasan 10 tahun
IR_1	Suku bunga utang untuk mata uang USD dengan jangka waktu pelunasan 5 tahun
IR_2	Suku bunga utang untuk mata uang USD dengan jangka waktu pelunasan 10 tahun
IR_3	Suku bunga utang untuk mata uang USD dengan jangka waktu pelunasan 30 tahun
IR_4	Suku bunga utang untuk mata uang EUR dengan jangka waktu pelunasan 7 tahun
	Berlanjut ke halaman berikutnya ...

Variabel	Keterangan
IR_5	Suku bunga utang untuk mata uang EUR dengan jangka waktu pelunasan 10 tahun
IR_6	Suku bunga utang untuk mata uang JPY dengan jangka waktu pelunasan 5 tahun
IR_7	Suku bunga utang untuk mata uang JPY dengan jangka waktu pelunasan 10 tahun
FX_1	Nilai tukar mata uang USD terhadap EUR
FX_2	Nilai tukar mata uang USD terhadap JPY

Berdasarkan variabel pada Tabel Tabel 3.1, biaya utang (C) ditentukan oleh tingkat suku bunga (IR) dan nilai tukar (FX). Dalam pelunasan utang valas, pemerintah Indonesia melakukan pembayaran menggunakan cadangan Dolar Amerika Serikat (USD). Oleh karena itu, biaya utang untuk instrumen berdenominasi USD ($i = 1, 2, 3$) hanya dipengaruhi oleh perubahan suku bunga (IR) dan tidak dipengaruhi oleh risiko nilai tukar. Sebaliknya, biaya utang untuk instrumen berdenominasi EUR dan JPY dipengaruhi oleh tingkat suku bunga mata uang terkait serta pergerakan nilai tukarnya (FX) terhadap USD.

3.3 Tahapan Penelitian

Tahapan penelitian disusun mengikuti alur pada diagram alir penelitian agar proses pengerjaan terarah dan konsisten dari awal sampai akhir.

3.3.1 Studi Literatur

Tahap awal dilakukan melalui studi literatur untuk membangun landasan teori dan memahami penelitian terdahulu. Literatur yang digunakan meliputi buku teks, artikel, dan laporan penelitian lainnya yang membahas optimasi portofolio, model MVO, ukuran risiko CVaR, serta metode peramalan deret waktu ARIMA(p, d, q)-GARCH(P, Q).

3.3.2 Pembentukan Model Biaya Utang

Dalam penelitian ini, konsep *return* pada teori portofolio investasi didefinisikan menjadi biaya utang. Pembentukan model biaya utang bertujuan untuk mengukur total beban yang harus ditanggung pemerintah dari setiap instrumen utang. Biaya utang ($C_{i,t}$) dimodelkan sebagai fungsi dari tingkat suku bunga ($IR_{i,t}$) dan perubahan nilai tukar (FX_t).

3.3.3 Preprocessing Data

Data harian terlebih dahulu diperiksa kelengkapannya untuk setiap bulannya dari periode 03 Juli 2017 hingga 24 November 2025. Setelah itu, data diubah menjadi data bulanan dengan menghitung nilai rata-rata setiap bulannya.

3.3.4 Pembentukan Model ARIMA-GARCH

Pembentukan model ARIMA(p, d, q)-GARCH(P, Q) dilakukan untuk meramalkan nilai tukar dan suku bunga sebagai variabel yang memengaruhi biaya utang. Prosesnya mengikuti alur pada diagram, dimulai dari uji stasioneritas hingga pemilihan model terbaik berdasarkan nilai AIC.

1. Model ARIMA
   Tahap ARIMA diawali dengan uji stasioneritas varians dan mean pada data bulanan. Jika data belum stasioner terhadap varians, maka ditransformasi menggunakan transformasi *Box-Cox* hingga data menjadi stasioner terhadap varians. Jika data belum stasioner terhadap mean, maka data dilakukan proses *differencing* hingga data

menjadi stasioner.Setelah data stasioner terhadap varians maupun mean, langkah selanjutnya adalah melakukan analisis pola ACF dan PACF untuk menentukan calon model ARIMA(p, d, q). Calon model kemudian diestimasi menggunakan metode MLE dan diuji signifikansi parameternya. Selanjutnya dilakukan uji diagnostik residual untuk memastikan residual berdistribusi normal dan bersifat *white noise*. Jika uji diagnostik tidak terpenuhi, maka proses identifikasi dan estimasi diulang hingga diperoleh model ARIMA(p, d, q) yang sesuai. Setelah diperoleh model ARIMA(p, d, q) yang sesuai, adalah menguji heteroskedastisitas untuk mengetahui apakah varians dari residual bersifat konstan atau mengalami perubahan seiring waktu. Jika varians bersifat konstan, maka tidak terdapat efek ARCH, sehingga varians dari residual tidak perlu dimodelkan dengan GARCH. Sebaliknya, jika varians mengalami perubahan seiring waktu, maka terdapat efek ARCH, sehingga varians dari residual perlu dimodelkan menggunakan GARCH.

2. Model GARCH
   Setelah model ARIMA terbentuk dan varians dari residualnya mengalami perubahan seiring waktu, maka varians dari residual tersebut akan dimodelkan menggunakan Persamaan (2.23). Tahap ini dimulai dari identifikasi model GARCH(P, Q) untuk mendapatkan calon model dengan cara melakukan analisis pola ACF dan PACF residual kuadratnya. Setelah diperoleh calon model GARCH(P, Q), selanjutnya dilakukan estimasi parameter model gabungan ARIMA(p, d, q)-GARCH(P, Q) menggunakan metode MLE dan uji signifikansinya. Terakhir, dilakukan uji diagnostik pada residual terstandarisasi $(\tilde{\varepsilon}_t)$ untuk memastikan model layak digunakan, yang meliputi uji normalitas residual terstandarisasi, uji *white noise* pada residual terstandarisasi, uji *white noise* pada residual terstandarisasi kuadrat, serta uji *ARCH–LM* untuk mendeteksi adanya efek *ARCH* tersisa. Jika model tidak lolos uji diagnostik tersebut, maka proses identifikasi dan estimasi diulang hingga diperoleh model ARIMA(p, d, q)-GARCH(P, Q) yang sesuai.

3. Pemilihan Model Terbaik
   Pemilihan model terbaik dilakukan dengan membandingkan nilai *Akaike Information Criterion* (AIC) dari seluruh kandidat model yang telah lolos uji diagnostik. Model dengan nilai AIC terkecil dan seluruh parameternya signifikan secara statistik dipilih sebagai model terbaik.

4. Evaluasi Akurasi Peramalan
   Akurasi model peramalan dievaluasi menggunakan data *testing* dengan menghitung nilai *Root Mean Square Error* (RMSE).

5. Hasil Peramalan
   Model terbaik yang terpilih digunakan untuk memproyeksikan nilai tukar dan suku bunga pada periode mendatang. Penetapan jangka waktu peramalan didasarkan pada evaluasi nilai RMSE yang dihasilkan untuk memastikan tingkat akurasi proyeksi tetap berada dalam batas yang dapat diterima.

3.3.5 Input Optimasi

Input optimasi disusun dalam dua skenario agar dapat dibandingkan dampak penggunaan hasil peramalan terhadap komposisi portofolio.

1. Data historis
   Pada skenario ini, optimasi dilakukan menggunakan data historis bulanan.

2. Data Historis dan Data Hasil Peramalan
   Pada skenario ini, optimasi dilakukan dengan menggabungkan data historis bulanan dan data hasil peramalan dari model ARIMA(p, d, q)-GARCH(P, Q)

3.3.6 Proses Optimasi

Optimasi dilakukan untuk memperoleh bobot portofolio utang valas yang optimal. Prosesnya terdiri atas langkah-langkah berikut.

1. Perhitungan Parameter Optimasi
   Perhitungan parameter dilakukan dengan menggunakan data biaya utang yang telah dimodelkan pada Subbagian 3.3.2. Parameter yang dihitung meliputi vektor ekspektasi biaya utang dan matriks varians–kovarians, baik untuk skenario data historis maupun gabungan data historis dan hasil peramalan.

2. Pembentukan model optimasi MVO
   Model MVO dibentuk sesuai Persamaan (2.28) untuk meminimalkan risiko portofolio berbasis varians dengan kendala yang digunakan pada penelitian ini.

3. *Quadratic programming*
   Model optimasi MVO yang telah dibentuk selanjutnya diselesaikan menggunakan *quadratic programming* dengan bantuan fungsi *quadprog* pada perangkat lunak MATLAB.

4. Pembentukan model optimasi CVaR
   Model CVaR dibentuk sesuai Persamaan (2.43) untuk meminimalkan risiko CVaR dengan formulasi linear dan kendala yang digunakan pada penelitian ini.

5. *Linear programming*
   Model optimasi CVaR yang telah dibentuk selanjutnya diselesaikan menggunakan *linear programming* dengan bantuan fungsi *linprog* pada perangkat lunak MATLAB.

3.3.7 Portofolio Optimal

Output dari proses optimasi adalah empat portofolio utang valas optimal. Portofolio pertama diperoleh dari model MVO berbasis data historis, sedangkan portofolio kedua diperoleh dari model MVO berbasis gabungan data historis dan data hasil peramalan. Portofolio ketiga diperoleh dari model CVaR berbasis data historis, sedangkan portofolio keempat diperoleh dari model CVaR berbasis gabungan data historis dan data hasil peramalan. Keempat portofolio tersebut digunakan sebagai bahan perbandingan untuk melihat perbedaan komposisi bobot, biaya, dan risiko pada masing-masing hasil.

3.3.8 Analisis Hasil dan Pembahasan

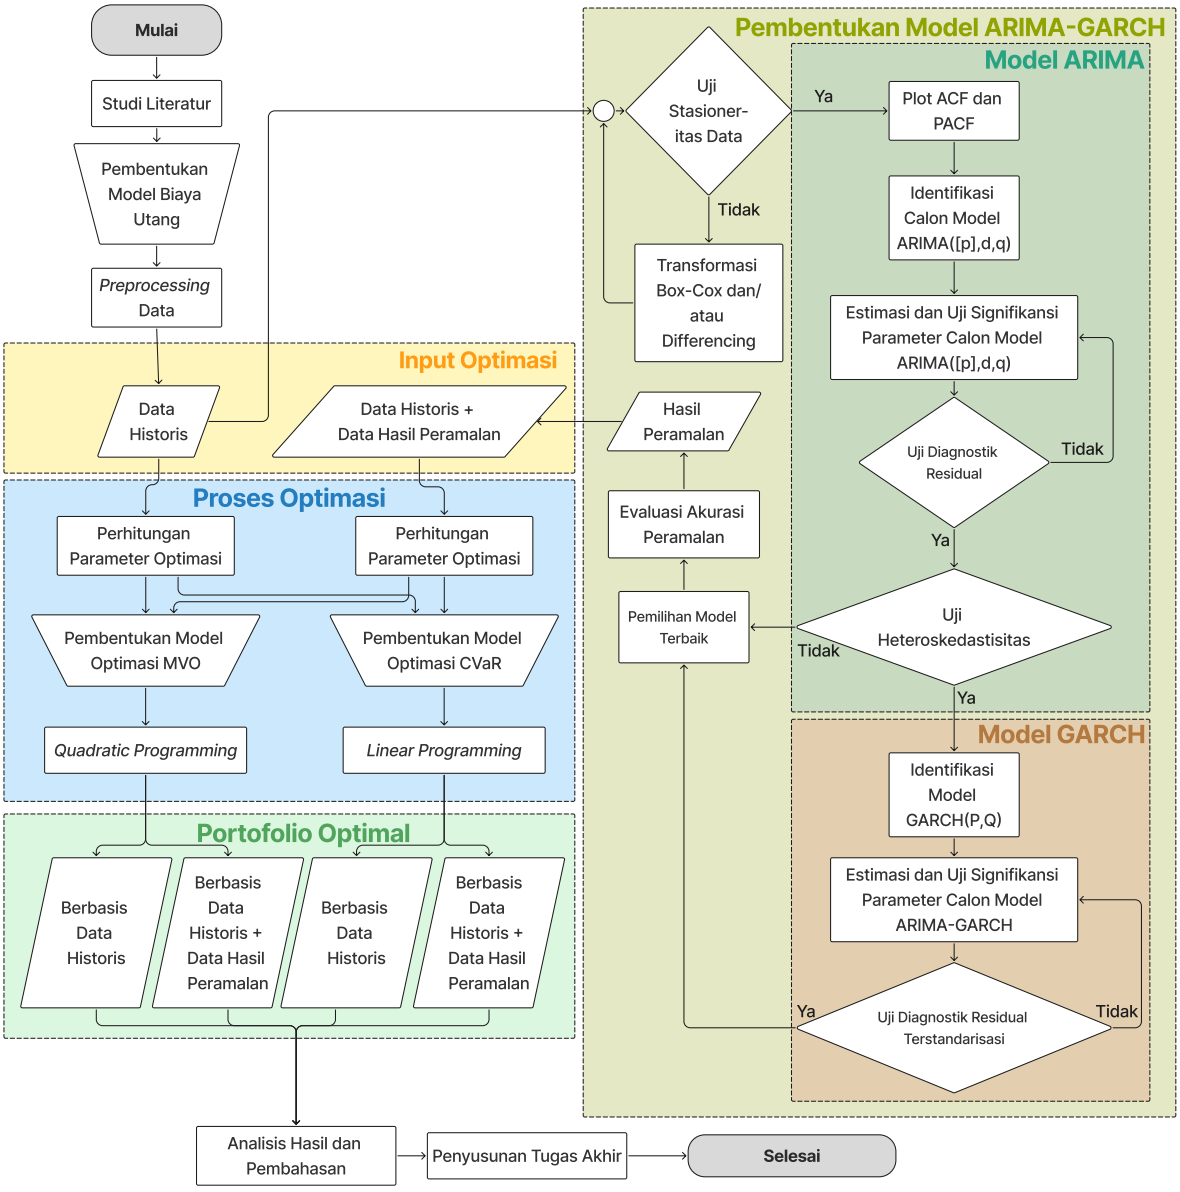
Tahapan selanjutnya setelah diperoleh empat portofolio utang valas optimal adalah melakukan analisis hasil untuk mengevaluasi kinerja dan perubahan komposisi portofolio. Analisis dilakukan dengan membandingkan kinerja portofolio yang dihasilkan oleh model MVO dan CVaR berdasarkan data historis serta data historis yang dikombinasikan dengan hasil peramalan. Selain itu, dibahas perubahan komposisi portofolio pada masing-masing model akibat penambahan data hasil peramalan. Hasil analisis ini memberikan dasar untuk menilai perbedaan karakteristik risiko dan stabilitas alokasi utang antar model.

3.3.9 Penyusunan Tugas Akhir

Seluruh tahapan penelitian didokumentasikan dalam bentuk laporan Tugas Akhir yang disusun secara sistematis sesuai pedoman penulisan Tugas Akhir di Departemen Matematika ITS.

3.4 Diagram Alir Penelitian

Berikut adalah diagram alir dari pengerjaan Tugas Akhir yang ditunjukkan pada Gambar 3.1.



Gambar 3.1 Diagram alir penelitian

3.5 Jadwal Kegiatan

Penelitian direncanakan berlangsung selama tiga bulan. Rincian jadwal kegiatan disajikan pada Tabel 3.2.

Tabel 3.2 Jadwal kegiatan Tugas Akhir

No	Nama Kegiatan	Bulan											
		1				2				3			
		1	2	3	4	1	2	3	4	1	2	3	4
1	Studi literatur												
2	Pengumpulan dan pengolahan data												
3	Peramalan nilai tukar dan suku bunga												
4	Pemodelan optimasi dan simulasi												
5	Analisis hasil dan pembahasan												
6	Penulisan laporan Tugas Akhir												

DAFTAR PUSTAKA

Alexander, G. J., & Baptista, A. M. (2004). A comparison of var and cvar constraints on portfolio selection with the mean-variance model. *Management Science*, *50*(9), 1261–1273.

Artzner, P., Delbaen, F., Eber, J.-M., & Heath, D. (1999). Coherent measures of risk. *Mathematical finance*, *9*(3), 203–228.

Avdjiev, S., Binder, S., & Sousa, R. (2021). External debt composition and domestic credit cycles. *Journal of International Money and Finance*, *115*, 102377.

Badan Pusat Statistik. (2025). *Indonesia's economic growth in q3-2025 was 5.04 percent (year-on-year)* (Press Release No. 2478). Badan Pusat Statistik. Retrieved 2025-11-30, from `https://www.bps.go.id/en/pressrelease/2025/11/05/2478/indonesia-s-economic-growth-in-q3-2025-was-5-04-percent--y-on-y-.html`

Bank Indonesia. (2025). *Maintaining stability, strengthening economic growth: Bank indonesia policy measures.* Retrieved 2025-11-30, from `https://www.bi.go.id/en/publikasi/ruang-media/news-release/Pages/sp_2727425.aspx` (Monetary Policy Decision and Economic Statement)

Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of econometrics*, *31*(3), 307–327.

Box, G. E., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: forecasting and control*. John Wiley & Sons.

Burnham, K. P., & Anderson, D. R. (2004). Multimodel inference: understanding aic and bic in model selection. *Sociological methods & research*, *33*(2), 261–304.

CNBC Indonesia. (2025). *Utang RI tembus Rp9.138 T, Masih Aman?* Retrieved 2025-11-16, from `https://www.cnbcindonesia.com/news/20251020073417-4-677312/utang-ri-tembus-rp9138-t-masih-aman`

Cornuéjols, G., Peña, J., & Tütüncü, R. (2018). *Optimization methods in finance* (2nd ed.). Cambridge University Press. (Comprehensive treatment of Markowitz portfolio optimization and quadratic programming)

Cryer, J. D., & Chan, K.-S. (2008). *Time series analysis: with applications in r*. Springer.

Dani, A. T. R., et al. (2025). Navigating samarinda's climate: A comparative analysis of rainfall forecasting models. *MethodsX*, *14*, 103080.

Direktorat Jenderal Pengelolaan Pembiayaan dan Risiko. (2025a). *Mitigasi risiko pembiayaan pemerintah: Upaya mencapai kesinambungan fiskal* (Tech. Rep.). Kementerian Keuangan Republik Indonesia. Retrieved 2025-11-16, from `https://djpb.kemenkeu.go.id`

Direktorat Jenderal Pengelolaan Pembiayaan dan Risiko. (2025b). *Optimalisasi komposisi utang valuta asing dengan model marginal conditional cost at risk (mccar)* (Kajian). Jakarta: Kementerian Keuangan Republik Indonesia. (Kajian Strategis Pengelolaan Utang)

Direktorat Jenderal Pengelolaan Utang. (2019). *Dinamika utang pemerintah indonesia* (Tech. Rep.). Kementerian Keuangan Republik Indonesia. Retrieved 2025-11-18, from `https://fiskal.kemenkeu.go.id/` (Official explanation of foreign currency debt composition and risk)

Engle, R. (2001). Garch 101: The use of arch/garch models in applied econometrics. *Journal of economic perspectives*, *15*(4), 157–168.

Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of united kingdom inflation. *Econometrica: Journal of the econometric society*, 987–1007.

Fadillah, F., Syahkilah, A., Rosyada, A. A., Hasmidyani, D., & Budiman, M. A. (2025). Valuta asing: Peran dan fungsinya dalam sistem pembayaran internasional. *Jurnal Penelitian Ekonomi Manajemen dan Bisnis*, *4*(2), 136–142.

Gujarati, D. N., & Porter, D. C. (2009). *Basic econometrics*. McGraw-hill.

Hassani, H., Yeganegi, M. R., Cuñado, J., & Gupta, R. (2020). Forecasting interest rate volatility of the united kingdom: Evidence from over 150 years of data. *Journal of Applied Statistics*, *47*(6), 1128–1143.

International Monetary Fund. (2025). *Imf staff completes 2025 article iv mission to indonesia* (Article IV Consultation No. PR/25/375). International Monetary Fund. Retrieved 2025-11-30, from `https://www.imf.org/en/news/articles/2025/11/14/pr-25375-indonesia-imf-staff-completes-2025-article-iv-mission`

Kim, J.-M., Kim, D. H., & Jung, H. (2021). Estimating yield spreads volatility using garch-type models. *The North American Journal of Economics and Finance*, *57*, 101396.

MacKinnon, J. G. (2010). *Critical values for cointegration tests* (Tech. Rep.). Queen's Economics Department Working Paper.

Markowitz, H. M. (2008). *Portfolio selection: efficient diversification of investments*. Yale university press.

Massey Jr, F. J. (1951). The kolmogorov-smirnov test for goodness of fit. *Journal of the American statistical Association*, *46*(253), 68–78.

Morgan, J., et al. (1997). Creditmetrics-technical document. *JP Morgan, New York*, *1*, 102–127.

Nasir, M. (2013). *Utang pemerintah: Peran dan ancamannya terhadap APBN* (Tech. Rep.). Pusat Pengelolaan Risiko Fiskal, Badan Kebijakan Fiskal, Kementerian Keuangan Republik Indonesia. Retrieved 2025-11-16, from `https://fiskal.kemenkeu.go.id/files/berita-kajian/file/Utang_Pemerintah_Peran_dan%20Ancamannya_TerhadapAPBN.pdf`

Quaranta, A. G., & Zaffaroni, A. (2008). Robust optimization of conditional value at risk and portfolio selection. *Journal of Banking & Finance*, *32*(10), 2046–2056.

Rockafellar, R. T., & Uryasev, S. (2002). Conditional value-at-risk for general loss distributions. *Journal of banking & finance*, *26*(7), 1443–1471.

Rockafellar, R. T., Uryasev, S., et al. (2000). Optimization of conditional value-at-risk. *Journal of risk*, *2*, 21–42.

Ruppert, D., & Matteson, D. S. (2011). *Statistics and data analysis for financial engineering* (Vol. 13). Springer.

Sk, B. R. (2015). Exchange rate forecasting using arima, neural network and fuzzy neuron. *Journal of Stock & Forex Trading*, *4*(03).

Sober, E. (1981). The principle of parsimony. *The British Journal for the Philosophy of Science*, *32*(2), 145–156.

Thakkar, A., & Chaudhari, K. (2021). Fusion in stock market prediction: A decade survey on the necessity, recent developments, and potential future directions. *Information Fusion*, *65*, 95–107.

Wei, W. W. S. (2006). *Time series analysis: Univariate and multivariate methods* (2nd ed.). New York: Pearson Addison Wesley.

Woodward, W. A., Gray, H. L., & Elliott, A. C. (2017). *Applied time series analysis with r*. CRC press.

World Bank. (2025). *Indonesia economic prospects, december 2025: Digital foundations for growth*. Jakarta: The World Bank. Retrieved from `https://openknowledge.worldbank.org/en/publication`

Yang, R., Li, L., Jiang, Q., & Qi, J. (2022). Optimal bond issuance with cost and liquidity constraints for chinese local governments: a multi-period stochastic programming approach. *Empirical Economics*, *63*(5), 2605–2632.

Yavuz, H. H., & Gölbaşı, U. (2019). Optimal composition of sovereign debt: An adaptation from modern portfolio theory. *Debt Management in Uncertain Times*, 107.

Zenios, S. A., Consiglio, A., Athanasopoulou, M., Moshammer, E., Gavilan, A., & Erce, A. (2019). Risk management for sovereign debt financing with sustainability conditions. *Globalization Institute Working Paper*(367).

Zhu, E. (2025). Implementation of the arima-garch model on usd/jpy exchange rate forecasting. In *2025 international conference on financial risk and investment management (icfrim 2025)* (pp. 829–839).